

Analiza in prognoza vremena - Predavanja

Filip Lovšin

1. september 2026

Uvod

Zapiske sem natipkal in uredil ob predavanjih dr. Žige Zaplotnika v študijskem letu 2024/25. Nekaj zapiskov sem tudi vključil ob pogovorih s sodelavci na ARSO, ker smo včasih imeli zanimive debate.

Ker so bila predavanja v angleščini se lahko tu in tam najde kakšen čuden prevod, zato sem ponekod še pustil izraz v angleščini ker nisem našel ustreznega prevoda.

Skice so (žal) vse večinoma moje in se vsem bralcem oproščam za moje umetniške sposobnosti.

Kazalo

1	Asimilacija in informacije	9
1.1	Informacije	9
1.2	Opazovanja	9
1.3	Model	9
1.4	Lastnosti informacij	10
1.5	Načini “krpanja” (filling in)	10
1.6	Primer: Kalmanov filter (enodimenzionalni primer)	11
1.7	Potek asimilacije podatkov	14
1.8	Pristopi k napovednim modelom	15
1.8.1	1. Persistenca	15
1.8.2	2. Na osnovi advekcije (prvi člen Taylorjeve ekspanzije)	15
1.8.3	3. Klimatološka napoved	15
1.8.4	4. Numerični napovedni model	15
1.9	Kaj sestavlja atmosferski model	15
1.9.1	Zakon ohranitve gibalne količine	16
1.9.2	Kontinuitetna enačba	16
1.9.3	Zakon ohranitve energije (prvi zakon termodinamike)	16
1.9.4	Enačba ohranitve vlage	17
1.10	Barotropna enačba vrtnčnosti za NWP (Numerical Weather Prediction)	18
1.10.1	Osnovne predpostavke barotropnega modela	18
1.10.2	Definicija vrtnčnosti	19
1.10.3	Helmholtzev izrek in nerazpršeni tok	20
1.11	Geostrofski veter	20
1.12	Tokovna funkcija in nedivergentni tok	21
1.13	Vrtnčnost in barotropna aproksimacija	22
1.14	Advekcija v Jakobijevi obliki in barotropna vrtnčna enačba	22
2	Primeri numeričnih rešitev barotropne vrtnčne enačbe	25
2.1	Motivacija in vrtnčna enačba	25
2.2	Vizualizacija numerične mreže	25
2.3	Diskretizacija hitrosti in vrtnčnosti	27
2.4	Diskretna oblika funkcionala F	28
2.5	Robni pogoji in Poissonova enačba	28
2.6	Popolna diskretizacija in časovni koraki	28
2.7	Spektralna metoda	30
2.7.1	Barotropna vrtnčna enačba v sferičnih koordinatah	30
2.7.2	Spektralna transformacijska metoda	32
2.7.3	Zaključek postopka	34
2.8	Metoda zaporednega popravljanja (Successive Correction Method)	36
2.9	Nudging na primeru modela plitke vode	39

3	Optimalno interpoliranje in opazovalni operatorji	43
3.1	Optimalno interpoliranje	43
3.1.1	Enodimenzionalna analiza	43
3.2	Večdimenzionalni problem	43
3.2.1	Primeri opazovalnih operatorjev	44
3.2.2	Opazovalni operator za Aeolusove vetrne meritve v vodoravni smeri (HLOS)	45
3.2.3	Še nekaj primerov opazovalnega operatorja	46
3.3	Optimalna analiza	46
3.3.1	Predpostavke o popolnih vseh	46
3.3.2	Povezava z enodimenzionalno formulo	47
3.3.3	Definicije napak in Taylorjeva razširitev opazovalnega operatorja	47
3.3.4	Kovariančne matrike in minimizacija napake analize	48
3.3.5	Alternativna oblika Kalmanove uteži in kovariančna matrika napak analize	49
3.3.6	Interpretacija in praktične omejitve	49
4	Struktura kovariančnih matrik v asimilaciji podatkov	51
4.1	Kovariančna matrika napak opazovanj R	51
4.2	Kovariančna matrika napak ozadja B	52
4.3	Korelacije napak v B	53
4.3.1	Avtokorelacijske funkcije	53
4.3.2	Razcep na variance in korelacije	54
4.3.3	Medspremenljivkine kovariance	54
4.4	Pogled naprej	55
4.4.1	Medspremenljivkine kovariance in uteženi popravki	55
4.4.2	Zakaj je optimalno interpoliranje boljše od metode zaporednega popravka?	59
4.5	Zgodovinska uporaba optimalnega interpoliranja	61
5	3D VAR Algoritem	63
5.1	Ideja algoritma 3D VAR	64
5.2	Zgodovinski razvoj 3D VAR in Bayesov izrek	65
5.2.1	Maximum Likelihood Approach	65
5.2.2	Ekvivalentnost rešitev 3D-Var in optimalne interpolacijske analize	67
5.3	Primer delujočega algoritma	69
5.3.1	Algoritem najbolj strmega spuščanja	70
5.4	Kako pospešiti konvergenco pri minimizaciji	73
6	4D VAR Asimilacija Podatkov	75
6.1	Od 3D VAR do 4D VAR	75
6.2	Cenilka v 4D VAR	76
6.3	Perspektiva omejene minimizacije	77
6.4	Strong vs. Weak Constraint 4D VAR	78
6.5	4D VAR ALGORITEM	78
6.6	4D VAR Učinkovitost	80
6.6.1	Praktičen oris algoritma.	81
6.7	Inkrementalni 4D VAR algoritem	82
6.8	Razlika med 3D-Var in 4D-Var	84
7	Dinamično in fizikalno ravnovesje v začetnih pogojih	87
7.1	Hitri in počasni načini v razvoju modela	87
7.2	Dinamično in fizično ravnotežje v začetnih pogojih	88
7.3	Model plitve vode	88
7.3.1	Glavne enačbe	88

7.3.2	Enačba barotropne vrtinčnosti in potencialna ohranitev vrtinčnosti	89
7.3.3	Hitri in počasni načini v plitvi vodi	90
7.3.4	Rešitve modela plitve vode	90
7.3.5	Geostrofična prilagoditev in relativni pomen različnih meritev	92
7.3.6	Linearizirano potencialno ohranjanje vrtinčenja	94
7.3.7	Hipotetični primer: Učinek mase v primerjavi z motnjami vetra na uravnotežen pretok	95
8	Predvidljivost ozračja	101
8.1	Osnovni teorem o predvidljivosti	102
8.2	Deterministični neperiodični tok	102
8.2.1	Lorenzov sistem	102
8.2.2	Iskanje fiksnih točk Lorenzovega sistema	103
8.2.3	Stabilnost fiksnih točk	104
8.2.4	Lastne vrednosti Jacobija	105
8.2.5	Lastnosti Lorenzovega sistema	108
8.3	Časovna lestvica predvidljivosti	112
8.4	Rast napak v numerični napovedi vremena	112
8.5	Lastnosti atmosferske predvidljivosti	116
8.5.1	Predvidljivost ni konstantna v času	116
8.5.2	Predvidljivost je odvisna tudi od prostorskega merila.	117
8.5.3	Podnebne razlike vplivajo na predvidljivost	117
8.5.4	Rast napake glede na prostorsko skalo	117
8.5.5	Zbirke napovedi	118
8.5.6	Časovni spektri atmosferske spremenljivosti	119
8.5.7	Kakšne časovne lestvice napovedujemo?	120
8.5.8	Predvidljivost prve in druge vrste	120
8.5.9	Viri predvidljivosti	121
9	Napoved ansambla	123
9.1	Kako oceniti negotovost začetnih pogojev v numeričnih sistemih za napovedovanje vremena?	123
9.2	Ansambelsko napovedovanje (Ensemble forecasting)	125
9.2.1	Zakaj je ansambelsko napovedovanje boljše?	126
9.2.2	ECMWF — primer operativnega ansambla	127
9.3	Kakšna je kakovost perturbirane analize?	127
9.4	Povprečna kakovost perturbirane analize	129
9.5	Metode preverjanja (Verification metrics) pri ansambelskem napovedovanju	129
9.5.1	Razmerje med razpršenostjo in napovedno sposobnostjo (Spread-skill relationship)	131
9.5.2	Primeri verifikacijskih metrik	133
9.6	Vrednost ansambelske napovedi	136
9.6.1	Preprost primer stroškov in izgub	136
9.7	Ravnotežje zahtev in omejitev	137
9.8	Ponovni ogled modela metulja Lorenz-63	137
9.9	Kako ustvarimo ansambel	138
9.10	Verjetnostna napoved ekstremnih hitrosti vetra okoli tropskega ciklona	138
9.10.1	Veščina ansambelskih napovedi	139
9.11	Kako predstaviti začetno negotovost v ansambelskih vremenskih napovedih?	140
9.12	Singularni vektorji	140
9.12.1	Razčlenitev singularne vrednosti (SVD)	141
9.12.2	Geometrična interpretacija singularnih vektorjev	143

10 Modeli omejenega območja (LAM)	145
10.1 Tipična shema LAM	146
10.2 Stranski robni pogoji	146
10.2.1 Lastnosti	146
10.3 Dobro postavljeni robni pogoji	147
10.3.1 Eliptičen problem	147
10.3.2 Paraboličen problem	147
10.3.3 Hiperbolični problem	148
10.3.4 Pogostost osveževanja LBC	149
10.3.5 Hiter prenos napak z roba	150
10.3.6 Zakaj vseeno poganjati 72-urno LAM-napoved?	150
10.3.7 Primer 1D SWM	150
10.4 Sheme robnih pogojev	151
10.4.1 Psevdo-radiacijski robni pogoji	151
10.4.2 Robna cona (boundary-zone) in difuzijsko blaženje	152

Poglavje 1

Asimilacija in informacije

1.1 Informacije

Glavni cilji zbiranja informacij so:

- izdelava napovedi,
- preverjanje hipotez,
- razumevanje vzroka in posledic (na primer, v kolikšni meri je segreto morje prispevalo k lanskim poplavam).

Zaporedje obdelave informacij:

1. Zbiranje informacij $\rightarrow$ meritve / opazovanja,
2. Postavljanje hipotez in njihovo preverjanje,
3. Določanje vzroka in posledice na podlagi prejšnjega koraka $\rightarrow$ na tej osnovi oblikujemo **model**,
4. Iz tega modela nato oblikujemo napovedi za prihodnost.

1.2 Opazovanja

Opazovanja so:

- vzorčenje sistema, ki nas zanima,
- diskretno vzorčenje v času ali prostoru,
- enosmerna, diskretna povezava s sistemom, ki ga preučujemo (torej merimo, ne da bi ga nujno spreminjali).

1.3 Model

Model nam poda informacijo o časovnem in prostorskem razvoju sistema, ki nas zanima. Zgrajen je na osnovi:

- vsega našega znanja o tem sistemu,
- preverjenih hipotez, teorij in izkušenj,
- opazovanj in meritev iz resničnega okolja.


1.4 Lastnosti informacij

Napake v meritvah in modelih


Meritve in modeli imajo *napake*, ki so pogosto naključne. Eden od načinov za zmanjšanje naključne napake je povprečenje (v skladu z zakonom velikih števil). Poznamo več vrst napak:

- **Sistemska napaka** (npr. pozabimo zasenčiti tipalo, kar povzroči konstanten pristranek),
- **Napaka reprezentativnosti** (npr. model s slabo prostorsko ločljivostjo zgladi lokalne topografske značilnosti, zaradi česar ne vidi dejanskega reliefa na pravi višini).


Na primer, model morda ne upošteva prave višine Triglava, zato je modelirana temperatura na Triglavu drugačna od dejanske.




(a) Napako lahko daš stran s tem, ko povprečiš.



(b) Sistematska napaka.



(c) Sistematska napaka, če bi recimo pozabili osenčiti senzor.



(d) Napaka reprezentativnosti, model ima slabo ločljivost.

Vrzel pri opazovanjih

Opazovanja niso zvezna v času in prostoru (imamo *vrzeli v opazovanjih*). Te vrzeli želimo zapolniti. Ena od metod je *linearna interpolacija*, kjer izračunamo gradient med znanimi točkami. Lahko pa uporabimo modele za zapolnitev vrzeli. Algoritmi, ki vključujejo podatke opazovanj in modela za zapolnitev vrzeli, se imenujejo *asimilacijski algoritmi*.

1.5 Načini “krpanja” (filling in)

Vsak algoritem, ki združuje ali “krpa” podatke, mora biti:

- **Izvedljiv**: npr. linearna interpolacija ali “nudging”,
- **Objektiven**: opira se na matematična načela, ne na samovoljno prilagajanje.

Primer nudginga

Oglejmo si adveksijsko enačbo:

$$\frac{\partial C}{\partial t} + \vec{v} \cdot \nabla C = 0. \quad (1.1)$$

Dodamo člen, ki predstavlja podatke iz opazovanj:

$$\frac{\partial C}{\partial t} = -\vec{v} \cdot \nabla C + \frac{C_0 - C}{\tau}, \quad (1.2)$$

kjer:

- C_0 je izmerjena (opazovana) vrednost,
- τ je relaksacijski koeficient. Če je τ velik, ima izmerjena količina majhen vpliv; če je τ majhen, izmerjena količina močno prevlada. (Izbira τ je subjektivna.)

Dodani člen lahko interpretiramo kot:

$$\frac{C_0 - C}{\tau} = \begin{cases} 0, & \text{če } C = C_0, \\ \frac{\partial C}{\partial t} < 0, & \text{če } C > C_0, \\ \frac{\partial C}{\partial t} > 0, & \text{če } C < C_0. \end{cases}$$

V praksi vrednost C gladko potiskamo proti C_0 skozi časovni interval, določen z τ .

Objektivni algoritmi

Objektiven asimilacijski algoritem uporablja matematične koncepte za združevanje informacij iz opazovanj in iz modela:

- Določimo merilo (utež), ki oceni zanesljivost vsakega vira informacij na podlagi njegove napake,
- Upoštevamo matematična pravila za *optimalno* združevanje informacij,
- Ločimo *prior* (ozadje ali prvo ugibanje) od *posteriorja* (posodobljeno stanje po novih opazovanjih).

Pri vremenski napovedi je prior pogosto kratkoročna modelska napoved, posterior pa je analiza, ki združuje to napoved z novimi opazovanji. Teoretske osnove za to izhajajo iz bayesovske statistike ali teorije optimalnega krmiljenja.

1.6 Primer: Kalmanov filter (enodimenzionalni primer)


Poskusimo izmeriti temperaturo v sobi:

- T_b je naša *predhodna ocena* (ozadje) temperature z napako ϵ_b .
- T_o je *opazovana* temperatura z napako ϵ_o .
- T_t je *resnična* temperatura (neznana).
- T_a je *analiza*, torej naša *najboljša ocena* T_t , če imamo na voljo T_b in T_o .

Predpostavimo, da sta napaki:

$$\epsilon_b = T_b - T_t, \quad \epsilon_o = T_o - T_t$$

naključni z ničelnim povprečjem ($\langle \epsilon_b \rangle = \langle \epsilon_o \rangle = 0$) ter medsebojno nekorelirani ($\langle \epsilon_b \epsilon_o \rangle = 0$).

Slika 1.2: Grafični prikaz iskanja optimalne α .

Izpeljava formule za analizo

Nastavimo linearno kombinacijo:

$$T_a = \alpha T_o + \beta T_b + \gamma, \quad (1.3)$$

in definiramo *napako analize*:

$$\epsilon_a = T_a - T_t. \quad (1.4)$$

Združitev $T_a = \alpha(T_t + \epsilon_o) + \beta(T_t + \epsilon_b) + \gamma$ želimo tako, da bo $\langle \epsilon_a \rangle = 0$. Z nekaj algebre pridemo do pogojev:

$$\gamma = 0, \quad \beta = 1 - \alpha.$$

Tako dobimo:

$$T_a = \alpha T_o + (1 - \alpha) T_b, \quad (1.5)$$

$$\epsilon_a = \alpha \epsilon_o + (1 - \alpha) \epsilon_b. \quad (1.6)$$

Želimo minimizirati varianco $\langle \epsilon_a^2 \rangle = \alpha^2 \langle \epsilon_o^2 \rangle + (1 - \alpha)^2 \langle \epsilon_b^2 \rangle$. Ko odvajamo po α in enačimo z 0, dobimo:

$$\alpha = \frac{\langle \epsilon_b^2 \rangle}{\langle \epsilon_o^2 \rangle + \langle \epsilon_b^2 \rangle}. \quad (1.7)$$

Posledično velja:

$$T_a = \frac{\langle \epsilon_b^2 \rangle}{\langle \epsilon_o^2 \rangle + \langle \epsilon_b^2 \rangle} T_o + \frac{\langle \epsilon_o^2 \rangle}{\langle \epsilon_o^2 \rangle + \langle \epsilon_b^2 \rangle} T_b, \quad (1.8)$$

kar je v 1D primeru “najboljši linearni nepristranski ocenjevalec”. Če enačbo malo obrnemo bomo dobili končno enačbo za našo analizo:

$$T_a = T_b + \frac{\langle \epsilon_b^2 \rangle}{\langle \epsilon_o^2 \rangle + \langle \epsilon_b^2 \rangle} (T_o - T_b), \quad (1.9)$$

torej analiza je enaka ozadju (ali first guess) plus korekcija ozadja, ko implementiramo opazovanje.

Grafični primeri obnašanja:

- Če je opazovanje zelo natančno ($\langle \epsilon_o^2 \rangle \ll \langle \epsilon_b^2 \rangle$), potem $T_a \approx T_o$.
- Če je ozadje zelo natančno ($\langle \epsilon_b^2 \rangle \ll \langle \epsilon_o^2 \rangle$), potem $T_a \approx T_b$.

Alternativna izpeljava: Maximum Likelihood

Do iste rešitve lahko pridemo tudi z uporabo metode največjega verjetja (Maximum Likelihood). Recimo, da imamo dve neodvisni meritvi neke količine T : neposredno opazovanje T_o z napako σ_o , ter ozadno oceno T_b z napako σ_b .

Porazdelitve meritev: Verjetnost (oz. gostota verjetnosti) da dobimo opazovano vrednost T_o , če je resnična vrednost T , je podana z normalno porazdelitvijo:

$$p(T_o | T; \sigma_o) = \frac{1}{\sqrt{2\pi} \sigma_o} \exp \left(-\frac{(T_o - T)^2}{2 \sigma_o^2} \right).$$

Enako za drugo neodvisno meritev T_b :

$$p(T_b | T; \sigma_b) = \frac{1}{\sqrt{2\pi} \sigma_b} \exp \left(-\frac{(T_b - T)^2}{2 \sigma_b^2} \right).$$

Skupna verjetnost (verjetnostna gostota): Ker sta T_o in T_b neodvisni meritvi, je skupna verjetnostna gostota (oz. likelihood) za dano vrednost T kar produkt posameznih gostot:

$$L(T | T_o, T_b; \sigma_o, \sigma_b) = p(T_o | T; \sigma_o) \cdot p(T_b | T; \sigma_b).$$

Ker je iskanje maksimuma produkta enako iskanju maksimuma logaritma (zaradi naraščajoče narave log funkcije), lahko maksimiziramo kar logaritmiran izraz:

$$\ln L(T) = -\frac{(T_o - T)^2}{2 \sigma_o^2} - \frac{(T_b - T)^2}{2 \sigma_b^2} + \text{konst.}$$

Maksimizacija $\ln L(T)$ po T je torej enaka minimizaciji sledeče funkcije stroškov:

$$J(T) = \frac{(T_o - T)^2}{2 \sigma_o^2} + \frac{(T_b - T)^2}{2 \sigma_b^2}.$$

Iskanje minimuma: Poiščemo točko, kjer je odvod te funkcije po T enak nič:

$$\frac{dJ}{dT} = -\frac{(T_o - T)}{\sigma_o^2} - \frac{(T_b - T)}{\sigma_b^2} = 0.$$

To enačbo rešimo za T in dobimo:

$$T_a = \frac{T_o/\sigma_o^2 + T_b/\sigma_b^2}{1/\sigma_o^2 + 1/\sigma_b^2}.$$

Ta izraz lahko zapišemo tudi kot uteženo povprečje med T_o in T_b , kjer je utež sorazmerna z inverzom varianc (torej z zaupanjem v posamezne meritve). Če uporabimo zapis z napakami $\langle \epsilon_o^2 \rangle = \sigma_o^2$ in $\langle \epsilon_b^2 \rangle = \sigma_b^2$, dobimo še:

$$T_a = T_b + \frac{\langle \epsilon_b^2 \rangle}{\langle \epsilon_o^2 \rangle + \langle \epsilon_b^2 \rangle} \cdot (T_o - T_b).$$

To je ista rešitev, kot jo dobimo tudi z metodo optimalne interpolacije (OI).

1.7 Potek asimilacije podatkov

V asimilaciji podatkov združimo:

- prejšnje kratkoročne napovedi (*background*),
- trenutno (in po možnosti pretekla) *opazovanja*.

Ta kombinacija vodi do nove *analize*, s katero inicializiramo naslednjo napoved; postopek se tako ciklično ponavlja:

- **Analiza** → **Kratkoročna napoved** + **opazovanja** → **Naslednja analiza** → **Nova kratkoročna napoved** + **opazovanja** → **Nova analiza** → ...

Takšno zaporedje čez daljše obdobje je **reanaliza**, v kateri rekonstruiramo preteklo stanje ozračja.


Tipična obdobja napovedi

- **Srednjeročne napovedi**: običajno 10–15 dni,
- **Polezonske napovedi**: od nekaj tednov do celotne sezone.

Reanalize predstavljajo neprekinjen vir zgodovinskih stanj.

Modeli omejenega območja (LAMs)

Globalni model daje robne pogoje za model z višjo ločljivostjo na omejenem območju (LAM). Na primer, 72- do 96-urna globalna napoved služi kot robni pogoj za manjše območje z zahtevnejšo topografijo (npr. doline, lokalni vetrovi, kot je burja). *Relaksacijsko območje* na robu zagotavlja gladek prehod med globalnim modelom in LAM-om. Robni pogoji se posodablajo v kratkih časovnih presledkih (urna ali polurna frekvenca).



Slika 1.3: Globalni model proizvaja robne pogoje za lokalne modele. Označena je tudi relaksacijska cona, ki omogoča gladek prehod med globalnim in lokalnim modelom.

1.8 Pristopi k napovednim modelom

1.8.1 1. Persistenca

Predpostavimo, da se stanje atmosfere ne spreminja:

$$\vec{x}_f(t) = \vec{x}(t_0). \quad (1.10)$$

Tu $\vec{x}(t)$ predstavlja neko polje v atmosferi, $\vec{x}(t_0)$ pa to polje v začetnem času t_0 .

1.8.2 2. Na osnovi advekcije (prvi člen Taylorjeve ekspanzije)

Ocenimo:

$$\vec{x}_f(t) = \vec{x}(t_0) + \left. \frac{\partial \vec{x}}{\partial t} \right|_{t_0} \Delta t, \quad (1.11)$$

kjer je $\Delta t = t - t_0$. Dejansko rečemo: “jutrišnje vreme = današnje vreme + (hitrost spremembe) $\times$ (časovni presledek).”

1.8.3 3. Klimatološka napoved

Ne opiramo se na trenutne pogoje, ampak uporabimo dolgoletno povprečje:

$$\vec{x}_f(t) = \left\langle \vec{x}_i(t) \right\rangle_{i \in [1971, 2020]}, \quad (1.12)$$

kjer povprečimo čez več let podatkov. S takim pristopom morda spregledamo trenutne podnebne spremembe, kar lahko vodi v pristranskost napovedi.

1.8.4 4. Numerični napovedni model

Popolnoma numerična napoved uporablja atmosferski model M :

$$\vec{x}_f(t) = M(\vec{x}(t_0)), \quad (1.13)$$

kjer $M(\cdot)$ predstavlja dinamično jedro in fizikalne parametre modela, ki razvijejo stanje iz t_0 v čas t .

1.9 Kaj sestavlja atmosferski model

Atmosferski model navadno sestavlja nabor nelinearnih parcialnih diferencialnih enačb, ki opisujejo:

- **Kinematiko fluida** (drugi Newtonov zakon za vrtečo se tekočino),
- **Termodinamiko**,
- **Fizikalne procese**, povezane z gibanjem v atmosferi (npr. turbulenca, oblačna mikrofizika),
- **Prenos sevanja** (radiativni procesi),
- **Fazne spremembe** (npr. kondenzacija, zmrzovanje),
- **Izmenjave med sestavinami Zemljinega sistema** (npr. vlaga, toplota, gibalna količina med površjem, atmosfero in morda oceanom).

1.9.1 Zakon ohranitve gibalne količine

Obravnavamo paket zraka na vrteči se Zemlji. Na ta paket delujejo centrifugalna sila, Coriolisova sila, gravitacijska sila in gradientni tlak. Vektorska oblika časovne spremembe hitrosti je:

$$\frac{d\vec{v}}{dt} = -\frac{1}{\rho} \nabla p - 2\vec{\Omega} \times \vec{v} + \vec{g} + \vec{f}_{\text{tr}}, \quad (1.14)$$

kjer:

- ρ je gostota zraka,
- p je tlak,
- $\vec{\Omega}$ je kotna hitrost vrtenja Zemlje,
- $\vec{g}$ je pospešek gravitacije (navzdol),
- $\vec{f}_{\text{tr}}$ so dodatne sile (npr. trenje, turbulenca).

Spomnimo se, da lahko *totalni odvod* (skupna sprememba) zapišemo kot:

$$\frac{d\vec{v}}{dt} = \frac{\partial \vec{v}}{\partial t} + (\vec{v} \cdot \nabla) \vec{v}. \quad (1.15)$$

Tako lahko enačbo (1.14) prepišemo v obliki lokalnega delnega odvoda:

$$\frac{\partial \vec{v}}{\partial t} = -(\vec{v} \cdot \nabla) \vec{v} - \frac{1}{\rho} \nabla p - 2\vec{\Omega} \times \vec{v} + \vec{g} + \vec{f}_{\text{tr}}, \quad (1.16)$$

pri čemer je $(\vec{v} \cdot \nabla) \vec{v}$ *nelinearen* člen.

1.9.2 Kontinuitetna enačba

Za kontrolni volumen $\delta V = \delta x \delta y \delta z = \text{konst.}$ velja (v obliki tokov):

$$\frac{\partial \rho}{\partial t} = -\nabla \cdot (\rho \vec{v}), \quad (1.17)$$

$$\frac{\partial \rho}{\partial t} = -\left(\frac{\partial(\rho u)}{\partial x} + \frac{\partial(\rho v)}{\partial y} + \frac{\partial(\rho w)}{\partial z} \right), \quad (1.18)$$

kjer $\vec{v} = (u, v, w)$ označuje hitrostno polje.

Če je vhodni tok v smeri x enak u_ℓ in izhodni tok u_d ter velja $u_\ell < u_d$, je $\frac{\partial(\rho u)}{\partial x}$ negativen (iz prostora odteka več mase, kot prihaja), zaradi česar se lokalno poveča gostota ($\frac{\partial \rho}{\partial t} > 0$).

1.9.3 Zakon ohranitve energije (prvi zakon termodinamike)

Preučimo hitrost spremembe notranje energije zračne gmote:

$$c_p \frac{dT}{dt} - \frac{1}{\rho} \frac{dp}{dt} = \frac{J}{m}, \quad (1.19)$$

kjer:

- c_p je specifična toplotna kapaciteta pri stalnem tlaku,
- T je temperatura,
- p je tlak,

- $J = \frac{dQ}{dt}$ je hitrost dovajanja (ali odvajanja) toplote iz zunanjih virov,
- ρ je gostota,
- m je masa zračne gmote (pogosto vključeno kar v ρ ali J , odvisno od zapisa).

Če je $J = 0$, se gmotica spreminja *adiabatno* (brez izmenjave toplote z okolico). Potem velja:

$$c_p dT = \frac{1}{\rho} dp. \quad (1.20)$$

Z uporabo stanja idealnega plina $\rho = \frac{p}{RT}$ lahko izpeljemo:


$$c_p \frac{dT}{T} = R \frac{dp}{p},$$

$$\int_{T_0}^{T(p)} \frac{dT}{T} = \int_{p_0}^p \frac{R}{c_p} \frac{dp}{p}.$$

Po integraciji:

$$T(p) = T_0 \left(\frac{p}{p_0} \right)^{\frac{R}{c_p}}, \quad (1.21)$$

kar kaže, da se dvigajoča se kocka pri ekspanziji adiabatno ohladi ($T < T_0$).



Slika 1.4: Ko dvignemo kocko s temperaturo T_0 na višino p se kocka razširi.

1.9.4 Enačba ohranitve vlage


Za vsako fazo j (para, tekoča, ledena) zapišemo:

$$\frac{\partial(\rho q_j)}{\partial t} = -\nabla(\rho q_j \vec{v}) + \sum_{i,j} P_{q_{ij}}, \quad (1.22)$$

kjer:

- q_j je specifična vlažnost (ali mešalno razmerje) za fazo j ,
- $P_{q_{ij}}$ predstavljajo odvzem ali dodajanje (fazne spremembe med i in j , padavine, ipd.).

Vse te osnovne enačbe (gibalna količina, kontinuiteta, energija in vlaga) tvorijo jedro atmosferskih modelov. Dodatne paramerizacije (npr. turbulenca, sevanje, tokovi s površjem) in numerične metode pa omogočijo diskretno reševanje v mreži ali spektralnem prostoru.



Slika 1.5: (1) Geopotencial je vzporeden z Δz , posledica tega je, da se veter ne spreminja z višino. (2) Cikloni bi imeli hladno anomalijo, medtem ko anticikloni toplo anomalijo.

1.10 Barotropna enačba vrtničnosti za NWP (Numerical Weather Prediction)

Začnimo z horizontalnim delom Eulerjevih enačb. Lahko ga zapišemo kot:

$$\frac{d\vec{v}_h}{dt} + f \vec{k} \times \vec{v}_h = -\frac{1}{\rho} \nabla p, \quad (1.23)$$

kjer je $\vec{v}_h$ vodoravna komponenta hitrosti vetra, $f = 2\Omega \sin \phi$ Coriolisov parameter (Ω je kotna hitrost vrtenja Zemlje, ϕ je geografska širina), ρ je gostota, p pa tlak.

1.10.1 Osnovne predpostavke barotropnega modela

1. **Barotropna atmosfera:** Veter se s spremembo višine ne spreminja (ne po velikosti ne po smeri), tj. $\vec{v}_h(p) = \text{const.}$
2. **Konture debeline vzporedne geopotencialnim konturam:** Debelina med dvema tlačnima plastema je sorazmerna povprečni temperaturi $\langle T \rangle$ med njima.
3. **Hidrostatika:** razlika v tlaku je podana z


$$\partial p = -\rho g \partial z,$$

pri čemer z uporabo $\rho = \frac{p}{RT}$ dobimo:

$$\begin{aligned} \frac{\partial p}{p} &= -\frac{g}{RT} \partial z, \\ \int_{p_0}^{p_1} \frac{\partial p}{p} &= -\int_{z_0}^{z_1} \frac{g}{RT} \partial z, \\ \Delta z &= \frac{R \langle T \rangle}{g} \ln\left(\frac{p_0}{p_1}\right). \end{aligned}$$

Hladnejši predeli (npr. pri polih) imajo manjšo debelino, pri čemer so cikloni pogosto povezani s hladno anomalijo, anticikloni pa s toplo. Torej debelina je odvisna od povprečne temperature med parcelama na višini p_0 in p_1 . Debelina se zelo spremeni, ko gramo iz ekvatorja na severni tečaj: $\langle T \rangle_{NP} < \langle T \rangle_{EQ}$.

4. **Brez viskozen, nerazpršen** ali iz mehanike kontinuov bolj znan **nestisljiv** ($\nabla \cdot \vec{v} = 0$) tok, kar pomeni konstantno gostoto v 2D-vodoravni ravnini ali zanemarljivo vodoravno divergenco.



Slika 1.6: (1) Anticiklonalna vrtničnost $\zeta < 0$; ko povečam x se zmanjša v , saj $\frac{\partial v}{\partial x} < 0$ ter/ali $\frac{\partial u}{\partial y} > 0$. (2) Ciklonalna vrtničnost $\zeta > 0$; ko povečam x se poveča v , saj $\frac{\partial v}{\partial x} > 0$ ter/ali $\frac{\partial u}{\partial y} < 0$. (3) Nevртеči tok $\zeta = 0$.

V dvodimenzionalnih vodoravnih koordinatah naj bo $\vec{v} = (u, v)$, kjer je u komponenta v smeri vzhod–zahod (zonalna), v pa v smeri sever–jug (meridionalna). Tedaj:

$$\begin{aligned}\frac{du}{dt} - f v &= -\frac{1}{\rho} \frac{\partial p}{\partial x}, \\ \frac{dv}{dt} + f u &= -\frac{1}{\rho} \frac{\partial p}{\partial y}.\end{aligned}$$

Pri tem si zapomnimo, da $\frac{d}{dt} = \frac{\partial}{\partial t} + \vec{v} \cdot \nabla$. Razširimo to:

$$\frac{\partial u}{\partial t} + u \frac{\partial u}{\partial x} + v \frac{\partial u}{\partial y} - f v = -\frac{1}{\rho} \frac{\partial p}{\partial x}, \quad (1.24)$$

$$\frac{\partial v}{\partial t} + u \frac{\partial v}{\partial x} + v \frac{\partial v}{\partial y} + f u = -\frac{1}{\rho} \frac{\partial p}{\partial y}. \quad (1.25)$$

1.10.2 Definicija vrtničnosti

Relativna vrtničnost ζ je definirana kot:

$$\zeta = \frac{\partial v}{\partial x} - \frac{\partial u}{\partial y}. \quad (1.26)$$

Fizikalna razlaga:

- $\zeta > 0$ navadno pomeni ciklonsko (v severni polobli protismerno urnemu kazalcu) vrtenje.
- $\zeta < 0$ pomeni anticiklonsko (v severni polobli v smeri urinega kazalca) vrtenje.
- $\zeta = 0$ v čisto divergentnih ali konvergentnih tokovih, kjer ni lokalne rotacije.

Za izpeljavo enačbe za vrtničnost ustrezno odvajanju podvržemo (1.24) in ju nato odštejemo:

- Prvo enačbo odvajamo po y ,
- Drugo enačbo odvajamo po x ,
- in drugo odštejemo od prve.

Če označimo $\beta = \frac{\partial f}{\partial y}$, se da pokazati, da:

$$0 = \frac{d}{dt}(\zeta + f) + (\zeta + f) (\nabla \cdot \vec{v}).$$

Tu je f planetarna vrtničnost. Če zgornjo enačbo obrnemo in jo zapišemo s skupno vrtničnostjo $\eta = \zeta + f$ dobimo:

$$\frac{d}{dt}\eta = -\eta\nabla\vec{v}.$$

Če je tok *divergenčni* potem velja $\frac{d}{dt}\eta < 0$ za $\eta > 0$, če je $\nabla \cdot \vec{v} > 0$ (slika 1.7) in vidimo lahko tudi v realnem primeru, da se vrtničnost zmanjša, če iztegneš roke, torej če se zračne parcele razširijo. Če je tok *konvergenčni* potem velja $\frac{d}{dt}\eta > 0$ za $\eta > 0$, če je $\nabla \cdot \vec{v} < 0$ (slika 1.7), vidimo, da grejo zračne parcele vedno bolj skupaj.



Slika 1.7: (1) Divergenčen tok. (2) Konvergenčen tok.

Če je tok *nestisljiv* ($\nabla \cdot \vec{v} = 0$), sledi:

$$\frac{d}{dt}(\zeta + f) = 0,$$

torej je $\zeta + f$ materialno ohranjena količina.

1.10.3 Helmholtzev izrek in nerazpršeni tok

V 2D vodoravni ravnini lahko vsak vektorski tok $\vec{v}$ zapišemo kot:

$$\vec{v} = \underbrace{\vec{k} \times \nabla\Psi}_{\text{nerazpršeni del}} + \underbrace{\nabla\chi}_{\text{brezvrtilni del}}. \quad (1.27)$$

Kjer je $\vec{\Psi}$ hitrostno/tokovno vektorsko polje in $\nabla\chi$ gradient hitrostnega skalarne polja. Če velja $\nabla \cdot \vec{v} = 0$, potem $\vec{v}_\psi = \vec{v} = \vec{k} \times \nabla\Psi$.

1.11 Geostrofski veter

Pri obravnavi velikih meril v atmosferi pogosto privzamemo, da je tok *stacionaren* glede na čas. To pomeni, da je horizontalno pospeševanje vetra enako nič, kar matematično zapišemo kot

$$\frac{d\vec{v}_h}{dt} = 0. \quad (1.28)$$

Tu je $\vec{v}_h$ vektorska hitrost vetra v vodoravni ravnini. Če velja $\frac{d\vec{v}_h}{dt} = 0$, sta Coriolisova sila in horizontalni gradient tlaka v ravnovesju. Ta približek vodi do tako imenovanega *geostrofskega vetra*.

Naj bo ρ (skoraj) konstanta gostota zraka, p pa polje tlaka. S $\vec{k}$ označimo enotni vektor, usmerjen navpično navzgor, ter s f Coriolisov parameter, ki ga navadno definiramo kot $f = 2\Omega \sin \phi$, kjer je Ω kotna hitrost vrtenja Zemlje, ϕ pa geografska širina. Geostrofski veter $\vec{v}_g$ izpolnjuje ravnovesje

$$\begin{aligned} f \vec{k} \times \vec{v}_g &= -\frac{1}{\rho} \nabla p, \\ \vec{v}_g &= \frac{1}{\rho f} \vec{k} \times \nabla p. \end{aligned} \quad (1.29)$$

Prva vrstica enačbe (1.29) pravi, da je Coriolisova sila, $f \vec{k} \times \vec{v}_g$, v ravnovesju z negativnim horizontalnim gradientom tlaka, $-\frac{1}{\rho} \nabla p$. Druga vrstica je le preurejena oblika, ki izrecno poda $\vec{v}_g$.

Operator ∇ tukaj pomeni odvod po vodoravni ravnini pri konstantni višini, zato ∇p predstavlja horizontalni gradient tlaka. Če zapišemo $\vec{v}_g = (u_G, v_G)$, pri čemer je u_G komponenta v smeri x (proti vzhodu) in v_G komponenta v smeri y (proti severu), dobimo

$$\begin{aligned} v_G &= \frac{1}{\rho f} \frac{\partial p}{\partial x}, \\ u_G &= -\frac{1}{\rho f} \frac{\partial p}{\partial y}. \end{aligned} \quad (1.30)$$

Iz teh enačb vidimo, da je geostrofski veter prečno na horizontali gradient tlaka in obratno sorazmeren parametru f .

Oblika z geopotencialom. Vpeljemo *geopotencial* Φ , definiran kot

$$\Phi = gz,$$

kjer je g pospešek zaradi gravitacije, z pa geometrijska višina. V meteorologiji uporaba Φ velikokrat poenostavi izraze. Posebej lahko zapišemo geostrofski veter tudi v obliki

$$\vec{v}_G = \frac{1}{f} \vec{k} \times \nabla \Phi. \quad (1.31)$$

Tudi tu $\nabla \Phi$ predstavlja horizontalni gradient geopotenciala na konstantni višini.

1.12 Tokovna funkcija in nedivergentni tok

Vsak dvodimenzionalni vektorski tok $\vec{v}$ lahko zapišemo kot vsoto divergenčnega in rotacijskega dela. V meteorologiji to običajno zapišemo kot

$$\vec{v} = \vec{v}_\psi + \vec{v}_\chi, \quad (1.32)$$

pri čemer velja

$$\vec{v}_\psi = \vec{k} \times \nabla \Psi, \quad \vec{v}_\chi = \nabla \chi. \quad (1.33)$$

Funkcija Ψ se imenuje *tokovna funkcija* (angl. *stream function*); tok, ki ga zapišemo kot $\vec{k} \times \nabla \Psi$, je v dvodimenzionalnem prostoru vedno brez divergence. Medtem je χ običajno imenovana *potencial hitrosti* in predstavlja nerotacijski (le divergenčni) del toka. V enostavnem barotropnem približku pogosto predpostavljamo, da je $\vec{v}_\chi = 0$, in se tako osredotočimo na rotacijski del.

Če primerjamo

$$\vec{v}_\psi = \vec{k} \times \nabla \Psi$$

z geostrofskim vetrom

$$\vec{v}_G = \frac{1}{f} \vec{k} \times \nabla \Phi,$$

vidimo, da imata enako matematično obliko. Tako lahko sklepamo na preprosto razmerje med tokovno funkcijo Ψ in geopotencialom Φ :

$$\Psi = \frac{1}{f} \Phi. \quad (1.34)$$

V barotropnem okviru se zato tokovna funkcija Ψ lahko enači z geopotencialom Φ , le da je množen s faktorjem $\frac{1}{f}$. To je posebej uporabno, ker so izolnije Ψ (t.i. *toknice*) v nedivergentnem

toku poravnane s tokom samim. V ohlapnem smislu velja, da je tokovna funkcija polje, kjer so vrednosti vzporedne tokovnicam.

Naš cilj je še zmeraj še zmeraj dobiti enako obliko barotropične enačbe kot so jo dobili prvič ko so jo iznajdli. Torej še vedno si prizadevamo dobiti točno takšno barotropno enačbo, kot so jo izvirno razvili ob začetkih numeričnih napovedi vremena. Naš namen je torej slediti klasični barotropni vrtnični (vorticity) enačbi, ki je bila uporabljena v zgodovini.

1.13 Vrtinčnost in barotropna aproksimacija

Spomnimo se, da je *relativna vrtinčnost* ζ dvodimenzionalnega polja $\vec{v} = (u, v)$ definirana kot

$$\zeta = (\nabla \times \vec{v}) \cdot \vec{k}.$$

Pogosto na kratko zapišemo

$$\zeta = \vec{k} \cdot (\nabla \times \vec{v}), \quad (1.35)$$

pri čemer je $\vec{k}$ vektor, usmerjen iz ravnine navzgor torej $\vec{k} = (0, 0, 1)^T$. Ker pri računanju rotacije $\nabla \times (\vec{k} \times \nabla \Psi)$ dobimo znan izraz $\nabla^2 \Psi$ (če je f konstanten ali se počasi spreminja), lahko ζ zapišemo tudi v smislu Φ . Najprej to razčlenimo:

$$\begin{aligned} \zeta &= \vec{k} \cdot (\nabla \times (\vec{k} \times \nabla \Psi)) \\ &= \vec{k} \cdot \left(\nabla \times \left(\frac{1}{f} \vec{k} \times \nabla \Phi \right) \right) \quad (\text{ker } \Psi = \frac{1}{f} \Phi). \end{aligned} \quad (1.36)$$

Če privzamemo, da se f ne spreminja z geografskimi koordinatami (t. i. f-ravnina), to vodi do

$$\zeta = \frac{1}{f} \nabla^2 \Phi \text{ ali } \zeta = \nabla^2 \Psi \quad (1.37)$$

Kadar pa dopuščamo spremembo f z geografsko širino (t. i. β -ravnina, kjer je $\beta = \frac{\partial f}{\partial y}$), se pojavi dodatni člen. Simbolično pogosto zapišemo:

$$\zeta = \frac{1}{f} \nabla^2 \Phi + (\text{členi, ki vključujejo } \beta \text{ in tok}). \quad (1.38)$$

Pri številnih aplikacijah v srednjih geografskih širinah je prvi člen dominantna aproksimacija, zato pogosto pišemo

$$\zeta \approx \frac{1}{f} \nabla^2 \Phi. \quad (1.39)$$

Vendar je treba vedeti, da opuščen β -člen ni zanemarljiv na velikih, planetarnih razsežnostih (npr. pri Rossbijevih valovih).

1.14 Advekcija v Jakobijevi obliki in barotropna vrtnična enačba

Naslednji korak je zapisati advekcijski člen v obliki z Jakobijevo determinanto. V nestisljivem (dvodimeziionalnem) toku lahko hitrost vedno predstavimo s *tokovno funkcijo*:

$$\vec{v}(x, y) = \vec{k} \times \nabla \Psi = \left(-\frac{\partial \Psi}{\partial y}, \frac{\partial \Psi}{\partial x} \right).$$

Za *geostrofski* veter je tokovna funkcija

$$\Psi = \frac{\Phi}{f},$$

kjer je Φ geopotencial in f Coriolisov parameter. S tem dobimo:

$$\vec{v}(x, y) = \left(-\frac{1}{f} \frac{\partial \Phi}{\partial y}, \frac{1}{f} \frac{\partial \Phi}{\partial x} \right).$$

Naj bo zdaj $\alpha(x, y)$ poljubno skalarno polje (npr. vrtničnost, temperatura ...). Adveksijski operator $\vec{v} \cdot \nabla \alpha$ postane

$$\vec{v} \cdot \nabla \alpha = (-\psi_{,y}, \psi_{,x}) \cdot (\alpha_{,x}, \alpha_{,y}) = -\psi_{,y} \alpha_{,x} + \psi_{,x} \alpha_{,y},$$

kar natanko ustreza (*minus*) Jakobijevi determinanti

$$J(\alpha, \psi) = \alpha_{,x} \psi_{,y} - \alpha_{,y} \psi_{,x}.$$

Torej je Jakobijeva determinanta $J(\alpha, \Phi)$ definirana kot

$$J(\alpha, \Phi) = \begin{vmatrix} \frac{\partial \alpha}{\partial x} & \frac{\partial \alpha}{\partial y} \\ \frac{\partial \Phi}{\partial x} & \frac{\partial \Phi}{\partial y} \end{vmatrix} = \frac{\partial \alpha}{\partial x} \frac{\partial \Phi}{\partial y} - \frac{\partial \alpha}{\partial y} \frac{\partial \Phi}{\partial x}.$$

in s tem dobimo

$$\boxed{\vec{v} \cdot \nabla \alpha = -J(\alpha, \psi),} \quad (1.40)$$

Za barotropni, nestisljiv tok z zanemarljivim trenjem velja

$$\frac{\partial \zeta}{\partial t} + \vec{v} \cdot \nabla (\zeta + f) = 0, \quad (1.41)$$

kjer je $\zeta = v_{,x} - u_{,y} = \nabla^2 \psi = (1/f) \nabla^2 \Phi$ (relativna vrtničnost).

Vstavimo (1.40) s $\alpha = \zeta + f$ in $\psi = \Phi/f$:

$$\frac{\partial \zeta}{\partial t} - J(\zeta + f, \psi) = 0.$$

Ker je $\psi = \Phi/f$ in $\zeta = \nabla^2 \psi = (1/f) \nabla^2 \Phi$, dobimo popolnoma v terminih geopotenciala

$$\boxed{\frac{\partial}{\partial t} (\nabla^2 \Phi) + J\left(\frac{1}{f} \nabla^2 \Phi + f, \Phi\right) = 0.} \quad (1.42)$$

Kaj pravzaprav opisuje enačba (1.42)?

- **Levi člen** $\partial_t(\nabla^2 \Phi)$ sledi *lokalni časovni spremembi* Laplacije geopotenciala, tj. hitrost spreminjanja Laplaciana geopotenciala v času. Oziroma, kako hitro se spreminja lokalna ukrivljenost geopotencialnega polja. Ker je laplacian geopotenciala povezan z laplacianom vrtničnosti, nam ta del hkrati pove časovni razvoj vrtničnosti. Ker je $\vec{v}_g \propto \nabla \Phi$ je $\nabla \cdot \vec{v}_g \propto \nabla^2 \Phi$, torej ta del enačbe tudi pove časovni razvoj divergence/konvergence hitrostnega/vetrovnega polja, ki pa je pomembna zaradi dviganja/spuščanja zraka.
- **Desni člen** je $J(\frac{1}{f} \nabla^2 \Phi + f, \Phi)$: nelinearna *advekcija absolutne vrtničnosti* ($\zeta + f$) z geostrofskim tokom. Jakobijeva oblika zagotavlja, da se v diskretizaciji ohrani skupna (integrirana) absolutna vrtničnost in energija
- **Odvisnost:**
 1. od *porazdelitve geopotenciala* $\Phi(x, y)$, ki diktira tokovno funkcijo;
 2. od *prostorske spremembe Coriolisovega parametra* $f(y) = f_0 + \beta y$ – β -ravninsko aproksimacijo, ki omogoča Rossbyjeve valove;
 3. od začetne/vzorčne relativne vortičnosti $\nabla^2 \Phi$.

Enačba pravi, da se absolutna vrtinčnost ohranja vzdolž poti (advekcije) nepovršinskega geostrofskega vetra. *Konvergenca* ali *divergenca* ne igrata več vloge, saj smo v barotropnem, nestisljivem režimu; ostanejo zgolj raztezanje/premikanje vrtinčnostnih filamentov.

Zgodovinski opomnik. Prva uspešna numerična napoved (Charney, Fjørtoft, von Neumann — 1950) je temeljila prav na diskretizirani obliki (1.42). Richardsonovo pionirsko delo (1922) je bilo zasnovano podobno, vendar še ni imelo stabilne numerične sheme. Končna oblika barotropne vrtinčne enačbe,

$$\frac{\partial \nabla^2 \Phi}{\partial t} + J(\nabla^2 \Phi, \Phi) = 0 \quad (\text{ob ustreznih poenostavitvah}),$$

je bila dejansko uporabljena pri prvih uspešnih poskusih numerične napovedi vremena. Čeprav gre za zelo poenostavljen model, je postavil temelje sodobnim, obsežnejšim modelom, ki vključujejo vlago, toplotni transport, orografijo in druge zapletenejše dejavnike.

Poglavje 2

Primeri numeričnih rešitev barotropne vrtnične enačbe

2.1 Motivacija in vrtnična enačba

V tem poglavju raziskujemo, kako numerično reševati barotropno vrtnično enačbo na diskretni mreži. Začnimo z obnovitvijo vrtnične enačbe v njeni običajni obliki:

$$\frac{d\zeta}{dt} = -(\vec{v} \cdot \nabla)(\zeta + f). \quad (2.1)$$

Tu je ζ relativna vrtničnost, $\vec{v}$ vektorsko polje hitrosti v vodoravni ravnini, f pa Coriolisov parameter, ki se lahko v načelu spreminja z geografskimi koordinatami. Desno stran enačbe 2.1 lahko označimo kot funkcional

$$F(x, y, t). \quad (2.2)$$

Ta funkcional se še posebej pojavi, če zapišemo $\vec{v} = \vec{v}_\psi + \vec{v}_\chi$, kjer je $\vec{v}_\psi$ nedivergentni del, povezan s tokovno funkcijo, $\vec{v}_\chi$ pa potencialni (divergenčni) del toka. Tako lahko zapišemo:

$$F(x, y, t) = \frac{\partial}{\partial x}(u \zeta) + \frac{\partial}{\partial y}(v \zeta) + v \frac{\partial f}{\partial y}. \quad (2.3)$$

Spomnimo se definicij, ki so povezane z geostrofsko sorodnim, nedivergentnim poljem hitrosti, pri čemer velja:

$$v_\psi = \vec{k} \times \nabla \Psi \quad \longrightarrow \quad \begin{cases} u_\psi = -\frac{\partial \Psi}{\partial y}, \\ v_\psi = \frac{\partial \Psi}{\partial x}, \end{cases} \quad \zeta = \nabla^2 \Psi.$$


Kasneje se bomo k tem podrobnostim še vrnili. Za zdaj se bomo osredotočili na to, kako se ti izrazi pojavijo na numerični mreži.

2.2 Vizualizacija numerične mreže


Preden se lotimo diskretizacije in reševanja, moramo natančno določiti svojo računsko domeno. Na slikah 2.1, 2.2 in 2.3 (ki so povzete po skicah, narisanih med predavanjem) vidimo, kako je pravokotna fizikalna domena razdeljena na mrežo točk. Črne pike pogosto predstavljajo robne ali zunanje točke, medtem ko zelene pike označujejo notranje točke, kjer računamo vrednosti Ψ , ζ ali komponent hitrosti.

Predpostavimo, da je ta mreža časovno fiksna in konstantna, z enakomerno razdaljo v obeh vodoravnih smereh: $\Delta x = \Delta y = d$. Zato lahko katerokoli točko v mreži označimo z dvojnim indeksom (m, n) , tako da


$$x_m = m \Delta x, \quad y_n = n \Delta y. \quad (2.4)$$



Slika 2.1: Shema domene z robnimi točkami, prikazanimi kot črni krožci, in notranjimi mrežnimi točkami kot zeleni krožci.



Slika 2.2: Ilustracija fizikalne domene v dejanskih (x, y) koordinatah, pri čemer so poudarjeni vogali in prikaz, kako $(0, 0)$ ustreza $(\max \Delta x, \max \Delta y)$.



Slika 2.3: Še en pogled na numerično mrežo za vrtilčno enačbo, ki ponazarja enakomerno razdaljo $\Delta x = \Delta y = d$.

Ti koordinati (x_m, y_n) neposredno predstavljata diskretne mrežne točke, ki so približki zveznim poljem Ψ , ζ in hitrostnim komponentam.

2.3 Diskretizacija hitrosti in vrtinčnosti

Sedaj definiramo diskretne aproksimacije raznih polj. Na primer:

$$u_\psi(x_m, y_n) = u_{m,n}, \quad \Psi(x_m, y_n) = \psi_{m,n}, \quad (2.5)$$

podobno pa velja za druga polja. Če si ogledamo definicijo odvoda, na primer

$$\frac{\partial \Psi}{\partial y} = \lim_{\delta y \rightarrow 0} \frac{\Psi(y + \delta y) - \Psi(y)}{\delta y},$$

lahko uporabimo centralne končne difference. Za komponento u_ψ na primer dobimo

$$u_{m,n} = -\left(\frac{\partial \Psi}{\partial y}\right)_{m,n} \approx -\frac{\psi_{m,n+1} - \psi_{m,n-1}}{2d}. \quad (2.6)$$

S podobnim centralnim odvajanjem dobimo za komponento v_ψ naslednjo aproksimacijo:

$$v_{m,n} = \left(\frac{\partial \Psi}{\partial x}\right)_{m,n} \approx \frac{\psi_{m+1,n} - \psi_{m-1,n}}{2d}. \quad (2.7)$$

Prav tako lahko na točki (m, n) diskretno izrazimo vrtinčnost ζ kot diskretni Laplaceov operator na ψ . V zvezni obliki namreč velja

$$\zeta = \nabla^2 \Psi = \frac{\partial^2 \Psi}{\partial x^2} + \frac{\partial^2 \Psi}{\partial y^2}.$$

V diskretni obliki to zapišemo kot

$$\zeta_{m,n} = \nabla^2 \psi_{m,n}.$$

Za prvi odvod lahko včasih uporabimo zapis s polovičnim korakom, npr.

$$\frac{\partial \Psi_{m,n}}{\partial x} \approx \frac{\Psi_{m+\frac{1}{2},n} - \Psi_{m-\frac{1}{2},n}}{d}.$$

Če izvedemo drugo odvajanje, dobimo dobro znano šablono s petimi točkami za Laplaceov operator. Natančneje,

$$\frac{\partial}{\partial x} \left(\frac{\partial \Psi}{\partial x} \right)_{m,n} = \frac{1}{d^2} (\psi_{m+1,n} - 2\psi_{m,n} + \psi_{m-1,n}).$$

Enako storimo še v smeri y in vse skupaj seštejemo, da dobimo diskretni Laplaceov operator:

$$\zeta_{m,n} = \frac{1}{d^2} (\psi_{m+1,n} + \psi_{m-1,n} + \psi_{m,n+1} + \psi_{m,n-1} - 4\psi_{m,n}). \quad (2.8)$$

Z besedami: vsaka notranja mrežna točka (m, n) ima vrednost vrtinčnosti, izračunano s seštevkom vrednosti ψ v štirih sosednjih točkah, zmanjšanem za štirikratno vrednost ψ v sami točki, vse skupaj pa je deljeno z d^2 . To je prav klasična petačna shema končnih diferenc za $\nabla^2 \Psi$.

2.4 Diskretna oblika funkcionala F

Nadalje želimo ovrednotiti $F(x, y, t)$ v diskretnih mrežnih točkah. Okrajšano pišemo

$$F_{m,n}(t) = F(x_m, y_n, t).$$

Spomnimo se, da po definiciji velja

$$F(x, y, t) = \frac{\partial}{\partial x}(u_\psi \zeta) + \frac{\partial}{\partial y}(v_\psi \zeta) + \beta v_\psi,$$

pri čemer lahko vključimo β -člen zaradi latitudinalnega spreminjanja f . V približku končnih diferenc to zapišemo kot

$$F_{m,n}(t) = \frac{u_{m+1,n} \zeta_{m+1,n} - u_{m-1,n} \zeta_{m-1,n}}{2d} + \frac{v_{m,n+1} \zeta_{m,n+1} - v_{m,n-1} \zeta_{m,n-1}}{2d} + \beta v_{m,n}. \quad (2.9)$$

Pri tem moramo biti pozorni na robne vrednosti, saj ima naša domena (glej sliko 2.1) robove, kjer (m, n) seže do ničle ali največjega indeksa. Ti robovi so pomembni, ker moramo v praksi določiti robne pogoje, na primer iz globalnega modela ali pa uporabiti periodične robne pogoje.

2.5 Robni pogoji in Poissonova enačba

Na skicah, ki smo jih imeli, vidimo robne točke ob robovih. Za določitev stanja tam lahko na primer določimo robne pogoje za tokovno funkcijo Ψ na robu. Simbolično lahko napišemo:

$$\Psi = \begin{cases} 0 & \text{če } m = 0, \\ 0 & \text{če } m = M, \\ 0 & \text{če } n = 0, \\ 0 & \text{če } n = N, \end{cases} \quad (2.10)$$

ali kakšno drugo fizikalno relevantno izbiro (npr. periodičnost ali znano polje). Nato definiramo vse notranje točke kot

$$\psi_{m,n}, \quad (m, n) \in [1, M-1] \times [1, N-1], \quad (2.11)$$

in zanje rešujemo diskretno Poissonovo enačbo $\nabla^2 \psi_{m,n} = \zeta_{m,n}$. V praksi to pomeni velik sistem linearnih enačb, ki ga lahko rešujemo z iterativnimi metodami, kot so Gauss-Seidel, SOR ali naprednejše metode.

2.6 Popolna diskretizacija in časovni koraki

Ko smo postavili mrežo, lahko orisujemo celoten numerični postopek. Potrebujemo začetni pogoji za Ψ , s tem pa tudi za ζ in $\vec{v}$. Običajno storimo naslednje: najprej podamo začetni geopotencial $\Phi(x_m, y_n, 0)$, pridobljen iz opazovanj, kar nam implicira začetno tokovno funkcijo

1. Pretvorba geopotenciala Φ v tokovno funkcijo Ψ

$$\Psi_{m,n}(0) = \frac{\Phi_{m,n}(0)}{f_{m,n}}$$

2. Izračun začetnih horizontalnih hitrosti u in v

$$u_{m,n}(0) = -\frac{\Psi_{m,n+1}(0) - \Psi_{m,n-1}(0)}{2d}, \quad v_{m,n}(0) = \frac{\Psi_{m+1,n}(0) - \Psi_{m-1,n}(0)}{2d}$$

3. Izračun začetne relativne vrtinčnosti

$$\zeta_{m,n}(0) = \frac{\Psi_{m+1,n}(0) + \Psi_{m-1,n}(0) + \Psi_{m,n+1}(0) + \Psi_{m,n-1}(0) - 4\Psi_{m,n}(0)}{d^2}$$

4. Izračun funkcionala $F_{m,n}(k)$ (izvajamo za vsak $k = 0, \dots, K-1$):

$$F_{m,n}(k) = \frac{u_{m+1,n}(k)\zeta_{m+1,n}(k) - u_{m-1,n}(k)\zeta_{m-1,n}(k)}{2d} + \frac{v_{m,n+1}(k)\zeta_{m,n+1}(k) - v_{m,n-1}(k)\zeta_{m,n-1}(k)}{2d} + \beta v_{m,n}(k)$$

5. Posodobitev vrtinčnosti (Eulerjeva shema)

$$\zeta_{m,n}(k+1) = \zeta_{m,n}(k) - \Delta t F_{m,n}(k)$$

6. Rešitev Poissonove enačbe za novo Ψ

$$\nabla^2 \Psi_{m,n}(k+1) = \zeta_{m,n}(k+1) \quad (\text{Gauss-Seidel, SOR, } \dots; \text{ robni pogoji fiksni})$$

7. Izračun novih hitrosti

$$u_{m,n}(k+1) = -\frac{\Psi_{m,n+1}(k+1) - \Psi_{m,n-1}(k+1)}{2d}, \quad v_{m,n}(k+1) = \frac{\Psi_{m+1,n}(k+1) - \Psi_{m-1,n}(k+1)}{2d}$$

Eden pomembnih vidikov je *numerična stabilnost*. Pri uporabi eksplcitne Eulerjeve sheme v času je namreč časovni korak Δt ponavadi omejen s pogojem Courant–Friedrichs–Lewy (CFL), ki je povezan s hitrostmi valovanja ali advekcije v modelu. Če tega pogoja ne upoštevamo, lahko pride do numerične nestabilnosti ali navideznih oscilacij v ζ in Ψ . Zato morda izberemo manjše Δt , ali pa uporabimo naprednejše sheme za integracijo v času (npr. *leapfrog* ali polimplicitne sheme), da ohranimo numerično stabilnost in hkrati omogočimo večje Δt .

Drugo ključno vprašanje je *obravnavo robov*. Če uporabimo Dirichletove robne pogoje (npr. $\Psi = 0$ na robovih), s tem vsilimo breztokovne razmere, ki so lahko fizično nerealne, odvisno od aplikacije. Velikokrat meteorologi uporabijo periodične robne pogoje (predvsem v poenostavljenih β -ravninskih kanalih) ali robne pogoje, pridobljene z interpolacijo iz globalnih ali večjih območij napovedi. Izbira robnega pogoja lahko močno vpliva na obnašanje rešitve.

Nazadnje po izračunu nove vrtinčnosti $\zeta_{m,n}(k+1)$ treba posodobiti še tokovno funkcijo $\Psi_{m,n}(k+1)$ z reševanjem Poissonove enačbe, navadno oblike

$$\nabla^2 \Psi_{m,n}(k+1) = \zeta_{m,n}(k+1).$$

Učinkovito reševanje tega velikega sistema je ključni korak, da pristop deluje v praksi. V meteoroloških aplikacijah se pogosto uporabljajo metode s Fourierjevo transformacijo (na periodičnih domenah) ali hitre direktne rešitve Poissonove enačbe. V zahtevnejših modelih, ki imajo neničelno topografijo ali neenakomerno mrežo, so lahko potrebne še bolj zapletene numerične metode.

S kombinacijo vseh naštetih korakov – določanjem mreže, diskretizacijo odvodov, reševanjem robnih pogojev, izbiro ustreznega časovnega koraka in natančnim reševanjem Poissonove enačbe – pridemo do praktične sheme za numerično reševanje barotropne vrtinčne enačbe. Ta postopek je sicer poenostavljen, a odseva temeljno idejo mnogih zgodnjih operativnih modelov za napovedovanje vremena in ostaja osnovni primer v *numeričnem napovedovanju vremena* (NWP).

2.7 Spektralna metoda

Pri spektralni metodi polje predstavimo kot vsoto valov (Fourierjeva ali, splošneje, sferična harmonična ekspanzija). Na ta način prostorske odvode prevedemo v množenje ustreznih spektralnih koeficientov z valovnim številom, kar bistveno poenostavi računanje odvodov in drugih operatorjev – še posebej Laplaca – na sferi ali v periodičnih domenah.

Najprej pogledjmo preprost enodimenzionalni primer. Denimo, da imamo funkcijo, ki jo aproksimiramo s prostim valom:

$$f(y) = e^{iky}. \quad (2.12)$$

Če želimo izračunati odvod funkcije f po spremenljivki y , dobimo

$$\frac{\partial f}{\partial y} = ik f(y). \quad (2.13)$$

Na ta način v spektralnem (Fourierjevem) prostoru diferenciranje po y ustreza množenju z ik . Po istem načelu se pri višjih dimenzijah prostorski odvodi preslikajo v množenje s pripadajočimi valovnimi števili v posameznih smereh.

Za različne geometrije uporabljamo različne bazne funkcije. V dvodimenzionalni kartezični geometriji so to tipično dvojne Fourierjeve vrste; v sferični geometriji uporabljamo sferične harmonike; v valjasti geometriji (npr. pri toku v obroču okoli Zemlje) pa se lahko uporabijo parabolične cilindrične funkcije. Ključna lastnost teh baznih funkcij je, da so *globalne* in pokrivajo celotno računsko domeno.

Vsako polje $A(x, y)$ v dveh dimenzijah lahko predstavimo kot vsoto baznih funkcij. Na primer, v kartezični geometriji zapišemo:

$$A(x, y) = \sum_k \sum_l \hat{A}_{kl} e^{i(kx+ly)}, \quad (2.14)$$

oziroma zvezno obliko

$$A(x, y) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} \hat{A}_{kl} e^{i(kx+ly)} dk dl. \quad (2.15)$$

Tu sta k in l valovni števili v smereh x in y , $\hat{A}_{kl}$ pa spektralni koeficienti.

2.7.1 Barotropna vrtinčna enačba v sferičnih koordinatah

Sedaj se osredotočimo na sferično geometrijo, kjer bomo v tej geometriji obravnavali barotropno vrtinčno enačbo:

$$\frac{d}{dt}(\zeta + f) = 0. \quad (2.16)$$

Tukaj je ζ relativna vrtinčnost, f pa Coriolisov parameter. Za vrtečo se kroglo (kot je Zemlja) lahko f zapišemo kot

$$f = 2\Omega \sin \phi, \quad (2.17)$$

kjer je Ω kotna hitrost vrtenja Zemlje, ϕ pa geografska širina. Barotropna vrtinčna enačba tako postane

$$\frac{d}{dt}(\zeta + 2\Omega \sin \phi) = 0. \quad (2.18)$$

Popolni (totalni) odvod v sferičnih koordinatah je

$$\frac{dA}{dt} = \frac{\partial A}{\partial t} + \frac{u}{R \cos \phi} \frac{\partial A}{\partial \lambda} + \frac{v}{R} \frac{\partial A}{\partial \phi}, \quad (2.19)$$

kjer sta u in v komponenti hitrosti v smeri dolžine (λ) in širine (ϕ), R je polmer Zemlje, λ je dolžina, ϕ pa širina.

Vpeljemo funkcijo toka Ψ v sferičnih koordinatah tako, da

$$\zeta = \nabla^2 \Psi, \quad (2.20)$$

kjer je ζ vrtinčnost, ∇^2 pa Laplaceov operator na sferi. V barotropnem (nestisljivem) toku velja $\nabla \cdot \vec{v} = 0$. Pri splošnejših (nelinearnih) tokih z majhnim divergenčnim delom pa pogosto nadaljujemo z definicijo komponent hitrosti iz funkcije toka Ψ . Za horizontalen vektor $\vec{v}_h = (u, v)$ je divergenca na sferi enaka:

$$\nabla \cdot \vec{v} = \frac{1}{R \cos \phi} \frac{\partial u}{\partial \lambda} + \frac{1}{R \cos \phi} \frac{\partial (v \cos \phi)}{\partial \phi}$$

Za nestisljiv tok je možno pokazati, da je:

$$\nabla \cdot \vec{v} = 0 \implies \frac{1}{R \cos \phi} \frac{\partial (u \cos \phi)}{\partial \lambda} + \frac{1}{R} \frac{\partial v}{\partial \phi} = 0$$

Mi želimo sedaj dobiti taka u, v da se členi v zgornji enačbi izničijo. S primernimi algebraičnimi koraki dobimo pogoje, ki določajo u in v v odvisnosti od Ψ :

$$u = -\frac{1}{R} \frac{\partial \Psi}{\partial \phi}, \quad v = \frac{\cos \phi}{R} \frac{\partial \Psi}{\partial \lambda}. \quad (2.21)$$

Ali to dejansko deluje? No pa pogledjmo, za u dobimo:

$$\frac{1}{R \cos \phi} \frac{\partial u}{\partial \lambda} = -\frac{1}{R^2 \cos \phi} \frac{\partial^2 \Psi}{\partial \lambda \partial \phi}$$

in za v , če najprej razpišemo: $\frac{1}{R \cos \phi} \frac{\partial (v \cos \phi)}{\partial \phi} = \frac{1}{R} \frac{\partial v}{\partial \phi} - \frac{v \tan \phi}{R}$ dobimo:

$$\frac{1}{R} \frac{\partial v}{\partial \phi} - \frac{v \tan \phi}{R} = \frac{1}{R^2} \left[\cos \phi \frac{\partial^2 \Psi}{\partial \phi \partial \lambda} - \sin \phi \frac{\partial \Psi}{\partial \lambda} \right] - \frac{\cos \phi}{R^2} \frac{\partial \Psi}{\partial \lambda} \tan \phi = + \frac{1}{R^2 \cos \phi} \frac{\partial^2 \Psi}{\partial \lambda \partial \phi}$$

torej nastavki dejansko delujejo. V kartezičnih koordinatah se barotropna vrtinčna enačba glasi:

$$\frac{\partial}{\partial t} (\zeta + f) + u \frac{\partial (\zeta + f)}{\partial x} + v \frac{\partial (\zeta + f)}{\partial y} = 0 \quad (2.22)$$

V sferičnih koordinatah lahko zapišemo evolucijsko enačbo za ζ :

$$\frac{\partial \zeta}{\partial t} + \frac{u}{R \cos \phi} \frac{\partial \zeta}{\partial \lambda} + \frac{v}{R} \frac{\partial \zeta}{\partial \phi} + v \frac{1}{R} \frac{\partial f}{\partial \phi} = 0. \quad (2.23)$$

Upoštevamo, da se iz kartezičnih koordinat $v \partial f / \partial y$ prevede v sferične koordinate tako;

$$v \frac{1}{R} \frac{\partial f}{\partial \phi} = v \frac{1}{R} \frac{\partial (2\Omega \sin \phi)}{\partial \phi} = v \frac{1}{R} 2\Omega \cos \phi,$$

in pri upoštevanju $\zeta = \nabla^2 \Psi$ in hkrati namesto u, v v enačbi 2.23 pišemo izraze iz 2.21, torej pišemo sedaj Ψ kot funkcijo toka, dobimo

$$\frac{\partial}{\partial t} (\nabla^2 \Psi) - \frac{1}{R^2} \frac{\partial \Psi}{\partial \mu} \frac{\partial (\nabla^2 \Psi)}{\partial \lambda} + \frac{1}{R^2} \frac{\partial \Psi}{\partial \lambda} \frac{\partial (\nabla^2 \Psi)}{\partial \mu} + \frac{2\Omega}{R^2} \frac{\partial \Psi}{\partial \lambda} = 0 \quad (2.24)$$

hkrati pa smo upoštevali zamenjavo spremenljivk $\mu = \sin \phi$. Pri tem uporabljamo verižno pravilo v sferičnih koordinatah in dejstvo, da sta $\frac{v}{R}$ ter odvajanje $\partial / \partial \phi$ pravilno povezana z odvodi po λ in μ .

Laplaceov operator Ψ na krogli lahko zapišemo kot

$$\nabla^2 \Psi = \frac{1}{R^2} \left[\frac{\partial}{\partial \mu} \left((1 - \mu^2) \frac{\partial \Psi}{\partial \mu} \right) + \frac{1}{1 - \mu^2} \frac{\partial^2 \Psi}{\partial \lambda^2} \right]. \quad (2.25)$$

In glavna diferencialna enačba, ki opisuje časovni razvoj Laplaca Ψ , je tako:

$$\frac{\partial}{\partial t} (\nabla^2 \Psi) = \frac{1}{R^2} \left[\frac{\partial \Psi}{\partial \mu} \frac{\partial (\nabla^2 \Psi)}{\partial \lambda} - \frac{\partial \Psi}{\partial \lambda} \frac{\partial (\nabla^2 \Psi)}{\partial \mu} \right] - \frac{2\Omega}{R^2} \frac{\partial \Psi}{\partial \lambda}. \quad (2.26)$$

Člen v oklepaju na desni strani predstavlja nelinearni transport vrtničnosti in advekcijo planetarne vrtilne količine (2Ω).

Naslednji korak je predstavitev poljubnega polja $A(\phi, \lambda)$ s sferičnimi harmoniki:

$$A(\phi, \lambda) = \sum_{l=0}^L \sum_{m=-l}^l \hat{A}_{lm} Y_l^m(\phi, \lambda),$$

kjer so $Y_l^m(\phi, \lambda)$ sferične harmonične bazne funkcije in je L skupna valovna številka pri krajsanju. Znano je, da lahko sferični harmonik zapišemo kot

$$Y_l^m(\phi, \lambda) = P_l(\sin \phi) e^{-im\lambda},$$

pri čemer je $P_l(\sin \phi)$ pridružen Legendrejev polinom, $e^{-im\lambda}$ pa Fourierjeva komponenta v vzdolžni smeri. Koeficiente $\hat{A}_{lm}$ dobimo z integralsko zvezo

$$\hat{A}_{lm} = \int_{-1}^1 \int_0^{2\pi} Y_l^m(\phi, \lambda) A(\phi, \lambda) d\lambda d\mu, \quad (2.27)$$

kjer je $\mu = \sin \phi$.

Zelo koristna lastnost je Laplaceov operator sferičnega harmonika:

$$\nabla^2 Y_l^m = -\frac{l(l+1)}{R^2} Y_l^m. \quad (2.28)$$

To nam kasneje močno poenostavi mnogo izrazov v spektralni obliki.

2.7.2 Spektralna transformacijska metoda

V naši glavni enačbi za barotropno vorticijo (in tudi v bolj zapletenih fluidnih enačbah) srečamo številne nelinearne odvode. Ti odvodi ustvarijo člene, ki lahko vodijo v kaotično ali zelo zapleteno obnašanje v fizičnem prostoru. Temeljno vodilo spektralne metode je:

Vse nelinearne člene računajmo v točkovnem (mrežnem) prostoru in rezultat šele nato transformirajmo nazaj v spektralni prostor.

To lahko ponazorimo s produktom $A(\phi, \lambda) \cdot B(\phi, \lambda)$. Naj bosta A in B predstavljena s sferično harmonično ekspanzijo:

$$A(\phi, \lambda) = \sum_{l=0}^L \sum_{m=-l}^l \hat{A}_{lm} Y_l^m(\phi, \lambda), \quad B(\phi, \lambda) = \sum_{l=0}^L \sum_{m=-l}^l \hat{B}_{lm} Y_l^m(\phi, \lambda).$$

Če bi želeli množiti ta izraza neposredno v spektralnem prostoru, bi dobili izraz z reda $O(L^4)$ členov, saj bi se del vsote nanašal na vse kombinacije l, m za A in B . Namesto tega naredimo naslednje:

1. Transformiramo $A(\phi, \lambda)$ in $B(\phi, \lambda)$ iz spektralne predstavitve v mrežo (ϕ_j, λ_i) . 2. Vrednotimo produkt točkovno: $C(\phi_j, \lambda_i) = A(\phi_j, \lambda_i) \cdot B(\phi_j, \lambda_i)$. 3. Produkt $C(\phi, \lambda)$ nato transformiramo nazaj v spektralni prostor, da dobimo $\hat{C}_{lm}$.

S tem bistveno znižamo računsko zahtevnost, še posebej če imamo na voljo hitre sferične transformacije (analogija hitri Fourierjevi transformaciji, a na sferi).

Vrnimo se k glavni enačbi za $\nabla^2 \Psi$. Definirajmo:

$$D(\mu, \lambda) = -\left(\frac{\partial \Psi}{\partial \mu}\right)\left(\frac{\partial \nabla^2 \Psi}{\partial \lambda}\right) + \left(\frac{\partial \Psi}{\partial \lambda}\right)\left(\frac{\partial \nabla^2 \Psi}{\partial \mu}\right).$$

Iz (2.26) sledi:

$$\frac{\partial(\nabla^2 \Psi)}{\partial t} = -\frac{1}{R^2} \left[2\Omega \frac{\partial \Psi}{\partial \lambda} + D(\mu, \lambda) \right]. \quad (2.29)$$

Zapišemo Ψ in D v sferični harmonični ekspanziji, pri čemer vključimo tudi časovno odvisnost koeficientov:

$$\Psi(\mu, \lambda, t) = \sum_{l=0}^L \sum_{m=-l}^l \hat{\Psi}_{lm}(t) Y_l^m(\mu, \lambda), \quad D(\mu, \lambda, t) = \sum_{l=0}^L \sum_{m=-l}^l \hat{D}_{lm}(t) Y_l^m(\mu, \lambda).$$

Upoštevamo lastnost $\nabla^2 Y_l^m = -\frac{l(l+1)}{R^2} Y_l^m$ in te ekspanzije vstavimo nazaj v enačbo. Z združitvijo izrazov ter izpustitvijo (splošnih) vsot zaradi preglednosti dobimo:

$$\frac{\partial}{\partial t} \left(-\frac{l(l+1)}{R^2} \hat{\Psi}_{lm}(t) Y_l^m \right) = -\frac{1}{R^2} \left[2\Omega (im \hat{\Psi}_{lm}(t)) Y_l^m + \hat{D}_{lm}(t) Y_l^m \right].$$

To se poenostavi v

$$\frac{d\hat{\Psi}_{lm}}{dt} = \frac{1}{l(l+1)} \left[2\Omega im \hat{\Psi}_{lm} + \hat{D}_{lm} \right]. \quad (2.30)$$

Tako ima vsak sferični harmonični koeficient $\hat{\Psi}_{lm}$ svojo lastno ordinatno diferencialno enačbo v času. Edini ostali numerični korak je diskretizacija tega časovnega odvoda. Vse prostorske operatorje smo vpeljali analitično z uporabo sferičnih harmonikov.

Ostane vprašanje, kako izračunati $\hat{D}_{lm}(t)$. Po inverzni transformaciji velja:

$$\hat{D}_{lm}(t) = \frac{1}{4\pi} \int_0^{2\pi} \int_{-1}^1 Y_l^m(\mu, \lambda) D(\mu, \lambda, t) d\mu d\lambda. \quad (2.31)$$

V praksi izračunamo $D(\mu, \lambda, t)$ v mrežnem prostoru:

$$D(\mu_j, \lambda_i) = \left(-\frac{\partial \Psi}{\partial \mu} \right)_{j,i} \left(\frac{\partial \nabla^2 \Psi}{\partial \lambda} \right)_{j,i} + \left(\frac{\partial \Psi}{\partial \lambda} \right)_{j,i} \left(\frac{\partial \nabla^2 \Psi}{\partial \mu} \right)_{j,i}. \quad (2.32)$$

Odvode $\partial \Psi / \partial \lambda$ in $\partial \Psi / \partial \mu$ dobimo tako, da najprej Ψ prestavimo iz spektralnega v mrežni prostor, nato pa uporabimo natančne zveze za odvode v spektralnem prostoru. Na primer:

$$\frac{\partial \Psi}{\partial \lambda} = \sum_{l=0}^L \sum_{m=-l}^l (im) \hat{\Psi}_{lm} Y_l^m(\mu, \lambda). \quad (2.33)$$

S tem lahko v vsakem točkovnem (μ_j, λ_i) prostoru izračunamo ta odvod natančno. Enako velja za

$$\frac{\partial \Psi}{\partial \mu}(\mu, \lambda) = \sum_{l=0}^L \sum_{m=-l}^l \hat{\Psi}_{lm} e^{im\lambda} \frac{d}{d\mu} P_l(\mu), \quad (2.34)$$

kjer je $P_l(\mu)$ pridružen Legendrejev polinom. Ko enkrat izračunamo zmnožke v mreži, jih transformiramo nazaj v spektralni prostor, da dobimo $\hat{D}_{lm}$.

Spektralna metoda je zelo učinkovita, ker se odvodi v spektralnem prostoru izračunajo brez (ali z minimalnimi) numeričnimi napakami za vsak posamezni modus. Glavna omejitev je rast računskih stroškov pri velikih l . Kljub temu uvedba hitrih sferičnih transformacij naredi te metode izvedljive za globalne izračune napovedi vremena.

2.7.3 Zaključek postopka

Sedaj predstavimo glavne korake pri reševanju barotropne vrtnične enačbe v sferičnih koordinatah s spektralno metodo. Metodologija se v praksi razširi tudi na zahtevnejše modele, toda barotropna enačba je dober uvodni primer:

$$(E1) \quad \frac{\partial}{\partial t}(\nabla^2 \Psi) = -\frac{1}{R^2} \left[2\Omega \frac{\partial \Psi}{\partial \lambda} + D(\mu, \lambda) \right]$$

$$(E2) \quad D = -\frac{\partial \Psi}{\partial \mu} \frac{\partial(\nabla^2 \Psi)}{\partial \lambda} + \frac{\partial \Psi}{\partial \lambda} \frac{\partial(\nabla^2 \Psi)}{\partial \mu}$$

$$(E3) \quad \nabla^2 Y_l^m = -\frac{l(l+1)}{R^2} Y_l^m$$

$$(E4) \quad \frac{d\hat{\Psi}_{lm}}{dt} = \frac{1}{l(l+1)} \left(2\Omega im \hat{\Psi}_{lm} + \hat{D}_{lm} \right)$$

$$(E5) \quad \hat{D}_{lm} = \frac{1}{4\pi} \int_0^{2\pi} \int_{-1}^1 Y_l^{m*} D(\mu, \lambda) d\mu d\lambda$$

1. Korak 1 (Inicializacija, $t = 0$)

- (a) Najprej določimo začetne pogoje za opazovano polje, denimo geopotencial Φ . Iz njega izračunamo začetno funkcijo toka $\Psi(0)$

$$f(\mu) = 2\Omega\mu, \quad \Psi(\mu, \lambda, 0) = \frac{\Phi(\mu, \lambda, 0)}{f(\mu)}.$$

Tako dobimo veter, ki je geostrofski in nestisljiv.

- (b) Laplaceov operator na krogli pretvori Ψ v relativno vrtničnost ζ . Ta začetni ζ postane primarni dinamični signal, ki ga bomo napovedovali v času.

$$\zeta(\mu, \lambda, 0) = \nabla^2 \Psi(\mu, \lambda, 0) = \frac{1}{R^2} \left[\frac{\partial}{\partial \mu} \left((1 - \mu^2) \frac{\partial \Psi}{\partial \mu} \right) + \frac{1}{1 - \mu^2} \frac{\partial^2 \Psi}{\partial \lambda^2} \right].$$

S tem postavimo začetno dinamično polje, ki ga bo model razvijal v času.

- (c) Z Gauss–Legendre kvadraturo in hitrim Fourierjem projiciramo Ψ na sferične harmonike Y_l^m .

$$\hat{\Psi}_{lm}(0) = \frac{1}{4\pi} \int_0^{2\pi} \int_{-1}^1 \Psi(\mu, \lambda, 0) Y_l^{m*}(\mu, \lambda) d\mu d\lambda.$$

Tako dobimo začetni komplet modov $\hat{\Psi}_{lm}(0)$, ki jih nato napovedujemo z ODE-ji.

2. Korak 2 (Inverzna transformacija v mrežo)

Iz spektralnih koeficientov sestavimo fizično polje

$$\Psi_{ij}(t_k) = \sum_{l=0}^L \sum_{m=-l}^l \hat{\Psi}_{lm}(t_k) Y_l^m(\mu_j, \lambda_i).$$

Tako dobimo vrednosti na Gauss–Legendre mreži, kjer so množenja najcenejša.

3. **Korak 3 (Analitični odvodi v spektru)** Spektralno polje $\hat{\Psi}_{lm}$ pretvorimo v fizično polje $\Psi(\mu_j, \lambda_i)$ na Gauss–Legendre mreži. Odvode dobimo točno, brez numeričnega razlikovanja:

$$\frac{\partial \Psi}{\partial \lambda} = \sum_{l,m} im \hat{\Psi}_{lm} Y_l^m, \quad \frac{\partial \Psi}{\partial \mu} = \sum_{l,m} \hat{\Psi}_{lm} \frac{dP_l^m}{d\mu} e^{im\lambda},$$

$$\nabla^2 \Psi = - \sum_{l,m} \frac{l(l+1)}{R^2} \hat{\Psi}_{lm} Y_l^m.$$

V mrežnem prostoru lahko izvajamo točkovne množilne operacije, ki so pri nelinearnih členih najcenejše. Namesto numeričnega razlikovanja na mreži odvode izračunamo eksaktno v spektru (faktorsko $\partial/\partial\lambda = im$, $\partial/\partial\mu = dP_l/d\mu$). S tem ohranimo visoko natančnost in stabilnost.

4. Korak 4 (Izračun Jakobijevega člena D na mreži)

Nelinearni Jakobijev člen D vsebuje produkt dveh odvodov. Izračunamo ga točkovno na mreži, ker je tam zgolj enostavno množenje; nato dobimo polje $D(\mu_j, \lambda_i)$.

$$D_{ij} = - \left(\frac{\partial \Psi}{\partial \mu} \right)_{ij} \left(\frac{\partial (\nabla^2 \Psi)}{\partial \lambda} \right)_{ij} + \left(\frac{\partial \Psi}{\partial \lambda} \right)_{ij} \left(\frac{\partial (\nabla^2 \Psi)}{\partial \mu} \right)_{ij}.$$

5. Korak 5 (Pretvorba D nazaj v spekter)

Ponovno uporabimo Gauss–Legendre + FFT, da D projiciramo na sferične harmonike. Tako zagotovimo, da lahko desni člen ODE-jev (E4) izrazimo v istem spektralnem prostoru kot $\hat{\Psi}_{lm}$.

$$\hat{D}_{lm}(t) = \frac{1}{4\pi} \int_0^{2\pi} \int_{-1}^1 Y_l^m(\mu, \lambda) D(\mu, \lambda, t) d\mu d\lambda.$$

6. Korak 6 (Časovna integracija spektralnih modov)

Vsak harmonični koeficient sledi svoji ODE $d\hat{\Psi}_{lm}/dt$. S shemo (leap-frog, RK, ipd.) ga posodobimo za en korak Δt . Ta korak poganja evolucijo simulacije v času.

$$\frac{d\hat{\Psi}_{lm}}{dt} = \frac{1}{l(l+1)} \left(2\Omega im \hat{\Psi}_{lm} + \hat{D}_{lm} \right).$$

Shema leap-frog (ali Runge–Kutta) da korak naprej

$$\hat{\Psi}_{lm}(t_{k+1}) = \hat{\Psi}_{lm}(t_k) + \Delta t \left(\frac{d\hat{\Psi}_{lm}}{dt} \right)_{t_k}.$$

7. Korak 7 (Zanka do ciljne ure T)

Ponovimo Korake 2–6 za vsak časovni korak, dokler ne dosežemo želene napovedne ure. Celoten cikel spekter $\rightarrow$ mreža $\rightarrow$ spekter se tako ponavlja, pri čemer *nelinearne produkte* vedno rešujemo v mrežnem prostoru, *odvode* pa v spektralnem.

Po zaključku zadnjega časovnega koraka imamo določeno $\hat{\Psi}_{lm}(T)$. Če želimo, rekonstruiramo $\Psi(\mu, \lambda, T)$ v fizičnem prostoru z inverzno transformacijo. Tako dobimo rešitev barotropne vrtnične enačbe v času T .

V praksi atmosferski modeli vključujejo še dodatne procese (npr. vlago, konvekcijo, sevanje), ki lahko zahtevajo druge načine diskretizacije ali parametre. Kljub temu pa za čisto dinamični del globalnega modela (advekcijo vrtničnosti, divergenčno polje in geopotencial) spektralna transformacijska metoda ostaja temelj za natančne napovedi v velikem merilu.


Tako celoten numerični postopek temelji na iteriranju prognostičnih enačb v spektralnem prostoru in prehodih v mrežni prostor, kjer obravnavamo nelinearne produkte. Cikel pretvori–izračunaj–inverzno pretvori ponovimo v vsakem časovnem koraku do konca simulacije ter tako dobimo stabilno in elegantno rešitev barotropne vrtnične enačbe na vrteči se krogli.

2.8 Metoda zaporednega popravljanja (Successive Correction Method)

Ta metoda, ki sta jo leta 1955 razvila Bergthorsson in Doos, velja za eno prvih oblik *asimilacije podatkov* v numerični napovedi vremena. Osnovni cilj je dobiti *analizo* polja $f_a(\vec{r})$, ki združuje:

- *Prvo oceno* oziroma *ozadje* $f_b(\vec{r})$, ki lahko izhaja iz kratkoročne napovedi ali iz klimatološkega polja (ali uteženega povprečja obeh).
- Dosegljive meritve $f_o(\vec{r}_k)$ na nekaterih lokacijah meritev $\vec{r}_k$.

Glavna ideja je “popravljanje” ali “posodabljanje” ozadnega polja z uteženim vplivom vsake meritve znotraj določenega dosega od modelne mrežne točke. Metoda se pogosto izvede *zaporedno*, prek več iteracij (t. i. “passov”), pri čemer se analiza na vseh mrežnih točkah postopoma izboljšuje.



Slika 2.4: Shematski prikaz metode zaporednega korigiranja. Črne pike (•) označujejo modelne mrežne točke $\vec{r}_i$, oranžni križci (×) pa lokacije meritev $\vec{r}_k$. Črne krivulje lahko ponazarjajo izolinije ozadnega polja. Puščice nakazujejo, kako meritve na lokaciji $\vec{r}_k$ vplivajo na analizo v bližnji mrežni točki $\vec{r}_i$.

Glavni namen. Prvotno je bila metoda razvita za inicializacijo

$$\frac{d}{dt}(\zeta + f) = 0$$

(na primer barotropne vrtnične napovedi) z izboljšano oceno $\Phi(0)$ ali sorodnega meteorološkega polja. Potrebujemo torej ozadje in nabor meritev, ki ju želimo združiti. Običajno potrebujemo ozadje, ki izvira iz predhodne (kratkoročne) napovedi in morda klimatološke ocene za večjo stabilnost. Nato to ozadje zaporedno korigiramo z novo pridobljenimi meritvami.

Označbe in definicije

Naj bo $f(\vec{r})$ 2D polje, ki nas zanima (npr. geopotencialna višina). Vektor $\vec{r}_i$ označuje položaj i -te točke modelne mreže, medtem ko je $\vec{r}_k$ lokacija k -te meritve. Iz meritev (npr. radiosondaž) pridobimo *opazovano* vrednost $f_o(\vec{r}_k)$. Hkrati imamo *ozadje* ali *prvo oceno* v vsaki mrežni točki, to je $f_b(\vec{r}_i)$. Na lokaciji meritve pišemo $f_b(\vec{r}_k)$ kot ozadje interpolirano na merilno lokacijo.

Včasih je ozadje f_b samo po sebi uteženo povprečje kratkoročne napovedi in klimatologije:

$$f_b = \frac{w_{\text{srfc}} f_{\text{srfc}} + w_{\text{clm}} f_{\text{clm}}}{w_{\text{srfc}} + w_{\text{clm}}}, \quad (2.35)$$

kjer veljata približka $w_{\text{srfc}} \approx \frac{1}{\sigma_{\text{srfc}}}$ in $w_{\text{clm}} \approx \frac{1}{\sigma_{\text{clm}}}$. Tu σ_{srfc} in σ_{clm} predstavljata standardni deviaciji (oziroma negotovosti) kratkoročne napovedi in klimatološkega polja.

Predpostavke o napakah

Naj bo $\epsilon_b(\vec{r})$ napaka ozadja in $\epsilon_o(\vec{r}_k)$ napaka meritve. Metoda zaporednega popravljanja predpostavlja nekaj poenostavitvev:

1. *Homogena napaka ozadja:* $\epsilon_b(\vec{r})$ ne zavisi od lege, zato je $\sigma_b^2 = \langle \epsilon_b^2(\vec{r}) \rangle$ konstanta.
2. *Brez krajevnne korelacije v napaki ozadja:* $\langle \epsilon_b(\vec{r}_k) \epsilon_b(\vec{r}_l) \rangle = 0$ za $k \neq l$.
3. *Nekorelirane napake meritev:* $\langle \epsilon_o(\vec{r}_k) \epsilon_o(\vec{r}_l) \rangle = 0$ za $k \neq l$. Poleg tega je $\sigma_o^2(k)$ lahko odvisna od vrste instrumenta, ne pa od kraja.
4. *Nekoreliranost napak ozadja in meritev:* $\langle \epsilon_o \epsilon_b \rangle = 0$.

Osnoven primer z eno samo meritvijo

Predpostavimo, da imamo eno samo meritev v točki $\vec{r}_k$, želimo pa oceniti vrednost f na modelni mrežni točki $\vec{r}_i$. Na voljo imamo:

- $f_b(\vec{r}_i)$: ozadje (kratkoročna napoved ali klimatologija) v $\vec{r}_i$.
- Meritev $f_o(\vec{r}_k)$ na $\vec{r}_k$, ki jo na nek način želimo "projicirati" na $\vec{r}_i$.

Če za trenutek zanemarimo razdaljo (tj. če bi veljalo $\vec{r}_i = \vec{r}_k$, ali če bi imeli neposredno "meritev" $\tilde{f}_o(\vec{r}_i)$ v točki $\vec{r}_i$), se uporablja klasična formula za zlivanje ozadja in meritev (analogno enostavni skalarni mešanici):

$$T_a = \frac{\langle \epsilon_b^2 \rangle}{\langle \epsilon_b^2 \rangle + \langle \epsilon_o^2 \rangle} T_o + \frac{\langle \epsilon_o^2 \rangle}{\langle \epsilon_b^2 \rangle + \langle \epsilon_o^2 \rangle} T_B,$$

oziroma ekvivalentno:

$$T_a = \frac{\frac{1}{\langle \epsilon_o^2 \rangle}}{\frac{1}{\langle \epsilon_o^2 \rangle} + \frac{1}{\langle \epsilon_b^2 \rangle}} T_o + \frac{\frac{1}{\langle \epsilon_b^2 \rangle}}{\frac{1}{\langle \epsilon_o^2 \rangle} + \frac{1}{\langle \epsilon_b^2 \rangle}} T_B.$$

Po analogiji in z uvedbo $\tilde{f}_o(\vec{r}_i)$ kot "efektivne meritve" $\tilde{f}_o(\vec{r}_i) = f_b(\vec{r}_i) + [f_o(\vec{r}_k) - f_b(\vec{r}_k)]$ (kjer je v oklepaju razlika med dejansko meritvijo in vrednostjo ozadja na poziciji meritve) v $\vec{r}_i$ dobimo

$$f_a(\vec{r}) = \frac{\frac{1}{\langle \epsilon_B^2 \rangle} f_B(\vec{r}) + \frac{1}{\langle \epsilon_o^2 \rangle} \tilde{f}_o(\vec{r})}{\frac{1}{\langle \epsilon_o^2 \rangle} + \frac{1}{\langle \epsilon_B^2 \rangle}}. \quad (2.36)$$

Toda, da bi bili realistični, moramo upoštevati:

1. Meritev se v resnici nahaja pri $\vec{r}_k$, ne pri $\vec{r}_i$.
2. Vpliv meritve mora upadati z razdaljo $\|\vec{r}_i - \vec{r}_k\|$.
3. Napaka $\langle \epsilon_o^2 \rangle$ je lahko različna za različne merilne sisteme.

Zato (2.36) spremenimo v

$$f_A(\vec{r}_i) = \frac{\frac{1}{\langle \epsilon_B^2 \rangle} f_B(\vec{r}_i) + \frac{1}{\langle \epsilon_o^2 \rangle(k)} w(\|\vec{r}_k - \vec{r}_i\|) \left[f_B(\vec{r}_i) + (f_o(\vec{r}_k) - f_b(\vec{r}_k)) \right]}{\frac{1}{\langle \epsilon_B^2 \rangle} + \frac{1}{\langle \epsilon_o^2 \rangle(k)} w(\|\vec{r}_k - \vec{r}_i\|)}, \quad (2.37)$$

kjer je $w(\|\vec{r}_k - \vec{r}_i\|)$ utež (jedro), ki se zmanjšuje z naraščajočo razdaljo med meritvijo in mrežno točko. Različne vrste opazovanj imajo različne $\langle \epsilon_o^2 \rangle(k)$, saj so negotovosti meritev različne.

Robna primera.

$$w(\|\vec{r}_k - \vec{r}_i\|) = \begin{cases} 1, & \text{če } \vec{r}_k = \vec{r}_i, \\ 0, & \text{če } \|\vec{r}_k - \vec{r}_i\| \rightarrow \infty. \end{cases}$$

Tako ima meritev *popoln* vpliv, če sta lokaciji meritev in mrežna točka enaki, medtem ko imajo *zelo oddaljene* meritve zanemarljiv vpliv.

Pogosto enačbo (2.37) zapišemo v *inkrementalni obliki*:

$$f_a(\vec{r}_i) = f_b(\vec{r}_i) + \underbrace{\frac{\frac{1}{\langle \epsilon_o^2 \rangle(k)} w(\|\vec{r}_k - \vec{r}_i\|)}{\frac{1}{\langle \epsilon_B^2 \rangle} + \frac{1}{\langle \epsilon_o^2 \rangle(k)} w(\|\vec{r}_k - \vec{r}_i\|)}}_{\text{utež analize}} \left(f_o(\vec{r}_k) - f_b(\vec{r}_k) \right).$$

Ta *prirastek analize* lahko poimenujemo w_{ik} , in tako zapišemo:

$$w_{ik} = \frac{\langle \epsilon_b^2 \rangle w(\|\vec{r}_i - \vec{r}_k\|)}{\langle \epsilon_o^2 \rangle + \langle \epsilon_b^2 \rangle w(\|\vec{r}_i - \vec{r}_k\|)}.$$

V praksi to popravljanje izvedemo za *vsako* obstoječo meritev, pogosto v več “krogih” (iteracijah), pri čemer se ozadje postopoma prilagaja novim informacijam.

Modeliranje razdaljne uteži

V zgodovinskih pristopih so funkcijo $\tilde{r} = \|\vec{r}_k - \vec{r}_i\|$ modelirali na več načinov:

(a) Cressmanova shema.

$$w_{ik} = \begin{cases} \frac{R^2 - r_{ik}^2}{R^2 + r_{ik}^2}, & r_{ik}^2 \leq R_n^2, \\ 0, & r_{ik}^2 \geq R_n^2. \end{cases}$$

Tukaj je R_n podan polmer vpliva v n -ti iteraciji. Tipično R_n v naslednjih krogih zmanjšujemo (npr. od velikih proti manjšim merilom).

(b) Barnes, Sasaki in Gaussovi pristopi.

$$w_{ik}^n = \exp\left(-\frac{r_{ik}^2}{2R_n^2}\right).$$

Spet se poslužimo iterativnega postopka, pri katerem velja $R_{n+1}^2 = \gamma R_n^2$ z $\gamma \leq 1$. V začetnih korakih uporabimo široko korekcijo, v kasnejših korakih pa vedno bolj ozko.

V izvirnem delu Bergthorssona in Doosa za geopotencial Φ pri 500 hPa so ugotovili, da se utež pogosto lahko vzame kot izotropna funkcija razdalje in prezre orografske zapreke. V sodobnih sistemih uporabljamo bolj dodelane modele korelacij, a glavno vodilo ostaja: bližje meritve imajo močnejši vpliv pri korigiranju polja kot bolj oddaljene.

2.9 Nudging na primeru modela plitke vode

Sedaj ponazorimo še drugo strategijo, *nudging*, s poenostavljenim *modelom plitke vode* (angl. *shallow water model*) kot primerom.

Osnovne enačbe plitvih voda

Predstavljajmo si rezervoar tekočine s povprečno globino H . Privzemimo konstantno gostoto $\rho = \rho_0$, tako da je tok *nestisljiv* in $\nabla \cdot \vec{v} = 0$. Nadalje predpostavimo, da so vodoravne razsežnosti veliko večje od navpične ($H \ll L$) ter da je stolpec hidrostatično uravnotežen:

$$\frac{\partial p}{\partial z} = \rho_0 g.$$

Tako je tlak na poljubni višini z :

$$p(x, y, z) = p_0 - \rho_0 g z, \quad (2.38)$$

kjer je p_0 tlak na dnu. Prosto gladino označimo z $z = h(x, y, t)$, pri čemer vzamemo $p_0 = \rho_0 g (H + h')$. Tedaj je $h = H + h'$, kjer se h' spreminja v prostoru in času. Na vrhu ($z = h$) je tlak enak nič. Posledično velja:

$$p(x, y, z, t) = \rho_0 g (h(x, y, t) - z).$$

Gibalna enačba: Vodoravna gibalna enačba za vrteč se sistem plitvih voda je:

$$\frac{d\vec{v}}{dt} = -f \mathbf{k} \times \vec{v} - g \nabla_z h, \quad (2.39)$$

kjer ∇_z pomeni 2D (vodoravni) gradient pri konstantnem z . Ker $\frac{1}{\rho_0} \nabla p = g \nabla h$, v enačbi nastopa samo višina h . Posledično je $\vec{v} = \vec{v}(x, y)$. Če bi bil $f = 0$, bi odpadel Coriolisov člen.

Ker je tekočina nestisljiva, velja $\nabla \cdot \vec{v} = 0$. V kontekstu plitvih voda vertikalna hitrost w na prosti gladini $z = h$ poveže spremembe h z vodoravno divergenčnostjo. Z integracijo

$$\frac{\partial w}{\partial z} = -\left(\frac{\partial u}{\partial x} + \frac{\partial v}{\partial y}\right) = -\nabla_h \cdot \vec{v}_h$$

od $z = 0$ do $z = h$ (in z upoštevanjem $w(z = 0) = 0$ na dnu) dobimo $w(z = h) = \frac{dh}{dt}$. Tako sledi:

$$\frac{dh}{dt} = -h \nabla_h \cdot \vec{v}_h,$$

v kartezičnih koordinatah pa

$$\frac{\partial h}{\partial t} + H \left(\frac{\partial u}{\partial x} + \frac{\partial v}{\partial y} \right) = 0, \quad (2.40)$$

če zanemarimo male člene drugega reda (npr. produkt h' z $\frac{\partial u'}{\partial x}$ ipd.).

Linearizirane enačbe plitvih voda. Označimo motnje $u' = u$, $v' = v$, $h' = h$ okoli majhnega srednjega toka ali okoli $(U, V) \approx 0$. Sistem (opustimo narekovaje) postane:

$$\begin{aligned}\frac{\partial u}{\partial t} - f v + g \frac{\partial h}{\partial x} &= 0, \\ \frac{\partial v}{\partial t} + f u + g \frac{\partial h}{\partial y} &= 0, \\ \frac{\partial h}{\partial t} + H \left(\frac{\partial u}{\partial x} + \frac{\partial v}{\partial y} \right) &= 0.\end{aligned}$$

To so klasične linearne enačbe plitvih voda.

Nudging

Nudging je tehnika, pri kateri v modelne enačbe dodamo člene, ki “popravljajo” polje glede na razpoložljive meritve. Modelno stanje se z relaksacijo približuje izmerjenim vrednostim. Za plitve vode lahko to zapišemo:

$$\begin{aligned}\frac{\partial u}{\partial t} - f v + g \frac{\partial h}{\partial x} - G_u (u_{\text{obs}} - u) &= 0, \\ \frac{\partial v}{\partial t} + f u + g \frac{\partial h}{\partial y} - G_v (v_{\text{obs}} - v) &= 0, \\ \frac{\partial h}{\partial t} + H \left(\frac{\partial u}{\partial x} + \frac{\partial v}{\partial y} \right) - G_h (h_{\text{obs}} - h) &= 0.\end{aligned}$$

Tu je $G_i = \frac{1}{\tau_i}$, pri čemer je τ_i čas relaksacije. Večji G_i pomeni, da bo model hitreje “prisiljen” k opazovani vrednosti, kar lahko v prevelikih vrednostih preveč duši naravno dinamiko. Če je G_i premajhen, je vpliv meritev skoraj zanemarljiv.

Fourierjeva predstavitev in linearni sistem. Za periodične robne pogoje lahko polja razširimo v Fourierjeve vrste:

$$\begin{bmatrix} u(x, y, t) \\ v(x, y, t) \\ h(x, y, t) \end{bmatrix} = \sum_k \sum_\ell \begin{bmatrix} \hat{u}_{k\ell}(t) \\ \hat{v}_{k\ell}(t) \\ \hat{h}_{k\ell}(t) \end{bmatrix} e^{ikx} e^{i\ell y}.$$

Z opazovanimi vrednostmi storimo enako (pridobimo $\hat{u}_{k\ell}^{\text{obs}}$ ipd.). Vstavitev v linearni sistem plitkih voda z dodanim “nudgingom” (brez eksponentnih faktorjev) da:

$$\begin{aligned}\frac{d\hat{u}_{k\ell}}{dt} - f \hat{v}_{k\ell} + g(ik) \hat{h}_{k\ell} - G_u (\hat{u}_{k\ell}^{\text{obs}} - \hat{u}_{k\ell}) &= 0, \\ \frac{d\hat{v}_{k\ell}}{dt} + f \hat{u}_{k\ell} + g(i\ell) \hat{h}_{k\ell} - G_v (\hat{v}_{k\ell}^{\text{obs}} - \hat{v}_{k\ell}) &= 0, \\ \frac{d\hat{h}_{k\ell}}{dt} + H(ik \hat{u}_{k\ell} + i\ell \hat{v}_{k\ell}) - G_h (\hat{h}_{k\ell}^{\text{obs}} - \hat{h}_{k\ell}) &= 0.\end{aligned}$$

V matrični obliki:

$$\frac{\partial}{\partial t} \begin{bmatrix} \hat{u}_{k\ell} \\ \hat{v}_{k\ell} \\ \hat{h}_{k\ell} \end{bmatrix} + \underbrace{\begin{bmatrix} G_u & -f & gik \\ f & G_v & g i\ell \\ H ik & H i\ell & G_h \end{bmatrix}}_A \begin{bmatrix} \hat{u}_{k\ell} \\ \hat{v}_{k\ell} \\ \hat{h}_{k\ell} \end{bmatrix} = \begin{bmatrix} G_u \hat{u}_{k\ell}^{\text{obs}} \\ G_v \hat{v}_{k\ell}^{\text{obs}} \\ G_h \hat{h}_{k\ell}^{\text{obs}} \end{bmatrix}.$$

Sistem ima homogeno rešitev (člen, ki razpada z eigenvrednostmi iz $\det(A - \lambda I) = 0$) ki je enaka:

$$\vec{z}_h = \vec{C}_1 e^{-\lambda_1 t} + \vec{C}_2 e^{-\lambda_2 t} + \vec{C}_3 e^{-\lambda_3 t}$$

in partikulirano rešitev, ki se relaksira proti merjenim vrednostim. Lastne vrednosti λ_i so odvisne od G_u, G_v, G_h in s tem spreminjajo naravne valovne načine tega sistema. *Nudging* torej posega v dinamični razvoj z dodajanjem dušenja ali prilagoditve v smeri meritev.

Pomen. V praksi *nudging* poskrbi, da model ne zaide predaleč od meritev. Če pa izberemo prevelike vrednosti G_i , lahko premočno dušimo lastno dinamiko modela ali ga “prisilimo” v nerealistična stanja. Če so G_i premajhni, model skoraj ne izkoristi informacij iz meritev.

Povzetek ključnih točk:

- **Metoda zaporednega korigiranja** (točka 2.8) je starejši, a konceptualno enostaven pristop za združevanje ozadja in meritev. Uporablja funkcije za razdaljno uteževanje, ki se ponavljajo prek več “korakov” popravkov.
- **Pristop nudging** (točka 2.9) v dinamični model (tukaj plitvih voda) doda relaksacijske člene. V spektralnem prostoru to spremeni lastne načine sistema ter omogoči, da se modelne rešitve sproti približujejo merjenim podatkom.

Ti ideji sta podlaga za naprednejše pristope asimilacije podatkov v sodobnih numeričnih napovedih vremena, kjer se uporabljajo raznolike metode (3D/4D-Var, ansambelski Kalmanov filter, hibridni pristopi ipd.), ki pa se v osnovi še vedno naslanjajo na temeljno idejo optimalne združitve modelnih napovedi z realnimi meritvami.

Poglavje 3

Optimalno interpoliranje in opazovalni operatorji

3.1 Optimalno interpoliranje

Optimalno interpoliranje je bilo na ECMWF uporabljeno do leta 1995. Najprej obravnavamo 1D analizo za temperaturo. V OI združujemo ozadje (prvo ugibanje) in opazovanja na statistično optimalen način, pri čemer predpostavljamo, da se napake ozadja in opazovanj porazdeljujejo Gaussovo in da so njihove statistike napak znane.

Čeprav je ECMWF prešel na naprednejše sheme (npr. 3D-Var, 4D-Var in ansambelske Kalmanove filtre), ostajajo načela OI pomembna osnova za razumevanje sodobnih metod asimilacije podatkov.

3.1.1 Enodimenzionalna analiza

V enodimenzionalnem kontekstu imamo predhodno temperaturo T_B (prva ocena) in opazovano temperaturo T_o . Analizno temperaturo T_a lahko izračunamo kot uteženo linearno kombinacijo ozadja in opazovanja, pri čemer so uteži odvisne od razmerja med velikostmi varianc napak. Matematično je to zapisano kot

$$T_a = \frac{\sigma_B^2}{\sigma_B^2 + \sigma_o^2} T_o + \frac{\sigma_o^2}{\sigma_o^2 + \sigma_B^2} T_B. \quad (3.1)$$

Tukaj je σ_B^2 varianca napake ozadja (tj. pričakovana negotovost v T_B), medtem ko je σ_o^2 varianca napake opazovanja (tj. pričakovana negotovost v T_o). Zgornja enačba pove, da bo analiza bližja T_o , če je opazovanje bolj zanesljivo (nižja σ_o^2). Obratno pa bo analiza bližja T_B , če je ozadje bolj zanesljivo (nižja σ_B^2).

Naša naloga sedaj je da to razširimo v večdimenzionalni problem. Torej poskusili bomo razširiti to enodimenzionalno ogrodje v situacijo, kjer imamo več spremenljivk stanja (npr. veter, temperaturo, vlago) in več opazovanj.

3.2 Večdimenzionalni problem

V večdimenzionalnem primeru predhodna temperatura T_b postane del vektorja stanja modela $\vec{x}_B$, opazovana temperatura T_o pa del vektorja opazovanj $\vec{y}$. To pomeni, da ne gre več za eno samo skalarno vrednost: $\vec{x}_B$ lahko obsega vsa ustrezna polja modela (npr. temperaturo, komponenti vetra, specifično vlago itd.), medtem ko $\vec{y}$ vključuje vsa opazovanja, ki lahko prihajajo iz različnih instrumentov in lokacij.

Ena od zapletenosti je, da si dimenziji $\vec{x}_B$ in $\vec{y}$ pogosto nista enaki. V resnici sta velikokrat različni, ker:

- Opazovanja so prostorsko in časovno neenakomerno razporejena.
- Opazovane količine se morda neposredno ne ujemajo z modelskimi količinami.

Torej prvi razlog je ta, da so opazovanja pogosto neenakomerno porazdeljena po prostoru in času, saj so odvisna od tega, kje se nahajajo inštrumenti ali kdaj sateliti preletavajo območje. Drugi razlog pa je, da se opazovane količine (na primer radiance ali odbojnost, ki jih zaznavajo sateliti) lahko razlikujejo od osnovnih spremenljivk v modelu (npr. temperature, hitrost vetra, vlaga). Posledično moramo modelske spremenljivke ustrezno preslikati v opazovalni prostor. To preslikavo izvede *opazovalni operator*, ki ga označimo z $\mathcal{H}$.

$$\mathcal{H}(\vec{x}) \longrightarrow \vec{y}_{\text{model}},$$

Torej opazovalni operator je matematična funkcija, ki preslika modelski vektor stanja $\vec{x}$ v opazovalni prostor, torej v tisto, kar bi naši instrumenti zaznali, če bi bilo stanje atmosfere res $\vec{x}$. $\vec{y}_{\text{model}}$ so torej modelsko simulirana opazovanja, torej kaj bi opazili, če bi bila atmosfera točno takšna, kot jo opisuje $\vec{x}$. Glavna ideja je, da če imamo stanje atmosfere $\vec{x}$ (ki lahko vključuje komponente vetra, temperaturna polja, polja vlage itd.), na $\vec{x}$ uporabimo $\mathcal{H}$, da dobimo modelno ekvivalentne vrednosti opazovanj, torej $\mathcal{H}(\vec{x})$. Ta rezultat lahko nato primerjamo z dejanskim vektorjem opazovanj $\vec{y}$. V idealnem primeru, če bi bil opazovalni operator popoln in bi stanje $\vec{x}_T$ bilo resnično stanje, bi veljalo:

$$\mathcal{H}(\vec{x}_T) = \vec{y}_T,$$

kjer $\vec{x}_T$ in $\vec{y}_T$ označujeta resnično stanje in resnična opazovanja. Vendar pa se lahko pojavijo različni viri napak, med drugim napake pri rekonstrukciji, napake zaradi interpoliranja in časovne reprezentacije. V praksi ne opravimo meritev le v enem trenutku (npr. $t = 0$), temveč v majhnem časovnem oknu, na primer od -1.5 ure do $+1.5$ ure okoli časa analize. V resnici ne vzamemo zgolj meritev v času $t=0$ ampak iz intervala $-1.5h, 1.5h$, vsaj tako deluje Aladin. Opazovanja so dodeljena sredini intervala. To pomeni, da v številnih sistemih asimilacije podatkov vključimo tudi opazovanja, ki se pojavijo nekoliko pred ali po času analize, in jih (s pomočjo ustrezne časovne interpolacije) obravnavamo kot veljavna za čas analize.

Razlog zakaj preslikamo model v opazovalni prostor in ne obratno je, da so opazovanja redkejša, natančnejša in bolj lokalna, zato jih ne moreš kar enostavno razširiti na celoten model. Model ima celovito (čeprav aproksimirano) sliko celotne atmosfere, in lažje je iz te slike vzeti točke, ki ustrezajo lokacijam opazovanj. Če bi hoteli preslikati opazovanja v model, bi morali ugibati, kaj pomeni opazovana radianca ali točkovna temperatura za celo polje - to pa je bistvo asimilacije in tega ne moreš narediti predhodno.

3.2.1 Primeri opazovalnih operatorjev

Osnovni primer opazovalnega operatorja je tisti, ki modelne spremenljivke (npr. temperaturo, površinsko emisivnost, oblačnost itd.) pretvori v radiance, kar je dejanska količina, ki jo satelitski inštrument izmeri. Tak operator označimo z $\mathcal{H}$ za radianco. Če je $\vec{y}$ vektor izmerjenih radianc (kot funkcija valovne dolžine λ ali frekvence ν), $\vec{x}$ pa stanje modela (ki lahko vključuje temperaturo T , geopotencial g , temperaturo površja T_s , emisivnost ϵ , albedo a_s , oblačno vodno mešanico q_l , oblačno ledeno mešanico q_i ter delež površine, prekrite z ledom ali snegom), potem dobimo modelni ekvivalent izmerjenih radianc z izračunom:

$$L(\nu) = \int_0^\infty B(\nu, T(z)) \frac{d\tau(\nu)}{dz} dz + \epsilon_s \sigma T^4 + X. \quad (3.2)$$

V tej enačbi je $B(\nu, T)$ Planckova funkcija, podana z

$$B(\nu, T) = \frac{2h\nu^2}{c^2} \frac{1}{e^{\frac{h\nu}{k_B T}} - 1},$$

kjer je h Planckova konstanta, c hitrost svetlobe, k_B Boltzmannova konstanta, T pa temperatura. Prvi člen v enačbi za radianco predstavlja prispevek iz atmosfere same, integriran od površja do vrha atmosfere, pri čemer $\tau(\nu)$ označuje prepustnost za frekvenco ν . Vsak sloj atmosfere na višini z oddaja sevanje glede na svojo temperaturo $T(z)$, faktor $\frac{d\tau(\nu)}{dz}$ pa označuje, koliko tega sevanja pride brez absorpcije do zgornje plasti atmosfere (oziroma do satelita). Drugi člen, $\epsilon_s \sigma T^4$, predstavlja prispevek s površja Zemlje, kjer je ϵ_s emisivnost površja, σ pa Stefan–Boltzmannova konstanta. Simbol T pri tem prispevku površja pomeni posebej temperaturo površja T_s , čeprav je pogosto zapisan krajše kot T . Končno člen X zajema dodatne procese, kot so odboj in sipanje, ki lahko še dodatno spremenijo izsevano radianco.

Za primerjavo modelnih vrednosti s satelitskimi meritvami moramo torej modelna polja prepustiti operatorju $\mathcal{H}$, ki izračuna radianco. Razlike med $\mathcal{H}(\vec{x}_B)$ in opazovanimi radianci $\vec{y}$ se nato uporabijo za prilagoditev oziroma posodobitev vektorja stanja $\vec{x}_B$ v postopku asimilacije podatkov.

Da bi modelne spremenljivke, kot so temperatura, vlaga in lastnosti površja, preoblikovali v simulirano radianco, moramo oceniti ali aproksimirati zgornji integral. V praksi radiativni modeli to izvedejo s seštevanjem prispevkov iz diskretnih plasti, pri čemer vsaka plast oddaja del sevanja, ki ga nato zgornje plasti delno zaustavijo (oslabi).

3.2.2 Opazovalni operator za Aeolusove vetrne meritve v vodoravni smeri (HLOS)

Oglejmo si še en pomemben primer: satelit Aeolus, ki meri veter v vodoravni smeri projekcije vidne črte (HLOS) z Dopplerjevim lidarjem. V praksi Aeolus kroži na tak način, da je sinhroniziran s Sončevim terminatorjem in meri projekcijo vektorskega vetra. Konkretno zaznava *vodoravno komponento* vetra v smeri opazovanja (HLOS).

Matematično predpostavimo, da je dejanski vektorski veter v vodoravni ravnini $\vec{v} = (u, v)$, kjer je u zonalna (vzhod–zahod) komponenta, v pa meridionalna (sever–jug) komponenta. Aeolus ne meri celotnega vektorja $\vec{v}$, ampak zazna določeno projekcijo, označeno z $\vec{v}_{HLOS}$. Geometrijsko naj bo ϕ kot med smerjo severa in smerjo satelitskega žarka (oziroma vidno črto). Tedaj lahko jakost HLOS-vetra, ki ga satelit dejansko opazuje, zapišemo kot:

$$|\vec{v}_{HLOS}| = u \sin \phi + v \cos \phi = \mathcal{H}(u, v). \quad (3.3)$$

Z drugimi besedami, Aeolusov opazovalni operator $\mathcal{H}$ vzame modelski polji u in v ter ju projicira na vidno črto satelitskega žarka. Natančna definicija predznakov (ali bo to $u \sin \phi + v \cos \phi$ ali $u \cos \phi + v \sin \phi$) je odvisna od geometrije skeniranja satelita ter definicije kota ϕ . Ključno je, da $\mathcal{H}$ združi u in v skladno z dejansko smerjo merjenja.

Da vidimo, zakaj dobimo ravno tak projekcijski zapis, si predstavljajmo, da vidna črta satelita tvori kot ϕ glede na smer severa (ali morda vzhoda, odvisno od izbranega referenčnega koordinatnega sistema). Projekcijo vektorja $\vec{v}$ na to vidno črto dobimo z njegovim skalarnim produktom z enotskim vektorjem v smeri žarka. Če je $\hat{e}_\phi$ enotski vektor pri kotu ϕ glede na smer severa, velja:

$$\hat{e}_\phi = (\sin \phi, \cos \phi),$$

kar vodi do

$$\vec{v} \cdot \hat{e}_\phi = (u, v) \cdot (\sin \phi, \cos \phi) = u \sin \phi + v \cos \phi.$$

Tako v sistemih asimilacije podatkov, ki uporabljajo Aeolusove HLOS-meritve, modelni ekvivalent izmerjenega vetra ustreza ravno temu skalarni produktu $u \sin \phi + v \cos \phi$. To sklence naš prikaz, kako je operator $\mathcal{H}$ sestavljen za določen opazovalni sistem.

3.2.3 Še nekaj primerov opazovalnega operatorja

Interpolacija v prostoru; če imamo temperaturo v modelu na višini 850 hPa na točkah 50 km narazen, satelit pa meri neke vmes, potem $\mathcal{H}$ interpolira vrednosti na točno mesto meritve.

Interpolacija v času; če imamo opazovanje ob recimo 12:07, model pa pozna le stanje ob 12:00, bo $\mathcal{H}$ interpoliral med bližnjimi časovnimi koraki.

Trnasformacija spremenljivk; če satelit meri radianco, ne pa temperaturo, potem $\mathcal{H}$ vsebuje sevalni model, ki iz modelskih temperatur in vlage izračuna kakšno radianco bi zaznal satelit.

Povprečevanje; če instrument meri povprečje čez neko območje, recimo radar čez nek volumen, potem $\mathcal{H}$ to povprečevanje izvede nad modelskimi podatki.

3.3 Optimalna analiza

V asimilaciji podatkov želimo združiti našo najboljšo predhodno oceno atmosfere (ozadje ali prvo oceno) z razpoložljivimi opazovanji, da bi dobili optimalno *analizo*. V enodimenzionalnem primeru za temperaturo smo pokazali, kako to analizo zapišemo kot linearno kombinacijo opazovanih in predhodnih temperatur. Tukaj pa se bomo poglobili v bolj splošno, večdimenzionalno formulacijo, ki je osnova sodobnih metod asimilacije podatkov.

Začnimo z obnovo preprostejšega enodimenzionalnega pristopa. Če je T_b predhodna temperatura, T_o opazovana temperatura in T končna analizna temperatura, lahko zapišemo

$$T = \alpha T_o + \beta T_b + \gamma. \quad (3.4)$$

Konceptualno sta α in β uteži, ki ju moramo določiti, medtem ko je γ konstantni zamik, ki se lahko prav tako pojavi. Iz klasične optimalne interpolacije pogosto dobimo

$$\alpha = \frac{\sigma_B^2}{\sigma_B^2 + \sigma_o^2}, \quad \beta = \frac{\sigma_o^2}{\sigma_B^2 + \sigma_o^2}, \quad \gamma = 0,$$

kjer sta σ_B^2 in σ_o^2 varianci napak ozadja in opazovanj. V večdimenzionalnem scenariju, namesto ene same vrednosti temperature, obravnavamo vektor stanja z mnogimi spremenljivkami. Zato dobi naša analiza bolj splošno obliko

$$\vec{x}_a = \mathbf{F} \vec{x}_b + \mathbf{K} \vec{y} + \vec{c}, \quad (3.5)$$

kjer je $\vec{x}_a$ analizni vektor stanja, $\vec{x}_b$ ozadni vektor stanja, $\vec{y}$ pa vektor opazovanj, $\mathbf{F}$ je linearen operator, ki deluje na ozadje, ($\mathbf{K}$ je *Kalmanov dobitna (gain) matrika* in $\vec{c}$ je dodaten vektorski člen (podoben γ v 1D primeru). Matrikama (oziroma operatorjema) F in K ter vektorju $\vec{c}$ moramo določiti vrednosti tako, da v nekem optimalnem smislu dosežemo najboljšo analizo.

3.3.1 Predpostavke o popolnih vhidih

Najprej uvedemo poenostavitvene predpostavke, da razumemo zgradbo analizne enačbe. Domnevamo, da je opazovalni operator, ki ga označimo z $\mathcal{H}$, popoln; to pomeni, da velja $\vec{y}_T = \mathcal{H}(\vec{x}_T)$, če sta $\vec{x}_T$ in $\vec{y}_T$ resnično stanje in resnična opazovanja. Poleg tega predpostavimo (zgolj zaradi izpeljave), da sta ozadje in opazovanja brez napak. Matematično zapisano:

$$\vec{x}_b = \vec{x}_T, \quad \vec{y} = \vec{y}_T, \quad \vec{x}_a = \vec{x}_T.$$

Analiza in prognoza vremena

Te predpostavke vključimo v splošno linearno obliko. Če mora resnično stanje $\vec{x}_T$ izpolnjevati

$$\vec{x}_T = \mathbf{F} \vec{x}_T + \mathbf{K} \vec{y}_T + \vec{c},$$

in velja tudi $\vec{y}_T = \mathcal{H}(\vec{x}_T)$, potem dobimo

$$\vec{x}_T = \mathbf{F} \vec{x}_T + \mathbf{K} \mathcal{H}(\vec{x}_T) + \vec{c}.$$

Da bi bila ta enakost izpolnjena za *katerokoli* $\vec{x}_T$, mora biti konstantni člen $\vec{c}$ enak nič, hkrati pa mora veljati

$$\mathbf{I} \vec{x}_T = (\mathbf{F} + \mathbf{K} \mathcal{H}) \vec{x}_T,$$

kar pomeni

$$\mathbf{F} = \mathbf{I} - \mathbf{K} \mathcal{H},$$

kjer $\mathbf{I}$ označa identično matriko. Če to vstavimo nazaj, dobimo dobro znano obliko analize enačbe:

$$\vec{x}_a = (\mathbf{I} - \mathbf{K} \mathcal{H}) \vec{x}_b + \mathbf{K} \vec{y}. \quad (3.6)$$

Pogosto to zapišemo še kot

$$\vec{x}_a = \vec{x}_b + \mathbf{K} (\vec{y} - \mathcal{H}(\vec{x}_b)), \quad (3.7)$$

s čimer posebej poudarimo, da $\vec{x}_a$ dobimo tako, da ozadju $\vec{x}_b$ prištejemo popravek. Člen $(\vec{y} - \mathcal{H}(\vec{x}_b))$ je *inovacija* oziroma *popravek zaradi opazovanja*, saj primerja dejanska opazovanja z njihovimi modelskimi ekvivalenti. Matrika $\mathbf{K}$ je v naprednejših formulacijah (npr. Kalmanov filter) znana kot *Kalmanov dobitnik* (angl. *Kalman gain*).

3.3.2 Povezava z enodimenzionalno formulo

Spomnimo se, da lahko v 1D primeru za temperaturo zapišemo

$$T_a = T_b + \alpha(T_o - T_b),$$

kjer α deluje kot utež, ki sklaplja opazovano odstopanje $(T_o - T_b)$ v ozadje T_b . V večdimenzionalni obliki α nadomesti matrika $\mathbf{K}$, namesto skalarjev T_b in T_o pa imamo vektorja $\vec{x}_b$ in $\vec{y}$. Oblika v enačbi (3.7) ta koncept posploši na katerokoli dimenzijo in katerokoli opazovano spremenljivko.

3.3.3 Definicije napak in Taylorjeva razširitev opazovalnega operatorja

V praksi ozadje in opazovanja *niso* popolni. Da to kvantificiramo, uvedemo vektorje napak:

$$\vec{\epsilon}_a = \vec{x}_a - \vec{x}_T, \quad \vec{\epsilon}_b = \vec{x}_b - \vec{x}_T, \quad \vec{\epsilon}_o = \vec{y} - \vec{y}_T.$$

Tukaj sta $\vec{x}_T$ in $\vec{y}_T$ resnično stanje in resnična opazovanja. Običajno predpostavimo $\langle \vec{\epsilon}_b \rangle = \vec{0}$ in $\langle \vec{\epsilon}_o \rangle = \vec{0}$, kar pomeni, da sta ozadje in opazovanja v povprečju nepristranska.

Nato razmislimo o operatorju $\mathcal{H}(\vec{x}_b)$. Operator $\mathcal{H}$ je lahko nelinearen (na primer satelitski operator za radianco). Predpostavimo, da so napake v ozadju dovolj majhne, da lahko $\mathcal{H}$ lineariziramo okoli $\vec{x}_b$ z uporabo Taylorjeve ekspanzije prvega reda:

$$\mathcal{H}(\vec{x}_b) = \mathcal{H}(\vec{x}_T + (\vec{x}_b - \vec{x}_T)) \approx \mathcal{H}(\vec{x}_T) + \left(\frac{\partial \mathcal{H}}{\partial \vec{x}} \right)_{\vec{x}_b} (\vec{x}_b - \vec{x}_T),$$

kar lahko zapišemo kot

$$\mathcal{H}(\vec{x}_b) \approx \mathcal{H}(\vec{x}_T) + \mathbf{H} \vec{\epsilon}_b,$$

kjer je $\mathbf{H}$ Jakobijeva matrika (matrika parcialnih odvodov) operatorja $\mathcal{H}$, ovrednotena v $\vec{x}_b$:

$$\mathbf{H}_{ij} = \frac{\partial(\mathbf{H}_i)}{\partial x_j},$$

kjer je $i = 1, 2, \dots, N_0$ število meritev in $j = 1, 2, \dots, N$ dimenzija vektorja $\vec{x}_b$. To nato lahko vstavimo v analizno enačbo (3.7) in iz obeh strani odštejemo $\vec{x}_T$, da dobimo izraz za $\vec{\epsilon}_a$:

$$\vec{\epsilon}_a = \vec{\epsilon}_b + K(\vec{\epsilon}_o - H \vec{\epsilon}_b).$$

Ta oblika je ključna, ker nam pokaže, kako se napake v ozadju in v opazovanjih prenašajo v analizo. Če $\langle \vec{\epsilon}_b \rangle = \vec{0}$ in $\langle \vec{\epsilon}_o \rangle = \vec{0}$, sledi

$$\langle \vec{\epsilon}_a \rangle = \vec{0}.$$

V povprečju so torej tudi napake analize brez srednje vrednosti.

3.3.4 Kovarirančne matrike in minimizacija napake analize

Osnovni cilj v asimilaciji podatkov je minimizirati negotovost oziroma napako v analizi. V enodimenzionalnem primeru poskušamo minimizirati $\langle \epsilon_a^2 \rangle$, srednjo kvadratno napako analize, s prilagajanjem skalarnega dobitnika α . V večdimenzionalnem primeru se to posploši na minimizacijo neke mere kovariance napake analize.

Če je $\vec{x}$ nek vektor, je njegova kovariančna matrika $\mathbf{C}$ definirana kot

$$\mathbf{C} = \langle (\vec{x} - \langle \vec{x} \rangle)(\vec{x} - \langle \vec{x} \rangle)^T \rangle.$$

V kontekstu asimilacije podatkov definiramo kovariančno matriko napake analize kot

$$\mathbf{C}_a = \langle \vec{\epsilon}_a \vec{\epsilon}_a^T \rangle.$$

Iz linearne dela

$$\vec{\epsilon}_a = (\mathbf{I} - \mathbf{K} \mathbf{H}) \vec{\epsilon}_b + \mathbf{K} \vec{\epsilon}_o,$$

in ob predpostavki, da napake v ozadju $\vec{\epsilon}_b$ niso korelirane z napakami v opazovanjih $\vec{\epsilon}_o$, dobimo

$$\mathbf{C}_a = (\mathbf{I} - \mathbf{K} \mathbf{H}) \langle \vec{\epsilon}_b \vec{\epsilon}_b^T \rangle (\mathbf{I} - \mathbf{K} \mathbf{H})^T + \mathbf{K} \langle \vec{\epsilon}_o \vec{\epsilon}_o^T \rangle \mathbf{K}^T.$$

Pri številnih izpeljavah uvedemo oznaki $B = \langle \vec{\epsilon}_b \vec{\epsilon}_b^T \rangle$ za kovariančno matriko napak ozadja ter $R = \langle \vec{\epsilon}_o \vec{\epsilon}_o^T \rangle$ za kovariančno matriko napak opazovanj. Teda j dobimo naslednji izraz:

$$\mathbf{C}_a = (\mathbf{I} - \mathbf{K} \mathbf{H}) \mathbf{B} (\mathbf{I} - \mathbf{K} \mathbf{H})^T + \mathbf{K} \mathbf{R} \mathbf{K}^T.$$

Da bi našli najboljši K , zahtevamo, da K minimizira skupno velikost $\mathbf{C}_a$. Matematično pogosto minimiziramo $\text{tr}(\mathbf{C}_a)$, sled (angl. *trace*) matrike $\mathbf{C}_a$, ker je sled kovariančne matrike vsota varianc vseh komponent napake. Če odvajamo $\text{tr}(\mathbf{C}_a)$ po K in postavimo odvod enak nič, dobimo izraz za optimalni K :

$$K = B H^T (H B H^T + R)^{-1}. \quad (3.8)$$

Ta rezultat je neposredni večdimenzionalni analog enodimenzionalnega dobitnika. V skalarni obliki to daje:

$$\langle \epsilon_a^2 \rangle = (1 - \alpha)^2 \langle \epsilon_b^2 \rangle + \alpha^2 \langle \epsilon_o^2 \rangle,$$

kar minimiziramo v:

$$\alpha = \frac{\langle \epsilon_b^2 \rangle}{\langle \epsilon_b^2 \rangle + \langle \epsilon_o^2 \rangle}.$$

3.3.5 Alternativna oblika Kalmanove uteži in kovariančna matrika napak analize

Kalmanovo utež v enačbi (3.8) lahko zapišemo tudi v alternativni obliki. Tako, da z obeh strani množimo z $(B^{-1} + H^T R^{-1} H)$ na ustrezen način in opravimo algebrske transformacije, dobimo

$$K = (B^{-1} + H^T R^{-1} H)^{-1} H^T R^{-1}.$$

Če ta izraz vstavimo v analizo enačbo ali v definicijo $\vec{\epsilon}_a = \vec{\epsilon}_b + \mathbf{K}(\vec{\epsilon}_o - \mathbf{H}\vec{\epsilon}_b)$ dobimo:

$$\vec{\epsilon}_a + (\mathbf{B}^{-1} + \mathbf{H}^T R^{-1} H)^{-1} H^T R^{-1} (\vec{\epsilon}_o - H\vec{\epsilon}_b),$$

če v zgornji enačbi izpostavimo $(B^{-1} + H^T R^{-1} H)^{-1}$ bomo dobili:

$$\vec{\epsilon}_a = (B^{-1} + H^T R^{-1} H)^{-1} (B^{-1} \vec{\epsilon}_b + H^T R^{-1} \vec{\epsilon}_o)$$

in s tem lahko izračunamo tudi kovariančno matriko napak analize $\mathbf{C}_a = \langle \vec{\epsilon}_a \vec{\epsilon}_a^T \rangle$. Ob predpostavki, da velja $\langle \vec{\epsilon}_b \vec{\epsilon}_o^T \rangle = 0$, dobimo zelo eleganten rezultat:

$$\mathbf{C}_a = (B^{-1} + H^T R^{-1} H)^{-1},$$

ki je pogosto zapisan tudi kot

$$A = (B^{-1} + H^T R^{-1} H)^{-1},$$

kjer $A = \langle \vec{\epsilon}_a \vec{\epsilon}_a^T \rangle$ označuje kovariančno matriko napak analize. Ta formula pokaže, da lahko A izračunamo, če sta B in R znani, *pod pogojem*, da lahko obvladamo inverze velikih dimenzij. V praksi so za globalne modele z visoko ločljivostjo dimenzije B reda $10^9 \times 10^9$, kar je nemogoče shraniti ali eksplicitno invertirati. Zato se v operativni asimilaciji podatkov uvažajo obsežne aproksimacije.

3.3.6 Interpretacija in praktične omejitve

Glavni teoretični zaključek je, da je optimalen način kombiniranja $\vec{x}_b$ in $\vec{y}$, če sta B in R popolnoma znana, določen s Kalmanovim dobitnikom K iz enačbe (3.8), medtem ko je najboljša mogoča kovariančna matrika napak analiznega stanja $A = (B^{-1} + H^T R^{-1} H)^{-1}$. Ta izpeljava pa predpostavlja, da sta B in R točno specificirani in da lahko obvladamo obsežne matrične operacije.

V resnici je natančen izračun B^{-1} za model z dimenzijo reda 10^9 popolnoma neizvedljiv. Sodobni sistemi asimilacije podatkov se zato zanašajo na približke ali metode z zmanjšano rango, ali pa na ansambelske pristope (ansambelski Kalmanov filter, ansambelske variacijske metode), ki oceno B pridobijo iz omejenega ansambla napovedi. Tudi z aproksimacijami ostaja osrednja teoretska struktura – enačbi za K in $\mathbf{C}_a$ – temeljno vodilo.

Podobno ima kovariančna matrika napak opazovanj R več prispevkov. Lahko jo zapišemo kot:

$$R = R_i + R_r + R_h,$$

kjer R_i predstavlja instrumentalno napako (šum merilne naprave), R_r napako reprezentativnosti (zaradi procesov pod mrežno celico, lokalnih variacij, ki jih modelska ločljivost ne zajame), R_h pa vključuje dodatne napake iz samega opazovalnega operatorja, na primer aproksimacije pri radiativnem prenosu ali napake modela naprej. Pogosta dodatna predpostavka je, da so napake opazovanj nekorelirane med različnimi postajami ali piksli, kar naredi R diagonalno. Ta predpostavka je vprašljiva pri nekaterih satelitskih inštrumentih, ki merijo prekrivajoča se območja, a je lahko približno veljavna za številna klasična *in-situ* opazovanja.

Zato, čeprav je teorija tukaj predstavljena v svoji najpreprostejši obliki, tvori osnovo za širok nabor variacijskih in Kalmanov-filter metod, ki se danes uporabljajo po vsem svetu za

napovedovanje vremena. Pojasnjuje, zakaj so stanja analize $\vec{x}_a$ pogosto izračunana kot ozadna stanja z dodatkom popravkov, sorazmernih z odstopanji opazovanj, in kako se dobitnik K določi iz medsebojnega vpliva med B , H in R .

Na kratko so glavni poudarki naslednji. Prvič, univariatno interpolacijsko formulo razširimo v več dimenzij, tako da dopustimo, da je dobitnik matrika. Drugič, optimalna matrika dobitnika K izvira iz minimizacije sledu kovariančne matrike napak analize. Tretjič, kovariančno matriko napak analize A lahko jedrnato izrazimo z B in R , kar da teoretično optimalno oceno, kako naj se napake analize porazdelijo po modelskih spremenljivkah. In končno, v operativnih sistemih moramo te formule približati, da se spoprimemo z izjemno velikostjo dimenzij v sodobnih modelih za numerično napovedovanje vremena, a kljub temu ostajamo pri načelih, ki so tukaj opisana.

Poglavje 4

Struktura kovariančnih matrik v asimilaciji podatkov

V prejšnjem poglavju smo predstavili enačbo za optimalno analizo

$$\vec{x}_a = \vec{x}_b + K(\vec{y} - \mathcal{H}(\vec{x}_b))$$

in podrobneje preučili Kalmanov dobitnik K . Zdaj bomo raziskali sestavne dele K v še večji globini, še posebej vlogo kovariančne matrike napak opazovanj R in kovariančne matrike napak ozadja B . Pokazali bomo tudi, kako je lahko B strukturirana in kako bi lahko v praksi ocenili njene elemente.

4.1 Kovariančna matrika napak opazovanj R

Spomnimo se, da $R = \langle \epsilon_o \epsilon_o^T \rangle$ označuje kovariančno matriko napak opazovanj. Zaradi enostavnosti pogosto privzamemo, da je diagonalna, kar pomeni, da so napake v opazovanjih nekorelirane med različnimi meritvami oziroma različnimi opazovalnimi platformami (na primer med različnimi postajami ali različnimi satelitskimi kanali). Konkretno lahko diagonalni R zapišemo kot

$$R = \begin{bmatrix} \sigma_{o1}^2 & 0 & 0 & \cdots \\ 0 & \sigma_{o2}^2 & 0 & \cdots \\ 0 & 0 & \sigma_{o3}^2 & \cdots \\ \vdots & \vdots & \vdots & \ddots \end{bmatrix},$$

kjer so $\sigma_{o1}^2, \sigma_{o2}^2, \dots, \sigma_{oN_0}^2$ variance posameznih napak opazovanj, N_0 pa je skupno število opazovanj v vektorju $\vec{y}$. Ta predpostavka o nekoreliranih napakah (tako da so členi zunaj diagonale enaki nič) je včasih smiselna za konvencionalna površinska ali radiosondna opazovanja, medtem ko je za satelitske podatke lahko manj veljavna, saj imajo sosednji piksli ali kanali pogosto prekrivajoča se vidna polja.

Diagonalni elementi v R pogosto zapišemo kot σ_{oi}^2 , da poudarimo, da gre za *variance napak*. V tipični shemi asimilacije podatkov so σ_{oi}^2 določene glede na lastnosti instrumenta (na primer nominalno standardno napako določenega radiometra), plus dodatne prispevke zaradi napak reprezentativnosti in napak v prednjem operatorju $\mathcal{H}$. Če je R res diagonalna, je računanje R^{-1} enostavno:

$$R^{-1} = \text{diag}(\sigma_{o1}^{-2}, \sigma_{o2}^{-2}, \dots, \sigma_{oN_0}^{-2}).$$

Kot smo videli, se R^{-1} pojavi v formuli za Kalmanov dobitnik $K = B H^T (H B H^T + R)^{-1}$ oziroma v alternativni obliki $K = (B^{-1} + H^T R^{-1} H)^{-1} H^T R^{-1}$. Zato je pri asimilaciji podatkov velikega obsega dejstvo, da je R diagonalna, pomembno poenostavitev pri izračunu.

4.2 Kovariančna matrika napak ozadja B

Nasprotno je kovariančna matrika napak ozadja $B = \langle \epsilon_b \epsilon_b^T \rangle$ običajno zelo velika, poleg tega pa lahko izkazuje zapletene prostorske in medspremenljivke korelacije. Že prej smo opozorili, da je shranjevanje ali invertiranje B v realnih operativnih primerih (kjer lahko dimenzija $\bar{x}_b$ preseže 10^9) daleč zunaj dosega trenutnih računalniških zmožnosti. Zato se v praktičnih sistemih asimilacije podatkov pogosto zanašamo na približne oblike B ali na ansambelske pristope, pri katerih ni treba izrecno tvoriti celotne kovariančne matrike.

Kljub temu, da ponazorimo strukturo B , si lahko zamislimo preprost primer. Denimo, da imamo majhno domeno modela, ki obsega tri mrežne točke, x_1, x_2 in x_3 . V vsaki točki sledimo trem spremenljivkam: zonalni komponenti vetra u , meridionalni komponenti vetra v in geopotencialu Φ . Skupna dimenzija stanja je tedaj 9, kajti obstajajo tri lokacije in tri spremenljivke na lokaciji. Posledično je B matrika velikosti 9×9 . Simbolično:

$$B = \langle \epsilon_b \epsilon_b^T \rangle \implies \dim(B) = 9 \times 9.$$

Napake vsake spremenljivke na vsaki mrežni točki lahko označimo tako: $\epsilon_{u_1}, \epsilon_{v_1}, \epsilon_{\Phi_1}$ za prvo mrežno točko, $\epsilon_{u_2}, \epsilon_{v_2}, \epsilon_{\Phi_2}$ za drugo itd. Potem je B lahko shematsko zapisana kot:

$$\mathbf{B} = \begin{bmatrix} \langle \epsilon_{u_1}^2 \rangle & \langle \epsilon_{u_1} \epsilon_{u_2} \rangle & \langle \epsilon_{u_1} \epsilon_{u_3} \rangle & \cdots & & & & & \\ \langle \epsilon_{u_2} \epsilon_{u_1} \rangle & \langle \epsilon_{u_2}^2 \rangle & \langle \epsilon_{u_2} \epsilon_{u_3} \rangle & \cdots & & & & & \\ \langle \epsilon_{u_3} \epsilon_{u_1} \rangle & \langle \epsilon_{u_3} \epsilon_{u_2} \rangle & \langle \epsilon_{u_3}^2 \rangle & \cdots & & & & & \\ \langle \epsilon_{u_1} \epsilon_{v_1} \rangle & \langle \epsilon_{u_2} \epsilon_{v_1} \rangle & \langle \epsilon_{u_3} \epsilon_{v_1} \rangle & \langle \epsilon_{v_1}^2 \rangle & \cdots & & & & \\ \vdots & \vdots & \vdots & \vdots & \ddots & & & & \\ \vdots & \vdots & \vdots & \vdots & & \ddots & & & \\ & & & & & & \langle \epsilon_{\Phi_1}^2 \rangle & & \\ & & & & & & & \langle \epsilon_{\Phi_2}^2 \rangle & \\ & & & & & & & & \langle \epsilon_{\Phi_3}^2 \rangle \end{bmatrix}. \quad (4.1)$$

kjer imamo na primer $\langle \epsilon_{u_1} \epsilon_{v_1} \rangle, \langle \epsilon_{u_1} \epsilon_{\Phi_1} \rangle$ ipd. v zunajdiagonalnih blokih (ki tukaj niso vsi nazorno prikazani). Izstopajo naslednje ključne točke:

Simetrija. Matrika B je simetrična: $b_{ij} = b_{ji}$. To sledi iz definicije kovariančne matrike.

Diagonalni elementi. Na glavni diagonalni so *variance napak*, na primer $\langle \epsilon_{u_1}^2 \rangle, \langle \epsilon_{v_2}^2 \rangle, \langle \epsilon_{\Phi_3}^2 \rangle$ in tako naprej. Te določajo velikost napake ozadja za vsako spremenljivko na vsaki lokaciji.

Zunajdiagonalni elementi. Zunajdiagonalni elementi določajo *kovariance* (in s tem korelacije) med različnimi spremenljivkami v modelu ter med napakami na različnih mrežnih točkah. Ti zunanji elementi imajo bistveno vlogo, saj kodirajo, kako neko opazovanje na eni lokaciji vpliva na analizo v sosednjih ali dinamično povezanih lokacijah. Na primer, če sta ϵ_{u_1} in ϵ_{u_2} močno korelirani, bo opazovanje u na mrežni točki 1 popravilo tudi u na mrežni točki 2. Na primer, če v dinamiki modela velja $u = -\frac{1}{f} \frac{\partial \Phi}{\partial y}$, so napake pogosto povezane z $\epsilon_u = -\frac{1}{f} \frac{\partial \epsilon_\Phi}{\partial y}$.

Blokovna zgradba. Pogosto govorimo o blokovnih diagonalskih podmatrikah, ki ustrezajo korelacijam iste spremenljivke prek različnih mrežnih točk (včasih imenovanim avtokovariante), kakor tudi o zunajblokovnih podmatrikah, ki zajemajo korelacije med različnimi spremenljivkami. Na primer, napake v u so lahko korelirane z napakami v v , če jih modelske enačbe dinamično povezujejo (denimo z geostrofsko ali hidrostatno uravnoteženostjo).

4.3 Korelacije napak v B

4.3.1 Avtokorelacijske funkcije

Kovariančna matrika napak ozadja B mora določati, kako so napake v isti spremenljivki na različnih mrežnih točkah medsebojno povezane. Pogosto uvedemo neko *avtokorelacijsko funkcijo*, ki upada z razdaljo. Denimo, da razmišljamo o napaki na dveh mrežnih točkah i in j za isto spremenljivko, recimo u . Označimo $\epsilon_{B,i} = x_i^{\text{FC}} - x_i^A$, če definiramo napako s primerjavo kratkoročne napovedi z analizo, ali pa s primerjavo dveh napovedi različnih dolžin, ki sta veljavni ob istem času. Formalno bi lahko zapisali:

$$\epsilon_{B,i} = x_i^{48\text{h FC}} - x_i^{24\text{h FC}},$$


ali

$$\epsilon_{B,i} = x_i^{24\text{h FC}} - x_i^A,$$

odvisno od konkretne strategije ocenjevanja. V obeh primerih podobno definiramo $\epsilon_{B,j}$ na mrežni točki j . Nato lahko izračunamo vzorčno kovarianco

$$\langle \epsilon_{B,i} \epsilon_{B,j} \rangle$$

prek številnih primerov (npr. številnih parov napovedi in analiz). Če te vzorčne kovariance (oziroma korelacije) prikažemo kot funkcijo razdalje med točkama i in j , pogosto ugotovimo, da se korelacije začnejo blizu 1 pri ničelni razdalji in upadejo k 0 pri velikih razdaljah, kot je shematsko ponazorjeno na Sliki 4.1. Na sliki vidimo avtokorelacijsko funkcijo Gaussove oblike za spremenljivki zonalnega vetra na višini 850 hPa in 200 hPa. Vidimo, da so za vetrove v višji atmosferi napake povezane nad večjim obsegom kot v spodnji atmosferi. To je posledica tega, da je zračni tok v zgornji atmosferi veliko manj spremenljiv kot v spodnji, kjer se lahko križa z orografijo.



Slika 4.1: Avtokorelacijska funkcija med točkami. Gledamo zonalni veter na višini 850 hPa in 200 hPa.

Preprost analitični zapis za izotropno, homogeno korelacijsko funkcijo je Gaussova oblika:

$$\mu_{ij} = \exp\left(-\frac{r_{ij}^2}{2\lambda^2}\right),$$

kjer je r_{ij} razdalja med mrežnima točkama i in j , λ pa značilna dolžina korelacije (včasih imenovana tudi dekoracijski polmer). Bolj zapletene oblike lahko upoštevajo anizotropijo ali nehomogenost, na primer različne korelacijske dolžine v x - in y -smeri ali odvisnost λ od zemljepisne širine. Ključno dejstvo je, da *avtokorelacijske funkcije* določajo, kako se popravke odstopanja (inovacija) na eni lokaciji razširi na druge lokacije med posodobitvijo analize.

4.3.2 Razcep na variance in korelacije

Zelo uporabna lastnost kovariančnih matrik je ta, da lahko vsako kovarianco b_{ij} zapišemo kot produkt standardnega odklona in korelacijskega koeficienta. Natančneje, za kovariančno matriko napak B lahko zapišemo:

$$B = \sqrt{D} C \sqrt{D},$$

kjer sta:

- D diagonalna matrika varianc,

$$D = \text{diag}(\langle \epsilon_{u_1}^2 \rangle, \langle \epsilon_{u_2}^2 \rangle, \dots, \langle \epsilon_{\Phi_3}^2 \rangle),$$

- C matrika *korelacij*:

$$C = \begin{bmatrix} \mu_{u_1 u_1} & \mu_{u_1 u_2} & \cdots & \mu_{u_1 \Phi_3} \\ \mu_{u_2 u_1} & \mu_{u_2 u_2} & \cdots & \mu_{u_2 \Phi_3} \\ \vdots & \vdots & \ddots & \vdots \\ \mu_{\Phi_3 u_1} & \mu_{\Phi_3 u_2} & \cdots & \mu_{\Phi_3 \Phi_3} \end{bmatrix}.$$

Konkretno, če je $b_{ij} = \langle \epsilon_i \epsilon_j \rangle$, potem definiramo

$$d_{ii} = b_{ii} = \langle \epsilon_i^2 \rangle,$$

ter

$$\mu_{ij} = \frac{b_{ij}}{\sqrt{b_{ii}} \sqrt{b_{jj}}}.$$

Tako je $C = (\mu_{ij})$ matrika korelacijskih koeficientov, pri katerih vrednosti ležijo med -1 in $+1$, $D = \text{diag}(d_{11}, d_{22}, \dots)$ pa je diagonalna varianc. Razcep $B = \sqrt{D} C \sqrt{D}$ je uporaben, ker loči *variance* (velikost napak) od *korelacij* (kako napake soodvisno nihajo med lokacijami ali spremenljivkami). V praksi pogosto določimo *korelacijski model* (npr. Gaussov prostorski upad) in *model varianc* (ocenjen iz ansambelskega razprševanja ali razlik med napovedjo in analizo), nato pa iz tega sestavimo B .

4.3.3 Medspremenljivkine kovariance

Medtem ko avtokorelacijske funkcije opisujejo, kako so napake v isti spremenljivki (npr. u) povezane prek domene, B vsebuje tudi kovariance med različnimi spremenljivkami. Na primer, $\langle \epsilon_u \epsilon_\Phi \rangle$ je lahko neničelna, če model zagotavlja neko fizično povezavo med vetrom in geopotencialom (na primer geostrofijo). Če iz dinamičnih enačb sledi $u \approx -\frac{1}{f} \partial \Phi / \partial y$, so lahko tudi njune napake korelirane:

$$\epsilon_u \approx -\frac{1}{f} \frac{\partial \epsilon_\Phi}{\partial y}.$$

Te medspremenljivkine kovariance so bistvene, ker določajo, kako opazovanja ene spremenljivke lahko popravijo tudi druge spremenljivke. Na primer, ena sama meritvena sonda temperature lahko posredno da informacije o tlaku ali geopotencialu, če so pripadajoče napake med seboj korelirane. To je temelj *večdimenzionalne* asimilacije podatkov, kjer B kodira fizične povezave, da analiza enega polja dobi korist tudi iz opazovanj drugega.

4.4 Pogled naprej

Na kratko, R je pogosto lažje obravnavati, če je diagonalna (ali blokovno diagonalna), ker je njen inverz R^{-1} enostavno izračunati. Nasprotno pa je B lahko izjemno velika in zapletena, saj povzema prostorske in medspremenljivkine korelacije pri napakah ozadja. Kljub temu je razumevanje strukture B in tega, kako jo približati ali parametrizirati, ključno, ker Kalmanov dobitnik bistveno temelji na B prek zveze $K = B H^T (H B H^T + R)^{-1}$. V naslednjih delih zapiskov bomo raziskali, kako v realnih sistemih asimilacije podatkov izrabimo te korelacijske strukture in kako se napredne metode soočajo z računsko zahtevnostjo, ki jo predstavljajo visokodimenzionalne kovariančne matrike.

4.4.1 Medspremenljivkine kovariance in uteženi popravki

Že smo opozorili, da če polji vetra in geopotenciala zadoščata dinamičnemu ravnovesju oblike

$$u = -\frac{1}{f} \frac{\partial \Phi}{\partial y}, \quad v = \frac{1}{f} \frac{\partial \Phi}{\partial x}.$$

lahko pričakujemo, da bodo tudi *napake* v teh poljih, ϵ_u in ϵ_Φ , kazale sorodno strukturo korelacij. Z drugimi besedami, če je fizikalni odnos med u in Φ podan z zgornjo enačbo, potem naj bi motnje ali napake v Φ povzročale ustrezne napake v u . To načelo pojasnjuje, zakaj so *medspremenljivkine kovariance* v kovariančni matriki napak ozadja B pomembne za širjenje popravkov opazovanj na dinamično skladen način.

Povezovanje kovarianc med različnimi spremenljivkami

Razmislimo o kovariancah med ϵ_{u_i} in ϵ_{u_j} oziroma, bolj splošno, med napakami različnih spremenljivk, kot sta ϵ_{u_i} in ϵ_{v_j} ali ϵ_{Φ_i} in ϵ_{Φ_j} . Še posebej, če so komponente vetra povezane z geopotencialom prek približne geostrofije, pričakujemo:

$$\epsilon_u \approx -\frac{1}{f} \frac{\partial \epsilon_\Phi}{\partial y}, \quad \epsilon_v \approx \frac{1}{f} \frac{\partial \epsilon_\Phi}{\partial x},$$

vsaj lokalno, in zato pričakujemo neničelne korelacije med ϵ_u , ϵ_v in ϵ_Φ . Denimo, da zapišemo:

$$\langle \epsilon_{u_i} \epsilon_{v_j} \rangle = \left\langle -\frac{1}{f_i} \frac{\partial \epsilon_{\Phi_i}}{\partial y_i} \cdot \frac{1}{f_j} \frac{\partial \epsilon_{\Phi_j}}{\partial x_j} \right\rangle.$$

Nato lahko trdimo, da sta ϵ_{Φ_i} in ϵ_{Φ_j} nekorelirani, če sta $i \neq j$ in sta točki i, j dovolj oddaljeni, medtem ko pri bližnjih mrežnih točkah lahko pride do medsebojnih korelacij. Poenostavitev omogoči, da izločimo faktorja $1/f_i$ in $1/f_j$ ter v operatorju za kovarianco izrazimo parcialne odvode:

$$\langle \epsilon_{u_i} \epsilon_{v_j} \rangle = -\frac{1}{f_i} \frac{1}{f_j} \left\langle \frac{\partial \epsilon_{\Phi_i}}{\partial y_i} \frac{\partial \epsilon_{\Phi_j}}{\partial x_j} \right\rangle$$

in ob ustreznih predpostavkah o gladkosti to povežemo z drugim odvodom in lahko zapišemo:

$$\langle \epsilon_{u_i} \epsilon_{v_j} \rangle = -\frac{1}{f_i} \frac{1}{f_j} \frac{\partial^2 \langle \epsilon_{\Phi_i} \epsilon_{\Phi_j} \rangle}{\partial y_i \partial x_j},$$

kjer je $\langle \epsilon_{\Phi_i} \epsilon_{\Phi_j} \rangle$ povezano z b_{ij} in μ_{ij} (koeficientom korelacije), pomnoženo z variancami, kot videno malo prej, kjer je veljalo da lahko elemente za kovariančno matriko napak $\mathbf{B}$ zapišemo kot:

$$b_{ij} = \langle \epsilon_i \epsilon_j \rangle$$

$$b_{ij} = \mu_{ij} \sqrt{b_{ii}} \sqrt{b_{jj}}$$

in lahko to vstavimo v izraz in dobimo:

$$\langle \epsilon_{u_i} \epsilon_{v_j} \rangle = -\frac{1}{f_i} \frac{1}{f_j} \frac{\partial^2 \mu_{ij}}{\partial y_i \partial x_j} \sqrt{\langle \epsilon_{u_i}^2 \rangle} \sqrt{\langle \epsilon_{v_j}^2 \rangle}.$$

Vemo pa, da lahko napake komponent vetra povežemo z napakami geopotenciala kot:

$$\sqrt{\langle \epsilon_{u_i}^2 \rangle} = \frac{1}{f_i} \sqrt{\langle \epsilon_{\Phi_i}^2 \rangle}, \quad \sqrt{\langle \epsilon_{v_j}^2 \rangle} = \frac{1}{f_j} \sqrt{\langle \epsilon_{\Phi_j}^2 \rangle},$$

tako da lahko koeficient korelacije ρ_{uv} zapišemo kot

$$\rho_{uv} = \frac{\langle \epsilon_{u_i} \epsilon_{v_j} \rangle}{\sqrt{\langle \epsilon_{u_i}^2 \rangle} \sqrt{\langle \epsilon_{v_j}^2 \rangle}} = \frac{\partial^2 \mu_{ij}}{\partial y_i \partial x_j}.$$


Na ta način vidimo, kako lahko korelacija napak geopotenciala μ_{ij} , ob predpostavkah geostrof-skega tipa, povzroči medsebojne korelacije med ϵ_u in ϵ_v . Posledično bodo spremembe Φ v analizi vodile k *uravnoveženim* spremembam v u in v .

$$\rho_{\Phi_i \Phi_j} = \mu_{ij}, \quad \rho_{\Phi_i u_j} = -\frac{\partial \mu_{ij}}{\partial y_i}, \quad \rho_{u_i \Phi_j} = -\frac{\partial \mu_{ij}}{\partial y_j},$$

in podobno za v . Ta razmerja zagotavljajo, da se morebitno popravilo v Φ prelije v skladna popravila polja vetra.

Primeri uravnoveženih popravkov

Primer 1: Opazovanje geopotenciala v sredini domene. Ponazorimo, kako lahko opazovanja ene spremenljivke vplivajo na druge spremenljivke na prostorsko skladen in fizično uravnovežen način. Denimo, da asimiliramo opazovanje geopotenciala Φ v središču domene, ki se razteza od $-\sqrt{2} \lambda_\phi$ do $+\sqrt{2} \lambda_\phi$ v obeh smereh x in y . Korelacijska zgradba, ki jo uporabimo, je taka, da so razdalje reda velikosti λ_ϕ bistveno pomembne.




Slika 4.2: Shema domene, ki sega od $-\sqrt{2} \lambda_\phi$ do $+\sqrt{2} \lambda_\phi$. V središču (označeno z rdečim "X") vnesemo opazovanje geopotenciala, ki povzroči spremembo geopotencialnega polja (oranžne krivulje) in s tem ustrezno prilagoditev smeri in velikosti vetra. Na sliki so nakazani večji gradienti geopotenciala severno in manjši južno od opazovanja ter podobna prilagoditev zonalnih in meridionalnih vetrov (modre puščice).

Slika 4.2 prikazuje razširitev popravkov v Φ okoli točke opazovanja. Avtokorelacije $\rho_{\Phi\Phi}$ se morda pokažejo kot koncentrični krogi, če je korelacijska funkcija izotropna, kar pomeni, da je popravek v geopotencialu največji pri lokaciji opazovanja in da radialno pojema.

Če zdaj pogledamo, kako enako opazovanje geopotenciala vpliva na zonalni veter u , opazujemo $\rho_{\Phi u}$. Kot je ponazorjeno na Sliki 4.2, lahko opazimo pozitivne korelacije severno od opazovalne točke in negativne južno. To odraža dejstvo, da povečan geopotencial v središču lahko pomeni močnejši gradient Φ v smeri y na severu in posledično večji negativni $\partial\Phi/\partial y$ na tistem območju (za severno hemisfero z $f > 0$ velja $u \approx -\frac{1}{f} \frac{\partial\Phi}{\partial y}$). Kot rezultat bo popravek v analizi za u severno od opazovalne točke pozitiven, južno pa negativen. Podoben argument velja za $\rho_{\Phi v}$, ki lahko pokaže dipolno zgradbo v smeri osi x , kar ponazarja, kako se gradient Φ v smeri x povezuje z v .

Skratka, *eno* samo opazovanje geopotenciala spremeni Φ po domeni v skladu s korelacijsko funkcijo, hkrati pa ustvari popravke vetra, ki upoštevajo geostrofsko ravnovesje. Tako dobimo fizično skladen popravek analize.



Slika 4.3: Devet panelov, ki prikazujejo raznolike prostorske korelacijske strukture napak med geopotencialom ϕ in komponentama vetra u , v . Vsak panel prikazuje pare spremenljivk, npr. $\phi\phi$, ϕu , ϕv , $u\phi$, uu , uv , $v\phi$, vu , vv . Pozitivne vrednosti korelacije so označene s “+” (oziroma pozitivnimi konturami, npr. 0.4 ali 0.8), negativne z “-” (npr. -0.4). Točnost vrednosti (0.4, 0.8 ipd.) je primer simbolnega praga, ki prikazuje amplitude korelacije.

Primer 2: Podrobnosti korelacij v devetih panelih Slika 4.3 prikazuje značilne korelacijske vzorce za devet kombinacij spremenljivk. Vsak kvadrat prikazuje, kako se napaka ene spremenljivke v središču domene (npr. geopotenciala) širi na isto spremenljivko v sosednjih točkah (avtokorelacija) ali na drugo spremenljivko (prekrižna korelacija). V nadaljevanju so opisani posamezni paneli in zakaj se pojavljajo tipične oblike “dipolov” (dvojnim znamenjem) ali “kvadripolov” (štiri področja različnih znamenj).

V panelu $\phi\phi$ (zgoraj levo) vidimo približno krožno ali eliptično razporeditev pozitivnih korelacij. Gre za avtokorelacijo geopotenciala, pri čemer v preprostem modelu ta pogosto velja,

da je v središču najmočnejša korelacija (lahko 1 ali 0.8) ter se navzven manjša. Negativne vrednosti se tu ponavadi ne pojavijo, ker navadno privzamemo monotono padajočo korelacijsko funkcijo.

V panelu ϕu (zgoraj na sredini) se opazi pas pozitivne korelacije nad središčem in pas negativne korelacije pod središčem. To sledi iz zveze za $u = -\frac{1}{f} \frac{\partial \Phi}{\partial y}$. Kadar geopotencial severno od središča naraste, se gradient okrepi, kar vodi v večji u , kar je tu upodobljeno s pozitivno vrednostjo. Južno od središča se gradient zmanjša, zato je korelacija tam negativna.

Panel ϕv (zgoraj desno) prikazuje podobno razdeljenost, a v smeri vzhod–zahod, saj $v = \frac{1}{f} \frac{\partial \Phi}{\partial x}$. Če se geopotencial zahodno od središča poveča, bo ta rast vrednosti vodila v večji meridionalni veter, vzhodno od središča pa obratno. To povzroča “dipol” z nasprotnimi znamenji.

V panelu $u\phi$ (sredaj levo) gre načeloma za simetričen odsev situacije ϕu . Ko v matriki kovarianc veljajo simetrični pogoji, velja $\rho_{u\phi} = \rho_{\phi u}$. Profil krivin je torej podoben, le da so vrisane malo drugače glede na grafično konvencijo.

Panel uu (sredaj v sredini) prikazuje avtokorelacijo napak zonalnega vetra. V središču je pogosto izrazit pozitivni maksimum, ker je napaka v točki najmočnejša, obrobje pa lahko kaže šibkejšo pozitivno in včasih negativno lobuse (prikazano z -0.4 zgoraj, -0.4 spodaj). Razlaga je, da če na sredini domene povečamo u , ga bo ozadni model v nekaterih območjih nekoliko zmanjšal, da bi ohranil vsaj približno nevtralnno ali uravnoteženo polje.

Panel uv (sredaj desno) ima štiri “loke” pozitivne ali negativne korelacije: zgoraj desno in spodaj levo je pogosto en znak, zgoraj levo in spodaj desno nasprotni znak. Taka “kvadripolna” struktura sledi dejstvu, da je u vezan na $\partial\Phi/\partial y$, v pa na $\partial\Phi/\partial x$. Vsaka sprememba geopotenciala lahko ustvari kombinacijo sprememb v obeh smereh, ki se pokažejo kot izmenjujoče se pozitivne in negativne korelacijske cone.

V panelu $v\phi$ (spodaj levo) ponovno vidimo zrcalno podobo ϕv . V sklopljenih modelih kovarianc je korelacija $\rho_{v\phi}$ praviloma enaka $\rho_{\phi v}$, saj so kovariance običajno simetrične, vendar je tukaj orientacija lobusov prilagojena odvodom po x namesto po y .

Panel vu (spodaj v sredini) je analogen uv , a s spremenjenima vlogama v in u . Tudi tu se pojavljajo kvadripolne oblike s štirimi različnimi znamenji, kar odraža isto vezanost na dvoosno razporeditev geostrofskih odvodov.

Panel vv (spodaj desno) prikazuje avtokorelacijo napak meridionalnega vetra. Enako kot v primeru uu se v središču pojavi maksimum pozitivne korelacije, ob straneh pa se lahko najdejo šibkejša območja z drugačnim znamenjem. Če se Φ in s tem v spremenita v središču, mora polje obrobno nadoknaditi oziroma se prilagoditi, kar lahko rodi pozitivne ali negativne vrednosti v različnih pasovih.

Te strukture ponazarjajo, kako parcialni odvodi geopotenciala narekujejo smer in znak vektorja vetra. Če gledamo vsako spremenljivko posebej, se zdi zadeva preprosta, toda kadar jih analiziramo skupaj, nastane večdimenzionalni sistem, v katerem so korelacije med spremenljivkami bistvene za doseganje “fizično skladnih” analiza-prirastkov.

Pomen uravnoteženih prirastkov

Ena najpomembnejših prednosti teh prekrivnih korelacij je, da se z njihovo pomočjo v analizi hkrati popravijo geopotencial, zonalni in meridionalni veter, kar zmanjša pojav nenadnih neravnotežij. Če bi, denimo, v izračun analize vpeljali velik popravek geopotenciala, ne da bi hkrati popravili veter, bi model ob integriranju tega stanja verjetno razvil močne gravitacijske valove, ki bi “odnašali” energijo stran od območja in izničili velik del uvajane informacije. S skrbno zasnovanimi prekrivnimi korelacijami v matriki $\mathbf{B}$ poskrbimo, da so prirastki že v analizi kolikor mogoče skladni z glavnimi ravnovesji atmosfere, zaradi česar so tudi modelne napovedi bolj stabilne.

V tropskih območjih, kjer je Coriolisov parameter f manjši, lahko pričakujemo daljše prostorske korelacije, saj se dinamično polje odziva na širšem območju. V srednjih geografskih

širinah pa so korelacijske dolžine zaradi večje vrednosti f običajno krajše. Prav tako so v spodnji troposferi korelacije lahko omejene zaradi stika z orografijo in drugimi turbulentnimi procesi, v zgornji troposferi pa so navadno daljše.

4.4.2 Zakaj je optimalno interpoliranje boljše od metode zaporednega popravka?

Glavna prednost *optimalnega interpoliranja* (OI) v primerjavi z *zaporednim popravkom* je v tem, da OI pri določanju uteži ne upošteva samo razdalje opazovanja od mrežne točke, temveč tudi **gostoto opazovanj** in statistične korelacije (kovariance), ki jih določa matrika $\mathbf{B}$. V metodah zaporednega popravka bi dve opazovanji na isti razdalji od mrežne točke dobili enako utež, ne glede na to, ali je območje bogato z opazovanji ali pa je opazovanj malo. Pri OI pa velja:

- V območju z gosto mrežo opazovanj vsako opazovanje prejme manjšo utež (ker je v tistem predelu veliko opazovanj).
- Če je v nekem območju zelo malo opazovanj, imajo obstoječa opazovanja lahko sorazmerno večjo utež, saj v bližini ni drugih podatkovnih točk.
- Medspremenljivkine kovariance in statistika napak ozadja prav tako pomagajo pri širjenju informacije opazovanj med različnimi spremenljivkami in različnimi točkami.

Okvir OI pogosto vključuje tudi superobiranje (angl. *superobing*), torej združevanje več opazovanj v lokalni regiji v eno samo reprezentativno opazovanje, preden izvedemo dejansko asimilacijo. S tem zmanjšamo redundanco in dosežemo bolj gladke popravke. Čeprav se s tem nekoliko zmanjša število opazovanj, je statistično vrednotenje bolj obvladljivo.

Nasprotno pa lahko naivna metoda zaporednega popravka preprosto zaporedoma obravnava opazovanja v nekem vrstnem redu in lokalno popravlja polje modela, ne da bi ustrezno upoštevala dolžine korelacij, gostote ali medspremenljivkine odnose. Če je veliko opazovanj med seboj zelo blizu, lahko metoda zaporednega popravka pretirano popravi mrežno točko, da ustreza lokalnemu grozdu opazovanj, pri tem pa zanemari možnost, da so v bližini na voljo še druga opazovanja.

Primer uporabe OI-asimilacije podatkov v majhnem modelu s 3 točkami

Da bi pokazali, kako OI deluje v praksi, si oglejmo zelo preprosto domeno modela s tremi mrežnimi točkami, označenimi 1, 2 in 3. Na vsaki točki imamo tri spremenljivke stanja: u , v in Φ (zonalni veter, meridionalni veter in geopotencial). Vektor stanja $\vec{x}$ je torej:

$$\vec{x} = (u_1, u_2, u_3, v_1, v_2, v_3, \Phi_1, \Phi_2, \Phi_3).$$

Tako je $\dim(\vec{x}) = 9$. Kovariančna matrika napak ozadja $\mathbf{B}$ pri tej nalogi ima velikost 9×9 , kot smo že videli v prejšnjih primerih.

Eno samo opazovanje. Denimo, da imamo le *eno* opazovanje: y_{u_1} , ki je izmerjena vrednost u_1 . Naš vektor opazovanj je torej preprost:

$$\vec{y} = (y_{u_1}),$$

vektor dimenzije 1. Operator opazovanja $\mathcal{H}$ v tem primeru zgolj izbere komponento u_1 iz vektorja stanja. V matrični obliki je H matrika velikosti 1×9 :

$$H = \begin{bmatrix} 1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \end{bmatrix},$$

kjer 1 nakazuje, da opazujemo prvo komponento stanja (tj. u_1). Varianca napake opazovanja je

$$R = \begin{bmatrix} \sigma_{ou_1}^2 \end{bmatrix},$$

kar je 1×1 matrika.

Račun Kalmanove utež za eno opazovanje. Optimalna utež (ali Kalmanova utež) je podana z

$$K = \mathbf{B} H^T \left(H \mathbf{B} H^T + \mathbf{R} \right)^{-1}.$$

Najprej pogledajmo dimenzije. Ker je $\mathbf{B}$ 9×9 , H je 1×9 , je H^T 9×1 . Zato:

$$\begin{aligned} \mathbf{B} H^T & \text{ je } 9 \times 1, \\ H \mathbf{B} H^T & \text{ je } 1 \times 1. \end{aligned}$$

Najprej izračunamo $H \mathbf{B} H^T$:

$$H \mathbf{B} H^T = [1 \times 9] [9 \times 9] [9 \times 1] = [1 \times 1]$$

in natančneje se s tem izlušči vrednost $\langle \epsilon_{u_1}^2 \rangle$ na diagonali v $\mathbf{B}$:

$$H \mathbf{B} H^T = \left[\langle \epsilon_{u_1}^2 \rangle \right].$$

Zato velja

$$H \mathbf{B} H^T + R = \langle \epsilon_{u_1}^2 \rangle + \sigma_{o_{u_1}}^2,$$

in njegov inverz je preprosto

$$\left(\langle \epsilon_{u_1}^2 \rangle + \sigma_{o_{u_1}}^2 \right)^{-1}. \quad (4.2)$$

Drugič izračunamo $\mathbf{B} H^T$. Rezultat je stolpec velikosti 9×1 :

$$\mathbf{B} H^T = \begin{bmatrix} \langle \epsilon_{u_1}^2 \rangle \\ \langle \epsilon_{u_1} \epsilon_{u_2} \rangle \\ \langle \epsilon_{u_1} \epsilon_{u_3} \rangle \\ \langle \epsilon_{u_1} \epsilon_{v_1} \rangle \\ \langle \epsilon_{u_1} \epsilon_{v_2} \rangle \\ \langle \epsilon_{u_1} \epsilon_{v_3} \rangle \\ \langle \epsilon_{u_1} \epsilon_{\Phi_1} \rangle \\ \langle \epsilon_{u_1} \epsilon_{\Phi_2} \rangle \\ \langle \epsilon_{u_1} \epsilon_{\Phi_3} \rangle \end{bmatrix},$$

kjer vidimo kovariance ϵ_{u_1} z *vsemi* drugimi spremenljivkami v vektorju stanja. Ti zunanji diagonalni členi odražajo medspremenljivkine in medlokacijske korelacije v $\mathbf{B}$.

Tretjič, združimo vse skupaj:

$$K = \mathbf{B} H^T \left[H \mathbf{B} H^T + R \right]^{-1} = \begin{bmatrix} \langle \epsilon_{u_1}^2 \rangle \\ \langle \epsilon_{u_1} \epsilon_{u_2} \rangle \\ \langle \epsilon_{u_1} \epsilon_{u_3} \rangle \\ \langle \epsilon_{u_1} \epsilon_{v_1} \rangle \\ \langle \epsilon_{u_1} \epsilon_{v_2} \rangle \\ \langle \epsilon_{u_1} \epsilon_{v_3} \rangle \\ \langle \epsilon_{u_1} \epsilon_{\Phi_1} \rangle \\ \langle \epsilon_{u_1} \epsilon_{\Phi_2} \rangle \\ \langle \epsilon_{u_1} \epsilon_{\Phi_3} \rangle \end{bmatrix} \cdot \frac{1}{\langle \epsilon_{u_1}^2 \rangle + \sigma_{o_{u_1}}^2}.$$

Popravek analize. Spomnimo se splošne enačbe za analizo v OI:

$$\vec{x}_a = \vec{x}_b + K(\vec{y} - \mathcal{H}(\vec{x}_b)).$$

Tukaj velja

$$\vec{y} - \mathcal{H}(\vec{x}_b) = y_{u_1} - (u_1)^b,$$

Analiza in prognoza vremena

saj $H(\vec{x}_b)$ samo izbere $(u_1)^b$. Popravek analize $\delta\vec{x}_a = K(y_{u_1} - u_1^b)$ je torej

$$\delta\vec{x}_a = \begin{bmatrix} \langle \epsilon_{u_1}^2 \rangle \\ \langle \epsilon_{u_1} \epsilon_{u_2} \rangle \\ \langle \epsilon_{u_1} \epsilon_{u_3} \rangle \\ \langle \epsilon_{u_1} \epsilon_{v_1} \rangle \\ \langle \epsilon_{u_1} \epsilon_{v_2} \rangle \\ \langle \epsilon_{u_1} \epsilon_{v_3} \rangle \\ \langle \epsilon_{u_1} \epsilon_{\Phi_1} \rangle \\ \langle \epsilon_{u_1} \epsilon_{\Phi_2} \rangle \\ \langle \epsilon_{u_1} \epsilon_{\Phi_3} \rangle \end{bmatrix} \frac{1}{\langle \epsilon_{u_1}^2 \rangle + \sigma_{o_{u_1}}^2} (y_{u_1} - u_1^b), \quad (4.3)$$

kjer prvi člen razprši informacijo ene spremenljivke u_1 na vse ostale spremenljivke (saj se povsod u_1 pojavlja), drugi člen ovrednoti spremenljivke opazovanja in ozadja, tretji člen pa meri razliko med meritvijo in ozadjem. Ker je ta popravek velikosti 9×1 , posodobi *vseh devet spremenljivk* v vektorju stanja. Prva komponenta (tj. popravek za u_1) se zoži na znano enodimenzionalno formulo:

$$u_1^a = u_1^b + \frac{\langle \epsilon_{u_1}^2 \rangle}{\langle \epsilon_{u_1}^2 \rangle + \sigma_{o_{u_1}}^2} (y_{u_1} - u_1^b), \quad (4.4)$$

medtem ko *medspremenljivkini členi* omogočajo, da posodobimo tudi $u_2, u_3, v_1, v_2, \dots, \Phi_3$ v skladu z njihovo korelacijo z u_1 . Tako lahko že eno samo opazovanje u_1 ustvari uravnotežene popravke v v in Φ , če $\mathbf{B}$ upošteva ustrezno dinamiko.

4.5 Zgodovinska uporaba optimalnega interpoliranja


Metoda *optimalnega interpoliranja* izvira iz del Gandina (1963) in se je operativno uporabljala med približno letoma 1979 in 1996 v številnih centrih, preden so jo nadomestili sistemi 3D-Var. V teh zgodnjih sistemih so globalno domeno za analizo razdelili v manjše *škatle* ali *območja*, kar je ponazorjeno shematično na Sliki 4.4. Vsako poddomeno so obravnavali ločeno:

$$\vec{x}_a^i = \vec{x}_b^i + K^i(\vec{y} - \mathcal{H}(\vec{x}_b^i)),$$

kjer je K^i Kalmanov dobitnik za območje i . Nabor opazovanj, uporabljenih za posamezno območje, je lahko segal tudi čez njegove meje, a le znotraj določenega polmera; opazovanja, ki so bila preveč oddaljena v prostoru (ali času), so bila izločena, da se zmanjšajo računske obremenitve. Tako je K^i ostala razmeroma majhna matrika, in $(H^i B^i H^{iT} + R^i)^{-1}$ je bilo lažje invertirati.

Slika 4.4 prikazuje, da je *škatla analize* (manjši rdeč pravokotnik) vsebovana v večji *škatli opazovanj* (veliki rdeč pravokotnik). Opazovanja, ki padejo v večjo škatlo (označena z modrimi x), so vključena, tista zunaj (črn x) pa so zavržena. Z medsebojnim prekrivanjem škatel metoda pokrije celotno globalno domeno korak za korakom, pri čemer vsaka lokalna analiza dostopa do bližnjih opazovanj.

Ta pristop, temelječ na škatlah, se je ob razpoložljivi računalniški moči tistega časa obnesel dokaj dobro, a je bil v določeni meri patchwork (zlepljen) po naravi in je lahko na mejah škatel povzročal neskladja ali suboptimalne rešitve. Ko se je obseg podatkov zrasel (npr. s satelitskimi opazovanji), so operativni centri prešli na 3D-Var in 4D-Var, ki obravnavata velike nabore opazovanj v variacijskem okviru, pogosto z naprednejšimi predstavitvami kovariančnih struktur napak ozadja.



Slika 4.4

Povzetek:

- **OI proti zaporednemu popravku.** OI je boljša v upoštevanju gostote opazovanj in medspremenljivkinih korelacij. Zaporedni popravek bi lahko enako utež dodelil opazovanjem, ki so enako oddaljena, ne glede na to, ali je neko območje bogato z opazovanji ali ne.
- **Posodabljanje med različnimi spremenljivkami.** Že eno samo opazovanje u_1 lahko povzroči popravke v v_2 , Φ_3 itn., če kovariančna matrika napak ozadja $\mathbf{B}$ kodira takšne odnose.
- **Zgodovinska uporaba.** OI je bila nekoč standardna metoda, pri kateri so globalna območja razdelili na manjše poddomene za obvladovanje računskih stroškov. Danes sta v mnogih primerih 3D-Var in 4D-Var to metodo nadomestila, saj ponujata bolj poenoten in prožen pristop k obsežnim problemom.

Poglavje 5


3D VAR Algoritem

Algoritem 3D VAR (Three-Dimensional Variational Data Assimilation) je postopek, ki se uporablja v številnih operativnih meteoroloških centrih po svetu, vključno z Agencijo RS za okolje (ARSO), za diagnostiko začetnih pogojev v vremenskem modelu ALADIN. Iz prejšnjih poglavij že vemo, da globalni vremenski modeli običajno napovedujejo od 0 do 10 ali 15 dni v prihodnost. Na drugi strani pa se zaradi hitre rasti napak pri omejenem območju (t. i. *limited-area model*) napoved izdela le do približno 4 dni vnaprej. Smiselnost napovedovanja po tem času upade, saj napake, ki se prenašajo iz globalnih modelov, sčasoma prevladajo nad lastnimi napakami modela omejenega območja.

Na podlagi navedenega si pri 3D VAR ne moremo privoščiti dolgega asimilacijskega okna, kot je to značilno za 4D VAR. Zato 3D VAR uporablja kratko asimilacijsko okno, v katerem se vse razpoložljive opazovalne podatke (opazovanja) pripiše tako imenovanemu "časovnemu trenutku 0." V praksi to pomeni, da zberemo meritve, ki se pojavijo v omejenem časovnem intervalu okoli začetne analize, in jih obravnavamo, kot da so vse veljavne ob istem času.

Kratek oris časovne osi v 3D VAR. Če si konceptualno zamislimo, kaj počnemo pri 3D VAR, lahko opišemo časovno os, ki sega od časa 0 do, denimo, 24 ali 48 ur v prihodnost. Trenutek 0 je sedanjost, iz katere vedno zaženemo napoved. Da bi postavili začetne pogoje za vremenski model, praviloma združimo opazovanja, zbrana v kratkem časovnem oknu okrog $t = 0$ (npr. od -1,5 do +1,5 ure), z napovedjo iz prejšnje krajšedosežne napovedi (t. i. *background* ali ozadje). Ker se v sodobni meteorologiji količina razpoložljivih opazovanj strmo povečuje (na primer satelitska, radarska, letalska poročila idr.), se lahko to časovno okno tudi zoži ali prilagodi glede na razpoložljivost podatkov in potrebe modela.

Z združitvijo (asimilacijo) novih opazovanj in prejšnje krajšedosežne napovedi tako dobimo najboljšo oceno trenutnega stanja atmosfere, ki jo imenujemo *analiza*. Na osnovi te analize izdelamo novo napoved, ob naslednjem ciklu pa se postopek ponovi.



Slika 5.1: Skica 3D VAR algoritma

Zgodovinski vidik in krajša asimilacijska okna. V preteklosti so bili radiosondažni podatki (meritve z baloni) na voljo zlasti ob 00 UTC in 12 UTC, zato je bila asimilacijska shema tradicionalno zasnovana na 12-urnem intervalu. Zaradi vse večje potrebe po hitrejših in natančnejših napovedih se je dolžina asimilacijskega okna krajšala. Danes se v praksi marsikje

uporablja 6-urna shema, pri najnovejših visoko ločljivih modelih pa se to lahko skrajša na 3 ali celo 1 uro. Tako na primer pri ALADIN-u, ki teče na mreži 4 km, asimilacija deluje v 3-urnih ciklih, pri ALADIN-u z 1 km ločljivostjo pa celo vsakih 1 uro. Pogostejša asimilacija omogoča boljše vključitev svežih opazovanj, kar vodi v ažurnejše in natančnejše začetne pogoje.

5.1 Ideja algoritma 3D VAR

Osnova algoritma 3D VAR izhaja iz problema *optimalne interpolacije* (angl. *optimal interpolation*), ki se lahko zapiše v nekoliko drugačnem okviru in razloži, kako 3D VAR deluje. Načeloma lahko zapišemo enostaven *matrični sistem*:

$$\mathbf{A} \vec{x} = \vec{b}. \quad (5.1)$$

Ta sistem pomeni, da želimo poiskati vektor $\vec{x}$ (tj. neznane popravke ali stanje atmosfere), ki ustreza pogojem, ki jih določa matrika $\mathbf{A}$ in desna stran $\vec{b}$. Enakovredno lahko to zapišemo kot

$$\mathbf{A} \vec{x} - \vec{b} = \vec{0}, \quad (5.2)$$

in tak sistem lahko rešujemo z iskanjem minimuma *kvadratne cenilne funkcije* (angl. *quadratic cost function*). Natančneje:

$$f(\vec{x}) = \frac{1}{2} \vec{x}^T \mathbf{A} \vec{x} - \vec{x}^T \vec{b}. \quad (5.3)$$

Z osnovno linearno algebro vemo, da pogoj $\nabla_{\vec{x}} f(\vec{x}) = 0$ privede do rešitve $\mathbf{A} \vec{x} = \vec{b}$.

Povezava s formulo optimalne interpolacije. Pri optimalni interpolaciji oziroma v Kalmanovem filtru imamo enačbo za analizo:

$$\vec{x}_a = \vec{x}_b + \mathbf{K} (\vec{y} - \mathcal{H}(\vec{x}_b)), \quad (5.4)$$

kjer je $\vec{x}_a$ *analiza*, $\vec{x}_b$ je *ozadje* (npr. prejša krajšedosežna napoved), $\vec{y}$ so opazovanja, $\mathcal{H}(\vec{x}_b)$ pa je *modelska ocena* teh opazovanj glede na ozadje. Matrika $\mathbf{K}$ je Kalmanov ojačevalec (angl. *Kalman gain*), ki opiše, kako ponderiramo opazovanja glede na ozadje. Značilno je:

$$\mathbf{K} = \left(\mathbf{B}^{-1} + \mathbf{H}^T \mathbf{R}^{-1} \mathbf{H} \right)^{-1} \mathbf{H}^T \mathbf{R}^{-1}, \quad (5.5)$$

pri čemer sta $\mathbf{B}$ in $\mathbf{R}$ matriki kovariančnih napak ozadja in opazovanj, $\mathbf{H}$ pa je lineariziran operater, ki iz stanja modela izračuna (ali "simulira") opazovanja.

Če definiramo $\delta \vec{x} = \vec{x}_a - \vec{x}_b$, dobimo

$$\delta \vec{x} = \left(\mathbf{B}^{-1} + \mathbf{H}^T \mathbf{R}^{-1} \mathbf{H} \right)^{-1} \mathbf{H}^T \mathbf{R}^{-1} (\vec{y} - \mathcal{H}(\vec{x}_b)), \quad (5.6)$$

pri čemer je $\delta \vec{x}$ *prirastek* (angl. *increment*), ki ga dodamo ozadju. Z množenjem obeh strani z $\mathbf{B}^{-1} + \mathbf{H}^T \mathbf{R}^{-1} \mathbf{H}$ dobimo:

$$(\mathbf{B}^{-1} + \mathbf{H}^T \mathbf{R}^{-1} \mathbf{H}) \delta \vec{x} = \mathbf{H}^T \mathbf{R}^{-1} (\vec{y} - \mathcal{H}(\vec{x}_b))$$

in iz tega obliko matričnega zapisa $\mathbf{A} \delta \vec{x} = \vec{b}$, kjer je $\mathbf{A} = \mathbf{B}^{-1} + \mathbf{H}^T \mathbf{R}^{-1} \mathbf{H}$ in $\vec{b} = \mathbf{H}^T \mathbf{R}^{-1} (\vec{y} - \mathcal{H}(\vec{x}_b))$. Tako vidimo, da je optimalna interpolacija ekvivalentna rešitvi istega sistema, ki bi ga dobili z minimizacijo kvadratne funkcije. S tem smo dobili $\mathbf{A}$ in $\vec{b}$ za našo cenilno funkcijo:

$$f(\delta \vec{x}) = \frac{1}{2} \delta \vec{x}^T \mathbf{A} \delta \vec{x} - \delta \vec{x}^T \vec{b}$$

in sedaj če notri vstavimo ti dve vrednosti lahko transformiramo naš matrični sistem v minimizacijo cenilne funkcije in iz tega dobimo končni rezultat. In potem lahko uporabimo kakšne alternativne metode za minimizacijo cenilne funkcije, kot so Newtonova metoda in konjugacija gradienta.

Praktične prednosti 3D VAR. Glavna prednost 3D VAR je, da nam ni treba eksplicitno računati matrike $\mathbf{A}$ ali njene inverze, kar bi bilo v velikih modelih (npr. z milijoni ali celo stomilijoni prostostnih stopenj) popolnoma nepraktično. Namesto tega se zanesemo na *iterativne* metode minimizacije, kot so konjugirani gradienti ali kvazi-Newtonovi postopki, pri katerih izračunavamo samo potrebne matrične produkte. Postopek iskanja minimuma tako *posredno* reši sistem brez dragih pomnilniških ali računskih zahtev, ki bi bile potrebne za eksplicitno invertiranje velikih matrik.

Iz zgodovinskega vidika 3D VAR ni bil prvotno razvit tako, da bi takoj prešli na cenilko, a danes je splošno sprejeto, da ga lahko obravnavamo kot optimizacijski problem: iščemo minimum funkcije, ki združuje prileganje opazovanjem in odklik od ozadja. Ta formulacija je dovolj prilagodljiva, da lahko vanjo (prek matrike $\mathbf{B}$ ipd.) vpeljemo dodatne fizikalne omejitve ali lastnosti napak. Prav tako vodi do razširitev, kot na primer 4D VAR.

3D VAR tako obravnava problem združevanja opazovanj in ozadja, ne da bi morali neposredno reševati velik matrični sistem ali računati drage inverze. To je računsko izvedljivo tudi za zelo velike modele in predstavlja enega od stebrov sodobnih numeričnih vremenskih napovedi.

5.2 Zgodovinski razvoj 3D VAR in Bayesov izrek

Zgodovinsko gledano se je razvoj 3D VAR naslanjal na *Bayesov izrek*. Ta pravi, da je pogojna verjetnost dogodka A , če se je zgodil dogodek B , sorazmerna z verjetnostjo, da se B zgodi, če se je zgodil A , pomnoženo z verjetnostjo dogodka A , vse to pa delimo s skupno verjetnostjo dogodka B . Zapišemo:

$$p(A | B) = \frac{p(B | A)p(A)}{p(B)} \approx \alpha p(B | A)p(A), \quad (5.7)$$

kjer α predstavlja proporcionalnostno konstanto. V sklopu asimilacije podatkov (angl. *data assimilation*) smo se prej osredotočali na določeno linearno kombinacijo opazovanj in ozadja, ki minimizira varianco napake analize (enkratno oz. večkratno, npr. v multivariatnem primeru). Zdaj pa lahko problem interpretiramo tudi z vidika *maksimalne verjetnosti* (angl. *maximum likelihood*).

5.2.1 Maximum Likelihood Approach

Iskali bomo najverjetnejšo analizo glede na opazovanja $\vec{y}$ in ozadje $\vec{x}_b$. Da bi to formalizirali, zapišemo verjetnost stanja analize $\vec{x}$ glede na opazovanja in ozadje kot

$$p(\vec{x} | \vec{y} \cap \vec{x}_b),$$

ki je pogojna verjetnost stanja $\vec{x}$, če sta $\vec{y}$ in $\vec{x}_b$ zagotovljena ali sta se zgodila. Naša končna analiza, ki je najboljša ocena trenutnega vremenskega stanja, je lahko opredeljena kot:

$$\vec{x}_a = \arg \max_{\vec{x}} (p(\vec{x} | \vec{y} \cap \vec{x}_b)). \quad (5.8)$$

V tej enačbi iščemo argument $\vec{x}$, ki maksimira pogojno verjetnost $p(\vec{x} | \vec{y} \cap \vec{x}_b)$. V prejšnjih metodah asimilacije podatkov je bila analiza tradicionalno pogosto opredeljena kot analiza, ki zmanjšuje varianco napake. Pri pristopu največje verjetnosti pa se osredotočamo na neposredno maksimiranje te verjetnosti.

Uvedemo tudi stroškovno funkcijo J , tako da jo opredelimo kot negativni logaritem pogojne verjetnosti:

$$J = -\log(p(\vec{x} \mid \vec{y} \cap \vec{x}_b)).$$

Ker je logaritem strogo naraščajoča (monotona) funkcija, je maksimiranje $p(\vec{x} \mid \vec{y} \cap \vec{x}_b)$ enako minimiziranju $-\log(p(\vec{x} \mid \vec{y} \cap \vec{x}_b))$. To pomeni, da lahko iskanje $\vec{x}_a$ preoblikujemo kot:

$$\vec{x}_a = \arg \min_{\vec{x}} (J(\vec{x})). \quad (5.9)$$

Z drugimi besedami, v enačbi (5.8) iščemo stanje $\vec{x}$, ki maksimira pogojno verjetnost, medtem ko v enačbi (5.9) minimiziramo negativni log te iste verjetnosti. Obe perspektivi pripeljeta do iste najboljše ocene $\vec{x}_a$.

Nato eksplicitno definirajmo pogojno verjetnost $p(\vec{x} \mid \vec{y} \cap \vec{x}_b)$. Z Bayesovim izrekom lahko zapišemo:

$$p(\vec{x} \mid \vec{y} \cap \vec{x}_b) = \frac{p(\vec{y} \cap \vec{x}_b \mid \vec{x}) p(\vec{x})}{p(\vec{y} \cap \vec{x}_b)}.$$

Tu $p(\vec{y} \cap \vec{x}_b)$ ni odvisen od $\vec{x}$, zato je le normalizacijska konstanta. Prav tako ne predvidevamo nobene predhodne prednosti enega $\vec{x}$ pred drugim (tj. vsa stanja so na začetku enako verjetna), zato je $p(\vec{x})$ glede na $\vec{x}$ dejansko konstanten. Zato ti izrazi ne vplivajo na lokacijo maksimuma, zato se osredotočimo na:

$$p(\vec{x} \mid \vec{y} \cap \vec{x}_b) \propto p(\vec{y} \cap \vec{x}_b \mid \vec{x}).$$

Nato ugotovimo, da ob določenih predpostavkah pogojne neodvisnosti $\vec{x}$,

$$p(\vec{y} \cap \vec{x}_b \mid \vec{x}) = p(\vec{y} \mid \vec{x}) \cdot p(\vec{x}_b \mid \vec{x}).$$

Če to ponovno vpišemo v definicijo stroškovne funkcije, dobimo:

$$J(\vec{x}) = -\log(p(\vec{y} \mid \vec{x})) - \log(p(\vec{x}_b \mid \vec{x})). \quad (5.10)$$

Naslednji korak je določitev načina modeliranja funkcij gostote verjetnosti $p(\vec{y} \mid \vec{x})$ in $p(\vec{x}_b \mid \vec{x})$. Pri asimilaciji meteoroloških podatkov se običajno predpostavlja, da napake ozadja in napake opazovanja sledijo Gaussovi porazdelitvi. Zato zapišemo:

$$p(\vec{x}_b \mid \vec{x}) = \frac{1}{(2\pi)^{N/2} |\mathbf{B}|^{1/2}} \exp\left(-\frac{1}{2}(\vec{x}_b - \vec{x})^T \mathbf{B}^{-1}(\vec{x}_b - \vec{x})\right),$$

kjer se $\dim(\vec{x}_b) = N$ in $\mathbf{B}$ običajno imenuje kovariančna matrika napake ozadja. Diagonalni (in nediagonalni) elementi v $\mathbf{B}$ predstavljajo, kako napake v različnih komponentah stanja modela korelirajo med seboj. Izraz $(\vec{x}_b - \vec{x})^T \mathbf{B}^{-1}(\vec{x}_b - \vec{x})$ meri kvadratno razdaljo med stanjem ozadja $\vec{x}_b$ in stanjem modela $\vec{x}$.

Podobno je verjetnost opazovanja $\vec{y}$ glede na stanje $\vec{x}$:

$$p(\vec{y} \mid \vec{x}) = \frac{1}{(2\pi)^{M/2} |\mathbf{R}|^{1/2}} \exp\left(-\frac{1}{2}(\vec{y} - \mathcal{H}(\vec{x}))^T \mathbf{R}^{-1}(\vec{y} - \mathcal{H}(\vec{x}))\right),$$

kjer je $\dim(\vec{y}) = M$, $\mathbf{R}$ kovariančna matrika napake opazovanja in $\mathcal{H}$ je operator opazovanja (modelsko stanje $\vec{x}$ pretvori v prostor opazovanja, tako da ga lahko primerjamo s $\vec{y}$). Tu $(\vec{y} - \mathcal{H}(\vec{x}))^T \mathbf{R}^{-1}(\vec{y} - \mathcal{H}(\vec{x}))$ meri kvadratno razdaljo med dejanskimi opazovanji in modelno simuliranimi opazovanji.

Če te Gaussove gostote verjetnosti nadomestimo z enačbo (5.10), dobimo stroškovno funkcijo:

$$J(\vec{x}) = \frac{1}{2}(\vec{x}_b - \vec{x})^T \mathbf{B}^{-1}(\vec{x}_b - \vec{x}) + \frac{1}{2}(\vec{y} - \mathcal{H}(\vec{x}))^T \mathbf{R}^{-1}(\vec{y} - \mathcal{H}(\vec{x})). \quad (5.11)$$

Ta izraz je znan kot stroškovna funkcija 3D-Var, ki se na primer uporablja v modelu napovedovanja ALADIN. Vključuje dva izraza: enega, ki meri razdaljo $\vec{x}$ od ozadja $\vec{x}_b$ (uteženo z $\mathbf{B}^{-1}$), in drugega, ki meri razdaljo modela- ekvivalenta opazovanj $\mathcal{H}(\vec{x})$ od dejanskih opazovanj $\vec{y}$ (uteženo z $\mathbf{R}^{-1}$). Iščemo $\vec{x}$, ki je blizu $\vec{x}_b$ in $\vec{y}$ na način, ki upošteva njune kovariance napak.

Nazadnje, po opredelitvi $J(\vec{x})$ se najboljša analiza $\vec{x}_a$ dobi z minimiziranjem te stroškovne funkcije:

$$\vec{x}_a = \arg \min_{\vec{x}} (J(\vec{x})). \quad (5.12)$$

Ta minimizacija daje stanje, ki usklajuje skladnost z ozadjem in skladnost z opazovanji v statistično optimalnem smislu (največja verjetnost) ob predpostavki Gaussovih napak. Pristop največje verjetnosti za asimilacijo podatkov kot takšen konča z oblikovanjem problema v smislu reševanja te minimizacije stroškovne funkcije 3D-Var.

5.2.2 Ekvivalentnost rešitev 3D-Var in optimalne interpolacijske analize

V tem razdelku bomo pokazali, da je rešitev, ki jo dobimo z minimiziranjem stroškovne funkcije 3D-Var, popolnoma enaka rešitvi, ki bi jo dobili z metodo optimalne interpolacije (OI). Čeprav se izpeljava pristopa 3D-Var začne z vidika največje verjetnosti (in ustrezne stroškovne funkcije), ko poiščemo minimum te stroškovne funkcije, vidimo, da sovpada s klasično rešitvijo OI.

Za začetek se spomnimo, da moramo za iskanje minimuma stroškovne funkcije $J(\vec{x})$ rešiti pogoj

$$\nabla_{\vec{x}} J(\vec{x}) = 0.$$

Zapišimo gradient $J(\vec{x})$ v smislu $\vec{x}$. Iz splošne oblike stroškovne funkcije 3D-Var (za podrobnosti glej prejšnje opombe in enačbo 5.10) lahko njen gradient izrazimo na naslednji način:

$$\nabla_{\vec{x}} J(\vec{x}) = \frac{\partial J}{\partial \vec{x}} = B^{-1}(\vec{x} - \vec{x}_b) + \frac{\partial \mathcal{H}}{\partial \vec{x}} R^{-1}(\mathcal{H}(\vec{x}) - \vec{y}).$$

Tu je B kovariančna matrika napake ozadja, $\vec{x}_b$ je stanje ozadja, R je kovariančna matrika napake opazovanja, $\mathcal{H}$ pa je (lahko nelinearni) operator opazovanja. V številnih aplikacijah asimilacije podatkov označujemo jakobian (ali linearizacijo) $\mathcal{H}$ glede na $\vec{x}$ z H . To pomeni,

$$\frac{\partial \mathcal{H}}{\partial \vec{x}} = H,$$

če je $\mathcal{H}$ linearen ali pa je lineariziran glede na ustrezno stanje. Posledično zapišemo:

$$\nabla_{\vec{x}} J(\vec{x}) = B^{-1}(\vec{x} - \vec{x}_b) + H^T R^{-1}(\mathcal{H}(\vec{x}) - \vec{y}).$$

Pogoj za minimum J je torej $\nabla_{\vec{x}} J(\vec{x}) = 0$. Da bi to rešitev primerjali z optimalno interpolacijo, moramo linearizirati $\mathcal{H}(\vec{x})$ okoli $\vec{x}_b$. Natančneje, zapišemo:

$$\mathcal{H}(\vec{x}) = \mathcal{H}(\vec{x}_b) + H(\vec{x} - \vec{x}_b) = \mathcal{H}(\vec{x}_b) + H \delta \vec{x},$$


kjer definiramo analitični prirastek $\delta \vec{x} = \vec{x} - \vec{x}_b$. Z zamenjavo te linearizacije v izraz za gradient in nastavitvijo gradienta na nič dobimo:

$$\nabla_{\vec{x}} J(\vec{x}) = B^{-1} \delta \vec{x} + H^T R^{-1}(\mathcal{H}(\vec{x}_b) + H \delta \vec{x} - \vec{y}) = 0.$$

S preureditvijo izraza dobimo:

$$(B^{-1} + H^T R^{-1} H) \delta \vec{x} = H^T R^{-1} (\vec{y} - \mathcal{H}(\vec{x}_b)). \quad (5.13)$$

To je natanko ista matrična enačba, ki se pojavi v formulaciji optimalne interpolacije (ob predpostavki linearnosti), ko rešujemo analitični prirastek. To je dokaz, da 3D VAR daje enako rešitev kot optimalna interpolacija za globalno izbirno polje. 3D VAR preprosto minimizira stroškovno funkcijo, seveda pa moramo poznati gradient stroškovne funkcije, saj bo ta določil optimalno smer, v katero se moramo spustiti, da dobimo minimum. Kako smo prišli do enačbe 5.13? Najprej smo rešitev največje verjetnosti pretvorili v rešitev minimalne stroškovne funkcije in dobili stroškovno funkcijo. In potem ta stroškovna funkcija minimizira razdaljo med vektorjem stanja $\vec{x}$ in opazovanjem $\vec{x}_b$. Torej $\vec{x}_a$ minimizira razdaljo do opazovanja $\vec{y}$ in stanja prejšnje napovedi kratkega dosega $\vec{x}_b$ v nekem določenem času (v primeru slike je ta čas $t = 0$). In to je bistvo algoritma 3D VAR; problem maksimiranja verjetnosti iz reševanja optimalne interpolacije, ki zahteva reševanje matričnega sistema z matrikami, ki jih je nemogoče invertirati, prenesemo na veliko boljši pristop, ki nam omogoča uporabo globalnega pristopa.



Slika 5.2: Minimizacija razdalje med $\vec{x}_b$ in $\vec{x}_a$ glede na meritve $\vec{y}$.

Pri izpeljavi optimalne interpolacije z minimalno varianco dobimo stanje analize $\vec{x}_a$ z

$$\vec{x}_a = \vec{x}_b + \mathbf{K} (\vec{y} - \mathcal{H}(\vec{x}_b)),$$

kjer je $\mathbf{K}$ (pogosto imenovana Kalmanova matrika povečanja, čeprav v statičnem kontekstu) podana z

$$\mathbf{K} = (B^{-1} + H^T R^{-1} H)^{-1} H^T R^{-1}.$$

Z identifikacijo $\delta \vec{x} = \vec{x}_a - \vec{x}_b$ vidimo, da je dobljena rešitev za $\delta \vec{x}$ popolnoma enaka tisti, ki jo dobimo z reševanjem problema minimizacije 3D-Var. Tako je ugotovljena enakovrednost med obema analizama.

Razlaga in vloga stroškovne funkcije

V prejšnjem podpoglavju smo opisali, kako deluje algoritem 3D-Var, in sicer z opredelitvijo stroškovne funkcije $J(\vec{x})$, ki meri razdaljo $\vec{x}$ do $\vec{x}_b$ in razdaljo $\mathcal{H}(\vec{x})$ do $\vec{y}$. Nato poiščemo $\vec{x}$, ki zmanjša te stroške. Če to razlagamo verjetnostno, smo rekli, da je maksimiranje verjetnosti ob Gaussovih predpostavkah enakovredno minimiziranju vsote kvadratnih razlik, obteženih z ustreznimi kovariančnimi matrikami.

Enakovrednost z optimalno interpolacijo poudarja, da lahko 3D-Var obravnavamo kot globalni pristop k reševanju istega sistema enačb. Namesto izrecnega zapisa $\vec{x}_a = \vec{x}_b + \mathbf{K} (\vec{y} - \mathcal{H}(\vec{x}_b))$ in oblikovanja velike matrike dobička $\mathbf{K}$ lahko neposredno minimiziramo cenilko. Ta vidik je še

posebej uporaben, kadar je razsežnost stanja velika in je pristop s stroškovno funkcijo morda bolj prilagodljiv ali enostavnejši za izvajanje v sodobnem variacijskem sistemu asimilacije podatkov.

Višjerazsežne variacijske metode: 3D-Var in 4D-Var

Ko smo ugotovili enakovrednost z optimalno interpolacijo, smo omenili tudi, da je 3D-Var del najsodobnejših variacijskih pristopov asimilacije podatkov, ki se rutinsko uporabljajo za numerično napovedovanje vremena. Druga pomembna metoda je 4D-Var, ki razširja analizo na časovno dimenzijo in učinkovito asimilira opazovanja, razporejena v časovnem oknu. Trenutno sta 3D-Var in 4D-Var še vedno glavna algoritma v operativnih centrih in nič ne kaže, da bi ju v kratkem zamenjali.

Minimiziranje stroškovne funkcije v zelo velikih dimenzijah

Pomembno vprašanje pri praktični asimilaciji podatkov je, da ima lahko vektor stanja $\vec{x}$ velikost 10^8 spremenljivk. Ta zelo velika razsežnost pomeni, da ko minimiziramo stroškovno funkcijo

$$J(\vec{x}) = \frac{1}{2}(\vec{x} - \vec{x}_b)^T B^{-1}(\vec{x} - \vec{x}_b) + \frac{1}{2}(\vec{y} - \mathcal{H}(\vec{x}))^T R^{-1}(\vec{y} - \mathcal{H}(\vec{x})),$$

moramo uporabiti algoritem, ki učinkovito uporablja gradient $\nabla J(\vec{x})$. Metode, ki ne uporabljajo gradientov (kot so nekateri simpleksni algoritmi ali simulirano žarjenje), so na splošno nepraktične za tako velike probleme, ker vzorčijo stroškovno funkcijo le v diskretnih točkah in tako zberejo zelo omejene informacije o smeri spuščanja.

Če na primer poskušamo oceniti

$$J(\vec{x} + \delta\vec{v}) - J(\vec{x}),$$

bi dobili samo eno smerno komponento gradienta, ki ustreza $\delta\vec{v}$. Ponavljanje tega za številne smeri v prostoru dimenzije 10^8 ni računsko izvedljivo. Zato so metode, ki temeljijo na gradientu (kot so konjugirani gradient, kvazi-Newton ali podobne), bistvene za asimilacijo podatkov velikega obsega, saj vsak izračun gradienta učinkovito zagotavlja informacije o smeri v vseh 10^8 dimenzijah hkrati.

Zato se izvedbe 3D-Var (in naprednejše metode 4D-Var) močno zanašajo na izračunavanje in uporabo $\nabla_{\vec{x}} J(\vec{x})$. Nato lahko iterativno prilagodijo $\vec{x}$ v smeri, ki najhitreje zmanjša $J(\vec{x})$ in konvergirajo k analizni rešitvi $\vec{x}_a$.

Če povzamemo, je v tem razdelku poudarjeno, kako je rešitev 3D-Var, ki jo najdemo z minimiziranjem stroškovne funkcije z metodami, ki temeljijo na gradientu, enaka klasični optimalni rešitvi interpolacije ob linearnih predpostavkah in Gaussovi statistiki napak. Prednost variacijskega pristopa je v tem, da ga je mogoče bolje razširiti na zelo velike probleme in se naravno razširi na bolj zapletene scenarije, vključno s 4D-Var, s čimer služi kot močno orodje v sodobnih operativnih in raziskovalnih sistemih za napovedovanje vremena.

5.3 Primer delujočega algoritma

V tem razdelku podajamo konkretno ponazoritev, kako numerično minimizirati stroškovno funkcijo 3D-Var in tako rešiti analizo $\vec{x}_a$. Posebej se osredotočamo na algoritem *najbolj strmega spuščanja* kot preprosto, vendar poučno metodo. V praksi se lahko uporabljajo tudi druge kvazi-Newtonove metode ali metode konjugiranega gradienta, ki lahko konvergirajo hitreje, vendar primer strmega spuščanja pomaga pojasniti temeljno idejo iterativne minimizacije v visokorazsežnih prostorih.

5.3.1 Algoritem najbolj strmega spuščanja

Začnemo z določitvijo začetne domneve za vektor stanja $\vec{x}$. Običajno je ta začetna domneva, označena kot $\vec{x}_0$, samo ozadje $\vec{x}_b$. Spomnimo se, da je v 3D-Var ozadje prejšnja napoved kratkega dosega, ki velja v trenutnem času analize. Opazovanja $\vec{y}$ skupaj z $\vec{x}_b$ nato določajo stroškovno funkcijo 3D-Var, ki jo želimo minimizirati.

Iterativni koraki strmega spuščanja. Vzpostavimo zanko (kot je konceptualno prikazano v tabeli 5.1):

1. *Izračunajte smer spuščanja $\vec{v}_k$:* Pri iteraciji k ocenite gradient stroškovne funkcije $J(\vec{x}_k)$. Spomnimo se, da gradient J kaže v smeri *največjega povečanja* J . Zato *negativna* vrednost tega gradienta kaže v smeri najbolj strmega *zmanjšanja*. Tako definiramo

$$\vec{v}_k = -\nabla J(\vec{x}_k).$$

Če smo v iteraciji $k = 0$, potem $\vec{x}_0 = \vec{x}_b$. Ocenjevanje $\nabla J(\vec{x}_0)$ določa prvo smer spuščanja.

2. *Poišči optimalno velikost koraka α_k :* Nato določimo, kako daleč se moramo premakniti vzdolž $\vec{v}_k$. Formalno upoštevamo α_k v izrazu

$$J(\vec{x}_k + \alpha_k \vec{v}_k),$$

in poiščemo vrednost α_k^{opt} , ki v tej smeri zmanjšuje J :

$$\alpha_k^{\text{opt}} = \arg \min_{\alpha} J(\vec{x}_k + \alpha \vec{v}_k).$$

Grafično (kot na sliki 5.3) si lahko predstavljamo, da narišemo J proti α_k in izberemo velikost koraka, ki daje najmanjšo vrednost J .

3. *Posodobitev vektorja stanja:* Ko najdemo α_k^{opt} , posodobimo $\vec{x}_{k+1}$ prek


$$\vec{x}_{k+1} = \vec{x}_k + \alpha_k^{\text{opt}} \vec{v}_k. \quad (5.14)$$

Povečamo $k \rightarrow k+1$ in ponavljamo do konvergence, tj. $\nabla J(\vec{x}_{k+1}) \approx 0$ ali dokler spremembe $J(\vec{x}_{k+1})$ ne postanejo zanemarljive.

WHILE	DO
$\vec{v}_k = -\nabla J(\vec{x}_k)$	Najdi negativen gradient cenilke J v točki $\vec{x}_k$
$\alpha_k^{\text{opt}} = \arg \min_{\alpha} J(\vec{x}_k + \alpha \vec{v}_k)$	Najdi optimalen korak v smeri $\vec{v}_k$
$\vec{x}_{k+1} = \vec{x}_k + \alpha_k^{\text{opt}} \vec{v}_k$	(Osveži stanje in inkrement k)

Tabela 5.1: Pseudokoda algoritma za najbolj strmo spuščanje. Pri vsaki iteraciji k izračunamo negativen gradient $\vec{v}_k$, določimo velikost koraka α_k^{opt} , ki najbolj zmanjša J , in ustrezno posodobimo $\vec{x}_k$.


Slika 5.3 konceptualno prikazuje, kako se od $\vec{x}_0$ zaporedoma spuščamo po večdimenzionalnem prostoru proti minimumu J . V realnem atmosferskem primeru ima lahko ta prostor razsežnost reda 10^8 . Vsaka iteracija spremeni smer $\vec{v}_k$ glede na lokalni gradient J .



Slika 5.3: Iskanje optimalnega koraka stroškovne funkcije.

Obnašanje pri sferičnih in eliptičnih nivojskih območjih . Strmec (steepest descent”) se dobro obnese, če so oblike obrisov (niza nivojev) J sferične (ali blizu sferičnim). V preprostejši dvodimenzionalni analogiji (Slika 5.4), če so izolinije krogi, je negativni gradient vedno usmerjen neposredno proti središču (minimum) in konvergenca je hitra.

Če pa so izolinije močno eliptične (Slika 5.4), se lahko smer najbolj strmega padca močno vijuga, kar lahko zahteva veliko iteracij, da se približamo središču. Čeprav običajno še vedno konvergiramo h globalnemu minimumu (zlasti če je stroškovna funkcija konveksna), je pot lahko zelo neučinkovita. Naprednejše metode, kot so metode konjugiranega gradienta ali kvazi-Newtonove metode, pogosto učinkoviteje obravnavajo te eliptične oblike.



Slika 5.4: Primer če so izolinije krogi ali elipse.

Sferičnost, Hessian in lastne vrednosti

Kako “sferična” je stroškovna funkcija, izmerimo tako, da preučimo lastne vrednosti njene Hessijeve matrike. Spomnimo se, da je Hessian J'' matrika drugih derivatov J glede na $\vec{x}$. Če ima stroškovna funkcija zelo anizotropno obliko (kot je raztegnjena elipsa), se lastne vrednosti Hessijeve matrike razlikujejo za velike faktorje. Nasprotno pa so lastne vrednosti podobne, če ima stroškovna funkcija skoraj sferične množice nivojev.

Matematično lahko za majhno motnjo $\delta\vec{x}$ izvedemo Taylorjevo razširitev J drugega reda okoli točke $\vec{x}$:

$$J(\vec{x} + \delta\vec{x}) \approx J(\vec{x}) + \delta\vec{x}^T \nabla J(\vec{x}) + \frac{1}{2} \delta\vec{x}^T J'' \delta\vec{x} + O(\|\delta\vec{x}\|^3).$$

Tu je $\nabla J(\vec{x})$ gradient, J'' (Hessian) pa:

$$J'' = \frac{\partial^2 J}{\partial \vec{x}^2}.$$

Gradient in hessian za stroškovno funkcijo 3D-Var . Spomnimo se, da je naša stroškovna funkcija 3D-Var

$$J(\vec{x}) = \frac{1}{2}(\vec{x} - \vec{x}_b)^T B^{-1}(\vec{x} - \vec{x}_b) + \frac{1}{2}(\vec{y} - \mathcal{H}(\vec{x}))^T R^{-1}(\vec{y} - \mathcal{H}(\vec{x})).$$

Njegov gradient glede na $\vec{x}$ je

$$\nabla J(\vec{x}) = B^{-1}(\vec{x} - \vec{x}_b) + H^T R^{-1}(\mathcal{H}(\vec{x}) - \vec{y}),$$

ob predpostavki, da je $\mathcal{H}$ lineariziran in predstavljen z H . V iterativnem postopku želimo, da je $\nabla J(\vec{x}) \approx 0$ na minimumu.

Z nadaljnjo izpeljavo dobimo Hessianovo vrednost:


$$J'' = \nabla_{\vec{x}}(\nabla J(\vec{x})) = B^{-1} + H^T R^{-1} H. \quad (5.15)$$

Ta hezijan je odvisen od B^{-1} in R^{-1} . Lastne vrednosti in lastni vektorji ($B^{-1} + H^T R^{-1} H$) določajo, kako "okrogle" (ali obratno, kako "podolgovate") so množice ravni stroškovne funkcije v različnih smereh.

Indikator sferičnosti κ . Za količinsko opredelitev sferičnosti se pogosto uporablja pogojno število (ali sorodno razmerje) Hessianovega koeficienta:

$$\kappa = \frac{\lambda_{\max}}{\lambda_{\min}},$$

kjer sta $\lambda_{\max}$ in $\lambda_{\min}$ največja in najmanjša lastna vrednost J'' . Če je κ blizu 1, je Hessian dobro pogojen in množice nivojev so skoraj sferične. V tem primeru strmec relativno hitro konvergira. Če je κ velik (recimo 10^8), so nizi ravni podolgovate elipse in algoritem lahko cik-cak, kar zahteva veliko iteracij za iskanje minimuma.



Slika 5.5

Pretvorba kontrolne spremenljivke. Običajna tehnika za ublažitev slabega pogojevanja je izvedba *transformacija kontrolne spremenljivke*, katere cilj je "predkondicioniranje" ali preoblikovanje problema, tako da je v novih koordinatah Hessian bližje identiteti. S tem se κ približa 1, kar pospeši konvergenco. Čeprav tukaj ne bomo podrobno opisali transformacije, je njeno glavno načelo ravno zmanjšanje razpona lastnih vrednosti v Hessianu.

Če povzamemo, **najhitrejšje spuščanje** (steepest descent") zagotavlja enostavno metodo za minimiziranje stroškovne funkcije 3D-Var z iterativnim izračunavanjem negativnega gradienta in iskanjem optimalne velikosti koraka. Ta algoritem dobro deluje pri skoraj sferičnih oblikah stroškovnih funkcij, vendar je lahko počasen, če je Hessian slabo pogojen (tj. ima zelo različne lastne vrednosti). Napredne metode, kot so konjugirani gradienti ali kvazi-Newtonovi pristopi (npr. BFGS, L-BFGS), rešujejo ta problem učinkoviteje z učinkovitim "obračanjem in skaliranjem" smeri iskanja na način, ki bolj zanesljivo obravnava eliptične oblike. Kljub temu ostaja algoritem najbolj strmega spuščanja odlično konceptualno orodje za ponazoritev, kako iterativne variacijske metode asimilacije podatkov potekajo v praksi.

5.4 Kako pospešiti konvergenco pri minimizaciji

Pri problemih asimilacije visokodimenzionalnih podatkov lahko oblika stroškovne funkcije $J(\vec{x})$ bistveno vpliva na učinkovitost iterativne minimizacije. Kot je bilo že obravnavano, lahko veliko število pogojev (tj. veliko razmerje med največjo in najmanjšo lastno vrednostjo Hessiana) povzroči počasno konvergenco ali cik-cak pri uporabi metod, ki temeljijo na gradientu. Da bi to rešili, pogosto izvedemo *transformacijo kontrolne spremenljivke*, ki redefinira naše spremenljivke tako, da je Hessian stroškovne funkcije v transformiranem prostoru bolj "sferičen," s čimer se zmanjša število pogojev in pospeši konvergenca.

Transformacija kontrolne spremenljivke

Uvedemo novo spremenljivko $\vec{\chi}$, ki je opredeljena z

$$\vec{\chi} = L^{-1}(\vec{x} - \vec{x}_b), \quad (5.16)$$

kjer je L običajno izbran tako, da

$$L L^T = B,$$

tj. L je operator kvadratnega korena kovariančne matrice napake ozadja B . V mnogih praktičnih izvedbah si lahko L predstavljamo kot Choleskyjev faktor ali drugo faktorizacijo B . Transformacija pomeni, da

$$\vec{x} - \vec{x}_b = L \vec{\chi}, \quad \text{in} \quad \vec{x} = \vec{x}_b + L \vec{\chi}.$$

Učinek na funkcijo stroškov. Spomnite se stroškovne funkcije 3D-Var v izvirni obliki:

$$J(\vec{x}) = \frac{1}{2}(\vec{x} - \vec{x}_b)^T B^{-1}(\vec{x} - \vec{x}_b) + \frac{1}{2}(\vec{y} - \mathcal{H}(\vec{x}))^T R^{-1}(\vec{y} - \mathcal{H}(\vec{x})).$$

Zdaj nadomestimo $\vec{x} = \vec{x}_b + L \vec{\chi}$. Za (lokalno) lineariziran $\mathcal{H}$ okrog $\vec{x}_b$, zapišemo:

$$\mathcal{H}(\vec{x}_b + L \vec{\chi}) \approx \mathcal{H}(\vec{x}_b) + H(L \vec{\chi}),$$

kjer je H Jacobian (ali tangentno-linearni operator) $\mathcal{H}$. Vstavljanje teh obrazcev v J in upoštevanje tega

$$(\vec{x} - \vec{x}_b)^T B^{-1}(\vec{x} - \vec{x}_b) = (L \vec{\chi})^T B^{-1}(L \vec{\chi}),$$

in da $B = L L^T$ implicira $B^{-1} = (L^T)^{-1} L^{-1} = L^{-T} L^{-1}$, dobimo transformirano stroškovno funkcijo. Simbolično (kot v opombah uporabnika) lahko zapišemo:

$$\begin{aligned} J(\vec{x}) &= \frac{1}{2}(\vec{x} - \vec{x}_b)^T B^{-1}(\vec{x} - \vec{x}_b) + \frac{1}{2}(\vec{y} - \mathcal{H}(\vec{x}_b) - H L \vec{\chi})^T R^{-1}(\vec{y} - \mathcal{H}(\vec{x}_b) - H L \vec{\chi}) \\ &= \frac{1}{2}\vec{\chi}^T \vec{\chi} + \frac{1}{2}(\vec{y} - \mathcal{H}(\vec{x}_b) - H L \vec{\chi})^T R^{-1}(\vec{y} - \mathcal{H}(\vec{x}_b) - H L \vec{\chi}). \end{aligned}$$

Tako v $\vec{\chi}$ -prostoru postane prvi člen $J \frac{1}{2} \vec{\chi}^T \vec{\chi}$, kar je preprosto sferična norma, ki močno poenostavlja ozadje stroškovne funkcije. Drugi izraz, povezan z opazovanji, ostaja, vendar je zdaj izražen z $\vec{\chi}$.

Gradient in Hessian v preoblikovanem prostoru. Da vidimo, zakaj to pomaga pri pogojevanju, izračunamo gradient nove stroškovne funkcije $J(\vec{\chi})$ glede na $\vec{\chi}$:

$$\nabla_{\vec{\chi}} J(\vec{\chi}) = \vec{\chi} + (H L)^T R^{-1} (\mathcal{H}(\vec{x}_b) + H L \vec{\chi} - \vec{y}).$$

Če vzamemo drugo izpeljanko, dobimo Hessian:

$$J''(\vec{\chi}) = \mathbf{I} + L^T H^T R^{-1} H L. \quad (5.17)$$

Tukaj identitetna matrika $\mathbf{I}$ izhaja iz $\frac{1}{2} \vec{\chi}^T \vec{\chi}$ člena, ki zagotavlja, da so vse lastne vrednosti tega Hessena premaknjene *navzgor* za vsaj 1. Posledično je najmanjša lastna vrednost $J''(\vec{\chi}) \geq 1$. To takoj zmanjša razmerje $\kappa = \lambda_{\max}/\lambda_{\min}$, zagotavljanje bolj pogojenega minimizacijskega problema. Po drugi strani pa lahko algoritmi, ki temeljijo na gradientu, konvergirajo hitreje, ker nimajo izjemno majhnih lastnih vrednosti (ki ustrezajo ravnim smerem) ali izjemno velikih lastnih vrednosti (strme smeri), kar lahko povzroči močno cik-cak ali počasno napredovanje v prvotnem $\vec{x}$ -prostoru.

Dobro pogojena minimizacija. S transformacijo kontrolne spremenljivke iz $\vec{x}$ v $\vec{\chi}$ smo naredili funkcijo stroškov bolj „podobno krogli“ v smislu, da ima njen Hessian lastne vrednosti, ki so bližje skupaj. Praktično gledano, če je v izvirnem prostoru številka pogoja reda 10^8 , se lahko po ustrezni transformaciji zmanjša na primer na 10^3 . Takšno zmanjšanje lahko dramatično zmanjša število ponovitev, potrebnih za najstrmejši spust, konjugirani gradient ali kvazi-Newtonove metode, da konvergirajo na globalni minimum.

Zato so *pretvorbe kontrolnih spremenljivk* (včasih imenovane *predkondicioniranje* v numerični optimizaciji) ključna strategija za pospešitev minimizacije pri obsežni asimilaciji podatkov. Pomagajo zagotoviti, da Hessian nima zelo majhnih lastnih vrednosti (ki bi kazale na izjemno ravne smeri v prostoru stroškovne funkcije) in nobenih pretirano velikih lastnih vrednosti. Zaradi tega je problem *dobro pogojen* in zato bolj obvladljiv za operativno numerično napovedovanje vremena, kjer lahko dimenzija vektorja stanja zlahka doseže 10^8 .

Prehod k 4D VAR

Čeprav se 3D VAR v praksi zelo dobro obnese za kratka asimilacijska okna in pogosta opazovanja, obstaja potreba tudi po upoštevanju *časovne razporeditve* opazovanj znotraj daljšega intervala (npr. 12 ali 24 ur). To nas vodi do razširitve v 4D VAR, kjer dovolimo, da model eksplicitno propagira začetno stanje skozi celotno asimilacijsko okno, pri tem pa primerjamo modelirane veličine z opazovanji ob njihovem pravem času. V naslednjem poglavju bomo podrobneje razložili koncept 4D VAR in kako se taka močno vezana (angl. *strong-constraint*) asimilacija izvaja v praksi.

Poglavje 6

4D VAR Asimilacija Podatkov

6.1 Od 3D VAR do 4D VAR


Kakšna je glavna razlika med 3D VAR in 4D VAR? Do zdaj smo vedno predpostavljali, da se opazovanja, analiza in ozadje dogajajo približno ob istem času. Na primer, če se spomnite, kaj smo zapisali pri 3D VAR, smo rekli, da dobimo napoved $\vec{x}_b$, jo propagiramo vse do časa, kjer želimo analizo (kjer je čas 0), nato pa upoštevamo opazovanja, ki se pojavijo med $t + \Delta t$ in $t - \Delta t$. Povedali smo, da je Δt običajno velikosti približno 1 ure, in na tej podlagi vse skupaj optimalno združimo, da dobimo analizo, ki jo označimo z $\vec{x}_a$, iz katere nato dobimo novo napoved, in vse skupaj ponovimo. To bi bil 3D VAR cikel. Predpostavili smo, da so vsa opazovanja na voljo v tistih časovnih oknih, ki se približno ujemajo z našim časom analize.

Zdaj pa so opazovanja v principu razpršena skozi čas. Potrebujemo algoritem, ki upošteva, da meritve pridejo kadarkoli se pač pojavijo. Ne zanima nas več samo zajem dela opazovanj, temveč celotna časovna serija opazovanj kadarkoli se pojavijo. Razumen ugovor bi bil: zakaj ne bi analize izvajali pogostejše in bolj pogosto, npr. vsako uro? Da, to bi seveda šlo, toda kaj pa, če želimo uporabiti *vs*a ta opazovanja za omejevanje te napovedi? Da bi to dosegli, uporabimo tako imenovani 4D VAR.

Če znova narišemo časovno os, imamo stanje na y -osi kot vektorsko spremenljivko $\vec{x}$. Tako imamo t. i. ozadje $\vec{x}_b$ iz prejšnje napovedi ob času 0. Denimo, da imamo spet veliko opazovanj, razpršenih skozi ves ta čas, od $t = 0$ naprej. Ta opazovanja (meritve) označimo z $\vec{y}$ stanja $\vec{x}$. Pri 4D VAR rečemo, da ne bomo uporabili le opazovanj v majhnem časovnem oknu, temveč v neprekinjenem oknu do časa $t = T$, kjer je lahko T 12 h, 24 h itd. Na ta način skušamo sestaviti analitično trajektorijo, ki se kar najboljše prilega ozadju $\vec{x}_b$ in opazovanjem v celotnem tem intervalu.

Naša analiza tako ni več zgolj en sam vektorski položaj, temveč zvezno stanje skozi čas, ki mu pravimo $\vec{x}_a$. Začetek, kjer se $\vec{x}_a$ poveže z $\vec{x}_b$, lahko imenujemo 4D okno. Na sliki (Slika 6.1) je rdeča krivulja trajektorija, ki sledi fizikalnim zakonom. Namen 4D VAR z besedami zapišemo takole: *4D VAR išče takšno začetno stanje, da se 12-urna analiza (ali izbrano časovno okno) kar najboljše prilega opazovanjem znotraj tega 12-urnega okna ter ozadju na začetku okna, hkrati pa spoštuje fizikalne zakone.*

V slovenščini temu rečemo "vezan ekstrem", kar bi lahko prevedli kot "bounded extremum" ali, v angleščini, pogosteje *constrained extremum*. Iščemo analizo, ki se v največji možni meri prilega ozadju in opazovanjem, hkrati pa je omejena z modelom (fizikalnimi zakoni). Tega bi torej lahko poimenovali *omejena minimizacija* oziroma *vezan ekstrem*. Lahko rečemo, da je fizikalni model omejitev. Na tej podlagi zapišemo stroškovno funkcijo 4D VAR.



Slika 6.1: 4D asimilacija variacijskih podatkov opazovanj, asimiliranih znotraj časovnega okna $[t_0, t_N]$.

6.2 Cenilka v 4D VAR

Najprej moramo opazovanja združiti v podvektorje opazovanj $\vec{y}_k$, ki so veljavni ob časih t_k . V praksi to dosežemo tako, da opazovanja razporedimo v specifične časovne intervale (npr. vsakih 15 minut), da jih lahko sistematično obravnavamo. Nato zapišemo minimizacijski problem; stroškovno funkcijo lahko zapišemo z izrazom za napako glede na ozadje (enak kot pri 3D VAR) plus vsoto po intervalih opazovanj:

$$J(\vec{x}) = \frac{1}{2}(\vec{x}_b - \vec{x})^T B^{-1}(\vec{x}_b - \vec{x}) + \frac{1}{2} \sum_{k=0}^K (\vec{y}_k - \mathcal{H}_k \mathcal{M}_k(\vec{x}))^T R^{-1} (\vec{y}_k - \mathcal{H}_k \mathcal{M}_k(\vec{x})). \quad (6.1)$$

V tej enačbi:

- Prvi člen meri razdaljo (v uteženem smislu) nove analize $\vec{x}$ od ozadja $\vec{x}_b$. Tu je B matrika za kovarianco napake glede na ozadje, B^{-1} pa njena inverzna.
- Drugi člen je vsota po časih opazovanj t_k . Za vsak k primerjamo stanje modela (propagirano do časa t_k) z opazovanji $\vec{y}_k$, zabeleženimi ob istem času. Tako je $\mathcal{M}_k(\vec{x})$ (pogosto zapisano bolj eksplicitno kot $\mathcal{M}_{t_0 \rightarrow t_k}(\vec{x})$) integracija modela naprej v času od t_0 do t_k , začenši z začetnim pogojem $\vec{x}$. $\mathcal{M}_{t_0 \rightarrow t_k}$ je integracija modela naprej v času, ki deluje na $\vec{x}$ in ustvari stanje $\vec{x}_k = \vec{x}(t_k)$, torej iz stanja $\vec{x}$, ki je v principu $\vec{x}(t_0)$ torej izvaja preslikavo od časa 0 do časa t_k . Operator $\mathcal{H}_k$ pretvori stanje modela v prostor opazovanj (npr. izbere spremenljivke, interpolira v prostoru ali pretvori vrsto spremenljivke), R pa je matrika kovariance napak pri opazovanjih (pogosto označena R_k , če je odvisna od časa).

Opazimo, da $\mathcal{M}_k(\vec{x}) = \mathcal{M}_{t_0 \rightarrow t_k}(\vec{x})$ lahko razumemo kot operator, ki integrira napovedni model od časa t_0 do časa t_k . Podobno je $\mathcal{H}_k$ operator opazovanj za k -ti podvektor opazovanj. Tako $\mathcal{M}$ kot $\mathcal{H}$ sta lahko (in pogosto tudi sta) nelinearni. Modelsko integracijo lahko razdelimo tudi na

krajše korake:

$$\mathcal{M}_{t_0 \rightarrow t_k} = \mathcal{M}_{t_{k-1} \rightarrow t_k} \mathcal{M}_{t_{k-2} \rightarrow t_{k-1}} \dots \mathcal{M}_{t_0 \rightarrow t_1}. \quad (6.2)$$

Tedaj lahko za stanje $\vec{x}_k$ ob času t_k zapišemo:

$$\vec{x}_k = \mathcal{M}_{t_0 \rightarrow t_k}(\vec{x}_0), \quad \vec{x}_k = \mathcal{M}_{t_{k-1} \rightarrow t_k}(\vec{x}_{k-1}). \quad (6.3)$$

6.3 Perspektiva omejene minimizacije

Ker imamo stanje, ki se razvija v času, lahko stroškovno funkcijo preoblikujemo tako, da obravnavamo vsa stanja $\vec{x}_0, \vec{x}_1, \dots, \vec{x}_k$ kot spremenljivke. Nato lahko zapišemo:

$$J(\vec{x}_0, \vec{x}_1, \dots, \vec{x}_k) = \frac{1}{2}(\vec{x}_b - \vec{x}_0)^T B^{-1}(\vec{x}_b - \vec{x}_0) + \frac{1}{2} \sum_{k=0}^K (\vec{y}_k - \mathcal{H}_k(\vec{x}_k))^T R^{-1}(\vec{y}_k - \mathcal{H}_k(\vec{x}_k)). \quad (6.4)$$

V tem pogledu se običajni minimizacijski problem

$$\vec{x}_a = \arg \min_{\vec{x}_0} J(\vec{x}_0) \quad (6.5)$$

preoblikuje v *omejeni* minimizacijski problem:

$$\vec{x}_a = \arg \min_{\vec{x}_0, \vec{x}_1, \dots, \vec{x}_k} J(\vec{x}_0, \vec{x}_1, \dots, \vec{x}_k), \quad (6.6)$$

z naslednjimi omejitvami:

$$\vec{x}_k = \mathcal{M}_{t_{k-1} \rightarrow t_k}(\vec{x}_{k-1}), \quad \text{za } k = 1, 2, \dots, K. \quad (6.7)$$

Te omejitve preprosto povedo, da mora razvoj modela biti fizikalno skladen (tj. $\vec{x}_k$ mora izhajati iz integracije $\vec{x}_{k-1}$). Pri "4D VAR s strogimi omejitvami" (angl. strong-constraint 4D VAR) predpostavimo, da je model popoln, zato model $\mathcal{M}$ strogo uveljavlja te omejitve. Zato rečemo, da fizikalni model deluje kot stroga omejitev, ki povezuje stanja. Stanje $\vec{x}_k$ se ne more poljubno ločiti od $\vec{x}_{k-1}$, četudi bi opazovanja nakazovala nenaden skok.

Dejansko model deluje tudi kot žglajevalnik" (angl. smoother), ki med seboj poveže ali omeji trajektorijo glede na vsa opazovanja. Tako se pri 4D VAR podatkovni asimilaciji uporablja okno, znotraj katerega so podatki asimilirani; opazovanja prihajajo neprekinjeno in morajo biti vsa upoštevana. Ozadje $\vec{x}_b$ nudi informacijo o začetnem stanju. 4D VAR išče analizo, pri kateri se modelna trajektorija čim manj razlikuje tako od opazovanj $\vec{y}_k$ kot od ozadja $\vec{x}_b$.

Z drugimi besedami lahko to zapišemo z drugo notacijo. Pogosto napišemo:

$$J(\vec{x}) = J_b + J_0 = \frac{1}{2}(\vec{x}_b - \vec{x})^T B^{-1}(\vec{x}_b - \vec{x}) + \frac{1}{2} \sum_{k=0}^K (\vec{y}_k - \mathcal{H}_k \mathcal{M}_{t_0 \rightarrow t_k}(\vec{x}))^T R^{-1}(\vec{y}_k - \mathcal{H}_k \mathcal{M}_{t_0 \rightarrow t_k}(\vec{x})). \quad (6.8)$$

Tu J_b meri razliko med začetno analizo $\vec{x}$ in ozadjem $\vec{x}_b$, medtem ko J_0 meri razdaljo med opazovanji $\vec{y}_k$ in modelskimi ekvivalenti teh opazovanj (tj. stanjem modela, preslikanim v prostor opazovanj ob ustreznem času). V praksi je k kazalec intervalov opazovanj, ki so lahko denimo postavljeni na 15-minutne intervale. Za vsak interval izračunamo modelski ekvivalent vseh opazovanj v tem intervalu. To je računsko lahko zelo drago, saj zahteva integracijo modela od t_0 do t_k in nato uporabo operatorja opazovanj $\mathcal{H}_k$.

Znano je tudi, da je možno izraz $\mathcal{H}_k \mathcal{M}_{t_0 \rightarrow t_k}(\vec{x})$ zapisati kot posplošen operator opazovanj $\mathcal{G}_k$. Včasih se stroškovna funkcija zapiše v obliki:

$$J(\vec{x}_0, \vec{x}_1, \dots, \vec{x}_k) = \frac{1}{2}(\vec{x}_b - \vec{x}_0)^T B^{-1}(\vec{x}_b - \vec{x}_0) + \frac{1}{2} \sum_{k=0}^K (\vec{y}_k - \mathcal{G}_k(\vec{x}_k))^T R_k^{-1}(\vec{y}_k - \mathcal{G}_k(\vec{x}_k)), \quad (6.9)$$

kar je v bistvu ista ideja. Končna analiza je

$$\vec{x}_a = \arg \min_{\vec{x}_0} J(\vec{x}_0), \quad (6.10)$$

ali, z omejenega vidika, ekvivalentno:

$$\vec{x}_a = \arg \min_{\vec{x}_0, \vec{x}_1, \dots, \vec{x}_k} J(\vec{x}_0, \vec{x}_1, \dots, \vec{x}_k), \quad \text{z omejitvijo} \quad \vec{x}_k = \mathcal{M}_{t_{k-1} \rightarrow t_k}(\vec{x}_{k-1}). \quad (6.11)$$

S tem smo opisali *4D VAR s strogimi omejitvami*, pri katerem predpostavimo, da je razvoj modela popoln in brez napak. $\mathcal{M}$ si lahko predstavljamo kot barotropično enačbo vrtničnosti ali pa enačbe modela plitke vode, torej je splošen izraz za vse ne linearne modele.

6.4 Strong vs. Weak Constraint 4D VAR

Seveda v resnici nimamo popolnega opisa atmosfere ali njenega razvoja. Vsi naši modeli so aproksimacije fizikalne realnosti. Tako lahko oblikujemo tudi *4D VAR s šibkimi omejitvami* (angl. *weak-constraint 4D VAR*), kjer pri vsakem koraku dopustimo napako modela:

$$\vec{x}_k = \mathcal{M}_{t_{k-1} \rightarrow t_k}(\vec{x}_{k-1}) + q_k, \quad (6.12)$$

kjer q_k predstavlja naključno (ali sistematično) modelno napako pri vsakem koraku. To pa naredi minimizacijski problem bolj zapleten, kajti zdaj moramo obravnavati tako vektorsko spremenljivko stanja (za vse časovne korake) kot zaporedje modelnih napak q_k kot neznank (oziroma jih moramo ustrezno parametizirati).

Z drugimi besedami, namesto da bi obravnavali zgolj $(\vec{x}_0, \vec{x}_1, \dots)$, bi morali zapisati še $(q_0, q_1, q_2, \dots)$, da bi upoštevali negotovost oziroma nepopolnost modelskih enačb pri vsakem časovnem koraku. Dimenzija problema lahko na ta način postane znatno večja, poleg tega pa so morda potrebne dodatne predpostavke ali strukture kovarianc za q_k . Enačba cenilke bi se v tem primeru preoblikovala v:

$$J(x_0, \dots, x_k, \eta_0, \dots, \eta_{k-1}) = \frac{1}{2}(x_0 - x_b)^T B^{-1}(x_0 - x_b) + \frac{1}{2} \sum_{i=0}^k (y_i - H_i(x_i))^T R_i^{-1}(y_i - H_i(x_i)) + \frac{1}{2} \sum_{i=1}^{k-1} \eta_i Q_i^{-1} \quad (6.13)$$

kjer je Q_i matrika napake modela. Dopuščanje modelskih napak dejansko razširi množico neznank v asimilacijskem problemu in s tem oteži minimizacijo. V praksi nekatere izvedbe 4D VAR s šibkimi omejitvami res storijo natanko to ali pa vnesejo dodatne omejitve na q_k . Kakorkoli, glavno sporočilo ostaja, da model ni več stroga omejitev, temveč bolj aproksimativna.

6.5 4D VAR ALGORITEM

Prva aproksimacija trajektorije (rdeča črta na Sliki 6.2) bi bila


$$\vec{x}_{fg}(t_k) = \mathcal{M}_{t_0 \rightarrow t_k}(\vec{x}_b(t_0)). \quad (6.14)$$

Z drugimi besedami, naša prva domneva za trajektorijo je pridobljena z integracijo ozadja $\vec{x}_b$ ob začetnem času t_0 naprej do vsakega časa t_k .

Nato izračunamo stroškovno funkcijo J . Najprej obravnavamo odstopanje od $\vec{x}_b$. Seveda je v prvi iteraciji to odstopanje lahko enako nič, če je x_0 dejansko nastavljeno na $\vec{x}_{fg}(0) = \vec{x}_b(0)$. Na splošno pa pišemo:

$$J_b = (\vec{x}_b - \vec{x}_0)^T B^{-1}(\vec{x}_b - \vec{x}_0). \quad (6.15)$$

Ta člen meri, kako daleč je naše začetno stanje $\vec{x}_0$ od ozadja $\vec{x}_b$, pri čemer uporabimo kovarianco napake ozadja B .



Slika 6.2: Skica 4D VAR algoritma

V drugem koraku nato izvedemo zanko od $k = 0$ do K , pri čemer seštejemo vse prispevke iz členov, ki vsebujejo opazovanja:

$$J = J_b + \frac{1}{2} (\vec{y}_k - \mathcal{H}_k(\vec{x}_k))^T R_k^{-1} (\vec{y}_k - \mathcal{H}_k(\vec{x}_k)). \quad (6.16)$$

Tukaj so $\vec{y}_k$ opazovanja, ki veljajo ob času t_k , $\vec{x}_k$ je stanje modela ob času t_k , $\mathcal{H}_k$ je operator opazovanj, ki preslika modelski prostor v prostor opazovanj, R_k pa kovarianca napak opazovanj ob času t_k . Vsak člen $(\vec{y}_k - \mathcal{H}_k(\vec{x}_k))$ meri razliko med modelsko napovedanimi opazovanji in dejanskimi opazovanji ob t_k .

Po tem, ko seštejemo te člene, gremo v modelu naprej v času, tako da integriramo

$$\vec{x}_k = \mathcal{M}_{t_{k-1} \rightarrow t_k}(\vec{x}_{k-1}). \quad (6.17)$$

Enačba (6.17) propagira stanje $\vec{x}_{k-1}$ naprej od časa t_{k-1} do t_k z (nelinearnim) modelskim operatorjem $\mathcal{M}$. Radi bi se izognili temu, da bi dvakrat izvajali polno nelinearno integracijo za isti časovni korak, zato lahko na začetku nastavimo $\vec{x}_{fg}(0) = \vec{x}_b(0)$ in nato dosledno za vsak korak uporabimo $\mathcal{M}$ enkrat.

Naš splošni cilj je *minimizirati* stroškovno funkcijo J . Denimo, da želimo zdaj najti novo stanje $\vec{x}_0$ (in s tem novo trajektorijo), ki zmanjša vrednost J . Moramo poiskati smer v faznem prostoru, v kateri se J manjša, da bi prešli od prve domneve k stanju, ki bo dalo manjši J . Ker je dimenzija stanja običajno zelo velika, ne moremo kar na slepo vzorčiti celotnega faznega prostora, temveč potrebujemo *gradient* stroškovne funkcije.

Ko enkrat izračunamo J na podlagi prve domneve za trajektorijo, poznamo njegovo vrednost in želimo posodobiti $\vec{x}_0$ v smeri, ki bo J zmanjšala. Zato potrebujemo gradient:

$$\nabla_{\vec{x}_0} J(\vec{x}_0) = B^{-1}(\vec{x}_b - \vec{x}_0) + \sum_{k=0}^K G_k^T R_k^{-1} (\vec{y}_k - \mathcal{G}_k(\vec{x}_0)). \quad (6.18)$$

V tem izrazu prvi člen $B^{-1}(\vec{x}_b - \vec{x}_0)$ ustreza prispevku ozadja, vsota po k pa zajame prispevke iz vseh opazovanj. Operator $\mathcal{G}_k(\vec{x}_0)$ je okrajšava za

$$\mathcal{G}_k(\vec{x}_0) = \mathcal{H}_k \mathcal{M}_{t_0 \rightarrow t_k}(\vec{x}_0),$$

tj. za stanje modela ob času t_k , preslikano v prostor opazovanj.

Vidimo, da če razširimo $\mathcal{G}_k(\vec{x}_0)$, dobimo verigo integracij:

$$\begin{aligned} \vec{y}_k - \mathcal{H}_k(\vec{x}_k) &= \vec{y}_k - \mathcal{H}_k \mathcal{M}_{t_0 \rightarrow t_k}(\vec{x}_0), \\ &= \vec{y}_k - \mathcal{H}_k \mathcal{M}_{t_{k-1} \rightarrow t_k} \mathcal{M}_{t_{k-2} \rightarrow t_{k-1}} \dots \mathcal{M}_{t_0 \rightarrow t_1}(\vec{x}_0), \\ &= \vec{y}_k - \mathcal{G}_k(\vec{x}_0). \end{aligned}$$

Torej $\vec{y}_k - \mathcal{G}_k(\vec{x}_0)$ preprosto predstavlja razliko med opazovanji in modelskim preračunom teh opazovanj ob času t_k .

Matrika/operator G_k^T je

$$G_k^T = \frac{\partial \mathcal{G}_k}{\partial \vec{x}_0}, \quad \text{in} \quad G_k^T = M_{t_0 \rightarrow t_1}^T M_{t_1 \rightarrow t_2}^T \cdots M_{t_{k-2} \rightarrow t_{k-1}}^T M_{t_{k-1} \rightarrow t_k}^T H_k^T.$$

Tukaj je vsak $M_{t_{i-1} \rightarrow t_i}$ *tangentni linearni model* (angl. *tangent linear model*) za nelinearni operator $\mathcal{M}_{t_{i-1} \rightarrow t_i}$, $M_{t_{i-1} \rightarrow t_i}^T$ pa je njegov *adjungirani* (transponirani) operator. Tako je G_k^T sestavljen iz zaporedja adjungiranih operatorjev, ki jim pogosto rečemo *adjungirani model* tangentnega linearnega modela, na koncu pa še H_k^T , adjungirani operator opazovalnega operatorja.

Ko enkrat izračunamo $\nabla_{\vec{x}_0} J(\vec{x}_0)$, algoritem poteka podobno kot pri 3D VAR. Z gradientom posodobimo $\vec{x}_0$ v smer, ki zmanjša J , nato z novo trajektorijo izračunamo J in postopek ponavljamo, dokler ne konvergiramo k minimumu. Ta minimum definira analizo, ki je naša najboljša ocena razvoja stanja atmosfere v času.

Z združevanjem takšnih 12-urnih oken (ali poljubne izbrane dolžine) zaporedoma lahko nenehno posodabljammo asimilacijski cikel. Tako lahko dobimo oceno stanja vremena skozi celotno zgodovino razvoja modela, teoretično tudi daleč v preteklost (npr. vse do začetkov 21. stoletja), če imamo na voljo ustrezna opazovanja, polja ozadja in računske vire.

6.6 4D VAR Učinkovitost

Kako lahko učinkovito izračunamo del gradienta, ki se nanaša na opazovanja,

$$\nabla_{\vec{x}_0} J_o(\vec{x}_0) = \sum_{k=0}^K G_k^T R_k^{-1} (\vec{y}_k - \mathcal{G}_k(\vec{x}_0)) ?$$

Če se tega lotimo neposredno — pri čemer vsako komponento izračunamo posebej za $k = 0, 1, 2, \dots, K$ — se bo zgodilo:

$$\begin{aligned} \sum_{k=0}^K G_k^T R_k^{-1} (\vec{y}_k - \mathcal{G}_k(\vec{x}_0)) &= H_0^T R_0^{-1} (\vec{y}_0 - \mathcal{H}_0(\vec{x}_0)) + M_{t_0 \rightarrow t_1}^T H_1^T R_1^{-1} (\vec{y}_1 - \mathcal{H}_1 \mathcal{M}_{t_0 \rightarrow t_1}(\vec{x}_0)) \\ &+ M_{t_0 \rightarrow t_1}^T M_{t_1 \rightarrow t_2}^T H_2^T R_2^{-1} (\vec{y}_2 - \mathcal{H}_2 \mathcal{M}_{t_1 \rightarrow t_2} \mathcal{M}_{t_0 \rightarrow t_1}(\vec{x}_0)) \\ &+ \dots \\ &+ M_{t_0 \rightarrow t_1}^T M_{t_1 \rightarrow t_2}^T \cdots M_{t_{K-1} \rightarrow t_K}^T H_K^T R_K^{-1} (\vec{y}_K - \mathcal{H}_K \mathcal{M}_{t_{K-1} \rightarrow t_K} \cdots \\ &\quad \dots, \mathcal{M}_{t_1 \rightarrow t_2} \mathcal{M}_{t_0 \rightarrow t_1}(\vec{x}_0)). \end{aligned}$$

Opazimo, da pri prvem členu ni modelske integracije — zgolj izračunamo razliko med opazovanjem in modelskim ekvivalentom opazovanja ter to pomnožimo z $H_0^T R_0^{-1}$. Pri $k = 1$ imamo eno integracijo modela ($M_{t_0 \rightarrow t_1}^T$); pri $k = 2$ imamo dve integraciji modela ipd. Zato naiven pristop pomeni ogromno ponavljajočih se modelskih integracij, na vrstni red $\frac{K(K+1)}{2}$, kar je zelo neučinkovito.

Ena od poti za zmanjšanje tega stroška je, da *shranimo nelinearno trajektorijo* $\{\vec{x}_0, \vec{x}_1, \dots, \vec{x}_K\}$ po tem, ko jo enkrat izračunamo naprej, namesto da znova integriramo model za vsak trenutek opazovanj. Poleg tega se operatorji $M_{t_i \rightarrow t_j}^T$ večkrat ponovijo, kar dodatno kaže na neučinkovitost, če vse začnemo vedno znova.

Da bi to rešili, zapisano vsoto preuredimo tako, da se jasno vidi, kako lahko adjungirane operatorje zaporedno uporabimo v obratni smeri časovno:

$$\begin{aligned}
\sum_{k=0}^K G_k^T R_k^{-1} (\vec{y}_k - \mathcal{G}_k(\vec{x}_0)) &= H_0^T R_0^{-1} (\vec{y}_0 - \mathcal{H}_0(\vec{x}_0)) \\
&+ M_{t_0 \rightarrow t_1}^T \left[H_1^T R_1^{-1} (\vec{y}_1 - \mathcal{H}_1(\vec{x}_1)) \right. \\
&\quad + M_{t_1 \rightarrow t_2}^T \left(H_2^T R_2^{-1} (\vec{y}_2 - \mathcal{H}_2(\vec{x}_2)) + \dots \right. \\
&\quad \left. \left. + M_{t_{K-1} \rightarrow t_K}^T (H_K^T R_K^{-1} (\vec{y}_K - \mathcal{H}_K(\vec{x}_K))) \dots \right) \right].
\end{aligned}$$

Namesto da izvedemo $\frac{K(K+1)}{2}$ integracij, tako izvedemo le K adjungiranih integracij modela, pri čemer vsakič v enem zamahu postopoma "potiskamo" občutljivost časovno nazaj.

6.6.1 Praktičen oris algoritma.

Najprej nastavimo $\nabla J = \vec{0}$. Nato gremo od končnega časovnega koraka $k = K$ nazaj proti $k = 0$. V vsaki fazi "vgnezdim" prispevek v prejšnjega. Konkretno:

- Začnemo pri $k = K$ tako, da izračunamo $\vec{y}_K - \mathcal{H}_K(\vec{x}_K)$.
- Pomnožimo z $H_K^T R_K^{-1}$, s čimer dobimo prvi del ∇J .
- Uporabimo adjungirani operatorski produkt $M_{t_{K-1} \rightarrow t_K}^T$, da se premaknemo za en časovni korak nazaj: $\nabla J = M_{t_{K-1} \rightarrow t_K}^T \nabla J$.
- Dodamo naslednji člen $\vec{y}_{K-1} - \mathcal{H}_{K-1}(\vec{x}_{K-1})$, pomnožimo z $H_{K-1}^T R_{K-1}^{-1}$ in uporabimo $M_{t_{K-2} \rightarrow t_{K-1}}^T$.
- Postopek nadaljujemo do $k = 0$.
- Na koncu pri $k = 0$ vključimo še ozadni člen $B^{-1}(\vec{x}_b - \vec{x}_0)$, da dokončamo izračun gradienta:

$$\nabla J = \nabla J + B^{-1}(\vec{x}_b - \vec{x}_0).$$

S tem se del gradienta zaradi opazovanja izračuna časovno nazaj prek *enega* zaporedja adjungiranih integracij in ne množice.

Ko zaključimo z opisom učinkovitega izračuna gradienta, lahko omenimo nekatere **praktične naloge 4D VAR**, ki se pogosto pojavljajo. Običajno ves postopek 4D VAR zahteva eno nelinearno integracijo naprej in eno adjungirano integracijo nazaj na iteracijo. Za vsak asimilacijski cikel lahko izvedemo kakšnih 50 iteracij. Če predpostavimo, da ena ura napovedi stane "1 enoto" računskih sredstev, potem adjungirani model pogosto stane približno "3 enote" na uro napovedi (ker adjungirani postopek vključuje dodatne operacije, kot so transpozicije, in več pomnilnika).

Predstavljajmo si globalni napovedni sistem, ki rutinsko izvaja 240-urno napoved (10 dni) po ceni "1 enote" na uro. Skupna cena za napoved je tedaj 240 enot. Toda pri 4D VAR za 10-dnevno okno stroški močno narastejo, zlasti če iteriramo veliko časi in večkrat zaganjamo adjungirani model. Dejansko se to lahko izkaže za približno 10-krat dražje. Da bi to omilili, se pogosto uporablja *inkrementalni 4D VAR* ali se zmanjša ločljivost 4D VAR (npr. z uporabo bolj grobe mreže ali manj navpičnih ravni), medtem ko se za končno integracijo ohrani model v polni ločljivosti. Na ta način lažje ohranjamo skupne računske stroške sprejemljive, ne da bi preveč ogrozili natančnost analize.

6.7 Inkrementalni 4D VAR algoritem

Eden od načinov, kako lahko v praksi izvedemo minimizacijo potencialno zapletene 4D VAR cenilne funkcije, je t.i. *inkrementalni 4D VAR algoritem*. Ta algoritem je dejanska oblika 4D VAR, ki se trenutno uporablja v več meteoroloških središčih. Ključna zamisel je, da kompleksno (pogosto zelo nelinearno) minimizacijsko nalogo razbijemo na zaporedje manjših, *inkrementalnih* problemov, pri čemer v vsaki iteraciji približamo polno nelinearno cenilno funkcijo s kvadratnim problemom okoli trenutnega najboljšega približka.

Najprej zapišemo običajno cenilno funkcijo, vendar pri tem v kvadratnih izrazih množimo s faktorjem -1 . Ta korak je le označevalne narave, kajti

$$(-x)^2 = x^2,$$

zato se sama cenilna funkcija pri tem ne spremeni. Pisanje $(-x)^2$ namesto x^2 je zgolj ličnejši način za določene delne odvode, ne vpliva pa na jedro problema. Tako obravnavamo naslednjo cenilno funkcijo:

$$J(\vec{x}_0) = \frac{1}{2} (\vec{x}_0 - \vec{x}_b)^T B^{-1} (\vec{x}_0 - \vec{x}_b) + \frac{1}{2} \sum_{k=0}^K (\mathcal{H}_k \mathcal{M}_{t_0 \rightarrow t_k}(\vec{x}_0) - \vec{y}_k)^T R_k^{-1} (\mathcal{H}_k \mathcal{M}_{t_0 \rightarrow t_k}(\vec{x}_0) - \vec{y}_k). \quad (6.19)$$

V tem izrazu je $\vec{x}_0$ začetno stanja modela ob času t_0 , $\vec{x}_b$ je ozadje (oziroma začetni približek), B je matrika kovariančne napake ozadja, $\vec{y}_k$ so opazovanja v časih t_k , R_k so ustrezne matrike kovariančne napake opazovanj, operator $\mathcal{M}_{t_0 \rightarrow t_k}$ pa nelinearni model, ki razvije začetno stanje $\vec{x}_0$ od časa t_0 do t_k , nakar $\mathcal{H}_k$ preslika modelski vektorski prostor v prostor opazovanj. Pomembno je poudariti, da $\vec{x}$ v prvem členu ni $\vec{x}(t)$ za nek čas t , temveč stanje ob času t_0 , ki ga lahko označimo z $\vec{x}_0$ ali zgolj $\vec{x}$. V bistvu s tem konceptualno ne spreminjamo ničesar; le opozarjamo, da sta $(-x)^2$ in x^2 matematično enaka izraza.

Naslednji korak je, da vpeljemo *inkrement*:

$$\vec{x} = \vec{x}^{(m)} + \delta\vec{x}^{(m)},$$

kjer je $\vec{x}^{(m)}$ stanje, okrog katerega lineariziramo (trenutni približek), $\delta\vec{x}^{(m)}$ pa *inkrement*, ki ga določimo v m -ti iteraciji. V začetku lahko vzamemo $\vec{x}_b$ kot prvi približek, torej naj bo $\vec{x}_0^{(0)} = \vec{x}_b$. Če je $\vec{x}_0$ iskano začetno stanje, potem velja $\delta\vec{x}^{(0)} = \vec{x}_0 - \vec{x}_b$. Namesto da bi cenilno funkcijo zapisovali neposredno v odvisnosti od $\vec{x}_0$, bomo zdaj problem izrazili v smislu inkrementa $\delta\vec{x}_0$.

To nas pripelje do tega, da prvotno cenilno funkcijo preoblikujemo v cenilno funkcijo, imenovano δJ , ki je odvisna od $\delta\vec{x}_0$:

$$\delta J(\delta\vec{x}_0) = \frac{1}{2} \delta\vec{x}_0^T B^{-1} \delta\vec{x}_0 + \frac{1}{2} \sum_{k=0}^K \dots \quad (6.20)$$

Prvi člen, $\frac{1}{2} \delta\vec{x}_0^T B^{-1} \delta\vec{x}_0$, meri razliko med posodobljenim stanjem in ozadjem v smislu inkrementa. Piko pa bomo razširili v drugi člen, ki izraža oddaljenost modelske trajektorije od opazovanj, prav tako v smislu tega inkrementa. Za ustrezno vpeljavo inkrementa v drugi člen moramo upoštevati, da se stanje od časa t_0 do časa t_k razvije preko nelinearnega operatorja $\mathcal{M}_{t_0 \rightarrow t_k}$, zato moramo napraviti *linearizacijo* cenilne funkcije iz (6.19) okoli $\vec{x}^{(m)}$. To storimo tako, da zapišemo:

$$\begin{aligned} \vec{x}^{(m)}(t) + \delta\vec{x}^{(m)}(t) &= \mathcal{M}_{t_0 \rightarrow t}(\vec{x}^{(m)}(t_0) + \delta\vec{x}^{(m)}(t_0)), \\ \vec{x}^{(m)}(t) + \delta\vec{x}^{(m)}(t) &= \mathcal{M}(\vec{x}(t_0)) + \left. \frac{\partial \mathcal{M}}{\partial \vec{x}} \right|_{\vec{x}(t_0)} \delta\vec{x}(t_0) + \mathcal{O}(|\delta x(t_0)|^2), \\ \vec{x}^{(m)}(t) + \delta\vec{x}^{(m)}(t) &= \mathcal{M}(\vec{x}(t_0)) + M_{t_0 \rightarrow t} \delta\vec{x}(t_0) + \mathcal{O}(|\delta x(t_0)|^2), \end{aligned}$$

kjer smo v drugi vrstici uporabili Taylorjevo ekspanzijo operatorja $\mathcal{M}$ okrog trenutnega približka, v tretji vrstici pa prepoznali, da je $M_{t_0 \rightarrow t}$ t.i. *tangentni linearni model*, to je Jacobijeva matrika $\mathcal{M}$, ovrednotena pri $\vec{x}(t_0)$.

Opisana shema pomeni, da najprej zapišemo 4D VAR cenilno funkcijo v njeni izvorni obliki. Nato pa, *namesto* da bi neposredno iskali optimum $\vec{x}_0$, v vsaki iteraciji vpeljemo inkrement $\delta\vec{x}_0$, ki se nanaša na prejšnji približek. Ta postopek večkrat ponovimo, pri čemer vsakokrat rešujemo lažji, lineariziran podproblem. Ozadje $\vec{x}_b$ običajno služi kot začetni približek, $x_0^{(0)}$. Da bi polno izrazili cenilno funkcijo v smislu inkrementov, moramo tudi člen, ki meri oddaljenost med modelsko trajektorijo in opazovanji, ustrezno zapisati z inkrementom. Pri tem si pomagamo z opisom, kako se vsota (prvega približka in inkrementa) razvije v času z nelinearnim modelom: nelinearni del uporabimo za ozadje, inkrement pa se razvija po *tangentnem linearnem modelu* $M_{t_0 \rightarrow t}$, kar utemeljuje Taylorjeva ekspanzija.

Kot preprost primer tangentnega linearnega modela vzemimo funkcijo $z = x^3 y^2$. Tedaj za majhna inkrementa $(\delta x, \delta y)$ okoli (x_0, y_0) velja

$$\delta z = 3x^2 y^2 \delta x + 2x^3 y \delta y,$$

kar je točno tangentno-linearni zapis omenjene nelinearne funkcije. Pri meteoroloških modelih je $\mathcal{M}$ dosti bolj zapletena in visokodimenzionalna, a načelo ostaja nespremenjeno. Izračun takšnih tangentnih linearnih modelov je seveda lahko drag, zato inkrementalni 4D VAR stremi k temu, da se *popolni* nelinearni model kliče čim redkeje.

Po linearizaciji tako ponovno izrazimo cenilno funkcijo (6.20):

$$\delta J(\delta\vec{x}_0) = \frac{1}{2} \delta\vec{x}_0^T B^{-1} \delta\vec{x}_0 + \frac{1}{2} \sum_{k=0}^K \left(\mathcal{H}_k \mathcal{M}_{t_0 \rightarrow t_k}(\vec{x}_b + \delta\vec{x}_0) - \vec{y}_k \right)^T R_k^{-1} \left(\mathcal{H}_k \mathcal{M}_{t_0 \rightarrow t_k}(\vec{x}_b + \delta\vec{x}_0) - \vec{y}_k \right). \quad (6.21)$$

Tu vstavimo $\vec{x}_b + \delta\vec{x}_0$ na mesto $\vec{x}_0$ in se zavedamo, da je ozadje $\vec{x}_b$ fiksno, inkrement $\delta\vec{x}_0$ pa spremenljiv. Da vse skupaj še dodatno poenostavimo, *spet* uporabimo linearno aproksimacijo v termu $\mathcal{H}_k \mathcal{M}_{t_0 \rightarrow t_k}(\vec{x}_b + \delta\vec{x}_0)$. Pridemo do

$$\delta J(\delta\vec{x}_0) = \frac{1}{2} \delta\vec{x}_0^T B^{-1} \delta\vec{x}_0 + \frac{1}{2} \sum_{k=0}^K \left(H_k M_{t_0 \rightarrow t_k} \delta\vec{x}_0 - \vec{d}_k \right)^T R_k^{-1} \left(H_k M_{t_0 \rightarrow t_k} \delta\vec{x}_0 - \vec{d}_k \right), \quad (6.22)$$

kjer uvedemo *odstopanje*

$$\vec{d}_k = \vec{y}_k - \mathcal{H}_k M_{t_0 \rightarrow t_k}(\vec{x}_b).$$


Vektor $\vec{d}_k$ torej izraža razliko med opazovanji in modelskim ekvivalentom teh opazovanj, izračunanem iz ozadja. Če vstavimo linearno aproksimacijo

$$\mathcal{H}_k \mathcal{M}_{t_0 \rightarrow t_k}(\vec{x}_b + \delta\vec{x}_0) \approx \mathcal{H}_k \mathcal{M}_{t_0 \rightarrow t_k}(\vec{x}_b) + H_k M_{t_0 \rightarrow t_k} \delta\vec{x}_0,$$

dobimo točno inkrementalno 4D VAR cenilno funkcijo (6.22), ki se danes široko uporablja v sodobnih sistemih za asimilacijo podatkov.

V čem je lepota tega algoritma? Bistvo se lepo ponazori z grafičnim prikazom cenilne funkcije in njenih zaporednih kvadratnih aproksimacij, kot je nakazano na Sliki 6.3. Zamislimo si, da ima izvorna nelinearna cenilna funkcija (na sliki rdeča črta) v odvisnosti od začetnega stanja veliko morebitnih lokalnih minimumov ali razgibane “oblike”; to lahko izhaja iz nelinearnosti opazovalnega operatorja, nelinearnih integracij v modelu ipd. Pri inkrementalnem 4D VAR pa izvorno nelinearno cenilno funkcijo postopno približamo z *zaporedjem* kvadratnih inkrementalnih cenilnih funkcij (modre črtkane aproksimacije).

Vidimo, da namesto neposrednega spuščanja po zapleteni rdeči funkciji v vsaki iteraciji rešujemo preprostejši kvadratni minimizacijski problem. Ker je cenilna funkcija (6.22) v inkrementu $\delta\vec{x}_0$ *izključno kvadratna*, ima “lep” konveksen značaj z nedvoumnim minimumom,



Slika 6.3: Shematski prikaz minimizacije inkrementalnega 4D VAR. Rdeča črta označuje izvorno nelinearno cenilno funkcijo $J(\vec{x}(t_0))$, modre črtkane krivulje lokalne kvadratne aproksimacije $\delta J(\delta \vec{x}_0)$ okoli zaporednih približkov in zelene črte dejanske inkrementalne korake $\delta \vec{x}^m$. Vsaka iteracija posodobi stanje s preračunanim inkrementom $\delta \vec{x}_0^{(m)}$, kar določi novo linearnizacijsko točko.

medtem ko so nelinearni operatorji zbrani v fiksnem delu $\vec{d}_k$ in ne povzročajo nelinearnosti v $\delta \vec{x}_0$. Tako se vsaka notranja minimizacija stabilno konvergira in ni v tolikšni meri podvržena pastem lokalnih minimumov kot neposredna minimizacija polne nelinearne funkcije.

Poleg tega inkrementalni 4D VAR omogoča, da v praksi delamo z *več ločljivostmi*. Na primer, začetne iteracije lahko izvedemo v grobi ločljivosti (denimo na mrežni razdalji okoli 80 km), kar bistveno zniža računske stroške. Nato, ko se približujemo rešitvi, postopno zvišujemo ločljivost (npr. do 9 km). Stroški v atmosferskih modelih namreč pogosto naraščajo kot $(1/\Delta x)^4$, tako da bi bila neposredna raba najvišje ločljivosti že od začetka izjemno draga. Z nizko ločljivostjo v uvodnih iteracijah in postopnim prehodom na višjo tako ohranimo dostopnost rešitve, obenem pa se še vedno približamo visokoločljivostni analizi. S tem se tudi poenostavi priprava začetnih pogojev za napoved, saj vsak inkrementalni korak predstavlja cenejši, poenostavljen podproblem.

Skratka, inkrementalni 4D VAR v osnovi ohranja isto izvorno cenilno funkcijo, vendar jo minimizira postopoma, prek več lineariziranih podproblemov. Tako se izognemo nekaterim pastem nelinearnih funkcij, pridobimo zanesljivejšo konvergenco, predvsem pa je tak pristop računsko učinkovit, sploh če izkoriščamo več ločljivosti. Posledično je v večjih prognostičnih centrih, med drugim tudi v ECMWF, tak postopek danes standard: prvo minimizacijo izvedejo pri približni ločljivosti 80 km, v zadnjih korakih pa preidejo na 9 km. Tako združujejo teoretične prednosti reševanja kvadratnih podproblemov v iteracijah in praktično nujo, da se upošteva računaska zahtevnost pri visokih ločljivostih.

6.8 Razlika med 3D-Var in 4D-Var

Tako 3D-Var kot 4D-Var združujeta *ozadje*, torej kratkoročno modelsko napoved, in opazovanja ter na podlagi obeh določita čim boljšo oceno trenutnega stanja atmosfere oziroma *analizo*. Glavna razlika med metodama je v obravnavi časa.

Pri 3D-Var se analiza določi za en sam referenčni čas t_0 . Opazovanja, zbrana znotraj

določenega asimilacijskega okna, se pri tem obravnavajo, kot da pripadajo temu času. Model med samo minimizacijo ne opisuje razvoja atmosfere od časa posameznega opazovanja do časa analize. Zaradi tega je 3D-Var razmeroma preprost in računsko učinkovit ter omogoča pogosto ponavljanje asimilacijskih ciklov. V sistemih hitrega osveževanja (*Rapid Update Cycle – RUC*) se lahko nova analiza na primer izračuna vsako uro, pri čemer je asimilacijsko okno razmeroma kratko.

4D-Var poleg treh prostorskih dimenzij eksplicitno upošteva še čas. Namesto stanja atmosfere v enem samem trenutku optimizira začetno stanje tako, da modelska trajektorija skozi celotno asimilacijsko okno čim boljše ustreza opazovanjem ob njihovih dejanskih časih. Če je na primer opazovanje opravljeno tri ure po začetku asimilacijskega okna, se njegova informacija primerja z modelskim stanjem tri ure po začetku integracije in ne neposredno z začetnim stanjem.

Za takšno minimizacijo 4D-Var poleg osnovnega numeričnega modela potrebuje tudi njegovo *tangentno-linearno* (TL) in *adjungirano* (AD) različico. Tangentno-linearni model približno opisuje, kako se majhna sprememba začetnega stanja skozi model razvija v času. Adjungirani model pa deluje v nasprotni smeri: informacijo o tem, kako močno se modelska trajektorija razlikuje od opazovanj, prenese nazaj skozi model in tako pokaže, kako je treba spremeniti začetno stanje. Na ta način lahko 4D-Var postopoma poišče začetno stanje, katerega časovni razvoj se najbolje ujema z opazovanji v celotnem asimilacijskem oknu.

Razvoj TL- in AD-različice atmosferskega modela je zahteven, saj morata ustrezno predstavljati ne le dinamiko, temveč tudi pomembne fizikalne procese. To je še posebej težavno pri modelih z zelo visoko prostorsko ločljivostjo, kjer postanejo procesi, povezani s konvekcijo, oblaki in padavinami, izrazito nelinearni. Zato je uporaba 4D-Var tehnično zahtevnejša od uporabe 3D-Var.

Pomembna razlika je tudi računski strošek. Pri 3D-Var se med minimizacijo model praviloma ne integrira skozi celotno asimilacijsko okno, medtem ko je pri 4D-Var potrebnih več integracij osnovnega, tangentno-linearne in adjungiranega modela. Zaradi tega je 4D-Var bistveno računsko dražji. 3D-Var je zato primernejši za sisteme, kjer želimo analizo zelo pogosto osveževati, na primer na eno ali tri ure.

Prednost 4D-Var pa je predvsem boljša časovna konsistentnost analize. Opazovanja se uporabijo ob času, ko so bila dejansko izmerjena, model pa njihovo informacijo dinamično povezuje skozi celotno asimilacijsko okno. Pri zaporednem ciklanju 3D-Var se namreč izmenjujejo kratka modelska napoved, nova analiza, ponovno modelska napoved in tako naprej. Po vsaki spremembi modelskega stanja potrebuje model nekaj časa, da se različne spremenljivke med seboj ponovno dinamično prilagodijo. Temu začetnemu prilagajanju pravimo *spin-up*. Zaradi časovno povezane modelske trajektorije je ta problem pri 4D-Var praviloma manj izrazit.

4D-Var ima prednost tudi pri časovno neenakomerno razporejenih oziroma *asinhronih* opazovanjih, kot so satelitske, radarske in GNSS-meritve. Pri 3D-Var se opazovanja znotraj določenega časovnega okna obravnavajo približno kot meritve ob času analize, medtem ko 4D-Var upošteva njihov dejanski čas nastanka. Zato lahko bolje izkoristi informacijo o časovnem razvoju atmosfere.

Razlika se pojavi tudi pri strukturi analitičnih prirastkov. V klasičnem 3D-Var je kovariančna matrika napake ozadja $\mathbf{B}$ vnaprej določena in se praviloma ne spreminja glede na trenutno vremensko situacijo. Zato je širjenje informacije iz posameznega opazovanja predvsem določeno s statističnimi lastnostmi te matrike. V 4D-Var pa razvoj motenj skozi tangentno-linearni model povzroči, da se vpliv opazovanj prilagaja trenutnemu atmosferskemu toku. Takšno lastnost imenujemo *odvisnost od toka* (*flow-dependency*). Če je na primer v določenem območju močan horizontalni veter, se lahko informacija iz opazovanja skozi asimilacijsko okno razširi predvsem vzdolž trenutnega zračnega toka in ne enakomerno v vse smeri.

Izbira med metodama je zato predvsem kompromis med kakovostjo časovne obravnave, kompleksnostjo sistema in računskim stroškom. 4D-Var je posebej primeren, kadar imamo veliko asinhronih opazovanj in že razvito TL- in AD-različico modela. 3D-Var pa je preprostejši in računsko cenejši ter je zato primeren za zelo pogoste asimilacijske cikle in modele visoke

prostorske ločljivosti, pri katerih bi bila izdelava ustreznega TL/AD sistema zelo zahtevna.

Glavne razlike lahko tako povzamemo:

- 3D-Var določa analizo v enem referenčnem času, medtem ko 4D-Var upošteva razvoj atmosfere skozi celotno asimilacijsko okno;
- 4D-Var uporablja opazovanja ob njihovih dejanskih časih in zato bolje izkorišča časovno informacijo;
- 4D-Var zahteva tangentno-linearni in adjungirani model, zaradi česar je razvojno in računsko bistveno zahtevnejši;
- 4D-Var omogoča večjo odvisnost analitičnih prirastkov od trenutnega atmosferskega toka in zmanjšuje težave s časovno nekonsistentnostjo ter spin-upom;
- pogosto ciklanje 3D-Var lahko del prednosti 4D-Var zmanjša, vendar njegove eksplicitne časovne obravnave opazovanj ne more v celoti nadomestiti.

Poglavje 7

Dinamično in fizikalno ravnovesje v začetnih pogojih

Zdaj se posvetimo pomembnosti različnih vrst opazovanj v procesu asimilacije podatkov. Bistveno se je zavedati, da vsa opazovanja nimajo enakega vpliva na zmanjšanje napak napovedi, saj obstajajo tako imenovana opazovanja, ki so "obvezna" (npr. temperatura, vlažnost, tlak) in tako imenovana "dinamična" opazovanja (npr. veter). Pomen teh kategorij se lahko razlikuje tudi glede na geografsko regijo: na območjih srednje zemljepisne širine (od približno 20°S do severnega pola) so "obvezna" opazovanja običajno bolj vplivna, medtem ko imajo lahko v tropskih regijah opazovanja vetra relativno večjo vlogo. Čeprav sta obe kategoriji pomembni, lahko vsaka prevladuje v različnih meteoroloških pogojih.

7.1 Hitri in počasni načini v razvoju modela

Za ponazoritev, zakaj je pomembna skrbna obravnava opazovanj in začetnih pogojev, predpostavimo, da se naš numerični model razvija v dveh različnih načinih: *hitrem* načinu in *počasnem* načinu. Rešitev neke spremenljivke modela lahko predstavimo kot superpozicijo teh dveh načinov, tako da lahko spremenljivko u zapišemo kot

$$u = U_{\text{slow}} e^{-i\omega_{\text{slow}} t} + U_{\text{fast}} e^{-i\omega_{\text{fast}} t}, \quad (7.1)$$

kjer U označuje velikost vsakega načina, medtem ko je ω ustrezna kotna frekvenca. V tej razgradnji je počasen način opisan z U_{slow} in ω_{slow} , hitri način pa z U_{fast} in ω_{fast} . Očitno, če se rešitev hitro razvija, je ω velik, tako da vemo, da $\omega_{\text{fast}} \gg \omega_{\text{slow}}$.

Koristno je pogledati ne samo rešitev u , ampak tudi njeno *nagnjenost*, tj. časovni odvod. Če vzamemo izpeljanko (7.1) in jo odvajamo glede na t , dobimo

$$\frac{du}{dt} = -i\omega_{\text{slow}} U_{\text{slow}} e^{-i\omega_{\text{slow}} t} - i\omega_{\text{fast}} U_{\text{fast}} e^{-i\omega_{\text{fast}} t}. \quad (7.2)$$

Če celotna rešitev vsebuje ta dva načina, potem je – tudi če počasni način prevladuje *amplitudno* v (7.1) (na primer, če $U_{\text{slow}} \gg U_{\text{fast}}$) — povsem možno, da *hitri način* prevladuje v težnji (7.2), ker $\omega_{\text{fast}} U_{\text{fast}}$ lahko postane večji od $\omega_{\text{slow}} U_{\text{slow}}$. Z drugimi besedami, hitra komponenta ima lahko kljub potencialni manjši amplitudi v (7.1) sorazmerno večji učinek v časovnem odvodu.

Ta ugotovitev ima pomembne posledice za to, kako določamo začetne pogoje. Če naše začetno stanje vsebuje znatne prispevke hitro razvijajočih se načinov, potem lahko ti načini močno vplivajo na težnjo in tako hitro vplivajo na poznejši razvoj modela. V praksi to pomeni, da mora biti naše začetno stanje zelo skrbno *uravnoreženo* fizično in dinamično; drugače se lahko pojavijo lažni hitri načini (včasih obravnavani kot "šum" ali neuravnoreženi prirastki) in se širijo skozi napoved.

7.2 Dinamično in fizično ravnotežje v začetnih pogojih

Pri asimilaciji podatkov o atmosferi zagotavljanje ravnotežja pomeni, da morajo začetni pogoji zadostiti primarnim fizikalnim in dinamičnim omejitvam atmosfere. Če vstavimo neobdelane meritve, ne da bi vsilili ali upoštevali ta ravnotežja, se lahko večina teh informacij hitro izgubi v obliki hitro razvijajočih se visokofrekvenčnih valov. Takšni valovi lahko "odsevajo" dragocene informacije, preden jih lahko model pravilno uporabi. Posledično je v teku prizadevanje za uveljavitev dinamične skladnosti v začetnem stanju.

Kovariančna matrika napake v ozadju (pogosto označena z $\mathbf{B}$) delno obravnava ta vprašanja tako, da zajame večdimenzionalna razmerja in korelacije. Vendar tudi najboljša $\mathbf{B}$ matrika ne more popolnoma odpraviti vseh neravnovesij v začetnih pogojih. Določena stopnja neravnovesja je neizogibna in se pojavi v vsaki resnični simulaciji. Z drugimi besedami, na splošno bomo uvedli vsaj nekaj neusklajenosti med hitrimi in počasnimi načini, ko bomo podatke vključili v naš modelni sistem.

Kljub tem omejitvam si sistemi za asimilacijo podatkov prizadevajo zmanjšati takšna neravnovesja z uporabo različnih metod, kot so digitalni filtri ali inicializacija običajnega načina, poleg omejitev kovariance napak v ozadju. Kljub temu je temeljni zaključek ta, da če začetni pogoj vsebuje preveč komponent hitrega načina, lahko napoved modela trpi zaradi neželenega prehodnega vedenja zgodaj v teku. Zato sta načrtovanje asimilacijskih postopkov in izbira, katera opazovanja vključiti (in kako jih vključiti), ključni koraki pri ohranjanju dinamičnega in fizičnega ravnovesja v začetnih pogojih.

7.3 Model plitve vode

Da bi nadalje preučili obstoj hitro in počasi razvijajočih se rešitev v atmosferi, lahko svojo pozornost usmerimo na najpreprostejši okvir, ki še vedno zajema bistvene dinamične lastnosti: model plitve vode (SWM). Ta model, na katerega lahko gledamo kot na pomanjšano obliko atmosferskih primitivnih enačb, nam omogoča, da ponazorimo, kako se nekateri načini razvijajo hitreje (npr. gravitacijski valovi), medtem ko se drugi razvijajo počasneje (npr. uravnoteženo gibanje). Videli bomo tudi, kako pojem potencialne ohranitve vrtnčenja naravno izhaja iz združevanja enačb plitve vode.

7.3.1 Glavne enačbe

Model plitve vode je mogoče opisati z naslednjimi tremi enačbami, ki urejajo horizontalne komponente hitrosti (u, v) in višino vodnega stolpca h . Prva enačba, ki opisuje časovni razvoj *conalnega vetra* (tj. u -komponente hitrosti), je:

$$\frac{\partial u}{\partial t} + u \frac{\partial u}{\partial x} + v \frac{\partial u}{\partial y} - f v = -g \frac{\partial h}{\partial x}. \quad (7.3)$$

Izraz $\frac{\partial u}{\partial t}$ predstavlja lokalno (v času) stopnjo spremembe *conskega vetra*. Naslednja dva mandata, $u \frac{\partial u}{\partial x} + v \frac{\partial u}{\partial y}$, predstavljajo *advekcijo u* s samim tokom. Izraz $-f v$ je *Coriolisov izraz*, ki opisuje učinek planetarne rotacije, ki poveže meridionalno hitrost v s spremembami u . Desna stran, $-g \frac{\partial h}{\partial x}$, ustreza vodoravnemu gradientu tlaka (ali členu vzgona), ki je sorazmeren z gravitacijskim pospeškom g in naklonom $\frac{\partial h}{\partial x}$.

Druga enačba, ki ureja razvoj *meridionalnega vetra* v , je

$$\frac{\partial v}{\partial t} + u \frac{\partial v}{\partial x} + v \frac{\partial v}{\partial y} + f u = -g \frac{\partial h}{\partial y}. \quad (7.4)$$

Ima podobno strukturo kot (7.3), le da ima Coriolisov člen zdaj obliko $+f u$, gradient tlaka pa $-g \frac{\partial h}{\partial y}$.

Tretja enačba opisuje razvoj tekočine *višina* h (ali v meteoroloških analogijah bi to lahko predstavljalo debelino plasti ali geopotencialno višino):

$$\frac{\partial h}{\partial t} + u \frac{\partial h}{\partial x} + v \frac{\partial h}{\partial y} = -h \left(\frac{\partial u}{\partial x} + \frac{\partial v}{\partial y} \right). \quad (7.5)$$

Na levi strani spet vidimo spremembo lokalnega časa in advekcijo $z(u, v)$. Na desni strani izraz $-h \left(\frac{\partial u}{\partial x} + \frac{\partial v}{\partial y} \right)$ opisuje, kako spremembe horizontalne divergence vplivajo na višino stolpca. Ko tok divergira ($\nabla \cdot \mathbf{v} > 0$), se h zmanjša; ko tok konvergira ($\nabla \cdot \mathbf{v} < 0$), h narašča.

7.3.2 Enačba barotropne vrtničnosti in potencialna ohranitev vrtničnosti

Iz teh enačb plitve vode je mogoče izpeljati *enačbo barotropne vrtničnosti* s kombinacijo (7.3) in (7.4). Najprej se spomnimo, da je *relativna vrtničnost* ζ definirana z

$$\zeta = \frac{\partial v}{\partial x} - \frac{\partial u}{\partial y}. \quad (7.6)$$

Da dobimo enačbo za ζ , lahko vzamemo delni odvod (7.4) glede na x , odštejemo delni odvod (7.3) glede na y in ustrezno združimo člene (spomnimo se Coriolisovega parametra f). V obliki barotropne vrtničnosti lahko rezultat izrazimo kot

$$\frac{d}{dt}(\zeta + f) = -(\zeta + f) \left(\frac{\partial u}{\partial x} + \frac{\partial v}{\partial y} \right), \quad (7.7)$$

kjer

$$\frac{d}{dt} \equiv \frac{\partial}{\partial t} + u \frac{\partial}{\partial x} + v \frac{\partial}{\partial y}$$

predstavlja *materialni (ali Lagrangejev) derivat*. Enačba (7.7) kaže, da spremembe v $\zeta + f$ poganja divergenca ali konvergenca toka.

Nato opazite, da se $\frac{\partial u}{\partial x} + \frac{\partial v}{\partial y}$ pojavi tudi na desni strani (7.5). Pravzaprav lahko iz (7.5) prepišemo

$$\frac{\partial h}{\partial t} + u \frac{\partial h}{\partial x} + v \frac{\partial h}{\partial y} = -h \left(\frac{\partial u}{\partial x} + \frac{\partial v}{\partial y} \right).$$

Levo stran lahko interpretiramo kot celotno (materialno) izpeljanko h : $\frac{dh}{dt}$. torej

$$\frac{dh}{dt} = -h \left(\frac{\partial u}{\partial x} + \frac{\partial v}{\partial y} \right).$$

Če to zamenjamo nazaj v (7.7), vidimo:

$$\frac{d}{dt}(\zeta + f) = -(\zeta + f) \left(-\frac{1}{h} \frac{dh}{dt} \right), \quad (7.8)$$

$$\frac{d}{dt}(\zeta + f) = \frac{\zeta + f}{h} \frac{dh}{dt}, \quad (7.9)$$

ki se lahko preuredi, da zagotovi ohranitev *potencialne vrtničnosti* v modelu plitve vode:

$$\frac{d}{dt} \left(\frac{\zeta + f}{h} \right) = 0. \quad (7.10)$$

V razširjeni obliki to pomeni, da količina $(\zeta + f)/h$ ostane konstantna po gibanju, in zajema bistvo združevanja enačb gibalne količine z enačbo kontinuitete (višine). Če bi razširili $\frac{d}{dt}((\zeta + f)/h)$, bi obnovili izraze, ki se pojavljajo v (7.3)–(7.5).

7.3.3 Hitri in počasni načini v plitvi vodi

Ko smo vzpostavili osnovno strukturo SWM, lahko ugotovimo, katere rešitve ustrezajo hitrim in počasnim načinom. Vsaka fizično verjetna rešitev mora upoštevati potencialno ohranjanje vrtničenja v (7.10). To pomeni, da se mora tok prilagoditi, ne glede na to, katere začetne motnje uvedemo, tako da $\frac{\zeta+f}{h}$ ostane materialno ohranjen. V praksi se bodo neravnovesja, vnesena v sistem, deloma pokazala v *gravitacijskih valovih*, ki se hitro širijo in predstavljajo hitro razvijajoče se načine. Medtem je bolj uravnotežen (počasi razvijajoč se) del gibanja tesno povezan s potencialnim ohranjanjem vrtničenja in kroženjem v večjem obsegu.

Ker **B** (matrika kovariance napak v ozadju, ki se uporablja pri asimilaciji podatkov) ne uveljavlja popolnoma vseh dinamičnih ravnovesij, atmosfera pogosto razvije te lažne hitre načine, če začetni pogoji niso pravilno omejeni. Kljub temu zaradi same narave (7.10) polje vrtnica in višine poskušata ostati konsistentna, tako da $(\zeta + f)/h$ ostane konstanten vzdolž trajektorij. Vsako pomembno neravnovesje se ponavlja "odsevaš" hitrimi gravitacijskimi valovi, kar poudarja pomen pravilnega upoštevanja hitrih in počasnih načinov pri asimilaciji podatkov in napovedovanju.

7.3.4 Rešitve modela plitve vode

V tem razdelku raziskujemo, kako model plitve vode (SWM) dopušča tako počasne (uravnotežene) kot hitre (gravitacijske) rešitve. Čeprav so izvirne enačbe plitve vode (7.3)–(7.5) nelinearne, lahko te glavne vrste rešitev izoliramo tako, da *lineariziramo* sistem okoli ustrezno definirane povprečne stanja in nato vsilimo valovitim rešitvam v prostoru in času.

Linearizacija okoli srednjega stanja

Začnemo tako, da vsako odvisno spremenljivko razdelimo na srednjo komponento in majhno motnjo:

$$\begin{aligned}u &= U + u', \\v &= V + v', \\h &= H + h'.\end{aligned}$$

V tej dekompoziciji U , V in H predstavljajo *mean* conski veter, meridionalni veter in višino vodnega stolpca, medtem ko so u' , v' in h' majhne motnje okoli teh povprečij. Zaradi poenostavitve na začetku predpostavimo $U = V = 0$, vendar $H \neq 0$. Nadalje predpostavimo, da je H konstanta tako v prostoru kot v času, torej $H \neq H(x, y)$ in da je f (Coriolisov parameter) konstanta, tj. tj. se ne spreminja z x ali y .

Pod temi predpostavkami so vsi *nelinearni* členi obrazca

$$(U + u') \frac{\partial(U + u')}{\partial x}, \quad (V + v') \frac{\partial(V + v')}{\partial y}, \quad \text{and cross products}$$

pri linearizaciji lahko zanemarimo, ker sta $U = V = 0$ in $(u')^2, (v')^2$ majhna člena drugega reda. Posledično se enačbe plitve vode (7.3)–(7.5) reducirajo na *lineariziran* sistem

$$\begin{aligned}\frac{\partial u'}{\partial t} - f v' &= -g \frac{\partial h'}{\partial x}, \\ \frac{\partial v'}{\partial t} + f u' &= -g \frac{\partial h'}{\partial y}, \\ \frac{\partial h'}{\partial t} &= -H \left(\frac{\partial u'}{\partial x} + \frac{\partial v'}{\partial y} \right).\end{aligned}$$

Te tri linearne parcialne diferencialne enačbe zdaj opisujejo majhne motnje (u', v', h') v sicer mirni tekočini s konstantno višino H .

Valove podobne rešitve in disperzijsko razmerje

Da bi našli glavne načine tega linearnega sistema, iščemo rešitve oblike

$$\begin{bmatrix} u' \\ v' \\ h' \end{bmatrix} = \begin{bmatrix} u_0 \\ v_0 \\ h_0 \end{bmatrix} \exp\{i(kx + ly - \omega t)\}, \quad (7.11)$$

kjer je k consko valovno število, l meridionalno valovno število, ω je (kotna) frekvenca in (u_0, v_0, h_0) predstavljajo amplitude motenj. Če zamenjamo ta ansatz v linearizirane enačbe, dobimo algebrske relacije

$$\begin{aligned} -i\omega u_0 - f v_0 &= -g(i k) h_0, \\ -i\omega v_0 + f u_0 &= -g(i l) h_0, \\ -i\omega h_0 &= -H(i k u_0 + i l v_0). \end{aligned}$$

Te lahko prepišemo v matrično obliko $\mathbf{A} \vec{x} = \vec{0}$, kjer $\vec{x} = [u_0, v_0, h_0]^T$ in

$$\mathbf{A} = \begin{bmatrix} -i\omega & -f & g i k \\ f & -i\omega & g i l \\ H i k & H i l & -i\omega \end{bmatrix}. \quad (7.12)$$

Netrivialne rešitve $\vec{x} \neq \vec{0}$ obstajajo le, če $\det(\mathbf{A}) = 0$. Rešitev tega determinantnega pogoja daje disperzijsko razmerje

$$\omega(\omega^2 - f^2 - g H(k^2 + l^2)) = 0. \quad (7.13)$$

Iz te značilne enačbe izhajata dve vrsti rešitev:

(1) $\omega = 0$: Stacionarni (počasen) ali »uravnotežen« način. Ko $\omega = 0$, se motnje ne spreminjajo v času, torej $\frac{\partial u'}{\partial t} = \frac{\partial v'}{\partial t} = \frac{\partial h'}{\partial t} = 0$. Če vstavimo $\omega = 0$ v lineariziran sistem, pokažemo, da se gibalne enačbe v SWM zreducirajo na *geostrofsko ravnovesje*:

$$-f v' = -g \frac{\partial h'}{\partial x}, \quad f u' = -g \frac{\partial h'}{\partial y}.$$

Enakovredno se lahko piše

$$u' = -\frac{g}{f} \frac{\partial h'}{\partial x}, \quad v' = \frac{g}{f} \frac{\partial h'}{\partial y}.$$

Ta stacionarna rešitev, ki jo narekuje ravnovesje med Coriolisovimi silami in silami gradienta tlaka, se imenuje *geostrofski način* in je običajno povezana s počasnim ali uravnoteženim gibanjem v modelu plitve vode.

(2) $\omega \neq 0$: Vztrajnostno-gravitacijski valovi (hitri načini). Za $\omega \neq 0$ postane disperzijsko razmerje

$$\omega^2 = f^2 + g H(k^2 + l^2).$$

Ti *vztrajnostni gravitacijski valovi* (včasih jih imenujemo tudi gravitacijski valovi, če $f = 0$) potujejo s končno fazno hitrostjo. V posebnem primeru $f = 0$ dobimo

$$\omega^2 = g H(k^2 + l^2), \quad \omega = \pm \sqrt{g H(k^2 + l^2)},$$

in fazno hitrostjo

$$c_{\text{phase}} = \frac{\omega}{\sqrt{k^2 + l^2}} = \sqrt{gH}.$$

To so čisti gravitacijski valovi. Če $f \neq 0$, je fazna hitrost nekoliko večja:

$$c_{\text{phase}} = \pm \sqrt{gH \left(1 + \frac{f^2}{k^2 + l^2} \right)},$$

kar kaže, da Coriolisovi učinki dajejo dodatno *inercialno* komponento, ki daje *inercialno-gravitacijske valove*.

Geostrofna prilagoditev in vloga uravnoveženih proti sevalnim rešitvam

Če se vrnemo k razlagi teh rešitev, vidimo, da je vsako majhno motnjo, vneseno v model plitve vode, mogoče razstaviti na dva glavna dela:

- $\omega = 0$ *uravnovežena* (stacionarna) komponenta, skladna z geostrofičnim ravnovesjem.
- $\omega \neq 0$ *hitra*, *sevalna* komponenta v obliki vztrajnostno-gravitacijskih valov.

Recimo, da izvedemo korak asimilacije podatkov, ki uvede neko začetno motnjo, recimo lokalizirano spremembo δh v višini tekočine, z nič začetnim vetrom. Ker je geostrofično ravnovesje na začetku porušeno, del amplitude motenj ostane blizu vira in se počasi razvija proti uravnoveženemu (stacionarnemu) stanju, drugi del pa ševa kot gravitacijski valovi. Ta proces se imenuje *geostrofična prilagoditev*. Sčasoma se vztrajni del začetne motnje poveže z na novo ustvarjenim poljem vetra, da se oblikuje kvazi enakomerno anticiklonsko (ali ciklonsko) kroženje okoli višinske anomalije. Medtem se hitri valovi premikajo navzven, odnašajo energijo in (potencialno) povzročajo majhne umetne pojave, kot so lažne padavine v vremenskih modelih visoke ločljivosti, kadar koli konvergenca ali divergenca sproži mikrofizične procese.

V ekstremnih situacijah, kot je jedrska eksplozija ali močan vulkanski izbruh, lahko velike motnje sprožijo močne udarne ali gravitacijske valove, ki potujejo s hitrostjo več sto metrov na sekundo in morda obkrožijo svet. Celo v bolj rutinskih meteoroloških kontekstih lahko vsako neravnovesje, vneseno v začetne pogoje, povzroči neželeno ustvarjanje hitrih valov, ki lahko poslabšajo napovedi. Eden glavnih ciljev asimilacije podatkov in zlasti konstrukcije kovariančne matrike napake v ozadju $\mathbf{B}$ je *filtrirati* ali vsaj minimizirati te lažne hitre načine. Z uveljavljanjem korelacije med vetrom, maso (višino) in drugimi spremenljivkami, ki so skladne z geostrofalnim in hidrostatičnim ravnovesjem, $\mathbf{B}$ zagotavlja, da se manj energije seva stran. Posledično več opazovalnih informacij ostane v sistemu na fizično pomemben način, kar prispeva k boljšim napovedim tako v simulacijah kratkega kot tudi daljšega dosega.

7.3.5 Geostrofična prilagoditev in relativni pomen različnih meritev

V modelu plitve vode smo videli, da v bistvu obstajata dva razreda rešitev: *uravnovežena* (stacionarna) geostrofična rešitev in *hitra* rešitev vztrajnostno-gravitacijskih valov. Ko začetni pogoji niso v ravnovesju, se del neravnovesja projicira na geostrofične (počasne) načine, medtem ko se preostanek projicira na vztrajnostno-gravitacijske (hitre) načine in seva stran kot valovi. Ta proces, kako model obravnava prvotno neuravnoveženo motnjo, se pogosto imenuje *geostrofična prilagoditev*. Zdaj si bomo podrobneje ogledali matematične podlage te prilagoditve in videli, kako kljub začetni motnji nekatere ohranjene količine močno omejujejo pretok.

Možno ohranjanje vrtničenja. Spomnimo se, da smo iz naše izpeljave modela plitve vode ugotovili, da *potencialna vrtničnost* (PV)

$$\frac{\zeta + f}{h}$$

Analiza in prognoza vremena

je materialno ohranjen:

$$\frac{d}{dt} \left(\frac{\zeta + f}{h} \right) = 0,$$

kjer je ζ relativna vrtničnost, f Coriolisov parameter in h višina stolpca tekočine. To pomeni, da ne glede na motnjo, ki jo vnesemo v tok, $(\zeta + f)/h$ obdrži isto vrednost, ko sledi parcelam tekočine.

Pogosto je priročno prepisati to ohraneno količino z množenjem števca in imenovalca z gravitacijskim pospeškom g , saj se v meteorologiji gh razlaga kot *geopotencial* Φ . Zato lahko enako pišemo

$$\frac{d}{dt} \left(\frac{\zeta + f}{gh} \right) = 0 \iff \frac{d}{dt} \left(\frac{\zeta + f}{\Phi} \right) = 0,$$

V dvodimenzionalnem toku na ravnini lahko hitrostno polje $\vec{v}$ razstavimo z uporabo funkcije toka $\vec{\Psi}$ in potenciala hitrosti χ :

$$\vec{v} = \vec{k} \times \nabla \vec{\Psi} + \nabla \chi$$

kjer je χ *potencial hitrosti*, ki predstavlja irotacijsko (divergentno) komponento toka, in $\vec{\Psi}$ *vektor funkcije toka*. V dvodimenzionalnih sistemih (kot je plitva voda na ravnini $(x - y)$) se $\vec{\Psi}$ običajno reducira na skalarno funkcijo toka Ψ , zato je zgornji navzkrižni produkt dejansko $\nabla \times \Psi \hat{z}$. Iz te razgradnje je mogoče pokazati, da je relativna vrtničnost ζ povezana z Ψ z

$$\zeta = \nabla \times \vec{v} = \nabla^2 \Psi.$$

To nam omogoča, da prepisemo potencialno vrtničnost plitve vode v smislu Ψ :

$$\frac{\zeta + f}{h} = \frac{\nabla^2 \Psi + f}{h}.$$

Če definiramo $\Phi = gh$, postane izjava o potencialnem ohranjanju vrtničenja

$$\frac{d}{dt} \left(\frac{\nabla^2 \Psi + f}{\Phi} \right) = 0.$$

Ne glede na to, kakšno majhno motnjo uvedemo, se mora tok prilagoditi tako, da $(\nabla^2 \Psi + f)/\Phi$ ostane materialno konstanten. Ta enačba je linearizirana izjava o ohranitvi potencialne vrtničnosti. Tok v modelu plitve vode se mora razvijati tako, da ohranja razmerje med vrtničnostjo in geopotencialom. Kakršnakoli sprememba enega (npr. višine) mora biti skladna s spremembo drugega (npr. laplacian tokovne funkcije). Če ni, se pojavijo hitri gravitacijski valovi, ki oddajo energijo in lahko povzročijo numerične ali fizične artefakte v vremenskem modelu.

Linearizacija potencialne enačbe vrtničenja za majhne motnje. Ker nas še posebej zanimajo scenariji *asimilacije podatkov*, imamo pogosto opravka z razmeroma majhnimi povečanji ali motnjami obsežnejšega, počasi spreminjajočega se toka. V takšnih kontekstih lahko lineariziramo potencialno enačbo vrtničenja okoli srednjega stanja. Linearizacija poenostavi analizo tako, da v motnjah ohrani samo člene prvega reda in zavrže produkte višjega reda. Ta pristop nam pomaga jasneje videti, kako se vsiljeno neravnovesje razdeli na uravnotežene (geostrofične) in neuravnotežene (gravitacijski valovi) komponente, poleg tega pa pojasni, zakaj so določeni opazovalni podatki (kot so veter v primerjavi z meritvami masnega polja) bolj ali manj pomembni, odvisno od tega, kako učinkovito omejujejo prevladujoče načine v toku.

V naslednjih korakih bomo uporabili to linearizirano obliko enačbe potencialne vrtničnosti, da bomo bolj eksplicitno ponazorili *geostrofično prilagoditev* in kvantitativno pokazali, kako del začetnega neravnovesja seva stran kot hitri valovi, medtem ko se ostanek usede v počasnejše uravnoteženo stanje. To poudarja, zakaj je treba pri asimilaciji podatkov skrbno upoštevati dinamična ravnovesja (npr. preko matrike kovariance napake v ozadju), da se izognemo pretiranemu sevanju dragocenih opazovalnih informacij v neželene hitre načine.

7.3.6 Linearizirano potencialno ohranjanje vrtničenja

Do te točke smo poudarjali, da je treba potencialno vrtničenje (PV) ohraniti v modelu plitve vode, tudi v prisotnosti motenj. V svoji nepribližani obliki je izjava o ohranjanju PV

$$\frac{d}{dt} \left(\frac{\zeta + f}{\Phi} \right) = 0,$$

kjer je $\zeta = \nabla^2 \Psi$ relativna vrtničnost (ob predpostavki 2D funkcije toka Ψ), f Coriolisov parameter in $\Phi = g h$ geopotencial (pri čemer je g gravitacijski pospešek in h višina stolpca tekočine). Zdaj *lineariziramo* to ohranitveno razmerje pod določenimi predpostavkami o tipičnih velikostih motenj vetra in višine. Ta linearizacija izrecno kaže, kako se lahko prirastki v poljih mase ali vetra projicirajo na počasne, uravnotežene načine (ki ostanejo v napovedi) v primerjavi s hitrimi, vztrajnostno-gravitacijskimi načini (ki sevajo stran in se dejansko "izgubijo").

Predpostavke.

1. Predpostavimo, da $\nabla^2 \Psi \ll f$. Na srednjih zemljepisnih širinah so na primer tipične velikosti relativne vrtničnosti običajno manjše (pogosto za red velikosti) od planetarne vrtničnosti v ozadju f . To ni strogo veljavno blizu ekvatorja (kjer $f \approx 0$), vendar je na splošno sprejemljivo v ekstrasropskih regijah.

2. Pustimo

$$\Phi = g H + \Phi',$$

kjer je $g H$ nemoten geopotencial (ob predpostavki neke srednje globine H plasti plitve vode) in $\Phi' = g h'$ je motnja tega srednjega geopotenciala, skladna s prejšnjimi koraki linearizacije $h = H + h'$.

3. Tudi pišemo

$$f = f_0 + f',$$

kjer je f_0 stalna referenčna vrednost Coriolisovega parametra (npr. na določeni zemljepisni širini) in f' je majhno odstopanje okoli te reference (na primer, če se tok razteza nekoliko severno in južno od osrednje zemljepisne širine, vendar še vedno ostajamo na srednjih zemljepisnih širinah).

Ob upoštevanju teh predpostavk preučujemo

$$\frac{\zeta + f}{\Phi} = \frac{\nabla^2 \Psi + f}{g H + \Phi'}.$$

Imenovalec razširimo v Taylorjev niz prvega reda okrog $g H$:

$$\frac{1}{\Phi} = \frac{1}{g H + \Phi'} = \frac{1}{g H} \frac{1}{1 + \frac{\Phi'}{g H}} \approx \frac{1}{g H} \left(1 - \frac{\Phi'}{g H} \right).$$

Če to razširitev vstavimo v $\frac{\nabla^2 \Psi + f}{\Phi}$ dobimo

$$\frac{\nabla^2 \Psi + f}{g H} \left(1 - \frac{\Phi'}{g H} \right) = \frac{(\nabla^2 \Psi + f) - (\nabla^2 \Psi + f) \frac{\Phi'}{g H}}{g H}.$$

Nato upoštevamo, da se majhni členi višjega reda, kot je $\nabla^2 \Psi \frac{\Phi'}{g H}$ ali $f' \frac{\Phi'}{g H}$, obravnavajo kot motnje drugega reda in jih je mogoče opustiti v linearnem približku. Po odstranitvi teh majhnih izdelkov nam ostane (prvo naročilo).

$$\frac{1}{g H} (\nabla^2 \Psi + f - f_0 \frac{\Phi'}{g H}).$$

Analiza in prognoza vremena

Ker je $\frac{1}{gH}$ konstanta, lahko "linearizirano" različico naše ohranjene količine zapišemo kot

$$f + \nabla^2 \Psi - \frac{f_0}{gH} \Phi'.$$

Zato izjava o (lineariziranem) potencialnem ohranjanju vrtinčenja,

$$\frac{d}{dt} \left(\frac{\zeta + f}{\Phi} \right) = 0,$$

postane

$$\frac{d}{dt} \left(f + \nabla^2 \Psi - \frac{f_0}{gH} \Phi' \right) = 0.$$

Če definiramo

$$\eta \equiv f + \nabla^2 \Psi - \frac{f_0}{gH} \Phi',$$

pridemo do:

$$\frac{d\eta}{dt} = 0, \quad (7.14)$$

ki pravi, da je η *materialno ohranjen* po toku. To je natanko *linearizirana* enačba ohranjanja potencialne vrtinčnosti za model plitve vode.

Interpretacija za asimilacijo podatkov. Količina η povezuje polje vetra (skozi $\nabla^2 \Psi$) in masno polje (skozi Φ') s Coriolisovim parametrom f . Kadarkoli vnesemo prirastke ali motnje v cikel asimilacije podatkov – pa naj bo to pri opazovanju vetra ali opazovanju višine – nam ta linearizirana potencialna ohranitev vrtinčenja pove, koliko tega prirastka projicira na:

- *Počasni (uravnoveženi) načini*, ki ostanejo v modelu kot geostrofično (ali skoraj geostrofično) prilagojen tok,
- *Hitri načini (vztrajnost-gravitacija)*, ki sevajo stran in se sčasoma dejansko izgubijo iz napovedi.

Če inkrement močno vzbudi hitre načine gravitacijskega valovanja, lahko poslabša napoved z vnosom lažnih nihanj ali neravnovesij (včasih celo ustvari umetne padavine ali druge numerične artefakte). Nasprotno pa inkrementi, ki upoštevajo omejitve ravnotežja, ponavadi okrepijo fizikalno pomembne spremembe v poljih mase/vetra, ki jih ohranja model. Vsako opazovanje torej ne izboljša samodejno napovedi: njegov ugoden učinek je odvisen od tega, ali (in koliko) postopek asimilacije uspe vključiti nove informacije v uravnovežene (počasne) strukture, namesto da bi jih izgubil zaradi hitro sevajočih hitrih valov. To poudarja pomembnost skrbnega modeliranja matrik kovarianc napake v ozadju in uporabe omejitev ravnotežja, tako da so opazovalni podatki pravilno projicirani na uporabne, dolgotrajnejše načine v atmosferskem toku.

7.3.7 Hipotetični primer: Učinek mase v primerjavi z motnjami vetra na uravnovežen pretok

Zdaj obravnavamo hipotetični scenarij, v katerem uvajamo začetno motnjo (z asimilacijo podatkov) v model plitve vode. Predpostavimo, da je ta motnja v obliki spremembe bodisi v masnem polju (tj. tj. v geopotencialu Φ) ali v polju vetra (skozi Ψ), in želimo videti, kako se sistem odziva skozi čas. Naše vodilno načelo ostaja ohranjanje linearizirane potencialne vrtinčnosti:

$$\delta\eta(0) = \delta\eta(t \rightarrow \infty), \quad \text{kjer je} \quad \delta\eta = f + \nabla^2 \Psi - \frac{f_0}{gH} \Phi.$$

Ko je tok podvržen *geostrofični prilagoditvi*, bo del prvotno uvedenih motenj (zlasti del, ki projicira na kratke, hitre načine) seval stran kot gravitacijski valovi, medtem ko bo preostanek (uravnovežena komponenta) ostal v sistemu. Končno se končno stanje (kot $t \rightarrow \infty$) vzpostavi v geostrofično uravnoveženi konfiguraciji, vendar z *skupno* linearizirano potencialno vrtničnostjo $\delta\eta$ nespremenjeno.

Od neravnovesja do geostrofično uravnoveženega končnega stanja. Ker je končno stanje v geostrofičnem ravnovesju, to vemo

$$\vec{v}_G = \frac{1}{f_0} \hat{k} \times \nabla \Phi_G \quad \text{and} \quad \vec{v}_G = \nabla \times \vec{\Psi}_G.$$

Primerjava teh dveh oblik $\vec{v}_G$ implicira

$$\Psi_G = \frac{\Phi_G}{f_0} \quad (\text{predpostavka: } f = f_0 \text{ konst.}).$$

Zato sta v strogo geostrofičnem končnem stanju Φ_G in Ψ_G neposredno sorazmerna.

Primer 1: Masna (geopotencialna) motnja pri $t = 0$. Upoštevajte, da naša asimilacija podatkov uvede prirastek v polju *masa*, tj. e. $\delta\Phi(0)$, medtem ko pusti $\delta\Psi(0) = 0$. Sprva ni motenj vetra, vendar je masno polje moteno. Sčasoma se mora sistem prilagoditi tako, da morebitna linearizirana PV ostane skladna s svojo začetno vrednostjo:

$$\delta\eta(0) = \delta\eta_G, \quad \text{kjer je} \quad \delta\eta = f_0 + \nabla^2 \Psi - \frac{f_0}{gH} \Phi.$$

Ker $\delta f = 0$ (tj. $f' \approx 0$, razen če upoštevamo meridionalni prenos), je edina začetna motnja pri $t = 0$ v Φ . Če označimo $\Phi(0) \equiv \Phi_0$ in pustimo, da ima končna geostrofično uravnovežena rešitev Φ_G in Ψ_G , zapišemo:

$$-\frac{f_0}{gH} \delta\Phi(0) = \nabla^2 \delta\Psi_G - \frac{f_0}{gH} \delta\Phi_G. \quad (7.15)$$

Tukaj leva stran predstavlja začetno, čisto z maso povezano motnjo, medtem ko desna stran predstavlja končno, uravnoveženo stanje, kjer

$$\Psi_G = \frac{\Phi_G}{f_0}.$$

Nato razčlenimo tako začetne kot končne motnje v vsote nad prostorskimi valovi. V spektralni obliki:

$$\delta\Phi_G(x, y) = \sum_{k,l} [\delta\hat{\Phi}_G(k, l)] e^{i(kx+ly)}, \quad \delta\Phi(0)(x, y) = \sum_{k,l} [\delta\hat{\Phi}_0(k, l)] e^{i(kx+ly)},$$

kjer sta k in l conska in meridionalna valovna števila in $K^2 = k^2 + l^2$. Podobno za Ψ_G ,

$$\delta\Psi_G(x, y) = \sum_{k,l} [\delta\hat{\Psi}_G(k, l)] e^{i(kx+ly)} = \sum_{k,l} \left[\frac{\delta\hat{\Phi}_G(k, l)}{f_0} \right] e^{i(kx+ly)}.$$

Nato računamo

$$\nabla^2 \delta\Psi_G = \nabla^2 \left[\frac{\delta\hat{\Phi}_G}{f_0} e^{i(kx+ly)} \right] = -K^2 \left[\frac{\delta\hat{\Phi}_G}{f_0} e^{i(kx+ly)} \right] = -\frac{K^2}{f_0} \delta\Phi_G.$$

Zamenjava nazaj v (7.15) (val za valom) daje:

$$-\frac{f_0}{gH} \delta\Phi_0 = -\frac{K^2}{f_0} \delta\Phi_G - \frac{f_0}{gH} \delta\Phi_G.$$

Po preurejanju in faktoriziranju konstant dobimo:

$$f_0^2 \delta\Phi_0 = (K^2 g H + f_0^2) \delta\Phi_G, \implies \delta\Phi_G = \frac{f_0^2}{K^2 g H + f_0^2} \delta\Phi_0.$$

Primerno je definirati Rossbyjev polmer deformacije $R \equiv \sqrt{\frac{gH}{f_0^2}}$. torej

$$\delta\Phi_G = \frac{1}{1 + K^2 R^2} \delta\Phi_0.$$

Razmerje

$$\frac{\delta\Phi_G}{\delta\Phi_0} = \frac{1}{1 + K^2 R^2}$$

nam pove, kolikšen del začetnega geopotencialnega prirastka preživi v uravnoteženem stanju, kot funkcija skupnega valovnega števila K in polmera deformacije R .

Razlaga v smislu valovnih lestvic.

- *Dolgi valovi* ($K^2 R^2 \ll 1$ ali valovna dolžina $L \gg R$):

V tem režimu je faktor $1 + K^2 R^2 \approx 1$. torej

$$\delta\Phi_G \approx \delta\Phi_0,$$

kar pomeni, da večina začetne masne motnje *ostane* v končnem uravnoteženem stanju. Model si žapomni" obsežne (dolgovalovne) prirastke, zato bo prostorsko obsežen prirast analize ostal in vplival na napoved.

- *Kratki valovi* ($K^2 R^2 \gg 1$ ali valovna dolžina $L \ll R$):

V tem primeru

$$\delta\Phi_G \approx 0,$$

kar pomeni, da skoraj nobena motnja mase kratkega obsega ne preživi po prilagoditvi. Namesto tega te značilnosti kratkega obsega projicirajo na hitre načine gravitacijskega valovanja in sevajo stran (pogosto znotraj časovne skale $\sim 1/f_0$). Pri asimilaciji podatkov se takšni neuravnoteženi prirastki hitro izgubijo ali lahko celo poslabšajo napoved, če sprožijo lažno aktivnost valov ali padavine.

Rossbyjev polmer deformacije in fizikalna interpretacija. Polmer deformacije $R = \sqrt{\frac{gH}{f_0^2}}$ določa lestvico, pri kateri rotacijski učinki (Coriolisova sila) postanejo primerljivi z učinki vzgona/vztrajnosti (gravitacijski valovi). Za tipično atmosfersko globino $H \approx 10^4$ m, $g = 10$ m s⁻² in $f_0 = 10^{-4}$ s⁻¹, dobimo

$$R \approx 3000 \text{ km.}$$

Zato so značilnosti z vodoravnimi lestvicami $\ll 3000$ km ponavadi pod močnim vplivom valovne disperzije (hitro sevajo), medtem ko perturbacije večjega obsega $\gg 3000$ km ostanejo navidežno uravnotežene. V tokovih z bolj plitvimi plastmi (npr. gorski vetrovni sistemi z $H \approx 100$ m) se R skrči na samo nekaj sto metrov in rotacija postane pomembna le pri relativno majhnih prostorskih merilih.

Posledice za asimilacijo podatkov. Zgornji rezultat,

$$\delta\Phi_G = \frac{1}{1 + K^2 R^2} \delta\Phi_0,$$

poudarja, da model naravno filtrira kratkoročne neuravnotežene prirastke. Če asimiliramo enotočkovno meritev mase (npr. radiosonda, ki meri temperaturo/tlak na eni lokaciji) brez ustreznega širjenja te informacije na večje lestvice, bi se prirastek projiciral na kratkovalovne strukture in hitro seval stran. Vendar pa je v operativnih sistemih za asimilacijo podatkov kovariančna matrika napake v ozadju $\mathbf{B}$ zasnovana tako, da širi opazovalne prirastke prostorsko (in med različnimi spremenljivkami) na način, ki poudarja fizikalno pomembne, uravnotežene strukture. To je natanko način, kako asimilacija podatkov ohranja koristen učinek opazovanj: tako, da jih projicira na velike, uravnotežene lestvice, ki se ne razpršijo hitro kot gravitacijski valovi.

Primer 2: Merjenje vetra (uvredba motnje $\delta\Psi$ pri $t = 0$)

Zdaj razmislimo o situaciji, v kateri asimilacija podatkov povzroči začetno motnjo v polju *vetra* namesto v polju mase/geopotenciala. V okviru plitve vode to pomeni, da posredujemo nekaj neničelnih $\delta\Psi(0)$, medtem ko $\delta\Phi(0) = 0$. Kot prej se predpostavlja, da je končna rešitev po geostrofični prilagoditvi v geostrofičnem ravnovesju, in ponovno uporabimo linearizirano potencialno ohranjanje vrtinčenja. Pišemo:

$$\nabla^2 \delta\Psi(0) = \nabla^2 \delta\Psi_G - \frac{f_0}{gH} \delta\Phi_G,$$

kjer $\delta\Psi_G$ in $\delta\Phi_G$ opisujeta *uravnoteženo* rešitev pri velikem času $t \rightarrow \infty$. Ker je ta končna rešitev geostrofična, imamo

$$\delta\Phi_G = f_0 \delta\Psi_G,$$

tako kot v primeru 1 (vendar uporabljeno v nasprotni smeri). Uporabljamo tudi spektralno razgradnjo z $\nabla^2 \delta\Psi \approx -K^2 \delta\Psi$. Zamenjava in preurejanje donosov:

$$-K^2 \delta\Psi(0) = -K^2 \delta\Psi_G - \frac{f_0^2}{gH} \delta\Psi_G,$$

tako da

$$\delta\Psi_G = \frac{K^2}{K^2 + \frac{f_0^2}{gH}} \delta\Psi(0).$$

Spomnimo se Rossbyjevega polmera deformacije $R = \sqrt{\frac{gH}{f_0^2}}$, lahko pišemo

$$\delta\Psi_G = \frac{K^2 R^2}{1 + K^2 R^2} \delta\Psi(0).$$

Zato je delež motnje *začetnega vetra* $\delta\Psi(0)$, ki ostane v končnem *uravnoteženem* stanju

$$\frac{\delta\Psi_G}{\delta\Psi(0)} = \frac{K^2 R^2}{1 + K^2 R^2}.$$

Razlaga v smislu valovnih lestvic. Za razliko od primera 1 so vloge obrnjene:

- Za **dolge valove** ($K^2 R^2 \ll 1$ ali valovno dolžino $L \gg R$):

$$\delta\Psi_G \approx 0.$$

To pomeni, da model v bistvu *pozabi* prirast vetra na velikih lestvicah, ker taka motnja ne ostane v končnem geostrofičnem ravnovesju za te načine valovanja (seval stran kot vztrajnostno-gravitacijski valovi).

- Za kratke valove ($K^2 R^2 \gg 1$ ali $L \ll R$):

$$\delta\Psi_G \approx \delta\Psi(0).$$

V tem režimu prirastek vetra preživi: motnja se "ohranja" v uravnoveženem toku, kar kaže, da informacije o vetru kratkega obsega ostajajo vplivne v končnem stanju.

Praktični primer in splošni zaključek. Za ponazoritev upoštevajmo parametre srednje zemljepisne širine: $f_0 \approx 10^{-4} \text{ s}^{-1}$ in $H \approx 10 \text{ km}$. Če vsiljujemo

$$K^2 R^2 = (2\pi/L)^2 \frac{gH}{f_0^2} \gg 1,$$

dobimo značilno dolžinsko merilo

$$L \ll \sqrt{\frac{4\pi^2 gH}{f_0^2}} \approx 20000 \text{ km}.$$

Zato na srednjih zemljepisnih širinah skoraj vsi neplanetarni valovi (tj. vse, kar je manjše od resnično planetarnih lestvic $\sim 20000 \text{ km}$) delujejo kot "kratki" valovi za polje vetra. Posledično se prirastki kratkovalovnega vetra v veliki meri ohranijo, medtem ko se prirastki mase na istih lestvicah večinoma sevajo stran (kot je razvidno iz primera 1). Posledično so na srednjih zemljepisnih širinah — še posebej v tropih, kjer je f_0 manjši — opazovanja vetra lahko pomembnejša od množičnih opazovanj na večini lestvic, razen če se povečanja mase projicirajo na zelo dolga (planetarna) merila.

Ti vpogledi nas pripeljejo do **splošnega pravila v meteorologiji**:

V tropih (kjer je f_0 majhen) ali na manjših vodoravnih skalah (kratek L) in za atmosferske plasti s precejšnjo globino (velik H) so meritve vetra za napoved bolj pomembne kot meritve mase. Nasprotno pa lahko na srednjih zemljepisnih širinah na dovolj velikih lestvicah množična opazovanja (npr. temperatura/tlak) prevladujejo nad izboljšanjem napovedi.

Zato nimajo vsa opazovanja enakega vpliva in njihova učinkovitost je kritično odvisna od obsega in zemljepisne širine, pa tudi od tega, kako sistem za asimilacijo podatkov razširi prirastke po prostorskih in spremenljivih domenah prek matrike kovariance napak v ozadju.

Poglavje 8

Predvidljivost ozračja

Kot veste, je vremenska napoved periodična s časom. Uporabniki vremenskih napovedi se tega zavedajo. Kadarkoli vidite na primer napoved za 30 dni, ki jo nekatere službe dejansko izdajajo, ste nekako nejeverni, saj ne morete zaupati napovedi za 20 dni. To je zato, ker - in to je že leta 1959 formuliral Charney - kljub napredku numeričnih modelov napovedovanja vremena (NWP) bo napovedljivost ozračja kljub vsemu napredku vedno neomejena. Seveda upamo, da bodo modeli sčasoma vedno boljši, vendar se, kot bomo videli, že približujemo teoretični meji predvidljivosti; zaradi notranje kaotične narave atmosferskega toka te meje ne bomo nikoli presegli.

Charneyjeva osrednja izjava se torej glasi: Obstaja končna meja predvidljivosti. Glavna težava je po njegovem mnenju v **neizogibnih napakah v začetnih pogojih**. Nikoli ne bomo mogli popolnoma opazovati stanja atmosfere. V prejšnjem poglavju smo obravnavali orodja, ki nam pomagajo pripraviti najboljše možne začetne pogoje.

Drugi viri napak se pojavljajo v samem numeričnem ali statističnem modelu. Konceptualno jih lahko razvrstimo v naslednje skupine: prvič, *napake pri diskretizaciji* v klasičnem NWP; drugič, *napake pri kartiranju (mapping errors)* v sodobnih pristopih strojnega učenja, kjer se nevronska omrežja (NN) poskuša naučiti operaterja, ki nadomesti fizični model; in tretjič, *napake pri parametrizaciji*, to so napake, povezane s fizičnimi procesi, ki so premajhni - pod-mrežni procesi, da bi bili eksplicitno predstavljeni.

Velik preboj v našem razumevanju napovedovanja ozračja je leta 1963 prineslo delo EDWARD N. LORENZ. Pokazal je, da lahko majhne razlike v začetnih pogojih (IC), tudi če je model popoln, kasneje povzročijo velike razlike, če je sistem dinamično nestabilen. Priljubljena prispodoba, ki jo je uvedel - *učinek metulja* - pravi, da lahko plapolanje kril metulja v Braziliji po določenem času vpliva na nastanek tornada v Teksasu. Z drugimi besedami, napake se povečujejo: najmanjše motnje lahko rastejo in preoblikujejo tok na največjih lestvicah.

Lorenz je do tega spoznanja prišel po naključju. Pri delu na računalniku Royal McBee LGP-30 je integriral preprost dinamični sistem treh navadnih diferencialnih enačb (ODE). Za začetno integracijo je moral vnesti tri števila s plavajočo vejico, na primer

$$x_0 = 3,14578036, \quad y_0 = \dots, \quad z_0 = \dots$$

Stroj je interno shranil šestnajst decimalnih števil, vendar je Lorenz naslednji dan ponovno začel integracijo tako, da je vnesel *poudaril samo prvih pet* števil za decimalno vejico. Nominalna motnja - 5×10^{-5} - je bila neznatna, vendar se je rešitev po dovolj dolgem času dramatično razlikovala od prvotne. Lorenz je na podlagi te numerične nesreče sklepal, da je začetno stanje ključnega pomena tudi v popolnem modelu.

Trenutno velja prepričanje, da bi lahko ob znatnem izboljšanju začetnih pogojev praktično območje napovedi podaljšali za približno pet dni, medtem ko bi izboljšave samih numeričnih shem v najboljšem primeru zagotovile dva dni. V resnici so torej začetni pogoji pomembnejši od samega modela.

8.1 Osnovni teorem o predvidljivosti

Za osnovni izrek o predvidljivosti, ki ga je postavil Lorenz, pravi, da imajo **nestabilni dinamični sistemi končno mejo predvidljivosti**. Z *nestabilnim* dinamičnim sistemom mislimo na sistem, v katerem neskončno majhne motnje naraščajo eksponentno - primeri vključujejo gravitacijski problem treh teles, dvojno nihalo in dinamiko tekočin (torej gibanje atmosfere).

Nasprotno pa stabilni dinamični sistemi - kot je idealen problem dveh teles (Zemlja-Luna) - kažejo stacionarne ali periodične rešitve, ki so reverzibilne. Zemljino ozračje vsebuje elemente obeh kategorij: nekatere sestavine njegovega razvoja so periodične (letni časi, plimovanje, dnevni sevalni cikel), vendar je ozračje kot celota dovolj nestabilno, da se uveljavlja težko predvidljiv horizont.

8.2 Deterministični neperiodični tok

Zdaj ponovno preučujemo Lorenzovo prelomno delo iz leta 1963, *Deterministični neperiodični tok*, ki je uvedel nov način razmišljanja o fiziki. Lorenz je reduciral fluidno-dinamični model toplotne konvekcije na sistem z *tremi* prognostičnimi spremenljivkami $x(t)$, $y(t)$ in $z(t)$. Analiza tega minimalnega modela nam pomaga videti, zakaj se resnično ozračje obnaša kaotično.

8.2.1 Lorenzov sistem

Vektor stanja je $\mathbf{x}(t) = (x(t), y(t), z(t))^T$. Veljavne enačbe se glasijo

$$\begin{aligned}\frac{dx}{dt} &= \sigma (y - x) = F_x, \\ \frac{dy}{dt} &= x(r - z) - y = F_y, \\ \frac{dz}{dt} &= xy - bz = F_z,\end{aligned}\tag{8.1}$$

kjer

- $\sigma \propto \text{Pr}$ je sorazmeren z *Prandtlovim številom*,
- r je *Rayleighovo število* (mera vsiljenega temperaturnega gradienta) in
- b je povezan z *razmerjem stranic* (globino) konvekcijske plasti.


Lorenz je v svojem arhetipskem eksperimentu izbral

$$\sigma = 10, \quad b = \frac{8}{3}, \quad r = 28,$$

kombinacija parametrov, zaradi katere je sistem *kaotičen*. Samo prva enačba je linearna; druga dva vsebujeta kvadratne produkte spremenljivk stanja, zaradi česar je sistem močno *nelinearen*.

RHS enačbe (8.1) lahko gledamo kot vektorsko funkcijo $\mathbf{F}(\mathbf{x})$. Komponenta $F_x = \sigma(y - x)$ predstavlja *sprostitev* x proti y s časovno skalo σ^{-1} . Komponenta $F_y = x(r - z) - y$ poveže meridionalno hitrost y s produktom conske hitrosti x in krmilnega parametra $(r - z)$, hkrati pa jo duši. Končno $F_z = xy - bz$ poveže z z nelinearnim produktom xy in ga duši sorazmerno z b .

Pogled faznega prostora. Ko analiziramo dinamične sisteme, kot je Lorenzov sistem, nas zanima, kako se začetno stanje sistema $\mathbf{x}(0)$ razvija skozi čas. Takšno časovno zaporedje stanj imenujemo orbita v faznem prostoru – prostoru, kjer vsaka točka predstavlja popolno stanje sistema. Orbita torej opisuje trajektorijo sistema v tridimenzionalnem prostoru spremenljivk x , y in z :



Slika 8.1: Periodična in neperiodična orbita

$$\mathcal{O} = \{\mathbf{x}(0), \mathbf{x}(\Delta t), \mathbf{x}(2\Delta t), \dots, \mathbf{x}(t)\} = \{[x_0, y_0, z_0], [x(\Delta t), y(\Delta t), z(\Delta t)], \dots\}.$$

Ta orbita je rezultat delovanja evolucijskega operatorja $\mathcal{M}_{0 \rightarrow t}$ na začetno stanje sistema. V primeru Lorenzovega sistema, za konkretne vrednosti parametrov $\sigma = 10$, $r = 28$, $b = 8/3$, opazujemo značilno neperiodično obnašanje: trajektorija v faznem prostoru se nikoli povsem ne ponovi in ni časovno reverzibilna. To pomeni, da sistem nikoli ne obišče točno iste točke večkrat in da iz znanega trenutnega stanja ne moremo enoznačno rekonstruirati preteklosti.

Neperiodičnost kaže na kaotično naravo sistema, kjer so majhne spremembe začetnih pogojev izjemno pomembne in vodijo v divergentne orbite. Za primerjavo, periodična orbita bi se zaprla sama vase (npr. krog), kar pomeni, da se sistem vrača v začetno stanje z neko periodičnostjo. Nasprotno pa konvergentna orbita vodi v eno točko – tako imenovano fiksno točko, kjer se sistem sčasoma ”umiri”:

$$\lim_{t \rightarrow \infty} \mathbf{x}(t) = \mathbf{x}_F.$$

Lorenzov sistem ima tri takšne fiksne točke, ki jih bomo izračunali kasneje. Opazovanje orbit in njihove oblike je ključno za razumevanje celotne dinamike sistema – še posebej, ko preučujemo pojav kaosa.

8.2.2 Iskanje fiksni točk Lorenzovega sistema

V dovolj dolgih časih lahko orbita $\mathbf{x}(t) = (x, y, z)^T$ konvergira k **fiksni točki**. Na tej točki vsaka časovna izpeljanka v (8.1) izgine:

$$\dot{x} = \dot{y} = \dot{z} = 0. \quad (8.2)$$

Nastavitev desnih strani (8.1) na nič ustvari tri algebraične omejitve:

$$\sigma(y - x) = 0, \quad (8.3)$$

$$x(r - z) - y = 0, \quad (8.4)$$

$$xy - bz = 0. \quad (8.5)$$

Trivialna fiksna točka. Ker vsak izraz v (8.3)–(8.5) vsebuje vsaj eno spremenljivko stanja, sam izvor izpolnjuje vse tri pogoje:

$$\mathbf{x}_F^{(1)} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}. \quad (8.6)$$

Netrivialne fiksne točke. Izključitev veje $x = 0$ od (8.3) povzroči $y = x$. Vstavljanje $y = x$ v (8.4) daje

$$x(r - z - 1) = 0 \longrightarrow z = r - 1 \quad (x \neq 0). \quad (8.7)$$

Če nadomestimo $y = x$ in $z = r - 1$ v (8.5) dobimo

$$x^2 - b(r - 1) = 0 \longrightarrow x = \pm\sqrt{b(r - 1)}. \quad (8.8)$$

Zato je par netrivialnih ravnovesij

$$\mathbf{x}_F^{(2,3)} = \begin{bmatrix} \pm\sqrt{b(r - 1)} \\ \pm\sqrt{b(r - 1)} \\ r - 1 \end{bmatrix}. \quad (8.9)$$

Geometrijska interpretacija. Risanje niza fiksnih točk v prostoru (x, y, z) razkrije simetrični par, ki se nahaja na obeh straneh izhodišča. Ko se trajektorija približa eni od teh točk, jo nelinearni členi v (8.1) odklonijo in ustvari jo ikonični atraktor v obliki metulja 8.2.



Slika 8.2: Lorenzov metulj

Praktična implikacija. Celo majhna napaka pri zaokroževanju - na primer pri rezovanju vhodne vrednosti s 3,14578036 na 3,14578 - ustreza začetni motnji $\mathcal{O}(10^{-5})$. V kaotičnem sistemu se lahko ta motnja poveča, dokler se orbita popolnoma ne oddalji od svoje nemotene dvojnice, tako kot se dve vremenski napovedi, inicializirani iz nekoliko različnih analiz, razhajata po približno dveh tednih.

8.2.3 Stabilnost fiksnih točk

Analizirajmo stabilnost fiksnih točk. Ali ima atmosfera fiksne točke? Da, in so *nestabilne*. Če bi bile stabilne, se atmosfera naše Zemlje ne bi spremenila - obstala bi na določeni lokaciji v določenem stanju. Toda naše vreme se spreminja, zato ni možnosti, da bi naše ozračje imelo stabilne fiksne točke.

Začnemo s pisanjem Lorenzove enačbe v vektorski obliki, pri čemer vse tri desne strani zapakiramo v eno vektorsko funkcijo:

$$\frac{d\mathbf{x}}{dt} = \mathbf{F}(\mathbf{x}). \quad (8.10)$$

Naj bo zdaj $\mathbf{x}_0$ fiksna točka. Zanima nas *motnja* okoli fiksne točke, zato je $\delta\mathbf{x}$ majhen premik. Da bi razvili to motnjo, nadomestimo

$$\mathbf{x}(t) = \mathbf{x}_0 + \delta\mathbf{x}(t) \quad (8.11)$$

v vodilno enačbo. To prinaša

$$\frac{d(\mathbf{x}_0 + \delta\mathbf{x})}{dt} = \mathbf{F}(\mathbf{x}_0 + \delta\mathbf{x}) \quad (8.12)$$

$$= \mathbf{F}(\mathbf{x}_0) + \underbrace{\frac{\partial \mathbf{F}}{\partial \mathbf{x}} \Big|_{\mathbf{x}_0}}_{J(\mathbf{x}_0)} \delta\mathbf{x} + \mathcal{O}(|\delta\mathbf{x}|^2). \quad (8.13)$$

Ker je $\mathbf{x}_0$ fiksna točka, $\mathbf{F}(\mathbf{x}_0) = \mathbf{0}$. Če ohranimo samo linearni člen, dobimo **tangentni–linearni sistem**

$$\frac{d\delta\mathbf{x}}{dt} = J(\mathbf{x}_0) \delta\mathbf{x}, \quad (8.14)$$

kjer je $J(\mathbf{x}_0)$ **jacobian**. (Prva izpeljanka vektorske funkcije se običajno imenuje Jacobian; druga izpeljanka je Hessian.)

Za referenco so tri fiksne točke

$$\begin{aligned} x_F^1 &= y_F^1 = z_F^1 = 0, \\ x^{23} &= \pm \sqrt{b(r-1)}, \\ y^{23} &= \pm \sqrt{b(r-1)}, \\ z^{23} &= r-1. \end{aligned}$$

Polna Jakobijeva matrika parcialnih odvodov je

$$J(\mathbf{x}) = \begin{bmatrix} \frac{\partial F_x}{\partial x} & \frac{\partial F_x}{\partial y} & \frac{\partial F_x}{\partial z} \\ \frac{\partial F_y}{\partial x} & \frac{\partial F_y}{\partial y} & \frac{\partial F_y}{\partial z} \\ \frac{\partial F_z}{\partial x} & \frac{\partial F_z}{\partial y} & \frac{\partial F_z}{\partial z} \end{bmatrix}. \quad (8.15)$$

Izvajanje derivatov, ki jih pridobimo

$$J(\mathbf{x}) = \begin{bmatrix} -\sigma & \sigma & 0 \\ r-z & -1 & -x \\ y & x & -b \end{bmatrix}. \quad (8.16)$$

8.2.4 Lastne vrednosti Jacobija

Sedaj moramo izračunati lastne vrednosti tega Jacobiana. Lastne vrednosti za tega Jacobija nam bodo povedale, ali se bo motnja okoli fiksnih točk povečala ali zmanjšala. Torej, ali se razvoj te motnje $\delta\mathbf{x}$ okoli fiksne točke povečuje ali zmanjšuje. Če bi motnja naraščala, to pomeni nestabilno fiksno točko. Recimo, da imamo stabilno fiksno točko in nestabilno fiksno točko. Recimo, da smo blizu prve točke—to je motnja proti fiksni točki. Če je fiksna točka stabilna, se bo motnja sčasoma zmanjšala; na razvoj motenj vplivajo lastne vrednosti te matrike. Če je fiksna točka stabilna, se bo motnja sčasoma zmanjšala, padla bo v fiksno točko - konvergirala bo nad fiksno točko. Če je fiksna točka nestabilna, to pomeni, da je vsaj ena od lastnih vrednosti večja od nič. Ko se približamo fiksni točki, nas bo brcnilo stran. To se zgodi v Lorenzovem sistemu: imamo dve nestabilni fiksni točki in opazujemo trajektorije, ki izgledajo, kot da bi ju fiksne točke izrinile. Ti dve fiksni točki sta nestabilni; takoj ko se približaš te brcnejo stran. Zdaj to prikažemo numerično z izračunom lastnih vrednosti.

Vemo, kako najti lastne vrednosti:

$$\det(J - \lambda I) = 0. \quad (8.17)$$

Ta determinanta se razširi na

$$\begin{vmatrix} -\sigma - \lambda & \sigma & 0 \\ r & -1 - \lambda & -x \\ y & x & -b - \lambda \end{vmatrix} = 0. \quad (8.18)$$

Preizkušanje trivialne fiksne točke. Za $x = y = z = 0$ se determinanta poenostavi na

$$\begin{vmatrix} -\sigma - \lambda & \sigma & 0 \\ r & -1 - \lambda & 0 \\ 0 & 0 & -b - \lambda \end{vmatrix} = 0. \quad (8.19)$$

Iz te oblike takoj preberemo $\lambda_1 = -b$. Preostali blok 2×2 reproducira:

$$\lambda^2 + \lambda(1 + \sigma) + \sigma(1 - r) = 0. \quad (8.20)$$

in s tem lastni vrednosti:

$$\lambda_{2,3} = \frac{1}{2}(-1 - \sigma \pm \sqrt{\sigma^2 - 2\sigma + 4r\sigma + 1}). \quad (8.21)$$

Preizkušanje netrivialnih fiksni točke. Fiksni točki:

$$x^{(2,3)} = \pm \sqrt{b(r-1)}, \quad y^{(2,3)} = \pm \sqrt{b(r-1)}, \quad z^{(2,3)} = r - 1$$

Jacobijeva matrika Lorenzovega sistema je:

$$J = \begin{pmatrix} -\sigma & \sigma & 0 \\ r - z & -1 & -x \\ y & x & -b \end{pmatrix}$$

Za nestacionarni fiksni točki vstavimo:

$$x = y = s = \sqrt{b(r-1)}, \quad z = r - 1 \Rightarrow r - z = 1$$

Dobimo Jacobija:

$$J = \begin{pmatrix} -\sigma & \sigma & 0 \\ 1 & -1 & -s \\ s & s & -b \end{pmatrix}$$

Iščemo lastne vrednosti, torej rešujemo:

$$\det(J - \lambda I) = 0$$

Karakteristična matrika:

$$\begin{vmatrix} -\sigma - \lambda & \sigma & 0 \\ 1 & -1 - \lambda & -s \\ s & s & -b - \lambda \end{vmatrix} = 0$$

Razširimo determinanto po prvi vrstici:

$$(-\sigma - \lambda) \begin{vmatrix} -1 - \lambda & -s \\ s & -b - \lambda \end{vmatrix} - \sigma \begin{vmatrix} 1 & -s \\ s & -b - \lambda \end{vmatrix}$$

Izračunamo manjše determinante:

$$(-1 - \lambda)(-b - \lambda) - (-s)(s) = (1 + \lambda)(b + \lambda) - s^2$$

$$1 \cdot (-b - \lambda) - (-s)(s) = -b - \lambda + s^2$$

Skupni izraz za determinanto:

$$(-\sigma - \lambda) \left[(1 + \lambda)(b + \lambda) - s^2 \right] - \sigma \left[-b - \lambda + s^2 \right] = 0$$

Z zamenjavo $s^2 = b(r - 1)$ dobimo karakteristični polinom:

$$\lambda^3 + (1 + \sigma + b)\lambda^2 + b(\sigma + r)\lambda + 2b\sigma(r - 1) = 0$$

To je polinom 3. stopnje z realnimi koeficienti. Njegove rešitve (lastne vrednosti) so:

$$\lambda_{1,2,3} = \text{rešitve zgornjega kubičnega polinoma, odvisne od parametrov } (\sigma, b, r)$$

Numerični primer Za parametre:

$$\sigma = 10, \quad b = \frac{8}{3}, \quad r = 28$$

Dobimo numerično Jacobijevo matriko:

$$J = \begin{pmatrix} -10 & 10 & 0 \\ 1 & -1 & -\sqrt{\frac{8}{3} \cdot 27} \\ \sqrt{\frac{8}{3} \cdot 27} & \sqrt{\frac{8}{3} \cdot 27} & -\frac{8}{3} \end{pmatrix}$$

Karakteristični polinom ima naslednje rešitve:

$$\lambda_1 = -13.855$$

$$\lambda_{2,3} = 0.094 \pm 10.195i$$

Interpretacija: Točka je nestabilna, ker imata dve lastni vrednosti pozitiven realni del. Sistem kaže na spiralno divergirajoče obnašanje v dveh smereh.

Interpretacija lastnih vrednosti

Rešitev linearnega sistema lahko zapišemo

$$\delta \mathbf{x}(t) = \sum_i c_i \mathbf{v}_i e^{\lambda_i t}, \quad (8.22)$$

kjer sta λ_i in $\mathbf{v}_i$ lastni vrednosti in lastni vektorji $J(\mathbf{x}_0)$. Če kateri koli $\text{Re}(\lambda_i) > 0$, se eksponenta poveča in motnja raste; fiksna točka je **nestabilna**. Če so vsi realni deli negativni, se motnja zmanjša in fiksna točka je **stabilna**. Ničelni realni del pomeni nevtralnost.

Pravilo stabilnosti

Če imamo $\text{Re}(\lambda_1)$ in $\text{Re}(\lambda_2)$ in $\text{Re}(\lambda_3) < 0$, imamo **stabilno** fiksno točko: kjer koli smo na trajektoriji, nas vleče proti Lorenzovi fiksni točki; perturbacija gre v času proti ničli. Če katerikoli $\text{Re}(\lambda_i) > 0$, imamo **nestabilno** točko. Zakaj je stabilen ali nestabilen za te pogoje? Jakobova matrika natančno manipulira s to motnjo: če je ena lastna vrednost večja od nič, bo vsaj ena komponenta δx rasla neomejeno, kar pomeni, da tudi če začnemo blizu fiksne točke, končamo vse dlje in dlje. Če so vse lastne vrednosti enake nič, lahko dobimo čisto rotacijo. Stabilna fiksna točka: lastne vrednosti manjše od 0—razpadi motenj. Eden od njih je večji od 0—motnja ojača vsaj eno komponento.

8.2.5 Lastnosti Lorenzovega sistema


Prva pomembna lastnost sistema Lorenz-63 je, da je **determinističen**. To pomeni, da je njegov razvoj odvisen izključno od začetnega stanja; ni stohastičnega vedenja:

$$\mathbf{x}(t) = \mathcal{M}_{0 \rightarrow t}(\mathbf{x}(0)) + \mathbf{r}(t), \quad (8.23)$$

kjer zavržemo stohastični člen $\mathbf{r}(t)$. Če bi šlo za stohastičen proces, bi to pomenilo, da ne opazimo vedno iste stvari.

Druga pomembna lastnost je, da je **disipativen**. To pomeni, da ni Hamiltonov in ne ohranja energije. Ne glede na začetne pogoje se vedno znajdemo na istem atraktorju in enako vedenje velja za Zemljino atmosfero. Tudi če začnemo podnebno simulacijo z začetnimi pogoji, ki so daleč od sedanjega stanja, končamo na istem opazovanem nizu točk – atraktorju.

Pokazali smo, da se končno vse trajektorije končajo na atraktorju dinamičnega sistema. Z drugimi besedami, obstaja univerzalna absorpcijska množica B_0 , kjer je globalni atraktor A podmnožica te množice: $A \subset B_0$. Atraktor A je invarianten in privlači vse trajektorije v faznem prostoru. Vsaka trajektorija $\mathbf{x}(t)$, ki se začne znotraj A , prav tako za vedno ostane v A . Poleg tega A privlači trajektorije, ki se začnejo zunaj A : če $\mathbf{x}_0 \in B_0$, potem gre razdalja $|\mathbf{x}(t) - A|$ na nič kot $t \rightarrow \infty$.




Slika 8.3: Prikaz atraktorja


Tretja lastnost je, da je sistem izjemno **občutljiv** na spremembe začetnih pogojev—to je kaotičen sistem. Trajektorije, ki se začnejo blizu skupaj, se razhajajo, zato je dolgoročna predvidljivost nemogoča: obstaja končna meja predvidljivosti. Ker je atraktor omejen – na primer Lorenzov atraktor ima obliko metulja – napaka ne more večno rasti; nasiči se na lestvici atraktorja.

Enako velja za Zemeljski sistem, kajti če ne bi bilo omejeno, bi vreme lahko doseglo stanja, ki so daleč onstran tega, kar imamo v povprečju, a tega nimamo. Omejen je z lastnostmi, ki ga določa atraktor. In te lastnosti so oddaljenost Sonca nagib Zemeljske osi hitrost vrtenja okoli osi. Torej je atraktor omejen tako v modelu Lorenz63. Torej, če to drži, napaka ne more večno naraščati, kar pomeni, da obstaja asimptotična zgornja meja med obema trajektorijama. Napaka sčasoma **nasiči**. Tipična krivulja rasti napake v primerjavi s pretočnim časom je videti kot slika 8.5.

Kjer je točka napake, se napaka nasiči, ker se dve trajektoriji ne moreta odložiti več kot to. Oglejmo si Lorenzov sistem, torej ta metulj, dve trajektoriji na robu sta meji, kjer je trajektorija najbolj zamaknjena. Torej obstaja asimptotična zgornja meja razdalje med dvema trajektorijama/rešitvama. Ne morejo odlašati v nedogled.



Slika 8.4: Z modro je prikazan atraktor Lorenzovega 63 sistema. Z rdečo sta prikazani dve najbolj skrajni točki v tem sistemu, s temno modro pa največja možna napaka sistema. S tem se vidi da je sistem dejansko omejen z atraktorjem.




Slika 8.5: Krivulja rasti splošne napake. Razdalja med dvema prvotno blizu trajektorijama narašča eksponentno, dokler ne doseže lestvice atraktorja, nato se nasiči.

Ljapunov koeficient Da bi boljše razumeli občutljivost Lorenzovega sistema na začetne pogoje, si oglejmo dve zelo podobni trajektoriji na atraktorju. Prvo označimo z $\vec{x}(t)$, drugo – ki se začne iz skoraj enakega začetnega stanja – z $\vec{x}(t) + \vec{\delta}(t)$, kjer je $\vec{\delta}(t)$ vektor razlike med obema trajektorijama ob času t . Takšna razlika lahko na začetku izvira iz minimalnih numeričnih napak (npr. zaradi zaokroževanja v računalniških simulacijah), npr.

$$\|\vec{\delta}(0)\| \approx 10^{-15}, \quad (8.24)$$

kar je približno najmanjša možna razlika v računalniški aritmetiki z dvojno natančnostjo.




Slika 8.6: Prikaz dveh krivulj.

Lorenz je pokazal, da se razlika med takima trajektorijama pri kaotičnih sistemih eksponentno povečuje v začetni fazi evolucije:

$$\|\vec{\delta}(t)\| \approx \|\vec{\delta}(0)\| e^{\lambda t}, \quad (8.25)$$

kjer je λ pozitivna konstanta – Ljapunov eksponent. V Lorenzovem sistemu znaša približno $\lambda \approx 0,9$, kar pomeni, da se razlika med dvema skoraj enakima začetnima stanjema podvoji vsakih nekaj enot časa. Takšna rast razlike pomeni, da sistema ne moremo napovedovati daleč v prihodnost, saj tudi minimalna negotovost na začetku sčasoma privede do popolnoma različnih rezultatov.

Na grafu $\ln\|\vec{\delta}(t)\|$ proti t to pomeni, da točke ležijo na premici s povprečnim naklonom λ . Ta rast se nadaljuje le do točke, ko razlika doseže velikost samega atraktorja – takrat napaka saturira, saj nobeni dve trajektoriji ne moreta biti bolj različni, kot je to dopuščeno zgradbo atraktorja. Intuitivno si lahko to predstavljamo kot prehod iz enega "krila metulja" v drugega – večja ločitev v faznem prostoru ni več smiselna.



Slika 8.7: Ločitev dveh trajektorij se eksponentno povečuje, dokler ne doseže dimenzije atraktorja.

To ima pomembne posledice tudi v praksi. Če bi napovedovali npr. zimsko vreme v Ljubljani, bi ena trajektorija predstavljala dejanski razvoj vremena, druga pa rezultat numerične vremenske napovedi. Čeprav se napoved in resničnost lahko močno razlikujeta čez nekaj dni, se razlika nikoli ne bo povečala preko fizikalno smiselnih meja – atraktor namreč določa, katere rešitve so sploh možne. Zato se v januarju temperatura v napovedi nikoli ne bo približala $+30,^{\circ}\text{C}$ ali $-30,^{\circ}\text{C}$.

Parameter λ imenujemo Ljapunov eksponent, natančneje vodilni Ljapunov eksponent ($\lambda_{\max}$), saj v n -dimenzionalnem sistemu obstaja n takih eksponentov – eden za vsako dimenzijo faznega prostora. Vodilni eksponent opisuje največjo stopnjo divergence in je definiran kot:

$$\lambda_{\max} = \lim_{t \rightarrow \infty}; \lim_{\|\vec{\delta}(0)\| \rightarrow 0} \frac{1}{t} \ln \frac{\|\vec{\delta}(t)\|}{\|\vec{\delta}(0)\|}, \quad (8.26)$$

kjer je $\vec{\delta}(0)$ je začetna razlika med dvema točkama, $\vec{\delta}(t)$ je razlika med njima po času t , potem ko sta obe točki sledili svojim potim skozi sistem, $\frac{\|\vec{\delta}(t)\|}{\|\vec{\delta}(0)\|}$ pomeni: koliko-krat se je razlika povečala glede na začetno vrednost, $\lim_{t \rightarrow \infty}$: opazujemo, kaj se zgodi dolgoročno, ko pustimo, da čas teče zelo dolgo in $\lim_{\|\vec{\delta}(0)\| \rightarrow 0}$: to pomeni, da nas zanima, kako se stvari obnašajo, če je začetna razlika res zelo majhna. (To je ključno pri kaosu – občutljivost na izjemno majhne spremembe.)

Enačba pove da če začnem z dvema točkama, ki sta skoraj enaki, in opazujem, kako se sčasoma razhajata, potem je $\lambda_{\max}$ število, ki mi pove, kako hitro (eksponentno hitro) se ta razlika povečuje.. Pozitiven $\lambda_{\max}$ je eden ključnih pokazateljev kaotičnega sistema. Če pa bi bil $\lambda_{\max} < 0$, bi to pomenilo, da se razlike manjšajo – to je značilno za stabilne (konvergentne) sisteme, kjer vse poti sčasoma "poniknejo" v isto točko.


Dolgoročna stabilnost in razvoj hipersfere Dolgoročna stabilnost dinamičnega sistema je določena z največjim Ljapunovim eksponentom $\lambda_{\max}$. Ta določa hitrost divergenca bližnjih trajektorij v faznem prostoru. Za ilustracijo si zamislimo sistem, ki sledi neki trajektoriji $\vec{x}(t)$, začetno definirani z $\vec{x}(0)$. V okolici začetne točke porazdelimo množico majhnih motenj, katerih končne točke ležijo na hipersferi polmera ε :

$$\|\delta\vec{x}(0)\| = \varepsilon.$$

Ta začetna hipersfera se s časom deformira v hiperelipsoid, katerega oblika in raztezanje sta določena z Jacobijevo matriko (oz. tangentnim propagatorjem) $M_{0 \rightarrow t} = \left. \frac{\partial \mathcal{M}}{\partial \vec{x}} \right|_{\vec{x}(0)}$. Polosi hiperelipsoida po času t so sorazmerne s singularnimi vrednostmi σ_i matrike $M_{0 \rightarrow t}$:

$$\text{pol-os}_i = \varepsilon \sigma_i.$$

Najdaljša os hiperelipsoida ustreza največji singularni vrednosti in je usmerjena v smer *vodilnega Ljapunovega vektorja*. V tej smeri motnje najhitreje naraščajo, kar neposredno povežemo z največjim Ljapunovim eksponentom.



Na zgornji skici je prikazan razvoj začetne hipersfere (levo) v hiperelipsoid (sredina), ki se kasneje – zaradi nelinearnih učinkov – začne upogibati v t. i. *ukrivljen hiperelipsoid* (desno). Ta "bananasta" oblika označuje trenutek, ko tangentno-linearna aproksimacija ni več veljavna.

Kvantificiranje nelinearnosti in razpad napovedljivosti Ko hiperelipsoid postane ukrivljen, pomeni, da je nelinearni razvoj pomemben. V tem primeru linearna aproksimacija $M_{0 \rightarrow t}$ ni več dovolj za opis razvoja motenj. Stopnjo nelinearnosti lahko kvantificiramo kot razliko med natančnim nelinearnim razvojem in njegovo tangentno-linearno aproksimacijo:

$$N = \mathcal{M}(\vec{x}(0) + \delta\vec{x}(0)) - (\mathcal{M}(\vec{x}(0)) + M_{0 \rightarrow t} \delta\vec{x}(0)).$$

Če je $|N| \ll |M_{0 \rightarrow t}, \delta\vec{x}(0)|$ potem linearni približek dobro deluje, če je $|N| \sim |M_{0 \rightarrow t}, \delta\vec{x}(0)|$ nelinearni del je postal pomemben, ker je približno enako velik kot linearni in če $|N| > |M_{0 \rightarrow t}, \delta\vec{x}(0)|$ linearna napoved skoraj nič ne prispeva več k pravilnemu rezultatu, kar pomeni linearna teorija popolnoma odpove. Če norma $\|N\|$ postane primerljiva z linearnim členom, potem je vpliv nelinearnosti dominanten in napovedljivost sistema upade. Takšno stanje označuje prehod v kaotično obnašanje, kjer se perturbirana trajektorija $\vec{x}(t) + \delta\vec{x}(t)$ bistveno razlikuje od osnovne $\vec{x}(t)$.

Taylorjeva ekspanzija modela $\mathcal{M}$ okrog $\vec{x}(0)$ pokaže, da za dovolj majhne motnje velja:

$$\mathcal{M}(\vec{x}(0) + \delta\vec{x}(0)) \approx \mathcal{M}(\vec{x}(0)) + M_{0 \rightarrow t} \delta\vec{x}(0) + \mathcal{O}(|\delta\vec{x}|^2).$$

Nelinearni člen $\mathcal{O}(|\delta\vec{x}|^2)$ predstavlja začetek zlaganja hiperelipsoida. Čas, ko ta člen začne prevladovati, označuje mejo napovedljivosti, ki jo bomo kasneje kvantificirali še z značilnimi časovnimi skalami.

8.3 Časovna lestvica predvidljivosti

Kot smo že povedali, **Ljapunov eksponenti** urejajo končno mejo deterministične napovedi. Vodilni eksponent $\lambda_{\max}$ nastavi karakteristični čas podvojitve napake; grobo pravilo je

$$\tau \simeq \frac{1}{\lambda_{\max}}, \quad (8.27)$$

kar je čas zvijanja neskončno majhne motnje ali tipična časovna lestvica rasti napake.

Da bi to stalno stopnjo rasti prevedli v praktično mejo napovedi, uvedemo *toleranco* a . Naša napoved postane neuporabna, ko ločitev preseže ta prag:

$$\|\delta(t)\| \geq a. \quad (8.28)$$

Če je začetna velikost napake $\|\delta_0\|$, zgornja meja zanesljive predvidljivosti sledi neposredno iz eksponentnega zakona $\|\delta(t)\| \approx \|\delta_0\|e^{\lambda_{\max}t}$:

$$t_{\text{pred}} \approx \frac{1}{\lambda_{\max}} \ln \frac{a}{\|\delta_0\|}. \quad (8.29)$$

Zato večji $\lambda_{\max}$ ali večja začetna negotovost skrajšata uporaben obseg napovedi; nasprotno pa je krčenje $\|\delta_0\|$ glavna pot za razširitev spretnosti. Večji kot je Ljapunov eksponent $\lambda_{\max}$, manj predvidljiv je sistem, zato je manjša predvidljivost na časovnem merilu. Večja $\|\delta_0\|$ manjša predvidljiva časovna lestvica, kar je spet zelo v skladu s tem, kar smo rekli prej. Veliko $\|\delta_0\|$ pomeni, da bi začeli z začetnimi pogoji, ki so že zelo negotovi. To pomeni, da bo naša napaka prej narasla na stopnjo tolerance. Torej, da bi povečali predvidljivost, moramo zmanjšati napako v začetnih pogojih.

Numerična ilustracija. Recimo $a = 10^{-3}$ in $\|\delta_0\| = 10^{-7}$. Potem

$$t_{\text{pred}}^{(1)} = \frac{1}{\lambda_{\max}} \ln \frac{10^{-3}}{10^{-7}} = \frac{4 \ln 10}{\lambda_{\max}}. \quad (8.30)$$

Izboljšanje analize za šest velikosti na $\|\delta_0\| = 10^{-13}$ daje

$$t_{\text{pred}}^{(2)} = \frac{1}{\lambda_{\max}} \ln \frac{10^{-3}}{10^{-13}} = \frac{10 \ln 10}{\lambda_{\max}} \approx 2,5 t_{\text{pred}}^{(1)}, \quad (8.31)$$

smo izboljšali začetno stanje za 10- do 6-krat, vendar smo povečali napovedni razpon samo za 2,5-krat. Vendar je zelo nerealno izboljšati začetno stanje za toliko. Tako spektakularno izboljšanje začetne natančnosti kupi le skromno razširitev obsega napovedi - značilnost kaotičnih sistemov.

8.4 Rast napak v numerični napovedi vremena

Operativni centri preverjajo napovedi za različna področja: geopotencialna višina 500 hPa, vektorski veter 850 hPa, parametri blizu površine, kot je temperatura 2-m, skupna količina padavin itd. V praksi prevladujeta dve meritvi spretnosti.

Korenska povprečna kvadratna napaka (RMSE). Definirana kot kvadratni koren srednje kvadratne napake med napovedjo v določenem času t in resnico

$$\text{RMSE}(t) = \sqrt{\langle (\mathbf{x}^f(t) - \mathbf{x}^t(t))^2 \rangle}, \quad (8.32)$$

kjer $\langle \cdot \rangle$ označuje prostorsko (in pogosto časovno) povprečje, je $\mathbf{x}^f$ napovedano stanje in $\mathbf{x}^t$ "resnica". Torej mislimo na razlike med napovedjo in stanjem resnice in potem pomenimo vse te kvadrate in izvedemo kvadratni koren. Resničnega stanja pa očitno nikoli ne izvemo. Analizo ali ponovno analizo raje uporabimo kot temeljno resnico, je najboljši približek resnice, ki ga lahko dobimo, vendar je le približek resnice.

Korelacijski koeficient anomalije (ACC). Mere korelacija med napovedjo minus klimatologija krat resnica minus klimatologija deljena z njihovimi variancami. Tako meri spretnost vzorca po odstranitvi klimatologije:

$$\text{ACC}(t) = \frac{\langle (\mathbf{x}^f - \mathbf{x}^c)(\mathbf{x}^t - \mathbf{x}^c) \rangle}{\sqrt{\langle (\mathbf{x}^f - \mathbf{x}^c)^2 \rangle} \sqrt{\langle (\mathbf{x}^t - \mathbf{x}^c)^2 \rangle}}, \quad (8.33)$$

kjer je $\mathbf{x}^f$ napovedano stanje, $\mathbf{x}^t$ resnično stanje in $\mathbf{x}^c$ klimatološko stanje, ki je povprečje več realizacij v določenem določenem obdobju. V imenovalcu imamo kovariance. In $\mathbf{x}^f - \mathbf{x}^c$ je anomalija napovedi, $\mathbf{x}^t - \mathbf{x}^c$ je anomalija resnice (koliko uresničitev odstopa od določenega obdobja). Oboje se meri glede na dolgoročno klimatološko povprečje. Vrednosti blizu 1 pomenijo visoko natančnost vzorca; vrednosti blizu 0 ne ustrezajo nobeni spretnosti.

Lorenz (1952) logistični model za RMSE

Zdaj, če pomislimo na RMSE, kako napaka raste s časom? Lorenz je predlagal, da se domensko povprečna napaka $E(t)$ razvija v skladu z

$$\frac{dE}{dt} = \alpha E(1 - E), \quad (8.34)$$

kjer je $E \in [0, 1]$ normalizirani RMSE, $E(0)$ začetna napaka in α parameter rasti. Enačba (8.34) je klasična *logaritemska enačba*. Njegovi fiksni točki sta $E = 0$ (brez napake) in $E = 1$ (nasičenost). Ločevanje spremenljivk:

$$\int_{E(0)}^{E(t)} \frac{dE}{E(1 - E)} = \int_0^t \alpha dt, \quad (8.35)$$


$$\ln \frac{E(t)}{1 - E(t)} - \ln \frac{E(0)}{1 - E(0)} = \alpha t, \quad (8.36)$$

ki se preuredi v rešitev zaprte oblike

$$E(t) = \frac{E(0) e^{\alpha t}}{1 + E(0)(e^{\alpha t} - 1)}. \quad (8.37)$$

Enačba (8.37) opisuje krivuljo v obliki črke S (sl. 8.8), ki odraža opazovano rast RMSE: zgodnja eksponentna faza, linearna srednja rast in morebitna nasičenost pri $E = 1$.

Torej je rast napake kot funkcije časa odvisna od napake v času nič in parametra rasti napake alfa in rekli smo, da je ta funkcija omejena med nič in 1. To je končna rešitev. Kar je logistična krivulja.




Slika 8.8: Idealizirana logistična rast domensko povprečne napake napovedi $E(t)$, podane z Eq. (8.37).

D''ahler–Kalnay (1987) razširitev

Za prilagoditev začetnemu *spin-up* obdobju (začetno obdobje simulacije, v katerem sistem še ni v ravnovesju oziroma še ne odraža značilnega (stabilnega ali statistično stacionarnega) obnašanja) – običajno v napovedovalnih sistemih iz 1980-ih, kjer so bile analize dinamično neuravnotežene – sta D''ahler in Kalnay (1987) dodala linearni izraz:

$$\frac{dE}{dt} = (\alpha E + B) \left(1 - \frac{E}{E_{\max}}\right), \quad (8.38)$$

kjer B zajame zgodnje obnašanje linearne napake, $E_{\max}$ pa nastavi raven nasičenosti (pogosto spremenjeno na 1). V preteklosti so napovedi pokazale *začetno zmanjšanje* napake, ko je model prilagodil lažni šum gravitacijskih valov; parameter B reproducira ta padec, preden se uveljavi eksponentna rast. Sodobne sheme asimilacije podatkov so večinoma odpravile potrebo po takem izrazu, saj so začetna stanja zdaj navidezno uravnotežena: *spin-up* je minimalen in zadostuje sam logistični model.



Slika 8.9: Rast napake po D''ahler-Kalnay razširitvi

Časi podvajanja napak trenutnih sistemov NWP

Pri operativnem napovedovanju pogosto povzamemo predvidljivost z navedbo *časa podvojitve napak* Δt : obdobja, ki je potrebno, da reprezentativna motnja naraste za faktor 2. Empirično gledano so današnji modeli uspešni

- $\Delta t \approx 2\text{--}3$ **dan** za značilnosti *sinoptičnega merila* na srednjih zemljepisnih širinah (npr. veliki baroklinični valovi),
- $\Delta t \approx 1$ **dan** za *mezoskalne* pojave (tropski cikloni, čelni deževni pasovi) in

- $\Delta t \approx 30$ **minute** za dogodke *konvektivne lestvice* (posamične nevihte, megle, lokalni vetrovi).

Te številke so vodila po vrstnem redu velikosti; nenehne izboljšave modela in opazovalna mreža jih vsako leto potiskajo navzgor.

Čas podvojitve napak v Lorenzovem logističnem modelu Videli smo Δt z Lorenzovim logističnim zakonom rasti RMSE. Spomnimo se logistične rešitve

$$E(t) = \frac{E(0) e^{\alpha t}}{1 + E(0)(e^{\alpha t} - 1)}, \quad (8.39)$$

kjer

$E(t)$ = domensko povprečen, normaliziran RMSE (omejen $0 \leq E \leq 1$),

$E(0)$ = začetna relativna napaka,

α = eksponentna stopnja rasti (dan^{-1}).

Za majhne $E(0)$ in kratke pretočne čase je imenovalc ≈ 1 in $E(t) \propto e^{\alpha t}$; čas podvojitve je takrat

$$\Delta t_{\text{logistic}} \simeq \frac{\ln 2}{\alpha}. \quad (8.40)$$

Z $\alpha \approx 0,35 \text{ day}^{-1}$ je teoretični čas podvojitve $\Delta t \approx 2$ d, kar je v skladu z izkušnjami na sinoptični ravni.

Povezovanje kakovosti analize z uporabnim časom Naj bo današnja napaka geopotencialne višinske analize 500 hPa $\text{RMSE}(z_{500}) \approx 5$ m, medtem ko je naravna vsakodnevna anomalija (odmiki od klimatološkega povprečja) $\sigma_{\text{clim}} \approx 100$ m. *Relativna* začetna napaka je torej

$$E(0) = \frac{5}{100} = 0,05 = 5\%. \quad (8.41)$$

V meji $t \rightarrow \infty$ se logistična krivulja nasiči pri $E_{\text{max}} = 1$. Recimo, da prihodnji opazovalni sistemi zmanjšajo $E(0)$ na 1%. Koliko dodatnega znanja lahko kupimo?

Če začnemo z Eq. (8.39) in preuredimo za začetni čas, pri katerem napaka doseže fiksni ulomek $E(t) = E_{\text{tol}}$, dobimo

$$t = \frac{1}{\alpha} \ln \frac{E_{\text{tol}}(1 - E(0))}{E(0)(1 - E_{\text{tol}})}. \quad (8.42)$$

Postavimo $E_{\text{tol}} = 0,5$ (napoved izgubi vrednost, ko je polovica klimatološke variance napačne) in ocenimo tri primere:

$E(0)$	t [dnevi]
0,10	$t = \frac{1}{\alpha} \ln \left(\frac{0,5 \times 0,9}{0,1 \times 0,5} \right) = 6,3$
0,05	8,4
0,01	13,1

Tako prepolovitev začetne napake (z 10% na 5%) razširi uporabi obseg za *samo* približno dva dni; desetkratno znižanje (na 1%) kupi približno šest dodatnih dni. Izboljšanje analiz postaja vedno težje, medtem ko donos v času priprave kaže vse manjše dobičke – temeljna ovira za NWP.

Zakaj preučevati preproste kaotične sisteme? Model Lorenz–63, čeprav minimalen, zajema bistveno vedenje veliko bogatejših sistemov:

1. **Kaotična konvekcija med dvema ploščama.** podobno kot zračni mehurčki, ki se dvigajo in spuščajo v atmosferi (kot v ponvi z vodo).
2. **Globalno kroženje.** vreme na velikih razdaljah, kjer se vzorci vrtincev hitro spreminjajo (npr. cikloni).

Lorenz–63 izvira iz skrajšanih Navier–Stokesovih enačb za takšno ploščato konvekcijo in zato služi kot pedagoški most med teorijo abstraktnih dinamičnih sistemov in oprijemljivo kompleksnostjo zemeljskega vremena.

8.5 Lastnosti atmosferske predvidljivosti

8.5.1 Predvidljivost ni konstantna v času

Ena ključnih značilnosti atmosferske dinamike je, da predvidljivost ni stalna – ne v času, ne v prostoru. Koliko časa napoved ostaja zanesljiva, zelo močno zavisi od trenutnega stanja atmosfere. To je lepo prikazano na Sliki 8.10, kjer so prikazane napovedne spretnosti več operativnih vremenskih modelov.



Slika 8.10: Napovedna spretnost modelov (anomaly correlation) za geopotencial 500, hPa na severni polobli (20°–90°N) za 5-dnevno napoved (T+120 h). Označen je časovni interval z izboljšano predvidljivostjo.

Na vertikalni osi je prikazana anomaljska korelacija (ACC) med napovedjo in resničnim stanjem za višino geopotenciala pri 500 hPa, kar je standardna višina za preučevanje sinoptičnega vremena. Višje vrednosti ACC (bližje 100%) pomenijo boljše ujemanje vzorca anomalij – torej večjo spretnost napovedi.

Na sliki opazimo da vse napovedi nihajo, torej spretnost modelov ni konstantna, okoli 5 do 12. maja se vidi obdobje, kjer imajo vsi modeli izboljšano predvidljivost - napovedi so bolj skladne in ACC vrednosti so višje. Po tem obdobju sledi izrazit padec kakovosti - napovedi postanejo bistveno manj zanesljive.

To pomeni, da obstajajo časovna okna, v katerih je atmosfera bolj "mirna" in omogoča bolj zanesljive napovedi. Pogosto se to zgodi v anticklonskem vremenu, kjer je manj dogajanja, manj turbulence in počasnejši razvoj napak.


8.5.2 Predvidljivost je odvisna tudi od prostorskega merila.

Iz prejšnjih poglavij vemo, da se napake različno hitro širijo za različna merila atmosferskih pojavov: sinoptična skala (veliki cikloni, Rossbyjevi valovi): $\Delta t \approx 2\text{--}3$ dni, mezoskala (fronte, tropski cikloni): $\Delta t \approx 1$ dan in konvektivna skala (nevihte, megla): $\Delta t \approx 30$ minut. To pomeni, da so večji pojavi bolj predvidljivi (napaka narašča počasneje), medtem ko manjši, lokalni pojavi hitro izgubijo predvidljivost – zaradi močnega vpliva nelinearnosti in občutljivosti na začetne pogoje.

8.5.3 Podnebne razlike vplivajo na predvidljivost

Predvidljivost je višja poleti in nižja pozimi. Zakaj? Poleti je več anticklonov, vreme je stabilnejše → napake rastejo počasneje. Pozimi je več ciklonov in valovitosti (Rossbyjevi valovi) torej atmosferski tokovi so bolj zapleteni in kaotični, in napake rastejo hitreje.

8.5.4 Rast napake glede na prostorsko skalo



Slika 8.11: Rast napake $[E(t)/E(0)]$ za različna spektralna območja (valovna števila k) v decembru 2014 (levo) in maju 2015 (desno).

Na Sliki 8.11 je prikazan razvoj napake napovedi ($E(t)$) glede na začetno napako ($E(0)$) za različne prostorske skale atmosferskih pojavov. Valovno število k je inverzno povezano z velikostjo pojavov: nižji k označuje večje (planetarne) strukture, višji k pa manjše (mezoskalne, konvektivne).


Rožnata ($0 \leq k \leq 3$) – planetarna skala: zelo veliki pojavi (npr. stacionarni valovi, globalne tlakovne razlike). Rdeča ($4 \leq k \leq 14$) – sinoptična skala: klasični vremenski sistemi (npr. cikloni, frontni sistemi). Modra ($15 \leq k \leq 120$) – subsinoptična / mezoskala: manjši in hitro razvijajoči se pojavi (npr. nevihte, fronte, tropski cikloni).

Graf prikazuje, koliko-krat se začetna napaka poveča ($E(t)/E(0)$) glede na dolžino napovedi (na osi x). Vsaka krivulja raste in se nato nasiči – kar pomeni, da napaka ne more več dodatno naraščati, ker doseže fizikalno omejeno velikost (npr. velikost variance znotraj atraktorja).

Subsinoptična skala (modro): napaka se nasiči že po 10 dneh → to pomeni, da manjših vremenskih pojavov (npr. tropskih ciklonov) ni mogoče napovedovati več kot 10 dni vnaprej, ne glede na izboljšave modela. Sinoptična skala (rdeče): nasičenje nastopi okoli 17–20 dni kar pomeni, da za ciklone in Rossbyjeve valove obstaja nekoliko daljši uporabni napovedni obseg. Planetarna skala (rožnato): napaka raste zelo počasi in se nasiči šele po 25 dneh ali več kar pomeni, da lahko zelo velike atmosferske vzorce napovedujemo precej dlje časa.

8.5.5 Zbirke napovedi


Ker spretnost niha z režimom toka in obsegom, ponuja deterministični izhod preveč krhko sliko za uporabnike. **Ensemble prediction systems** (EPS) to odpravijo z vzorčenjem negotovosti v začetnih pogojih in fiziki modela. Slika 8.12 skicira koncept z Lorenzovim atraktorjem metulja: ena sama napoved (črna pika) lahko skrene s prave poti (modra), medtem ko *oblak* motenj integracij (siva) oklepa resnico in prinaša pomembne verjetnosti.



Slika 8.12: Slika ansambla proti deterministični trajektoriji na Lorenzovem atraktorju. Srednja vrednost ansambla (rdeče točke) ostajajo bližje resnici (modra) kot kateri koli posamezen izstop.

Vendar sama zanesljivost ansambla niha. Slika 8.13 razporedi tri posnetke istega EPS v prostoru stanja:

1. **Zelo predvidljivo** – člani ostanejo omejeni na ozko cev; pretok je dinamično stabilen več časov zganjanja.
2. **Mejno predvidljivo** – polovica članov migrira v nasprotni reženj; verjetnostno vodenje je še vedno uporabno, vendar izpolnjuje pogoje za širše intervale.
3. **Nepredvidljivo** – člani se razpršijo po celotnem atraktorju; verjetnost napovedi se sesuje proti klimatologiji.




Slika 8.13: Razvoj perturbacijske hipersfere (črni pas) pod Lorenzovim tokom: (a) omejena, (b) delno predvidljiva, (c) popolnoma razpršena.

Analog realnih podatkov je prikazan na sliki 8.14. Dve sledi EPS za temperaturo 2-m na enem mestu razkrivata, da lahko širjenje ansambla (rdeče) en teden objame opazovanje za preverjanje (modro), vendar eksplodira v 48 h med bolj nestanovitno epizodo. Deterministični nadzor (temno modra) vedno najprej izgubi zvestobo.

Zdaj na desni imamo primer nepredvidljivega režima. V začetnih pogojih imamo hipersfero, ki se hitro začne raztezati v obliko banane in hitro raste nelinearno, po določenem času pa je lahko napoved kjerkoli na atraktorju. Ansambelska napoved v tem primeru prinaša malo ali nič dodane vrednosti. Napoved ni čarobno orodje. To le malo prispeva k našemu orodju za napovedovanje.

Tako lahko vidite, da je razvoj vremena zelo dovzeten za začetne razmere. A ne le na začetne pogoje, temveč tudi na stanje toka. V nekaterih primerih je tok zelo stabilen in lahko dosežete dobro predvidljivost. Torej vse krivulje ansambla, ki so na začetku blizu druga drugi, čez nekaj



Slika 8.14: Dobra (zgornja) in slaba (spodnja) izvedba ansambla za T_{2m} . Srednja skupna vrednost ostane uporabna dlje kot posamezna najboljša (kontrolna) napoved.

časa dosežejo podobne vzorce in trajektorije. In povprečje ansambla je najboljša napoved na levi sliki. Pa tudi razpršenosti članov ansambla ni veliko. Na desni strani imate ogromno število članov ansambla in lahko vidite, da je širjenje v kratkem času ogromno. Kmalu po tem se izgubi vsa predvidljivost. Začetno stanje je vedno negotova zaradi nepopolnih in nezanesljivih meritev. Modeli napovedi vključujejo tudi napako modela.


Ansambelsko napovedovanje upošteva te negotovosti s simulacijo vzporednih podobnih modelov.

Dolgoročni trendi. Od poznih 1970-ih se je obzorje predvidljivosti – merjeno z, recimo, globalno srednjo vrednostjo ACC, ki presega 0,6 – podaljšalo približno 1day na desetletje. Satelitska sevanja zagotavljajo levji delež izboljšav, zlasti na južni polobli, ki je bila zgodovinsko redka s podatki. Kljub temu asimetrija sever-jug ostaja: današnja petdnevna spretnost NH je v SH dosegljiva šele pri treh do štirih dneh.

8.5.6 Časovni spektri atmosferske spremenljivosti

Slika 8.15 povezuje vrhove variance v časovni domeni z **rezervoarji predvidljivosti**. Delo od desne proti levi:

- **Intradiurnalni vrh (1day).** Dnevni cikel je posledica rotacije Zemlje; ker je sončni zenit popolnoma predvidljiv, je tudi astronomska faza. Oblaki in turbulenca pa povzročajo kaotično variabilnost amplitude.
- **Sinoptični vrh (3-7days).** Baroklinični valovi Rossby prevladujejo v zunajtropskem vremenu; njihov čas barotropne rasti določa mejo srednjega dosega.
- **Intrasezonski vrh (30-60days).** Ta signal vključuje Madden-Julian Oscillation (MJO) in monsunске prelome. Skupne povratne informacije med konvekcijo in kroženjem podaljšujejo spomin, ki presega čisti atmosferski kaos.



Slika 8.15: Idealiziran spekter variance sklopljenega podnebne sistema. Vrhovi ustrezajo prevladujočim načinom; sivi kontinuum predstavlja širokopasovni kaotični šum.

- **Medletni vrhovi.** ENSO (2-7yr) in kvazi-bienalna oscilacija (28mo) izhajata iz oceanskih termoklinskih načinov oziroma interakcije med stratosferskim valom in srednjim tokom.
- **Orbitalni vrhovi.** Milankovičevi cikli (20-400) modulirajo osončenost in določajo tempo za ledeniško-medglacialna podnebna nihanja – predvidljivost druge vrste na geoloških časovnih skalah.

Predvidljivost se poveča, kjer se energija združi v koherentne načine, in zmanjša v sivem kontinuumu, kjer jo turbulenca razprši.

8.5.7 Kakšne časovne lestvice napovedujemo?


- **Srednji obseg** (ure–15dn) – Odpravlja sinoptične in mezoskalne motnje. Uporabnikom so pomembne *lokalne* spremenljivke: 2-m temperatura T_{2m} , akumulirane padavine P , 10-m veter u_{10} . Spretnost anomalije propade, ko tok postane dekoriran.
- **Polsezonsko / mesečno** (tedni–2meseci) – Obresti se preusmerijo na *statistiko*: odstopanja od klimatologije (toplo/hladno, mokro/suho). Valovni vlaki in faze MJO zagotavljajo okna spretnosti.
- **Sezonsko do medletno** (3-12months) – Spretnost izhaja predvsem iz počasi razvijajočih se robnih pogojev: stanje ENSO, obseg morskega ledu, rezervoarji vlage v tleh.

8.5.8 Predvidljivost prve in druge vrste

Po Lorenzu ločimo dva mehanizma:

1. **Prva vrsta – predvidljivost začetne vrednosti.** Vremenska napoved rešuje Cauchyjev problem; spretnost je omejena z napako začetnega pogoja in pozitivnimi eksponenti Ljapunova.
2. **Druga vrsta – mejna prisilna predvidljivost.** Počasne spremembe v zunanjih ali spodnjih mejnih pogojih (gradienti SST, koncentracije toplogrednih plinov, orbitalno forsiranje) vtisnejo spomin v sistem. Sezonski obeti in stoletne podnebne projekcije izkoriščajo ta vir.

Slika 8.16 vizualizira kontinuum.



Slika 8.16: Shematska ločitev predvidljivosti prve vrste (zelena) in druge vrste (rdeča) v obdobjih napovedi.

8.5.9 Viri predvidljivosti

Madden–Julian Oscillation (MJO)

MJO je 30-60dni ekvatorialna planetarna motnja, v kateri konvektivna ovojnica, povezana z dinamiko valov Kelvin–Rossby, potuje proti vzhodu na $5\text{--}10\text{ m s}^{-1}$. Ker modulira tropsko ogrevanje, seje Rossbyjeve valove, ki vplivajo na režime srednje zemljepisne širine do dva tedna kasneje. Anomalije OLR služijo kot približek v realnem času, zaradi česar je faza MJO vrhunski napovedovalec v polsezonskih obetih.

Temperatura morske površine (SST)

Mešana plast oceana ima toplotno vztrajnost $50\text{--}100\text{ W m}^{-2}\text{ K}^{-1}$, kar zagotavlja mesece spomina. Skupne povratne informacije, kot so ENSO, dipol v Indijskem oceanu ali atlantski Niño, zato razširjajo napovedne sposobnosti.

Skupni modeli z visoko ločljivostjo prekašajo modele samo za atmosfero, zlasti za intenzivnost tropskega ciklona.

Vlažnost tal

Spomin vlažnosti tal sega od nekaj dni v vlažnih tropih do 60–90dni v polsušnih regijah (sezonski zemljevidi na desni strani slike). Natančna inicializacija zemlje izboljša napovedi vročinskih valov in spomladanske padavine.

Morski led

Debelina morskega ledu združuje toplotne tokove v mesecih; motnje se širijo v anomalije temperature površinskega zraka v naslednji sezoni. Skupna prostornina morskega ledu ohranja spomin skoraj eno leto, medtem ko hitrost ledu izgubi skladnost v nekaj dneh.

Poglavje 9

Napoved ansambla

Tik pred uporabo ansambelske napovedi si bomo ogledali, kako pravilno upoštevati napake v začetnih pogojih (initial conditions — IC). Zanima nas, kakšna bi bila meja predvidljivosti, če bi bile edine napake napake začetnih pogojev. To je bila naloga, ki jo je izvedel Lorenz leta 1982. Kasneje so jo tudi ponovno preverili. Ključno vprašanje je, kako v današnjih operativnih sistemih pravilno obravnavati negotovost začetnih pogojev?

9.1 Kako oceniti negotovost začetnih pogojev v numeričnih sistemih za napovedovanje vremena?

Eden od načinov je, da izvedemo ansambelsko napoved z neperturbiranim modelom, torej da upoštevamo zgolj napako v začetnih pogojih. Kaj pa, če ansambelska napoved ni na voljo? Obstaja tudi metoda brez uporabe ansambla — to je bila pravzaprav Lorenzova zamisel iz leta 1982.

Opredelimo dve oznaki. Napoved označimo kot $\vec{x}^f$ za časovni zamik (lead time) 24 ur, ki izhaja iz analize ob času 0:

$$\vec{x}^f(24, 0) = \mathcal{M}_{0 \rightarrow 24}(\vec{x}^a(0)) \quad (9.1)$$

Ta enačba predstavlja integracijo numeričnega modela od časa 0 do časa 24, pri čemer začnemo z analizo $\vec{x}^a(0)$, kar pomeni najboljšo oceno atmosferskega stanja ob začetnem času (0 h). Operator $\mathcal{M}_{0 \rightarrow 24}$ predstavlja napovedni model, ki izvede simulacijo atmosferskega razvoja skozi 24 ur.

Zdaj to napoved primerjamo z analizo ob času 24 ur, $\vec{x}^a(24)$. To je tako imenovana potrditvena analiza (verifying analysis) za dano napoved, saj boljše ocene dejanskega atmosferskega stanja ob tem trenutku nimamo. Gre za najboljšo možno oceno resničnega stanja ozračja 24 ur po začetnem času.


Na podlagi te primerjave uvedemo napako napovedi:

$$\delta\vec{x} = \vec{x}^f(24, 0) - \vec{x}^a(24) \quad (9.2)$$

To pomeni: vektor napake $\delta\vec{x}$ je razlika med 24-urno napovedjo in potrditveno analizo. Ta razlika predstavlja napako 24-urne napovedi.

- $\vec{x}^f(24, 0)$: napovedan atmosferski vektor (npr. temperatura, tlak, veter ...) za čas 24 h, začet iz analize ob času 0 h.
- $\vec{x}^a(24)$: analiza, torej najboljša ocena stanja ozračja ob času 24 h.
- $\delta\vec{x}$: napaka napovedi, ki nam pove, kako natančna je bila napoved glede na znano stanje ozračja po enem dnevu.

Zdaj lahko napako $\delta\vec{x}$ prikažemo kot funkcijo časa napovedi (forecast lead time). Dobimo naslednjo sliko:



Slika 9.1: Rast napake v odvisnosti od trajanja napovedi. Črna krivulja predstavlja skupno napako, vključno z napako modela. Vijolična črta predstavlja idealiziran primer popolnega modela, kjer je vir napake zgolj začetni pogoj (IC). Rdeča puščica ponazarja napako modela.

Krivulja napake, ki jo dobimo, ima značilno logistično obliko. Označimo točke, kot so $(24, 0)$, $(48, 0)$, $(72, 0)$ itd. Te točke predstavljajo napako napovedi po 24h, 48h, 72h ..., če so vse začetne napovedi začele v času 0.

Analogno definiramo napako za 48-urno napoved:

$$\delta\vec{x}(48, 0) = \vec{x}^f(48, 0) - \vec{x}^a(48)$$

To je razlika med 48-urno napovedjo, inicializirano iz analize v času 0, in analizo v času 48 ur. Enako velja za druge čase. To je napaka napovedi glede na potrditveno analizo.

Prej smo zapisali, da je ta napaka logistična funkcija: začetna rast napake je eksponentna in jo vodi vodilni Ljapunov eksponent, nato sledi eksponentna nasičenost, ki doseže velikost atraktorja.

Če se spomniš Lorenzovega modela (npr. "metulja"), vse rešitve sistema ostanejo znotraj atraktorja. Napaka ne more prerasti velikosti atraktorja – to imenujemo nasičenje napake (error saturation).

Pomembno: takšno krivuljo dobimo le kot povprečje mnogih napovedi. Zato je ključno, da napake preverjamo na velikem številu vzorcev.

Napaka je omejena z velikostjo atraktorja – to je razlog, zakaj pride do nasičenja napake. Razen če imamo nestabilen napovedni sistem, kjer napaka eksponentno naraste in "eksplodira" (kar se dogaja npr. pri nekaterih modelih strojnega učenja).

Če bi, recimo, z nevronske mreže učili Lorenzov atraktor, bi mreža znala nadaljevati simulacijo, če se začetno stanje nahaja znotraj atraktorja. Če pa začnemo zunaj atraktorja (npr. iz stanja, ki ga še ni videla), bo napaka hitro narasla, saj mreža nima špominiža to stanje. Numerični vremenski model (NWP) pa ve, kaj storiti, saj bo sistem prej ali slej znova padel v atraktor.

Poglejmo ponovno napako iz slike 9.1, torej napako 24-urne napovedi. Kaj pa če bi to primerjali z nečim drugim?

Zapišimo še enkrat enačbo za 48-urno napoved:

$$\vec{x}^f(48, 0) = \mathcal{M}_{0 \rightarrow 48}(\vec{x}^a(0))$$

Kaj pa, če bi naredili 24-urno napoved, začetkovano iz 24-urne analize?

$$\vec{x}^f(48, 24) = \mathcal{M}_{24 \rightarrow 48}(\vec{x}^a(24))$$

To je torej 24-urna napoved (od 24h do 48h), inicializirana iz analize ob 24h. Kaj pa napaka v tem primeru?

$$\delta \vec{x}^f(48, 24) = \vec{x}^f(48, 0) - \vec{x}^f(48, 24)$$

To je razlika med 48-urno napovedjo (od 0h do 48h) in 24-urno napovedjo (od 24h do 48h).

Na istem grafu bi bila krivulja te napake pod prejšnjo krivuljo, saj napaka raste počasneje. Razlika je, da v prvem primeru napako merimo glede na analizo, v drugem primeru pa napako med dvema napovedma.

Zakaj sploh izvajamo takšno vajo? Ker smo prej omenili, da rast napake v zgornjem primeru vodi napaka modela. Ostanek napake pa izhaja iz začetnega pogoja. In v meji, ko nadaljujemo takšno primerjavo, dobimo vse boljše približke, ki pa se vsi sčasoma nasičijo.

Z večkratnim ponavljanjem takšnih primerjav dobimo nekaj zelo pomembnega: mejo predvidljivosti dinamičnega sistema, ki ni pogojena z napako modela. Če torej nadaljujemo postopek, pridemo do meje predvidljivosti popolnega modela — kar pomeni, da vsa rast napake izhaja iz napak v začetnih pogojih.

Ključna ideja je, da napovedi ne primerjamo več s "resničnim stanjem" (analizo), ampak med seboj — dve napovedi, ki napovedujeta za isti čas, vendar z različno dolgo potjo. In s tem, ko takšne primere ponavljamo, določimo mejo predvidljivosti.

9.2 Ansambelsko napovedovanje (Ensemble forecasting)

Zakaj sploh potrebujemo ansambelsko napovedovanje? Matematično gledano, ansambelsko napovedovanje ustvarja vzorec možnih evolucij dinamičnega sistema. Na tej osnovi lahko izračunamo verjetnostno gostoto (PDF), ki nam omogoča vzorčenje negotovosti.

Kje se pojavijo napake v začetnih pogojih (IC)? Če pomisliš, kako IC nastanejo — izhajajo iz postopka združevanja preteklih kratkoročnih napovedi z opazovanji, kar imenujemo **združevanje podatkov (data assimilation)**. Ta postopek ni popoln, saj vključuje negotovost opazovanj, ki so sama po sebi podvržena napakam in vplivu modela.

Glavni viri negotovosti:

- napake v opazovanjih in napake v postopku združevanja podatkov $\Rightarrow$ povzročijo napake v IC,
- napake modela (numerične napake, napake parametrizacij),
- napake spodnjih robnih pogojev (npr. vpliv oceana, gozda ...),
- napake na stranskih robovih (če model gnezdiš iz globalnega v omejeno področje).

Odgovor na vse te negotovosti je prav **ansambelska napoved**. Gre za izvajanje več vzporednih, rahlo spremenjenih (nepopolnih) napovedi, ki skupaj upoštevajo te negotovosti.

9.2.1 Zakaj je ansambelsko napovedovanje boljše?

Kaj se zgodi s povprečjem ansambla? Vrnimo se k primeru Lorenzovega modela (metulj 8.12). Predstavljaj si, da začnemo z več različnimi začetnimi pogoji (člani ansambla). Modra pika predstavlja "resnično" evolucijo, rdeče pike pa posamezne ansambelske napovedi.


V tem primeru napak modela ni bilo — le napake v IC. Napake začnejo rasti skozi čas. Vsak član ansambla se lahko razvije po svoji poti in se precej oddalji od "resnice", toda ****srednja vrednost ansambla**** ostaja precej blizu resničnemu stanju. Z drugimi besedami: posamezni člani se lahko žmotijo", toda skupaj kot povprečje dajejo bolj zanesljivo oceno.

Kasneje v času, ko se posamezne trajektorije porazdelijo npr. proti različnim fiksnim točkam sistema, srednja vrednost ansambla ni več uporabna — a do tega pride šele po določenem času.

Zakaj je torej ansambelska napoved boljša od deterministične?

- Srednja vrednost ansambla je pogosto natančnejša od posamezne deterministične napovedi.
- Dobimo **verjetnostno gostoto (PDF)** možnih scenarijev — to vključuje tudi izredne dogodke (ekstreme) in njihove verjetnosti.


Oglejmo si primer: recimo, da nas zanima verjetnost celotnih padavin večjih od 100 mm.



Slika 9.2: Gostota verjetnosti skupne količine padavin (PDF). Zasenčen predel desno od 100 mm predstavlja verjetnost, da bodo padavine presegle 100 mm.

Na sliki 9.2 vidimo PDF celotne količine padavin. Če želimo oceniti verjetnost, da bo padlo več kot 100 mm padavin, torej integriramo površino pod krivuljo desno od te vrednosti.

Zdaj PDF pretvorimo v kumulativno porazdelitveno funkcijo (CDF):



Slika 9.3: Kumulativna porazdelitvena funkcija (CDF) za količino padavin. Vodoravna črta predstavlja verjetnostni prag.

Na sliki 9.3 lahko torej odčitamo verjetnost za vrednosti nad 100 mm kot:

$$P(RR > 100 \text{ mm}) = 1 - P(100 \text{ mm})$$

in ta vrednost je — v tem primeru — zelo majhna.

Drugi pomemben razlog, zakaj je ansambelska napoved uporabna: omogoča **odločanje**. Če ima kmet podatek, da obstaja 50 % verjetnost za dež, lahko veliko bolje presodi, kot če bi imel le eno deterministično možnost. Seveda pa je pogoj za to zanesljiv ansambel.

9.2.2 ECMWF — primer operativnega ansambla

Evropski center za srednjeročne napovedi vremena (ECMWF) uporablja ansambel z 50 člani. Vsak član se pridobi z ločeno združitvijo podatkov, kjer se opazovanja različno perturbirajo. Na ta način upoštevajo negotovost v postopku združevanja podatkov in samih opazovanj.

Poleg tega uporabljajo 50 različnih **singularnih vektorjev**, ki so posebej izračunani za severno poloblo, južno poloblo in tropske predele.

Kako je izračunan prvi član ansambla?

$$\vec{x}^{f1}(t) = \mathcal{M}_{0 \rightarrow t}^1 \left(\vec{x}^{aC} + S_{1279 \rightarrow 159} \left(\vec{x}^{EDA1} - \overline{\vec{x}^{EDA}} \right) + \delta_{\vec{x}_1}^{SV1} \right) \quad (9.3)$$

Pojasnimo posamezne člene:

- $\vec{x}^{f1}(t)$ — napoved (trajektorija) prvega člana ansambla ob času t ,
- $\mathcal{M}_{0 \rightarrow t}^1$ — numerični model, ki integrira stanje od časa 0 do časa t ,
- $\vec{x}^{aC}$ — kontrolna analiza (HRES), torej brez perturbacij,
- $S_{1279 \rightarrow 159}$ — operator poenostavitve oz. glajenja (iz višje prostorske ločljivosti $T1279$ v nižjo $T159$),
- $\vec{x}^{EDA1}$ — analiza iz prvega člana EDA (ensemble data assimilation),
- $\overline{\vec{x}^{EDA}}$ — povprečna analiza ansambla EDA,
- $\delta_{\vec{x}_1}^{SV1}$ — perturbacija v smeri prvega singularnega vektorja, ki predstavlja najbolj občutljive smeri rasti napake.

Sklep: perturbacije v začetnih pogojih v ECMWF ansamblu dodamo na tri načine:

1. z uporabo singularnih vektorjev,
2. z odstopanjem EDA od povprečja (v prostoru zglajenih polj),
3. z različnimi verzijami modela (različne konfiguracije fizikalnih parametrov).


In ta postopek se ponovi za vseh 50 članov ansambla ($i = 1$ do 50). V teh simulacijah želimo zajeti tudi najbolj ekstremne, vendar še vedno možne rešitve.

9.3 Kakšna je kakovost perturbirane analize?

Perturbirano analizo lahko zapišemo kot:

$$\vec{x}^{aP} = \vec{x}^{aC} + S_{1279 \rightarrow 159} (\vec{x}^{EDA1} - \overline{\vec{x}^{EDA}}) + \delta_{\vec{x}_1}^{SV1}$$

kjer $\vec{x}^{aC}$ predstavlja kontrolno (neperturbirano) analizo, $S_{1279 \rightarrow 159}$ je operator glajenja (trunkacija valovnih števil), $(\vec{x}^{EDA1} - \overline{\vec{x}^{EDA}})$ je odstopanje posameznega člana ansambla združevanja podatkov, $\delta_{\vec{x}_1}^{SV1}$ pa je prispevek singularnega vektorja.



Slika 9.4: Geometrijska interpretacija razmerja med analizo A , perturbirano analizo P in resničnim stanjem T . Razdalje $|A - T|$ in $|P - A|$ sta enaki, zato leži P na krožnici z radijem enakim napaki analize.

Da bolje razumemo kvaliteto take perturbirane analize, si oglejmo naslednjo shemo:

Predpostavimo, da točka A predstavlja analizo, T pa resnico, ki je nepoznana, vendar vemo, da je povprečna razdalja $|A - T|$ znana iz statistike preteklih napovedi. To torej določa črni krog — resnica je nekje na tem krogu.


Zdaj vpeljemo perturbirano analizo P , za katero velja, da naj bo oddaljena od A za isto razdaljo $|P - A| = |A - T|$. Perturbacija naj torej upošteva napako analize. Narišemo nov krog okoli točke P , modri krog.

Zdaj se vprašamo: kakšna je povprečna razdalja $|P - T|$ od perturbirane analize do resnice? Če narišemo pravokotnico na $P - A$, ki gre skozi A in prečka črni krog, dobimo točko, ki predstavlja povprečno oddaljenost P od resnice. Ugotovimo, da velja:

$$|P - T| = |A - T| \cdot \sqrt{2}$$

torej je povprečna napaka perturbirane analize **večja** od napake kontrolne analize za faktor $\sqrt{2}$.

Ključni rezultat: Le približno 35 % perturbiranih analiz je v povprečju **bližje resnici kot kontrolna analiza**. To je razvidno iz zasenčenega vijoličnega območja v naslednji shemi:



Slika 9.5: Zelena krožnica predstavlja lokacije vseh možnih perturbiranih analiz P , ki so v razdalji $|P - A|$. Samo 35% perturbiranih analiz leži v vijoličnem območju — torej so bližje resnici kot A .

Kako je potem ansambelsko povprečje še vedno boljše?

Čeprav so začetni pogoji perturbiranih analiz v povprečju slabši kot pri kontrolni analizi, je ansambelsko povprečje (ensemble mean) napovedi še vedno boljše. Zakaj?

Glavni razlog je v tem, da se napake na majhnih prostorskih skalah izničujejo. Napake na velikih skalah rastejo počasneje in bolj usklajeno. Ko vzamemo povprečje več napovedi, torej:

$$\overline{\vec{x}^f(t)} = \frac{1}{N} \sum_{i=1}^N \vec{x}^{f_i}(t)$$

dobimo gladko napoved. Ta povprečena napoved filtrira naključni šum majhnih skal.

Torej, če imamo ansambel npr. 100 napovedi, je povprečna (srednja) napoved zelo gladka — izgubi določeno informacijo o ekstremih, vendar je **v smislu srednje kvadratne napake (RMSE)** boljša. Ne bomo videli natančne lokacije tropskega ciklona po 24 urah, ampak bomo videli **velike strukturne značilnosti** atmosfere.

9.4 Povprečna kakovost perturbirane analize

Na prejšnji shemi smo predpostavili, da poznamo resnico T . Toda v praksi poznamo samo analizo A , resnice pa ne. Torej definiramo povprečno napako perturbirane analize glede na znano analizo A — torej krog okoli A z radijem $|P - A|$.

Znova ugotovimo, da bo le 35 % perturbiranih analiz bližje resnici kot A . Če zdaj to posplošimo:

- Če vzamemo le eno točko (en grid point), bo 35
- Če pa povprečimo čez celotno področje (recimo površje Zemlje S_E), bo ta verjetnost **padla**.

Torej: **večja kot je površina**, manjša je verjetnost, da bo celotna perturbirana napoved boljša od kontrolne.

V operativnih pogojih: napovedi ECMWF imajo približno 10^9 točk pri 9 km ločljivosti. Celo če je napoved na nekem mestu boljša, to še ne pomeni, da je globalno boljša.

Primerjava napovedne sposobnosti

- Napoved, osnovana na **kontrolni analizi**, ima v povprečju napovedno sposobnost, ki je **za 1 dan boljša** kot pri perturbirani analizi.
- **Ansambelsko povprečje** pa ima **boljšo napovedno sposobnost kot kontrolna analiza**.

Razlog za to je, kot že omenjeno, v tem da ansambelsko povprečje filtrira nepredvidljive majhne skale in tako poudari velike, pomembne atmosferske strukture.

Sklep: čeprav perturbirane analize niso boljše od kontrolne posamezno, pa ansambelsko povprečje predstavlja robustnejšo oceno, ki je v praksi bolj uporabna za srednjeročno napovedovanje.

9.5 Metode preverjanja (Verification metrics) pri ansambelskem napovedovanju

Vsak napovedni sistem mora biti preverjen. Zakaj? Obstaja več razlogov:

- da prepoznamo prednosti in slabosti napovednega sistema,

- da diagnostika napak usmerja nadaljnje raziskave in izboljšave modela,
- da ocenimo ekonomsko vrednost napovedi – še posebej v primeru ansambelskih napovedi, ki omogočajo oceno verjetnosti dogodkov.

Ansambel namreč omogoča izračun verjetnostne gostote (PDF), kar pomeni, da lahko kvantitativno ocenimo verjetnost določenega dogodka. Vsak tak dogodek pa ima svojo ceno (npr. strošek preventivnega ukrepa). Ansambelska napoved nam tako omogoča optimalno odločanje in vključitev napovedi v t. i. modele tveganj, če je napoved zanesljiva.

Deterministični metrični kazalniki (uporabni tudi za ansambelsko sredino)

- **RMSE – Root Mean Square Error:**

$$\text{RMSE} = \sqrt{\frac{1}{M} \sum_{k=1}^M (x_k - y_k)^2}$$

kjer x_k predstavlja napovedano vrednost, y_k pa opazovanje (ali analiza). RMSE kaže povprečno kvadratno napako – manjša kot je, boljša je napoved.

- **MAE – Mean Absolute Error:**

$$\text{MAE} = \frac{1}{M} \sum_{k=1}^M |x_k - y_k|$$

ki prav tako meri povprečno napako, vendar brez kvadriranja – manj občutljiv na velike izjemne napake.

- **ME – Mean Error:**

$$\text{ME} = \frac{1}{M} \sum_{k=1}^M (x_k - y_k)$$

če ta ni nič, to pomeni, da sistem ni pristranski. V nasprotnem primeru sistem napoveduje prevelike ali premajhne vrednosti.

- **ACC – Anomaly Correlation Coefficient** je tudi pogosto uporabljen, a ga bomo tukaj izpustili.

Te meritve lahko uporabimo tudi za:


- ocenjevanje ansambelske sredine (ensemble mean),
- kontrolne napovedi iz kontrolne analize,
- posamezne perturbirane napovedi iz perturbiranih analiz.

Zakaj je ansambelska sredina tako pomembna? Kot smo že povedali: ker je gladka (filtrira majhne skale) in ima v splošnem nižji RMSE od posamezne deterministične napovedi. Z daljšanjem napovednega časa se ansambelska sredina približuje klimatološki sredini, saj člani ansambla sčasoma zapolnijo celoten atraktor – torej vse možne atmosferske rešitve.

Potrebujemo še dodatne meritve – verjetnostni vidik

Preverjanje samo ansambelske sredine je premalo. Ansambelska napoved je verjetnostna napoved, zato moramo oceniti tudi kakovost verjetnostne informacije. Za to potrebujemo **dodatne metrike**. Obstajata dve ključni lastnosti kakovostne verjetnostne napovedi:

- **Zanesljivost (Reliability)** – statistična skladnost napovedanih verjetnosti in dejanskega pojava. Npr., če napovemo 1% verjetnost za nek dogodek (npr. nevihta), potem mora dolgoročna statistika pokazati, da se ta dogodek res zgodi v 1% takšnih primerov.
- **Ločljivost (Resolution)** – meri širino porazdelitve napovedi. Bolj ozka (koncentrirana) kot je porazdelitev, bolj "odločna" je napoved. Če je porazdelitev preširoka, napoved nima uporabne vrednosti – vse je možno.



Slika 9.6: Primerjava ločljivosti: črna porazdelitev je široka (slaba ločljivost), modra porazdelitev je ozka (visoka ločljivost). Obe lahko imata enako zanesljivost, a le modra ima visoko napovedno vrednost.

Matematična definicija zanesljivosti:

Verjetnostna napoved je **zanesljiva**, če relativna frekvenca dogodka konvergira proti napovedani verjetnosti p , za veliko število napovedi s to verjetnostjo. To mora veljati za vsak $p \in [0, 1]$.

Toda – v praksi imamo le končen ansambel!

Npr. ECMWF uporablja 50 članov. Čeprav teorija velja v limitnem primeru $N \rightarrow \infty$, v praksi to ni tako. Zato obstaja:

- **vzročna negotovost vzorčenja (sampling uncertainty)**, še posebej za ekstremne vrednosti ($p \approx 0$ ali $p \approx 1$),
- zanesljivost za te dogodke je nižja, saj jih premalo vzorcev zajame.

Zaključek: Zanesljiva in ozka (visoko ločena) verjetnostna napoved ima **visoko uporabno vrednost**. Sistem, ki daje zanesljive, a zelo razpršene (široke) napovedi, ima bistveno manjšo vrednost za odločanje.

9.5.1 Razmerje med razpršenostjo in napovedno sposobnostjo (Spread–skill relationship)

Ko govorimo o meritvah kakovosti napovedi, moramo nasloviti tudi tako imenovano razmerje med razpršenostjo (spread) in napovedno sposobnostjo (skill).

Prej smo rekli, da mora biti RMSE ansambelske sredine (ensemble mean) skladen z negotovostjo, ki jo izraža sam ansambel. Z drugimi besedami: **tipična napaka ansambelske sredine**

(RMSE) naj bi ustrezala razpršenosti ansambla. Če to drži, je ansambel **statistično skladen in zanesljiv**.

Za ponazoritev tega vzemimo idealen ansambel z N člani in vzorec M neodvisnih primerov (npr. različni datumi, za katere izvajamo ansambelsko napoved). Označimo:

- $k = 1, 2, \dots, M$ — indeks primerov,
- $x_{T,k}$ — resnično (ali referenčno) stanje za primer k ,
- $x_{1,k}, x_{2,k}, \dots, x_{N,k}$ — posamezni člani ansambla za ta primer.

Lahko si predstavljamo, da so ti člani vzorci iz porazdelitve $p_k = \mathcal{N}(u_k, \sigma_k)$, torej Gaussove funkcije z sredino u_k in standardnim odklonom σ_k .

Povprečje ansambla označimo z operatorjem:

$$\langle \cdot \rangle_N = \frac{1}{N} \sum_{j=1}^N (\cdot)$$

Tako je ansambelska sredina za primer k :

$$\langle x_k \rangle_N = \frac{1}{N} \sum_{j=1}^N x_{j,k}$$

Razpršenost (spread) ansambla meri, kako razpršeni so posamezni člani okoli srednje vrednosti:

$$s_k^2 = \frac{1}{N} \sum_{j=1}^N (x_{j,k} - \langle x_k \rangle_N)^2 = \langle (x_k - \langle x_k \rangle_N)^2 \rangle_N$$

To imenujemo tudi **RMS razpršenost** — večja kot je, večja je negotovost napovedi in manjša je "ostrost" (sharpness) ansambla.

Napovedna sposobnost (skill) pa pride v obliki napake ansambelske sredine (ensemble mean error), kar izraža dejansko natančnost napovedi:

$$\epsilon_k^2 = (x_{T,k} - \langle x_k \rangle_N)^2$$

To je kvadratna napaka srednje napovedi v primeru k — torej RMSE.

Statistična skladnost: za zanesljiv ansambel naj bi v povprečju veljalo:

$$\frac{1}{M} \sum_{k=1}^M (\epsilon_k^2 - s_k^2) \rightarrow 0 \quad \text{za } M \rightarrow \infty$$

To pomeni, da se povprečna kvadratna napaka ansambelske sredine (skill) ujema z razpršenostjo ansambla (spread).

Intuitivno: če povprečimo napovedi in resnice čez veliko število primerov, se ansambelska sredina in resnica približata klimatološkemu povprečju. Člani ansambla bodo zapolnili celoten atraktor in ansambel bo v povprečju zanesljivo opisal svojo negotovost.

Ključni zaključek:


Za zanesljiv ansambel mora veljati: **razpršenost ansambla naj ustreza RMSE ansambelske sredine.**

9.5.2 Primeri verifikacijskih metrik

V tem poglavju predstavimo primere metrik za verifikacijo, ki ocenjujejo verjetnostne informacije ansambla. Razpršenost (spread) je koristna metrika, ki nam pove, ali je dogodek zelo gotov ali zelo negotov, vendar nam sama po sebi ne pove ničesar o verjetnosti dogodka.

Histogram rangov (Rank histogram)


Histogram rangov ocenjuje položaj meritve znotraj porazdelitve ansambla. Predstavljajmo si, da imamo napoved temperature in meritev temperature.



Slika 9.7: Primer rangiranja meritve znotraj ansambla

Na zgornji sliki rdeča črta predstavlja meritev, črne pa člane ansambla (napovedi temperature). Če je meritev pod vsemi člani ansambla, govorimo o rangju 1. Če je meritev nekje v sredini ansambla, recimo na petem mestu (od $N+1$ možnih položajev), govorimo o rangju 5.

S tem, ko analiziramo histograme teh rangov skozi čas (npr. čez eno leto), lahko ocenimo značilnosti ansambla. Histogram, kjer je verjetnost enakomerno porazdeljena med vse rangi, pomeni, da so meritve statistično neodvisne od članov ansambla — tak ansambel je skladen oziroma zanesljiv.



Slika 9.8: Različne oblike histogramov rangov

Če histogram upada eksponentno, je ansambel pristranski — meritve so pogosto nižje od povprečja ansambla, kar pomeni, da ansambel precenjuje vrednosti.

Če ima histogram obliko kosinusoide, je razpršenost prenizka — ansambel ne pokriva celotne negotovosti, zato govorimo o "underspread" ansamblu.

Če ima histogram obliko zvonca (Gaussova oblika), je razpršenost previsoka — ansambel je "overspread", kar pomeni, da meritve prepogosto padajo v sredino ansambla.

Plosk histogram je potreben, vendar ne zadosten pogoj za oceno zanesljivosti ansambla.

Brierjeva ocena (Brier Score)

Brierjeva ocena (BS) se uporablja za oceno binarnih dogodkov (ali se je dogodek zgodil ali ne). Definirana je kot:

$$BS = \frac{1}{M} \sum_{k=1}^M (p_k - o_k)^2$$

kjer je:

- p_k napovedana verjetnost za k -ti primer,
- o_k dejanski izid dogodka (1, če se je zgodil; 0, če se ni).

Gre za povprečno kvadratno napako napovedi verjetnosti. Vrednosti BS so v intervalu $[0, 1]$, kjer 0 pomeni popolno ujemanje med napovedjo in izidom, 1 pa popolno zgrešeno napoved.

Primeri:

- $p_k = 1, o_k = 1 \Rightarrow BS = 0$ (popolna napoved),
- $p_k = 1, o_k = 0 \Rightarrow BS = 1$ (popolna napaka),
- $p_k = 0.7, o_k = 1 \Rightarrow BS = (0.7 - 1)^2 = 0.09$,
- $p_k = 0.7, o_k = 0 \Rightarrow BS = (0.7 - 0)^2 = 0.49$.

BS je torej zelo nelinearna metrika.

Kontinuirana ocena rangirane verjetnosti (Continuous Ranked Probability Score, CRPS)


CRPS je metrika, ki zajema tako zanesljivost kot tudi točnost ansambelskih napovedi. Definirana je kot kvadratna razlika med napovedano kumulativno porazdelitveno funkcijo (CDF) in CDF meritve:

$$CRPS = \int_{-\infty}^{\infty} (P_{fc}(x) - P_y(x))^2 dx$$

kjer:

- $P_{fc}(x)$ je kumulativna porazdelitvena funkcija ansambelske napovedi,
- $P_y(x) = \Theta(x - y)$ je Heavisidova funkcija, ki predstavlja meritev y (0, če $x < y$, in 1, če $x \geq y$).


Za deterministično napoved (en sam izračun, ne ansambel) je CRPS enak klasični srednji kvadratni napaki (MSE).



Slika 9.9: Primer CDF meritve (Heavisidova funkcija)

CDF ansambelske napovedi ($P_{fc}(x)$) je običajno "žglajena" funkcija, podobna normalni porazdelitvi.

CRPS meri kvadratno razliko med obema funkcijama po celotni realni osi. Manjša kot je razlika, boljši je ansambel.



Slika 9.10: Primer CDF in PDF ansambelske napovedi


Pri več napovedih se CRPS računa kot povprečje:

$$CRPS = \frac{1}{M} \sum_{k=1}^M \int_{-\infty}^{\infty} (P_{fc,k}(x) - \Theta(x - y_k))^2 dx$$

Gre za eno najbolj uporabljenih metrik za oceno verjetnostnih napovedi.

Na spodnjih dveh skicah je ponazorjen pomen in interpretacija metrike CRPS (Continuous Ranked Probability Score). CRPS meri kvadratno razliko med kumulativno porazdelitveno funkcijo ansambelske napovedi $P_{fc}(x)$ in CDF meritve $P_y(x)$, ki je Heavisidova funkcija. Matematika za en primer je:

$$CRPS = \int_{-\infty}^{\infty} (P_{fc}(x) - P_y(x))^2 dx$$




Slika 9.11: Primer dobre napovedi — meritev se nahaja blizu središča napovedane porazdelitve.

Na sliki 9.11:

- Rdeča krivulja $P_y(x)$ je Heavisidova funkcija meritve.
- Črna krivulja $P_{fc}(x)$ je kumulativna porazdelitvena funkcija ansambla.
- Modro osenčeno območje predstavlja kvadratno razliko, ki se integrira v CRPS.
- Ker se napoved dobro ujema z meritvijo, je CRPS majhen.

Na sliki 9.12:



Slika 9.12: Primer slabe napovedi — napovedana porazdelitev ne pokriva dejanske meritve.

- Meritev je daleč od območja, ki ga zajema napoved.
- Modra površina (razlika med funkcijama) je velika, kar pomeni velik CRPS.
- Takšna napoved je nekonsistentna in neuporabna — ne pokriva dejanske vrednosti.

Sklep: Manjši kot je CRPS, bolj se napoved ujema z opazovanjem. Dobro umerjeni ansambli imajo nizke vrednosti CRPS, slabo umerjeni pa visoke.

9.6 Vrednost ansambelske napovedi

Kot smo že povedali, so ansambelske napovedi odlično orodje za odločanje. Omogočajo nam odgovoriti na ključna vprašanja o tem, kaj moramo sprejeti, da se pripravimo na določeno vremensko situacijo. Pomembno vprašanje je, ali ima sistem ansambelske napovedi večjo praktično vrednost kot ena sama deterministična napoved po "najboljši ugibanju". Številne študije – ki zajemajo številne primere in leta – kažejo, da je odgovor *da*.

9.6.1 Preprost primer stroškov in izgub

Predstavljajte si uporabnika, ki je občutljiv na določen vremenski dogodek E (na primer dnevna količina padavin, ki presega 30mm). Uporabnik bo utrpel izgubo L , če se dogodek zgodi in ni bil sprejet noben zaščitni ukrep. Cena zaščitnega ukrepa je C , pri čemer predpostavimo, da je $C < L$ (sicer bi človek vedno ščitil).

$$P(E) \times L > C \iff P(E) > \frac{C}{L}. \quad (9.4)$$

- $P(E)$ – verjetnost dogodka, ocenjena neposredno iz ansambla (npr. 15 članov od 50 preseže prag padavin daje $P(E) = 0,30$).
- $\frac{C}{L}$ – razmerje med stroški in izgubami. Če je $C/L = 0,25$, je ukrep ekonomsko upravičen, ko je $P(E) > 0,25$.

Skupina torej zagotavlja **kritično verjetnost**, potrebno za optimalno odločitev. Nasprotno pa ena sama deterministična napoved ponuja le izjavo da/ne: dogodek se bo zgodil ali pa ne. Ne daje nobene kvantitativne ocene negotovosti, zato odločevalec ne more uporabiti pravila stroškov in izgub.

9.7 Ravnotežje zahtev in omejitev

Zahteve za naše napovedi so *ločljivost*—veliko podrobnosti želimo razrešiti z večjo natančnostjo; moramo *zaužiti* čim večje število meritev; in želimo imeti čim več članov ansambla, da bi raziskali široko paleto možnih scenarijev.


Nato imamo *komponente modela*. Te komponente bi morale idealno zajemati vse napovedovalce, ki urejajo atmosfersko dinamiko. Na primer, izbira komponent modela je zelo pomembna: ali naj vključimo atmosferski ozon v naš model NWP? Odgovor je *da*. Ali naj v naše modele NWP vključimo aerosole? Odgovor je *morda*, če nameravamo izdelati razširjene napovedi in ne le srednjeročne (≈ 10 -dnevne) napovedi. Aerosoli so zelo pomembni v sezonskih ali polsezonskih časovnih lestvicah, ker vplivajo na količino sevanja, ki vstopa v zemeljski sistem s Sonca.

Dolžina napovedi se nanaša na to, kako daleč v prihodnost želimo izdati napoved: ali je 10 dni, 14 dni ali celo več? To močno vpliva na stroške napovedi.

Pogostost posodabljanja: kako pogosto izdajamo napoved? Ali izdamo napoved vsakih 3 h, 6 h ali manj pogosto?

Omejitve so predvsem *računalniški viri*—količina superračunalniške moči, ki je na voljo v obliki časa CPE ali GPE—ter *prenos in izmenjava podatkov*. Satelitski podatki so na primer običajno prejeti šele pol ure po meritvi. Ta zamuda je posledica velike količine podatkov in omejenega števila sprejemnih postaj; večina teh postaj se nahaja blizu severnega tečaja ali vsaj znotraj arktičnega kroga, kjer imajo sateliti v polarni orbiti visoko pogostost ponovnih obiskov. Prenos podatkov je velik problem, saj moramo najprej prenesti vse vhodne podatke (prejšnjo napoved in opazovanja), da lahko izdelamo novo analizo; potem moramo učinkovito izračunati napoved; in nazadnje moramo razširjati napoved vsem meteorološkim uradom, ki jih to zanima (ECMWF, na primer), ker lokalni meteorološki uradi uporabljajo globalno napoved kot robne pogoje v svojih lokalnih modelih.

9.8 Ponovni ogled modela metulja Lorenz-63



Slika 9.13: Primer Lorenz-63 modela.

Ponovno si oglejmo zaplet na sliki 9.13, da ga umestimo v pripoved ansambla. Na levi vidite metulja Lorenza in lahko si omislite hipersfero začetnih pogojev. Ker je tukaj režim linearen, se ta hipersfera deformira v hiperelipsoid. Ker pa je režim zelo predvidljiv, se bo ta hiperelipsoid skrčil nazaj v hipersfero - ali vsaj zaenkrat je režim popolnoma linearen. V tem primeru zadostuje ena sama deterministična napoved.

Na srednji sliki imate še en primer s hipersfero, ki je spet zelo podobna. Najprej sledi linearni dinamiki, nato pa se začne zlagati; dinamika je tukaj zelo nelinearna in lahko vidite, da se ta hiperelipsoid začne zlagati. Postopoma dobi obliko banane. To se zgodi zaradi nelinearnega učinka. Naprej se zloži in počasi postane velikost atraktorja; to je največja razdalja med točkami

v faznem prostoru. Ta primer je *napol predvidljiv* režim. V takšnih dogodkih je potrebna ansambelska napoved za določitev verjetnosti dogodkov in razširitev obsega napovedi dlje v prihodnost. V tem trenutku deterministična napoved ne bi pomagala, saj bi lahko ležala bodisi na skrajni levi bodisi na skrajni desni strani banane. Če pa pogledate povprečje ansambla, lahko vidite, da se začne premikati v levo. Tako gostota verjetnosti in povprečje ansambla dosežeta nekoliko daljšo predvidljivost kot ena deterministična napoved. V takih primerih je za razširitev meje predvidljivosti potrebna ansambelska napoved.

9.9 Kako ustvarimo ansambel


Narediti moramo *vzorčiti negotovost* v izvorih napak. Razlikujemo dva glavna vira:

- **Negotovost začetnega stanja** — vsak član skupine začne iz nekoliko drugačnega začetnega stanja;
- **Negotovost modela** — vsak član uporablja vznemirjeno fiziko modela.

Negotovost začetnega stanja izhaja iz napak v opazovanjih, ki jih asimiliramo, zato uporabljamo *zbirke asimilacije podatkov* (EDA). Čeprav tukaj jasno razlikujemo, ne pozabite, da na negotovost začetnega stanja *vpliva* negotovost modela. Pri štiridimenzionalni variacijski asimilaciji (4D-VAR) model zagotavlja omejitev trajektorije, tako da se vsaka napaka modela dovaja neposredno v začetne pogoje.

Negotovost modela je uvedena s *stohastično motenimi tendencami parametrizacije* (SPPT) in drugimi stohastičnimi shemami. Negotovost začetnega stanja obravnava sama EDA *in singularni vektorji*, ki ciljajo na najhitreje rastoče dinamične režime. Singularni vektorji raziskujejo smeri v faznem prostoru, vzdolž katerih napaka napovedi raste najhitreje; seveda želimo vzorčiti te smeri.

9.10 Verjetnostna napoved ekstremnih hitrosti vetra okoli tropskega ciklona



Slika 9.14: Primer ensambelske napovedi ekstremnih hitrosti vetra okoli tropskega ciklona.


Ta primer kaže, da ansambel ni čarobna palica. Na levi plošči vidimo verjetnostno napoved ekstremnih hitrosti vetra okoli tropskega ciklona, izdelano z modelom 28km; desna plošča uporablja model 9km. Črta zelena označuje najboljšo oceno resnice (analiza). Črta črna je napoved determinističnega nadzora, debela črta rdeča pa je sredina ansambla.

Na levi nihče od članov ansambla niti približno ne sledi analizi; na desni je prileganje le malo boljše. Ključna točka je, da preprosto povečanje števila članov (na primer na 1000) ne zagotavlja, da bo vzorčen tropski ciklon, ki se hitro krepi. Najprej potrebujete model z zadostno ločljivostjo in fizičnimi podrobnostmi, da *omogočite* razvoj takšnega dogodka. Brez te resolucije so vsi ti člani ansambla za ta konkretni primer neuporabni.

Tudi pri skupini 9 km je razpon premajhen: interval negotovosti bi moral zajeti zeleno krivuljo analize, vendar vsak član podcenjuje razvoj hitrosti vetra. Načeloma bi potrebovali model še višje ločljivosti.

Tako mora biti ansambelska napoved *zanesljiva* (statistično skladna z opazovanji) in *ostra* (sposobna predstaviti dogodek z ustrezno ločljivostjo). Dober ansambel poveča vsebino informacij glede na klimatologijo.

9.10.1 Veščina ansambelskih napovedi



Kot smo rekli, **nadzorna napoved** uporablja najbolj znan model in najboljše začetne pogoje ter tako ustvari najboljšo deterministično posamezno napoved. Na spremljajoči sliki črta **rdeča** označuje kontrolno analizo, medtem ko črte **črna** prikazujejo motene člene.

Vidite lahko, da je **povprečje ansambla** *boljše* od kontrolne napovedi, ker so bile nepredvidljive lestvice gibanja izfiltrirane, tako da je ostal samo signal predvidljivih lestvic. Filtrirajo se tudi nekateri eksplozivni dinamični dogodki, kar pomeni, da ima povprečje ansambla razmeroma malo vrednosti za napovedovanje *ekstremnih* vremenskih dogodkov, vendar precejšnjo vrednost za napovedovanje *anomalij*. Ko se razpon napovedi poveča, povprečje ansambla (modra črta) konvergira proti klimatološkemu povprečnemu stanju.

Zanesljivost. Napoved je *zanesljiva*, ko

$$\text{ensembleRMSE} \approx \text{razširitev ansambla} = \sigma_{\text{ens}},$$

t.j. povprečna kvadratna napaka povprečja ansambla (preverjena z lastno analizo) se ujema s širjenjem standardne deviacije ansambla. Na sliki je krivulja rdeča RMSE povprečja ansambla; modra krivulja je širjenje ansambla. Njihov dogovor kaže na zanesljivo skupino, katere dolgoročna statistika odraža dejanske napake napovedi.

Razširjena občutljivost spretnosti. Kaj se zgodi, če izločimo določene komponente?

- **Brez motenj začetnega stanja (brez singularnih vektorjev).** Brez teh motenj ostane širjenje ansambla prenizko—*premajhno razpršeno*. Krivulja širjenja leži precej pod krivuljo RMSE.

- **Brez predstavitve napak modela.** Če napaka stohastičnega modela ni vključena, je skupek spet premalo razpršen, zlasti v tropih, kjer je začetna rast napake znatna (zaradi konvektivnih gibanj majhnega obsega). V tem primeru je razpon veliko nižji, kot bi moral biti glede na RMSE, in skupina ni zanesljiva.

Končno želimo skupino, v kateri so *vse* negotovosti vzorčene skupaj. V idealnem svetu bi samo **skupina asimilacije podatkov** (EDA) zadostovala, da bi motila začetne pogoje in model napovedi. V praksi še vedno dopolnjujemo EDA z motnjami singularnega vektorja.

Če petdesetkrat zaženete 4D-VAR z *motenimi opazovanji* in *motenimi modeli*, dobite nabor motenj analiz, ki sestavijo kasnejšo ansambelsko napoved.

9.11 Kako predstaviti začetno negotovost v ansambelskih vremenskih napovedih?

Ker je naše znanje o negotovosti omejeno, se uporabljajo različne tehnike, ki pa so same po sebi povezane prek 4D-VAR, kjer se negotovost modela vrača v negotovost začetnega stanja.

Skupina I: Skupina asimilacije podatkov (EDA)

vznemirjena opazanja + moteč model $\longrightarrow$ moteča analiza $\longrightarrow$ vznemirjena napoved

Prednosti: optimalno v idealnem svetu. **Pomanjkljivost:** vsi viri napak niso vzorčeni; napake pri opazovanju se domnevajo brez korelacije.

Skupina II: Dinamično motivirane motnje

Te metode vzorčijo negotovost v prostoru stanj *smeri*, ki so dinamično najbolj odgovorne za razpršenost napovedi – smeri največje rasti napake.

- **Bredovi vektorji** (uporabljeni npr. pri NCEP).
- **Singularni vektorji** (bolj razširjeno). *vodilni* singularni vektorji povečajo rast motenj v začetnem obdobju napovedi; identificirajo smeri, ki povzročajo največjo negotovost napovedi in s tem vodijo do širjenja ansambla – neposredno merilo te negotovosti.

V naslednjem podrazdelku se poglobimo v *singularne vektorje*.

9.12 Singularni vektorji

Začnimo z *nelinearnim* razvojem atmosferskega stanja. Operator modela $\mathcal{M}$ premakne začetno stanje $\vec{x}(0)$ na čas t :

$$\vec{x}(t) = \mathcal{M}_{0 \rightarrow t}(\vec{x}(0)),$$

kjer $\mathcal{M}$ pomeni sistem navadnih diferencialnih enačb—diskretiziranih v prostoru in času—ki opredeljuje popolno, nelinearno integracijo modela.

Tangentno-linearna evolucija majhnih motenj

Med našimi predavanji o asimilaciji podatkov smo predstavili *tangentno-linearno model*. Razvoj majhne motnje $\delta\vec{x}(t)$ okoli referenčne trajektorije $\vec{x}(t)$ ureja Jacobian

$$\delta\vec{x}(t) = \mathbf{M}_{0 \rightarrow t} \delta\vec{x}(0), \quad \mathbf{M} = \frac{\partial \mathcal{M}}{\partial \vec{x}},$$

torej $\mathbf{M}_{0 \rightarrow t}$ deluje kot matrika na začetni motnji $\delta\vec{x}(0)$.

Linearna evolucija matrike napak-kovariance

Predpostavimo *Gaussovo* porazdelitev začetnih stanj. Če je ta porazdelitev dovolj ozka v primerjavi z velikostjo atraktorja, se lahko njen razvoj približa s tangentno-linearnim modelom. Kovarianca $\mathbf{C}(0)$ se nato razvija kot

$$\mathbf{C}(t) = \mathbf{M}_{0 \rightarrow t} \mathbf{C}(0) \mathbf{M}_{0 \rightarrow t}^T,$$

kjer je $\mathbf{M}_{0 \rightarrow t}^T$ adjunkt $\mathbf{M}_{0 \rightarrow t}$. Ta linearni režim velja za obsežni NWP približno dva dni; pri majhnih lestvicah se napaka nasiči veliko prej.

Praktična napaka. Shranjevanje $\mathbf{C}(t)$ je nemogoče (njegova dimenzija je $\sim 10^9 \times 10^9$), njegovo eksplicitno razvijanje pa je računsko prepovedano. Vendar bi radi vedeli, *katere smeri* v prostoru stanj najbolj prispevajo k rasti napake napovedi.

Vnesite singularne vektorje

Ključna ideja je izračunati, v času $t = 0$, smeri, ki se bodo razvile v vodilne lastne vektorje $\mathbf{C}(t)$. Namesto shranjevanja in širjenja celotne kovariance neposredno najdemo te optimalne začetne motnje:

- Singularni vektorji maksimizirajo rast izbrane norme (običajno skupne energije) v končnem intervalu napovedi.
- Zato identificirajo smeri v faznem prostoru, vzdolž katerih bo napaka napovedi naraščala najhitreje.

Zakaj potrebujemo singularne vektorske motnje?

Načeloma bi **zbirka asimilacije podatkov** (EDA) v celoti vzorčila negotovost začetnega stanja. V praksi pa je samo EDA *premalo disperziven*: ne upošteva koreliranih napak pri opazovanju in motnje belega šuma, ki jih uporablja, se bolj razblinijo kot projicirajo na dinamično ustrezne načine.

Zato *dodamo* niz motenj singularnega vektorja analizam, ki jih izdela EDA. Te optimalne motnje napihnejo širjenje natančno v tistih smereh, ki so najpomembnejše, kar daje bolj zanesljivo skupino, katere negotovost se bolje ujema z dejansko napako napovedi.

V idealnem svetu s popolno karakterizacijo napak opazovanja in popolno stohastično fiziko ne bi potrebovali singularnih vektorjev; v resničnem svetu ostajajo nepogrešljivi za učinkovito vzorčenje negotovosti začetnega stanja.

9.12.1 Razčlenitev singularne vrednosti (SVD)

V nadaljevanju je vsaka *matrika* napisana krepko ($\mathbf{A}$), vsak *vektor* v puščičnem zapisu ($\vec{a}$) in notranji produkti v $\langle \cdot, \cdot \rangle$. Koraki izpeljave so prikazani natanko tako kot v izvirnih opombah; the odstavek takoj za vsako prikazano enačbo pojasnjuje njen pomen.

SVD tangentno-linearne propagatorja. Za kateri koli tangentno-linearni propagator $\mathbf{M}$ (velja v določenem času interval $0 \rightarrow t$) obstajata dve realni, pravokotni matriki $\mathbf{U}, \mathbf{V}$, tako da

$$\mathbf{U}^T \mathbf{M} \mathbf{V} = \mathbf{S}, \quad (9.5)$$

kjer $\mathbf{S} = \text{diag}(\sigma_1, \sigma_2, \dots, \sigma_n)$ je diagonalna matrika *singularnih vrednosti* $\sigma_i > 0$ in $n = \dim(\vec{x})$. Relacije ortogonalnosti $\mathbf{U}\mathbf{U}^T = \mathbf{U}^T\mathbf{U} = \mathbf{V}\mathbf{V}^T = \mathbf{V}^T\mathbf{V} = \mathbf{I}$ zagotavljajo, da stolpca $\mathbf{U}$ in $\mathbf{V}$ tvorita dve ortonormirani bazi.

Razlaga. Enačba (9.5) je standardni SVD, napisan v strnjeni obliki. Levi singularni vektorji (stolpci $\mathbf{U}$) bodo postali relevanten v *končnem* času t ; desni singularni vektorji (stolpci $\mathbf{V}$) živijo ob *začetnem* času 0.

Množenje z $\mathbf{U}$ na levi.

$$\mathbf{U}\mathbf{U}^T\mathbf{M}\mathbf{V} = \mathbf{U}\mathbf{S} \longrightarrow \mathbf{M}\mathbf{V} = \mathbf{U}\mathbf{S}.$$

Ker $\mathbf{U}\mathbf{U}^T = \mathbf{I}$, prefaktor izgine.

Razlaga. Delovanje z $\mathbf{U}$ ga odstrani z leve strani $\mathbf{M}\mathbf{V}$; dobljeni produkt se ujema z $\mathbf{U}\mathbf{S}$. Izražanje tega *stolpec za stolpcem* daje

$$\mathbf{M}\vec{v}_i = \sigma_i \vec{u}_i, \quad (9.6)$$

kjer je $\vec{v}_i$ i -ta *desna* ednina vektor (začetna motnja) in $\vec{u}_i$ je ustrezen *levi* singularni vektor (motnja v času t).

Množenje z $\mathbf{V}^T$ na desni.

$$\mathbf{U}^T\mathbf{M}\mathbf{V}\mathbf{V}^T = \mathbf{S}\mathbf{V}^T \longrightarrow \mathbf{U}^T\mathbf{M} = \mathbf{S}\mathbf{V}^T.$$

Ob transponiranju dobimo

$$\mathbf{M}^T\mathbf{U} = \mathbf{V}\mathbf{S},$$

ali stolpec za stolpcem,

$$\mathbf{M}^T\vec{u}_i = \sigma_i \vec{v}_i. \quad (9.7)$$

Razlaga. Pridruženi (transponirani) operator $\mathbf{M}^T$ razširja *končni* singularni vektor $\vec{u}_i$ *nazaj* na začetni čas 0, pri čemer nastane $\sigma_i\vec{v}_i$.

Problem lastne vrednosti za $\mathbf{M}^T\mathbf{M}$. Množenje (9.6) na levi z $\mathbf{M}^T$ in uporaba (9.7) daje

$$\mathbf{M}^T\mathbf{M}\vec{v}_i = \sigma_i \mathbf{M}^T\vec{u}_i = \sigma_i^2 \vec{v}_i,$$

tako da

$$(\mathbf{M}^T\mathbf{M} - \sigma_i^2\mathbf{I})\vec{v}_i = \vec{0} \implies \det(\mathbf{M}^T\mathbf{M} - \sigma_i^2\mathbf{I}) = 0. \quad (9.8)$$

Razlaga. Kvadrat singularnih vrednosti σ_i^2 je *lastne vrednosti* λ_i od $\mathbf{M}^T\mathbf{M}$, medtem ko so desni singularni vektorji $\vec{v}_i$ pridruženi lastni vektorji. S tem se vzpostavi enakovrednost med SVD in problem lastne vrednosti za simetrično, pozitivno določeno matrika $\mathbf{M}^T\mathbf{M}$.

Razširitev poljubnih motenj v bazah SVD. Ker stolpca $\mathbf{U}$ in $\mathbf{V}$ tvorita ortonormirane baze, lahko vsako začetno motnjo zapišemo kot

$$\delta\vec{x}(0) = \sum_{i=1}^n \langle \delta\vec{x}(0), \vec{v}_i \rangle \vec{v}_i,$$

in vsaka končna motnja kot

$$\delta\vec{x}(t) = \sum_{i=1}^n \langle \delta\vec{x}(t), \vec{u}_i \rangle \vec{u}_i. \quad (9.9)$$

Razlaga. Koeficienti so preprosti notranji produkti, ker so baze ortonormalne.

Razširjanje začetne motnje. Z uporabo tangentno-linearne modela,

$$\delta\vec{x}(t) = \mathbf{M}_{0 \rightarrow t} \delta\vec{x}(0) = \mathbf{M}_{0 \rightarrow t} \sum_{i=1}^n \langle \delta\vec{x}(0), \vec{v}_i \rangle \vec{v}_i.$$

Uporaba (9.6) ($\mathbf{M}\vec{v}_i = \sigma_i \vec{u}_i$) daje

$$\delta\vec{x}(t) = \sum_{i=1}^n \langle \delta\vec{x}(0), \vec{v}_i \rangle \sigma_i \vec{u}_i.$$

Projekcija na končne singularne vektorje. Če vzamemo notranji produkt $\delta\vec{x}(t)$ z $\vec{u}_i$ in izkoriščanje ortonormalnosti,

$$\langle \delta\vec{x}(t), \vec{u}_i \rangle = \sum_{j=1}^n \langle \delta\vec{x}(0), \vec{v}_j \rangle \sigma_j \underbrace{\langle \vec{u}_j, \vec{u}_i \rangle}_{=\delta_{ij}} = \sigma_i \langle \delta\vec{x}(0), \vec{v}_i \rangle.$$

Kompaktno,

$$\langle \delta\vec{x}(t), \vec{u}_i \rangle = \sigma_i \langle \delta\vec{x}(0), \vec{v}_i \rangle. \quad (9.10)$$

Razlaga. Enačba (9.10) kaže, da je amplituda vsakega način vzdolž $\vec{u}_i$ je *pomanjšano* z ednino σ_i . če $\sigma_i > 1$ ustrezna motnja raste; če $\sigma_i < 1$ razpade.

Sestavljanje vsega skupaj. Zamenjava (9.10) v (9.9) obnovi celotno motnjo v času t :

$$\delta\vec{x}(t) = \sum_{i=1}^n \langle \delta\vec{x}(0), \vec{v}_i \rangle \sigma_i \vec{u}_i.$$

Tolmačenje. Vsak desni singularni vektor $\vec{v}_i$ pri $t = 0$ je preslikan v ustrezen levi singularni vektor $\vec{u}_i$ pri t , *obrnjeno* v prostoru stanja in *prilagojeno* za σ_i . Torej:

$$\sigma_i > 1 \implies \text{napaka raste}, \quad \sigma_i < 1 \implies \text{napaka razpade}.$$

Izbira *vodnega* (največjega $-\sigma_i$) ednine vektorjev za začetne motnje zato vnaša variabilnost prav v smereh, kjer napaka napovedi raste najhitreje, ki prinaša ansambel z realističnim—in *zanesljivim*—širjenjem.

9.12.2 Geometrična interpretacija singularnih vektorjev


Da bi vizualizirali, kaj nam govori algebra v prejšnjem pododdelku, si predstavljajte *začetni* čas $t = 0$ na levi strani skice in *končni* čas $t = t$ na desni. Recimo, da je fazni prostor tridimenzionalen; najprej ga vzorčimo z dvema desno-singularnima vektorjema $\vec{v}_1$ in $\vec{v}_2$, ki se raztezata na enotni hipersferi:

$$\|\vec{v}_i\| = 1, \quad i = 1, 2.$$

Integracija naprej $\mathbf{M}_{0 \rightarrow t}$. Uporaba tangentno-linearne propagatorja $\mathbf{M}_{0 \rightarrow t}$ pretvori to hipersfero v nagnjen hiperelipsoid, katerega pol-osi so *pomanjšani* in *zasukani* vektorji

$$\sigma_1 \vec{u}_1, \quad \sigma_2 \vec{u}_2,$$

kjer $\sigma_1 > 1$ in $\sigma_2 < 1$. Tako se ena os razširi, medtem ko se druga krči; oblika se tudi *vrti* iz smeri $\vec{v}_i$ v $\vec{u}_i$.



Slika 9.15: Razvoj začetne hipersfere v hiperelipsoid, kjer se vidi razvoj singularnih vektorjev.

Integracija nazaj $\mathbf{M}_{0 \rightarrow t}^T$. Razmnoževanje tega elipsoida nazaj na $t = 0$ s pridruženim modelom, $\mathbf{M}_{0 \rightarrow t}^T$, obnovi prvotno orientacijo, vendar se spreminja osi še enkrat:

$$\sigma_1^2 \vec{v}_1, \quad \sigma_2^2 \vec{v}_2.$$

Od tod sestavljeni operator $\mathbf{M}^T \mathbf{M}$ vzorci istih smeri ($\vec{v}_i$), medtem ko jih ponderirate s kvadratom njihove ednine vrednosti, tj. z intrinzičnimi stopnjami rasti ali upada napake. Dominantna smer $\vec{v}_1$ (največja σ_1) je torej *optimalna* os začetne motnje.

Zdaj obrnite miselni poskus. Začnite z enotno hipersfero v *končnem* času, razpeto z dvema levo-singularnima vektorjema $\vec{u}_1, \vec{u}_2$. Razširjanje nazaj na $t = 0$ daje $\sigma_1 \vec{v}_1, \sigma_2 \vec{v}_2$; širjenje teh vektorjev naprej daje rezultate $\sigma_1^2 \vec{u}_1, \sigma_2^2 \vec{u}_2$. Tukaj je sestavljeni operator $\mathbf{M} \mathbf{M}^T$; njegov lastni vektorji so $\vec{u}_i$.

Iterativna močna metoda. Ponavljajoča se uporaba $\mathbf{M}^T \mathbf{M}$ na istem časovno okno—recimo integracija $[0, 48 \text{ h}]$ —okrepi vodilna smer za σ_1^2 vsako ponovitev in duši vse drugi z σ_i^2 ($i > 1$). Po približno 100 ponovitvah postopek konvergira k ~ 30 singularni vektorji, ki obsegajo podprostor najhitrejšega rast napake. To so motnje, ki jih vnesemo v začetnico pogoje za doseg realističnega širjenja ansambla.

Linearna kombinacija za operativno uporabo. Operativno združujemo posamezne singularne vektorske motnje (SV_{ik}) v širše vzorce prek

$$\text{SV}_j = \sum_l \sum_k \alpha_{lk} \text{SV}_{ik},$$

običajno ohrani približno 50 takšnih kombinacij na severu Hemisfera. Koeficienti α_{lk} so izbrani tako, da je nastale motnje skupaj vzorčijo najbolj energične smeri prostor-stanje.

Poglavje 10

Modeli omejenega območja (LAM)

Do zdaj smo opisovali le *globalne* numerične modele. Ti izvajajo napoved, asimilacijo podatkov in ansambelsko računanje na celotni Zemlji. Globalni modeli diskretizirajo celotno domeno v številne mrežne točke in v vsaki rešujejo parcialne diferencialne enačbe z različnimi numeričnimi pristopi, na primer s spektralnimi metodami. Toda predstavljati celotno Zemljo z zadostno ločljivostjo pomeni tako veliko število točk, da postane izračun računsko predrag. Kako rešiti to težavo?

Rešitev je uporaba *povečevalnega okna* nad izbranim delom domene, imenovanega **model omejenega območja** (LAM). Različni raziskovalci trdijo, da LAM-i nimajo dodane vrednosti, a naš predavatelj s tem ne soglaša. LAM nad Slovenijo ne vpliva na rezultate nad Kitajsko, ker gre za enosmerno gnezdenje: globalni model posreduje *stranske robne pogoje*, LAM pa informacij ne vrača. Kljub temu nudi odlično povečavo, zlasti nad razgibanim reliefom. Naš cilj je zmanjšati napake modela z večjo ločljivostjo.

ECMWF kot vodilni globalni center deluje pri 9 km in poskusno že pri 4,4 km. Slovenska agencija ARSO je uporabljala 4,4-kilometrski ALADIN in zdaj rutinsko poganja model z ločljivostjo 1,1 km. V globalnem okolju bi bila taka ločljivost predraga, LAM pa 1 km zmore. Nekatere službe gnezdiyo model znotraj modela in dosega jo še manj kot 1 km.

Povečana ločljivost je nujna za opis konvektivnih procesov, orografsko proženih padavin, megle v kotlinah ter lokalnih vetrov, kot sta fen in burja. Pomembna je tudi za interakcije med majhnimi in velikimi merili. Pogosto se sprašujemo, čemu visoka ločljivost v globalnih modelih; zakaj ne bi uporabili nizke ločljivosti in nato vse skupaj povečali z LAM-om? Visoka ločljivost globalnega modela in začetnih pogojev omogoča zajem večje atmosferske spremenljivosti, s čimer dosežemo boljše ujemanje z opazovanji in boljše začetne razmere. Boljše začetne razmere zaradi lastne rasti napake vedno vodijo v boljšo napoved.


V visoki ločljivosti lahko rešimo večji del spektra gravitacijskih valov, natančneje opišemo njihove navpične motnje in razporeditev impulza ob zlomu v srednji stratosferi. Tako izboljšamo opis stratosfere, kar se povratno pozna tudi v troposferi. Prehod z 9 km na 4,4 km v asimilaciji in napovedi je mejno predvidljivost podaljšal za približno dvanajst ur.

Čeprav LAM po četrtem ali petem dnevu ne prinaša večjega dobička, saj se napake globalnega modela širijo prek robov domen, ansambel globalnih modelov omogoča ansambel LAM-ov in s tem ohranja dodatno vrednost. LAM-i opisujejo pojave, ki jih globalni modeli z omejeno ločljivostjo spregledajo, denimo meglo, prečne vetrove in konvekcijo. Kljub skeptikom večina stroke meni, da morata globalni in omejeni model delovati z roko v roki. Smiselno je tudi

usklajevanje prekrivajočih se nacionalnih domen (hrvaške, avstrijske in slovenske), saj bi enotna, večja gnezdena domena prihranila računske vire.

10.1 Tipična shema LAM

Klasična shema modela omejenega območja (LAM) vključuje *gostiteljski* model, ki zagotavlja robne pogoje. Vse, kar je zunaj šrafirane površine na skici, pripada temu gostiteljskemu modelu; ta ni nujno globalen, lahko je tudi večji regionalni model v večnivojskem gnezdenju. Sledi *relaksacijska cona*, znotraj katere je *gnezdni model*. Notranji rob označimo z **C**; to je računsko območje, kjer sistem parcialnih diferencialnih enačb (ali, v podatkovnem pristopu, nevronska evolucija) rešujemo popolnoma neodvisno od zunanjega modela. Izven C potekajo vsi izračuni v gostiteljskem modelu; v relaksacijski coni sta vpliva obeh modelov mešana; znotraj C pa je računanje povsem ločeno. Zunanji okvir tvorijo **stranski robni pogoji (LBC)**.



Slika 10.1: Shematski prikaz tipične LAM-domene. Zelena črta predstavlja zunanji obod z LBC, poševno šrafirano območje je relaksacijska cona R, modri notranji okvir označuje računsko domeno C.

10.2 Stranski robni pogoji

10.2.1 Lastnosti

Stranski robni pogoji morajo brez popačenja prenašati pojave iz gostiteljskega modela v LAM, zlasti velike sisteme. Sinoptični ciklon nad severnim Atlantikom mora brez težav vstopiti skozi LBC v srednjeevropski LAM. Po drugi strani ni kritično, če se pri prehodu dušijo majhni gravitacijski valovi, saj za napoved niso bistveni.

Kadar pa eksplozivna konvekcija v domeni sproži močne gravitacijske valove, ki se širijo proti robu, mora relaksacijska cona preprečiti njihovo umetno odbojnost; odboja ne sme biti. Robni pogoji se morajo spreminjati v času, da odražajo dogajanje zunaj gnezdenega modela, saj se tam pojavi nenehno rojevajo in gasijo. Večina LAM-ov je *enosmerno* gnezdena: gostiteljski model vpliva na gnezdeni model, ne pa obratno. Dinamični, a izključno z gostiteljem določeni robni pogoji tako vodijo gnezdeni model, medtem ko notranje računsko območje ne vpliva na gostiteljski model. Poskusi z globalno mrežo medsebojno povezanih LAM-ov niso uspeli; za zdaj ostaja enosmerno gnezdenje najustreznejša rešitev.

10.3 Dobro postavljeni robni pogoji

Kaj pravzaprav pomeni, da so robni pogoji *dobro postavljeni*? Ogledali si bomo nekaj nalog in podatke, ki jih potrebujemo pri parcialnih diferencialnih enačbah drugega reda različnih tipov.

10.3.1 Eliptičen problem

Za dvodimenzionalno Laplaceovo enačbo

$$\nabla^2 u = \frac{\partial^2 u}{\partial x^2} + \frac{\partial^2 u}{\partial y^2} = 0,$$

kjer je $u(x, y)$ npr. potencialno polje, moramo na vsakem robu pravokotne domene predpisati vrednosti:

$$u(x, 0), \quad u(x, L_y), \quad u(L_x, y), \quad u(0, y).$$

Če predpišemo *same vrednosti* u , govorimo o **Dirichletovih** robnih pogojih. Druga možnost je, da določimo *normalne odvode*,

$$u_y(x, 0), \quad u_y(x, L_y), \quad u_x(L_x, y), \quad u_x(0, y),$$

kar so **Neumannovi** robni pogoji. Linearna kombinacija vrednosti in odvodov,

$$\alpha u(x, 0) + \beta u_y(x, 0) = 0,$$

je **Robinov** ali mešani robni pogoj; α in β sta dana koeficienta. Vse tri oblike, ustrezno izbrane, zagotavljajo enoličnost in stabilnost rešitve eliptične naloge.

10.3.2 Paraboličen problem

Značilen primer parabolične enačbe je enačba difuzije

$$u_t = D u_{xx},$$


kjer je $u(x, t)$ denimo temperatura, D pa difuzijski koeficient. Ker gre za časovni razvoj, potrebujemo najprej **začetni pogoj**

$$u(t = 0, x)$$

za vse x . Nato moramo določiti še dva časovno odvisna robna pogoja na krajiščih intervala,

$$u(t, 0) \quad \text{in} \quad u(t, L),$$

kot prikazuje skica. S temi tremi podatki je naloga dobro postavljena: za gladke vhode obstaja enolična gladka rešitev, ki zvezno zavisi od podatkov.



Slika 10.2: Prostor-časovni diagram difuzijske enačbe. Vodoravna os je prostor x , navpična čas t . Valovita modra črta spodaj predstavlja začetni pogoju $u(t=0, x)$. Prekinjeni modri črti pri $x=0$ in $x=L$ označujeta časovno odvisna robna pogoja $u(t, 0)$ in $u(t, L)$. Zelena črta je notranja rešitev $u(x, t)$.

10.3.3 Hiperbolični problem

Pri hiperbolični parcialni diferencialni enačbi (PDE) velja pravilo, da potrebujemo toliko robnih pogojev, kolikor karakteristik seka rob in je usmerjenih v domeno; številu karakteristik, ki prečkajo mejo proti notranjosti, mora torej ustrezati enako število robnih pogojev.

Primer: transportna enačba

$$u_t = -c u_x,$$

kjer je $u(x, t)$ transportirano skalarско polje, c pa stalna hitrost prenosa ($c > 0$ pomeni prenos v pozitivni smeri x). Rešitev poiščemo s pomočjo karakteristik.

Karakteristike splošne kvazilinearne enačbe Za splošno kvazilinearno enačbo prvega reda

$$a(x, y, t) \frac{\partial u}{\partial x} + b(x, y, t) \frac{\partial u}{\partial y} = c(x, y, u)$$

so karakteristike tiste krivulje, vzdolž katerih se PDE pretvori na sistem navadnih diferencialnih enačb (ODE). Če s označuje parametrizacijo krivulje, tedaj

$$\begin{aligned} \frac{dx}{ds} &= a(x, y, u), \\ \frac{dy}{ds} &= b(x, y, u), \\ \frac{du}{ds} &= c(x, y, u). \end{aligned}$$

Uporaba na transportni enačbi Za našo enačbo so koeficienti

$$a = c, \quad b = 1, \quad c = 0,$$

zato dobimo ODE-sistem

$$\begin{aligned} \frac{dx}{ds} &= c \implies x = cs + x_0, \\ \frac{dt}{ds} &= 1 \implies t = s + t_0, \\ \frac{du}{ds} &= 0 \implies u = \text{konst.} \end{aligned}$$

Ker je $s = t - t_0$, vstavimo v prvo enačbo in dobimo premice

$$x = c(t - t_0) + x_0 = ct + (x_0 - ct_0),$$

torej


$$x - ct = x_0 - ct_0 = \text{konst.}$$

Vsaka karakteristika je premica $x - ct = \text{konst.}$, in ker je u po zgornji izpeljavi konstanten vzdolž karakteristik, velja

$$u(x, t) = f(x - ct),$$

kjer funkcija f predstavlja vrednost u na začetni karakteristiki. Na skici 10.3 so te premice narisane kot družina vzporednih črt; vzdolž vsake od njih ostaja u nespremenjen.

Rešitev transportne enačbe je *potujoči profil*: začetna porazdelitev $f(\xi)$ se brez spreminjanja oblike prenaša s hitrostjo c . Ker se vse karakteristike pri $c > 0$ začnejo na robu $x = 0$ in vstopajo v domeno, potrebujemo natanko en robni pogoj $u(0, t)$; določanje $u(L, t)$ bi pre-določilo problem in ga naredilo nestabilnega (ill-posed). Pri $c < 0$ velja enak argument na nasprotnem robu.



Slika 10.3: Skica karakteristik v hiperboličnem problemu

Koliko robnih in koliko začetnih pogojev? Naj bo prostorska domena $0 \leq x \leq L$, čas pa $0 \leq t \leq t_1$. Pravilo o karakteristikah pravi, da moramo predpisati toliko robnih pogojev, kolikor je karakteristik, ki prečkajo rob in vstopajo v domeno. Za transportno enačbo z $c > 0$ vse karakteristike vstopajo pri $x = 0$, zato **moramo** določiti $u(0, t)$, medtem ko je predpis $u(L, t)$ **prepovedan** — tak problem bi bil pre-določen in torej slabo postavljen. Vrednosti v točki ($x = L$) določa zgolj evolucija v računski domeni; dodatno vsiljen pogoj bi povzročil neskladje z rešitvijo PDE.

Oglejmo si tri točke: $u(x_1, t_1)$, $u(x_2, t_2)$, $u(x_3, t_3)$. Točki $u(x_1, t_1)$ in $u(x_2, t_2)$ se nahajata na karakteristikah, ki izhajajo iz robnega pogoja pri $x = 0$, zato ju ta pogoj neposredno določi. Točka $u(x_3, t_3)$ leži na karakteristiki, ki izhaja iz začetne črte $t = 0$, zato jo določa začetni pogoj.

10.3.4 Pogostost osveževanja LBC

Ker robni pogoji vplivajo globoko v notranjost, jih je treba pogosto osveževati, da informacije ostanejo pravilne. Tipično vprašanje je, kako pogosto posodabljam lateralne robne pogoje (LBC): ob vsakem časovnem koraku globalnega modela ali v fiksnih presledkih? Bolj ko skrajšamo interval posodobitve, natančnejše bodo vhodne informacije.

Zgled: globalni model ima časovni korak 15 min, LBC pa se posodablja na 30 min. Lokalni LAM, ki zaradi fine mreže in CFL-kriterija zahteva $\Delta t_{\text{lokal}} = 2$ min, mora vmesnih 28 minut vrednosti pridobiti z interpolacijo (običajno linearno). To ni idealno; izboljšamo lahko

- z manjšim časovnim korakom globalnega modela,
- s krajšim intervalom posodabljanja LBC,
- z uporabo višje-rednih interpolacijskih shem.

10.3.5 Hiter prenos napak z roba

Značilna hitrost zgornjetroposferskega toka je približno 100 km h^{-1} , tipična razdalja od roba do središča 2000-km LAM-domene pa 1000 km; napake z roba torej dosežejo središče v približno 10 urah. Ko trdimo, da LAM presega globalni model, govorimo predvsem o prvih 5–10 urah, ko LAM še razvija lastno dinamiko iz svojih začetnih pogojev in asimilacije. Po tem času LAM deluje predvsem kot *povečevalno okno* grobe globalne rešitve; notranje polje postopno preplavi informacija, ki vstopa z LBC.

10.3.6 Zakaj vseeno poganjati 72-urno LAM-napoved?

Tudi če LAM po desetih urah ne ustvarja več samostojne sinoptične evolucije, povečava še vedno pomembno izboljšša predstavitev krajevnih procesov, ki jih globalni modeli ne zmorejo razločiti:

- pojav in razvoj konvekcije,
- orografsko prožene padavine,
- dolinska megla,
- lokalni vetrovi (fen, burja) v gorskem reliefu.

Tako je vlaganje v LAM upravičeno predvsem v goratih in razčlenjenih pokrajinah, kjer natančnost lokalnih podrobnosti močno vpliva na uporabo napovedi.

10.3.7 Primer 1D SWM

V enorazsežnem lineariziranem plitvovodnem modelu (SWM) brez Coriolisa naj bo ozadni tok $U > 0$. Dana je adveksijska enačba kot uvodni zgled

$$\frac{\partial u}{\partial t} = -c \frac{\partial u}{\partial x},$$

kjer za $c > 0$ zadostuje en sam robni pogoj pri $x = 0$, za $c < 0$ pa en sam pogoj pri $x = L$. Vprašanje je, koliko robnih pogojev potrebujemo v 1D-SWM in na katerem koncu domene, ter ali naloga s praktičnega vidika sploh omogoča dobro postavljeno rešitev.

Modelne enačbe.

$$\frac{\partial u}{\partial t} + U \frac{\partial u}{\partial x} = -g \frac{\partial h}{\partial x}, \quad (10.1)$$

$$\frac{\partial h}{\partial t} + U \frac{\partial h}{\partial x} = -H \frac{\partial u}{\partial x}, \quad (10.2)$$

kjer $u(x, t)$ označuje motnjo hitrosti, $h(x, t)$ motnjo višine, g gravitacijski pospešek, H srednjo globino in U konstanten ozadni tok.

Izpeljava valovne enačbe. Odvajamo (10.1) po t in (10.2) po x , nato izločimo h :

$$\frac{\partial^2 u}{\partial t^2} = gH \frac{\partial^2 u}{\partial x^2}.$$

Notranja fazna hitrost plitvovodnih (gravikinetičnih) valov je torej $\tilde{c} = \sqrt{gH}$. S tem dobimo dve rešitvi za notranjo fazno hitrost,

$$\tilde{c}_{1,2} = \pm \sqrt{gH},$$

skupni fazni hitrosti pa znašata

$$c_{1,2} = U \pm \sqrt{gH}.$$

Karakteristike in robni pogoji. Karakteristiki napredujeta z $c_+ = U + \sqrt{gH}$ in $c_- = U - \sqrt{gH}$. Število in lega potrebnih robnih pogojev sta odvisna od predznaka teh hitrosti:

Če je $U < \sqrt{gH}$ je $c_+ > 0$ in $c_- < 0$; ena karakteristika vstopa pri $x = 0$, druga pri $x = L$, zato moramo predpisati dva robna pogoja, enega na vsakem robu.

Če je $U > \sqrt{gH}$ sta oba c_+ in c_- pozitivna, vse karakteristike vstopajo skozi $x = 0$, zato potrebujemo dva robna pogoja izključno na tem robu, na $x = L$ pa ne smemo predpisati ničesar.

Če $U = \sqrt{gH}$ dobimo $c_- = 0$ – druga karakteristika je stacionarna – in zadošča en pogoj pri $x = 0$, medtem ko na $x = L$ postavimo le gladkostno zahtevo. V vseh primerih ostaneta obvezni začetni polji $u(0, x)$ in $h(0, x)$.

Število robnih pogojev je torej odvisno od razmerja med U in $\sqrt{gH}$, natančneje:

$$\begin{cases} \text{dva pogoja, eden pri } x = 0 \text{ in eden pri } x = L, & \text{če } U < \sqrt{gH}, \\ \text{dva pogoja pri } x = 0, & \text{če } U > \sqrt{gH}, \\ \text{en pogoj pri } x = 0, & \text{če } U = \sqrt{gH}. \end{cases}$$

Naloga je v vseh treh primerih praktično rešljiva, saj pravilna umestitev robnih pogojev prepreči pre- ali pod-določenost sistema.

10.4 Sheme robnih pogojev

10.4.1 Psevdo-radiacijski robni pogoji

Predpostavimo, da lahko ob robu katero koli PDE nadomestimo z advekcijsko enačbo

$$\frac{\partial u}{\partial t} + c \frac{\partial u}{\partial x} = 0,$$

kjer je $x = b$ položaj robne točke, $x = b - 1$ pa notranja točka tik pred robom. Fazno hitrost c ocenimo *in situ* kot razmerje med lokalnima odvodoma

$$c = - \frac{\partial u / \partial t}{\partial u / \partial x},$$

kar v shemi prvega reda ($\gg$ upwind $\ll$) zapišemo diskretno

$$c = \frac{u_{b-1}^{n+1} - u_{b-1}^n}{\Delta t} \bigg/ \frac{u_{b-1}^n - u_{b-2}^n}{\Delta x}.$$

Algoritem robnega pogoja


$$u_b^{n+1} = \begin{cases} u_b^n - \frac{c \Delta t}{\Delta x} (u_b^n - u_{b-1}^n), & c > 0, \\ u_b^{\text{host}}(t^{n+1}), & c < 0. \end{cases}$$

Težave sheme

- Slaba ocena c privede do napačnega števila robnih pogojev in pre-določenega (nestabilnega) problema.
- Napačno izračunana vrednost u_b^{n+1} vnaša napake, ki se širijo v domeno.

Zaradi teh pomanjkljivosti sodobni LAM-i takšne sheme ne uporabljajo več.

10.4.2 Robna cona (boundary-zone) in difuzijsko blaženje



Slika 10.4: Prikaz robne cone z rdečo

Rob vpeljemo kot *robno cono* širine B (od $x = 0$ do $x = B$ ter od $x = L - B$ do $x = L$) in v tem pasu spremenimo dinamično enačbo:

$$\frac{\partial u}{\partial t} + c \frac{\partial u}{\partial x} = F_{bz}.$$

Člen F_{bz} je prisoten le znotraj robne cone, kar lahko formalno zapišemo s Heavisideovo funkcijo. Pogosta izbira je **horizontalna difuzija**


$$F_{bz} = \frac{\partial}{\partial x} \left(U(x) \frac{\partial u}{\partial x} \right),$$

kjer $U(x)$ določa moč blaženja, največjo ob samem robu.

Posledice

- Iz hiperboličnega problema smo ustvarili parabolnega, zato se *vs*i valovi, ki prihajajo iz računske domene, zadušijo in ne odbijejo.
- Žal se zadušijo tudi valovi, ki jih host-model pošilja proti notranjosti, kar slabša kakovost prenosa informacij.

Robne cone z difuzijo se zato v LAM-ih skoraj ne uporabljajo več (ostajajo pa v globalnih modelih na zgornji meji, kjer iz vesolja v atmosfero valovi skoraj ne prihajajo).



h!

Slika 10.5: Korekcija tendence

Korekcija tendence

Pri tej shemi adveksijsko enačbo na robu dopolnimo s korekcijskim členom:

$$\frac{\partial u}{\partial t} + c \frac{\partial u}{\partial x} = -\gamma \frac{\partial(u - \bar{u})}{\partial t},$$

kjer je $\gamma = \gamma(x) \geq 0$ *koeficient korekcije tendence*. V sami domeni je $\gamma = 0$, v robni točki $x = L$ pa naj $\gamma \rightarrow \infty$; v robni coni $x \in [L - B, L]$ torej $\gamma(x)$ monotonno narašča od 0 do zelo velikih vrednosti, medtem ko u predstavlja polje gnezdenega modela, $\bar{u}$ pa polje gostiteljskega (host) modela. Sedaj zapišimo adveksijsko enačbo ločeno za notranjost domene in za robno cono. V notranjosti velja običajna advekcija brez vpliva zunanjih podatkov, medtem ko v robni coni že predpostavljamo, da želimo vrednosti modela postopoma uskladiti s ciljnim (gostiteljskim) poljem, zato vključimo korekcijski člen.

Enačbe znotraj domene in v robni coni

$$\text{Domena: } \frac{\partial u}{\partial t} + c \frac{\partial u}{\partial x} = 0, \quad (10.3)$$

$$\text{Robna cona: } \frac{\partial \bar{u}}{\partial t} + c \frac{\partial \bar{u}}{\partial x} + \gamma \frac{\partial(u - \bar{u})}{\partial t} = 0. \quad (10.4)$$

Evolucija razlike Definirajmo odklon $u' = u - \bar{u}$. Če odštejemo (10.3) od (10.4), dobimo

$$\frac{\partial u'}{\partial t} + c \frac{\partial u'}{\partial x} + \gamma \frac{\partial u'}{\partial t} = 0.$$

Člene preuredimo in delimo z $1 + \gamma$:

$$\frac{\partial u'}{\partial t} + \frac{c}{1 + \gamma} \frac{\partial u'}{\partial x} = 0,$$

kar je znova adveksijska enačba, tokrat s *upočasnjeno* hitrostjo

$$c^* = \frac{c}{1 + \gamma}.$$

Lastnosti sheme

- Če $\gamma = 0$ (globoko v notranjosti), je $c^* = c$ in razlika u' se prenaša s polno hitrostjo modela.
- Ko $\gamma \rightarrow \infty$ (pri samem robu), gre $c^* \rightarrow 0$: prenos odklonov se ustavi, zato se neskladje med gnezdenim in gostiteljskim modelom ne širi preko roba.
- S tem se izognemo *pre-določenosti* robnih pogojev: kakršna koli nenatančnost na robu je močno zadušena in ostane tam, problem pa ostane dobro postavljen.

Korekcija tendence torej deluje kot *dušilnik* razlik: karakteristike odklona se z bližanjem robu upočasnijo in na robu zamrznejo, s čimer preprečimo propagacijo morebitnega neskladja v širšo domeno.

Newtonova relaksacijska shema

Robno cono lahko obvladujemo z **Newtonovim relaksacijskim členom**

$$\frac{\partial u}{\partial t} + c \frac{\partial u}{\partial x} = -K(x) (u - \bar{u}_{\text{BZ}}), \quad (10.5)$$

kjer $K(x) \geq 0$ določa, kako hitro želimo polje u v robni coni skozi časovno skalo $\tau(x) \approx 1/K$ približati *ciljni vrednosti* $\bar{u}_{\text{BZ}}$ iz gostiteljskega modela. V notranjosti domene je $K = 0$, medtem ko proti robu ($x = L$) narašča in lahko doseže velike vrednosti.

Odklon med modeloma Notranja dinamika (brez relaksacije) zadošča

$$\frac{\partial \bar{u}}{\partial t} + c \frac{\partial \bar{u}}{\partial x} = 0. \quad (10.6)$$

Odštejmo (10.6) od (10.5) in definirajmo odklon $u' = u - \bar{u}$:

$$\frac{\partial u'}{\partial t} + c \frac{\partial u'}{\partial x} = -K u'.$$

Odklon se torej *advektira* in hkrati *eksponentno ugaša*; relaksacija ne spreminja samega u , temveč le odpravlja razliko do gostiteljskega polja.

Numerična izvedba (ALADIN) V LAM-u ALADIN (in sorodnih kodah) se časovni razcep izvede leap-frogovo, relaksacijski člen pa implicitno:

$$\frac{u^{n+1} - u^{n-1}}{2\Delta t} = F^n - K (u_{\text{int}}^{n+1} - \bar{u}^{n+1}),$$

kjer F^n združuje advekcijo, difuzijo in vire, u_{int}^{n+1} pa je surova vrednost po integracijskem koraku

$$u_{\text{int}}^{n+1} = u^{n-1} + 2\Delta t F^n.$$

Vstavitev da končno u^{n-1} nam da *relaksacijsko posodobitev*

$$u^{n+1} = (1 - \alpha) u_{\text{int}}^{n+1} + \alpha \bar{u}^{n+1}, \quad \alpha = 2\Delta t K(x).$$

Torej je nova vrednost linearna kombinacija notranje evolucije in gostiteljskega polja; utež $\alpha(x) \in [0, 1]$ običajno narašča od 0 (globoko v domeni) do 1 na samem robu. Pogoste izbire so

$$\alpha(j) = \begin{cases} 1 - (1 - j/B)^p, & 0 \leq j \leq B, \\ 0, & j > B, \end{cases}$$

kjer je j razdalja od roba, B širina robne cone, $p \in [1, 4]$ pa določa strmino prehoda.

Prednost sheme Ker se odklon u' blaži z eksponentom $-Kt$, se razlike med LAM-om in host-modelom ne prenašajo nazaj v domeno; robni pogoji ostanejo dobro postavljeni, ne da bi povzročili odboj ali pre-določenost.

Alternativa brez klasične LBC Météo-France je razvil *neravno* (nestalno) mrežo, ki ima kilometrsko ločljivost nad Francijo, proti obrobju pa se mreža postopno grobi; s tem znatno zmanjša potrebo po eksplizitnih stranskih robnih pogojih, a ohrani visoko ločljivost na območju primarnega interesa.

ICON primer

Nemški operativni model ICON (DWD) združuje *stranske* (Newtonova relaksacija) in *zgornje* robne pogoje v več prekrivajočih se pasov, prikazanih na sliki 10.6. Osrednja ravnina predstavlja prostorsko domeno modela; pasovi ob levi in desni označujejo lateralno robno cono, zgoraj pa sta še gobasta plast in cona zgornje relaksacije.

Lateralna robna cona (oznaka 0) V štirih dodatnih stolpcih točk teče klasična Newtonova relaksacija

$$\Psi(t) = \Psi_{\text{int}}(t) + \alpha_0 \frac{\bar{\Psi} - \Psi_{\text{int}}}{\Delta t},$$

kjer je

$$\alpha_0 = f_0 \exp\left[-\frac{|x - x_0|}{\mu}\right], \quad |x - x_0| \leq L.$$

Parametri pomenijo: x indeks mrežne točke, x_0 prvo točko robne cone, L njeno širino, μ polširino profila, $f_0 = 1$ za potencialno temperaturo θ , $f_0 = 0,5$ za horizontalni veter (u, v) in vlago q .

Zgornja robna plast Pas med višinama z_{start} in z_{top} je razdeljen na

- *gobasto plast* (sponge layer), kjer se vse vertikalne hitrosti in fluksi postopoma dušijo na nič,
- *cono zgornje relaksacije*, v kateri teče linearni nudging


$$\alpha_1 = B_0 \frac{z - z_{\text{start}}}{z_{\text{top}} - z_{\text{start}}},$$

konstanta B_0 določa časovno skalo približevanja gostiteljskemu polju $\bar{\Psi}$.

Prekrivanje robnih režimov Ker se lateralna in zgornja cona križata (območje označeno z α_2), ICON uporabi

$$\alpha_2 = \max(\alpha_0, \alpha_1),$$

s čimer vedno prevlada *močnejša* relaksacija in prepreči, da bi se razlikujeta režima medsebojno motila. Rezultat je zanesljiva kombinacija: lateralna cona skrbi za vpliv gostiteljskega modela v vodoravni smeri, zgornja plast duši navpične odboje in ohranja stabilnost v prostorskem nadstropju blizu vrha.



Slika 10.6: Shema robnih con v modelu ICON. Pasovi 0 so stranske Newtonove relaksacijske cone z utežjo α_0 ; pasova 1a (gobasta plast) in 1b (zgornja relaksacija) delujeta z utežjo α_1 ; v prekrivajočem območju velja $\alpha_2 = \max(\alpha_0, \alpha_1)$. Debela krivulja prikazuje primer polja, ki se notranje razvija z minimalnim odbojem ob vseh robovih.