

4. naloga: Fourierova analiza

Filip Lovšin 28242022

April 24, 2026

1 Naloga

Naloga je od nas zahtevala, da izračunamo Fourierov obrat Gaussove porazdelitve in nekaj enostavnih vzorcev. Za slednje smo primerjali rezultate, ko je vzorec v intervalu periodičen (izbrane frekvence so mnogokratniki osnovne frekvence), z rezultati, ko vzorec ni periodičen. Opazovati moramo pojav potujevanja na vzorcu, ki vsebuje frekvence nad Nyquistovo frekvenco. Napravil bom še obratno transformacijo in preveril natančnost metode. Nato smo še morali z Fourierom analizirati 2.3 s dolge zapise začetka Bachove partite za violino solo.

2 Teoretično ozadje

Pri numeričnem izračunu Fourierove transformacije

$$H(f) = \int_{-\infty}^{\infty} h(t) e^{2\pi i f t} dt \quad (1)$$

ter njenega inverza

$$h(t) = \int_{-\infty}^{\infty} H(f) e^{-2\pi i f t} df, \quad (2)$$

funkcijo $h(t)$ navadno ne obravnavamo kot zvezno, temveč jo predstavimo z naborom diskretnih vzorcev:

$$h_k = h(t_k), \quad t_k = k\Delta, \quad k = 0, 1, 2, \dots, N-1. \quad (3)$$

Tako dobljene vrednosti pomenijo, da smo funkcijo vzorčili z vzorčno frekvenco $f_s = 1/\Delta$. V takem primeru je zgornja meja uporabnega frekvenčnega območja določena z Nyquistovo frekvenco $f_c = 1/(2\Delta)$, to je najvišja frekvenca, ki jo lahko še pravilno rekonstruiramo, saj ima signal pri tej frekvenci natanko dva vzorca na periodo. Če spekter funkcije $h(t)$ ne presega intervala $[-f_c, f_c]$, pri vzorčenju ne izgubimo nobene informacije. Kadar pa vsebuje višje frekvence, se te zrcalijo nazaj v dovoljeni interval, kar imenujemo aliasing oziroma potujevanje spektra.

Pri numeričnem računanju Fourierove transformacije vzorčene funkcije izračunamo spekter le v N točkah, kar omogoča ohranjanje količine informacije. Uporabimo diskretno Fourierovo transformacijo (DFT), podano z izrazom

$$H_n = \sum_{k=0}^{N-1} h_k e^{2\pi i k n / N}, \quad n = -\frac{N}{2}, \dots, \frac{N}{2}. \quad (4)$$

Povezava med zveznim in diskretnim spektrom se lahko zapiše kot

$$H\left(\frac{n}{N\Delta}\right) \approx \Delta \cdot H_n. \quad (5)$$

Moč signala, ki je odvisna od amplitud posameznih komponent, se ohranja ne glede na to, ali je signal zapisan v časovni ali frekvenčni domeni. To opisuje Parsevalova enačba:

$$\sum_{k=0}^{N-1} |h_k|^2 = \frac{1}{N} \sum_{n=0}^{N-1} |H_n|^2. \quad (6)$$

Z obratno diskretno Fourierovo transformacijo lahko iz H_n ponovno dobimo prvotno zaporedje h_k :

$$h_k = \frac{1}{N} \sum_{n=0}^{N-1} H_n e^{-2\pi i k n / N}. \quad (7)$$

Razlika glede na prejšnjo enačbo je v predznaku eksponenta in dodatnem faktorju $1/N$.

3 Reševanje

Pri nalogi sem uporabil knjižnico `NumPy`, ki ponuja implementacijo diskretne Fourierove transformacije (DFT) prek funkcije `fft`. Za namen primerjave sem dodatno implementiral tudi dve počasnejši različici algoritma: eno z dvojno zanko in drugo z matričnim množenjem, da sem lahko primerjal njihove čase izvajanja in učinkovitost.

Naloga 1

Najprej sem pripravil funkcijo, ki generira enostaven signal kot vsoto sinusov in kosinusov. Na tem signalu sem naredil Fourierovo transformacijo, spekter prestavil z `fftshift` in izrisal realni, imaginarni ter absolutni del. Nato sem naredil še obratno transformacijo z `ifft` in primerjal, kako dobro dobim nazaj začetni signal. Pri periodičnem primeru so bile črte v spektru ostre, pri neperiodičnem pa se je energija razlila v širši pas.

V posebnem primeru sem v signal dodal frekvenco, ki je bila višja od Nyquistove. V spektru se je ta komponenta preslikala v nižji del, kar lepo pokaže pojav potujevanja (aliasing). V časovni domeni se je to videlo kot popačen signal.

Dodatno sem obravnaval še Gaussovo porazdelitev. Če sem naredil DFT kar neposredno, so se pojavile oscilacije zaradi robnih diskontinuitet. Ko pa sem Gaussovo funkcijo najprej premaknil v središče intervala oziroma jo pomnožil z oknom (Hann), je bil spekter veliko lepši in bolj podoben teoretičnemu Gaussu. Obratna transformacija je dala zelo dober približek začetne funkcije.

Za različne velikosti vzorca N sem primerjal čas izvajanja treh metod: počasne zanke, matrični DFT in hitro Fourierovo transformacijo. Rezultati so pokazali, da je FFT praktično takojšnja, medtem ko sta počasni metodi čedalje manj uporabni z večanjem N .

Naloga 2

V drugem delu naloge sem analiziral začetne sekunde Bachove partite za violino solo, ki so bile dane v obliki `.txt` datotek z različnimi frekvencami vzorčenja (od 44 100 Hz do 882 Hz). Najprej sem iz datoteke prebral signal in odstranil enosmerno komponento. Nato sem naredil enostranski spekter s pomočjo funkcije `rfft` in izrisal spektralno gostoto moči na logaritemski skali.

Rezultati so pokazali, da pri visoki frekvenci vzorčenja spekter sega do 22 kHz in zvok ohranja vse harmonike. Ko pa frekvenco vzorčenja zmanjšujemo, se zgornja meja spektra znižuje, zato se višji toni izgubijo. Pri 882 Hz ostanejo samo najnižji toni, signal pa je že povsem popačen.

4 Rezultati

4.1 Časovna in frekvenčna domena

Na začetku sem preveril delovanje diskretne Fourierove transformacije. Na slikah 1 in 2 sta prikazana primer neperiodičnega in periodičnega signala. V frekvenčni domeni (sliki 3, 4) se vidi, da se pri neperiodičnem signalu pojavi razlivanje spektra, medtem ko je pri periodičnem signalu spekter sestavljen iz ostrih vrhov. S pomočjo inverzne transformacije (sliki 5, 6) sem preveril, da lahko signal uspešno rekonstruiramo.




Figure 1: Neperiodičen signal v časovni domeni.




Figure 2: Periodičen signal v časovni domeni.

4.2 Časovna zahtevnost različnih metod

Na sliki 7 je primerjava časovne zahtevnosti treh pristopov k izračunu Fourierove transformacije: gnezdena zanka, matrična oblika in FFT. Vidimo, da FFT narašča bistveno počasneje z N in je zato daleč najbolj učinkovita metoda.




Figure 3: Spekter neperiodičnega signala – opazimo razlivanje.

4.3 Aliasing

V naslednjem delu sem prikazal pojav aliasinga. V časovni domeni (slika 8) se signal pojavi popačen, ker vsebuje komponento nad Nyquistovo frekvenco. V frekvenčni domeni (slika 9) se ta visoka frekvenca preslika v nižje območje.




Figure 4: Spekter periodičnega signala z ostrimi vrhovi.




Figure 5: Inverzna transformacija – neperiodičen primer.

4.4 Gaussova porazdelitev

Gaussovo porazdelitev sem analiziral z različnimi pristopi Fourierove transformacije. Pri naivnem pristopu se pojavijo oscilacije (slika 10), premik v središče izboljša rezultat (slika 11), medtem ko uporaba Hannovega okna zmanjša robne efekte (slika 12). Rekonstrukcija z inverzno transformacijo pokaže, da se




Figure 6: Inverzna transformacija – periodičen primer.




Figure 7: Primerjava časovne zahtevnosti metod DFT in FFT.

signal v vseh primerih dobro povrne.




Figure 8: Časovni potek signala z aliasingom.




Figure 9: Spekter signala – pojav potujevanja.

4.5 Bach – analiza zvočnega posnetka

V drugem delu sem analiziral Bachovo Partito iz podatkovnih datotek pri različnih frekvencah vzorčenja. Na sliki 13 so prikazani enostranski spektri moči. Opazimo, da višja vzorčevalna frekvenca omogoča zaznavanje višjih frekvenčnih komponent. Pri nižjih frekvencah vzorčenja pa pride do izgube informacij in morebitnega aliasinga.




Figure 10: Naivna Fourierova transformacija Gaussove porazdelitve.




Figure 11: Gaussova porazdelitev s premikom v središče.




Figure 12: Gaussova porazdelitev z uporabo Hannovega okna.




Figure 13: Spektri Bachove Partite pri različnih vzorčevalnih frekvencah.