

13. Naloga: Nevronske mreže

Filip Lovšin 28242022

Januar 2025

1 Uvod

Nevronske mreže so modeli, ki temeljijo na veriženju preslikav med vektorji. Vsaka plast v nevronske mreži preslika vhodne podatke v izhod s pomočjo linearne preslikave, definirane z matrikami uteži, in nelinearne aktivacijske funkcije. V splošnem lahko zapis za posamezno plast predstavimo kot:

$$\mathbf{y}^{(l+1)} = f\left(\mathbf{W}^{(l)}\mathbf{y}^{(l)}\right),$$

kjer $\mathbf{W}^{(l)}$ označuje matriko uteži, f pa je nelinearna aktivacijska funkcija, ki se uporablja na komponentni ravni. V tej nalogi uporabljamo funkcijo $f(x) = \tanh(x)$.

Nevronske mreže so univerzalni približevalniki, ki lahko modelirajo različne funkcijske zveze med vhodnimi in izhodnimi podatki. Odlikuje jih sposobnost hierarhične obdelave informacij, kjer večplastne ("deep learning") mreže gradijo kompleksne predstavitve podatkov.

Za treniranje nevronskih mrež uporabljamo metodo minimizacije napake, ki jo merimo z uporabo funkcije izgube:

$$E = \frac{1}{2}\|\mathbf{y}_L - \mathbf{t}\|^2,$$

kjer $\mathbf{y}_L$ predstavlja izhod mreže, $\mathbf{t}$ pa ciljno vrednost. Optimizacija parametrov poteka z metodo gradientnega spusta, pri čemer posodabljam matrike uteži na podlagi propagacije napake nazaj skozi plasti.

2 Analiza nevronske mreže za prepoznavanje števil

2.1 Nastavitev mreže in podatki

Za analizo sem uporabil nevronske mreže s tremi plastmi: vhodno plast s 784 nevroni, skrito plast z enako dimenzijo in izhodno plast z 10 nevroni. Vhodni podatki so slike dimenzij 28×28 pikslov, normalizirane na interval $[0, 1]$. Izhodni nevroni predstavljajo številke od 0 do 9, kjer je ciljna vrednost 1 za pravilno številko in -1 za napačne.

Mrežo sem treniral 20 epoh z metodo gradientnega spusta, pri čemer sem spremljal izgubo in natančnost na učnem in testnem naboru. Učni podatki so vključevali 90% razpoložljivih primerov, 10% pa sem prihranil za testiranje.

2.2 Spremljanje izgube skozi epohe

Izguba (merjena z MSE) se je postopoma zmanjševala skozi epohe, kar je prikazano na Sliki 1. Vidimo hitro zmanjšanje v prvih nekaj epohah in nato počasnejšo konvergenco proti koncu treniranja.

2.3 Natančnost skozi epohe

Na Sliki 2 je prikazana natančnost na učnem in testnem naboru skozi epohe. Končna natančnost na testnem naboru je bila 97.73%, kar kaže na dobro generalizacijo modela.

2.4 Napaka po posameznih epohah

Spremljal sem napako na posameznih učnih primerih skozi prve tri epohe, kar je prikazano na Sliki 3. Vidimo, da se napaka zmanjšuje z vsako naslednjo epohami, čeprav je prisotno nekaj nihanj.




Figure 1: Izguba (MSE) skozi epohe.




Figure 2: Natančnost skozi epohe.




Figure 3: Napaka na učnih primerih skozi prve tri epohe.

2.5 Analiza napačnih napovedi

Na Sliki 4 so prikazani deleži napačnih napovedi za vsako številko. Največji delež napačnih napovedi je opazen pri številkah 5, 8 in 9, kar nakazuje težave pri razlikovanju teh števil.



Figure 4: Deleži napačnih napovedi za posamezne številke.

Prav tako smo analizirali posamezne primere napačnih klasifikacij. Primeri napačnih klasifikacij so prikazani na Sliki 5 in Sliki 6.

Na slikah lahko vidimo, da napačne klasifikacije pogosto vključujejo številke s podobnimi oblikami, kot je 6, ki je zamenjana za 8, ali 3, ki je zamenjana za 5. Zanimivo se mi zdi, da je 1 pogostokrat zamenjana z 2 in ne s 7, ki sta bolj podobne oblike.




Figure 5: Primeri napačnih klasifikacij.




Figure 6: Primeri napačnih klasifikacij.

3 Generiranje vhodnih slik za izbrane številke

Pri učenju nevronske mreže iterativno minimiziramo napako na izhodu z optimizacijo uteži $\mathbf{W}$. Po zaključenem učenju pa lahko mrežo uporabimo za obratno nalogo: iskanje vhodnega vektorja $\mathbf{y}_0$, ki minimizira napako na izhodu za izbrani cilj.

Ta proces izvedemo z uporabo istega postopka gradientnega spusta, ki smo ga uporabili za prilagajanje uteži. Iterativno posodablamo vhodni vektor $\mathbf{y}_0$ po naslednjem pravilu:

$$\mathbf{y}_0 \leftarrow \mathbf{y}_0 + \eta \delta_0 \mathbf{W}_0,$$

kjer je δ_0 napaka, pridobljena s propagacijo napake nazaj skozi mrežo. Proces ponavljamo, dokler napaka na izhodu ne postane dovolj majhna.

Za začetni približek vhodnega vektorja $\mathbf{y}_0$ lahko uporabimo črno sliko (ničelni vektor) ali naključno inicializirano sliko. Ta metoda, znana tudi kot "deep dream", omogoča vpogled v značilnosti, ki jih mreža prepozna kot pomembne za klasifikacijo posameznih števk.

Rezultati generiranja vhodnih slik za številke od 0 do 9 so prikazani na Sliki 7. Vidimo, da so generirane slike skladne z oblikami števk, ki jih mreža prepozna. Le številki 1 in 7 sta malce čudni, ampak zelo zanimivi.




Figure 7: Generirane slike za številke od 0 do 9, ki jih mreža prepozna kot optimalne za dani izhod.